

مروری بر مدل‌های زبانی

سپهر کراچی

۱۴۰۵

فهرست مطالب

۳	آموزش (Training)	۱
۳	۱.۱ داده‌ها (Data)	۱.۱
۳	۱.۱.۱ پیش‌آموزش (Pre-Training)	۱.۱.۱
۳۰	۲.۱.۱ پس‌آموزش (Post-Training)	۲.۱.۱
۶۲	۲.۱ روش (Method)	۲.۱
۶۳	۱.۲.۱ پیش‌آموزش (Pre-Training)	۱.۲.۱
۷۳	۲.۲.۱ پس‌آموزش (Post-Training)	۲.۲.۱
۱۱۵	ساختار (Architecture)	۲
۱۱۵	۱.۲ کدگذاری موقعیت (Positional Encoding)	۱.۲
۱۱۶	۲.۲ بردارکننده (Tokenizer)	۲.۲
۱۱۶	۳.۲ شبکه عصبی (MLP)	۳.۲
۱۱۶	۴.۲ تابع فعالساز (Activation Function)	۴.۲
۱۱۷	۵.۲ نرمالسازی (Normalization)	۵.۲
۱۱۷	۶.۲ مکانیزم توجه (Attention)	۶.۲
۱۱۷	۷.۲ ساختار ترنسفورمر (Transformer)	۷.۲
۱۱۸	بهینه‌سازی (Optimization)	۳
۱۱۸	۱.۳ الگوریتم (Algorithm)	۱.۳
۱۱۸	۲.۳ تابع هزینه (Loss Function)	۲.۳
۱۱۸	تنظیم هایپرپارامتر (Hyperparameter Tuning)	۴
۱۱۹	قوانین مقیاس‌پذیری (Scaling Laws)	۵
۱۱۹	۱.۵ مقدمه	۱.۵
۱۱۹	۲.۵ اصلاح و توسعه قوانین مقیاس‌پذیری کلاسیک	۲.۵
۱۱۹	۳.۵ تاثیر معماری و شکل مدل (Model Shape & Architecture)	۳.۵
۱۲۰	۴.۵ قوانین مقیاس‌پذیری برای مدل‌های ترکیبی از خبرگان (MoE)	۴.۵
۱۲۰	۵.۵ نقش داده‌ها: کیفیت، ترکیب و چگالی	۵.۵
۱۲۱	۶.۵ فراتر از خطای مطلق: معیارهای نوین ارزیابی	۶.۵
۱۲۱	۷.۵ نتیجه‌گیری	۷.۵
۱۲۱	ارزیابی (Evaluation)	۶
۱۲۲	یادگیری تقویتی (Reinforcement Learning)	۷
۱۲۶	۱.۷ الگوریتم بهینه‌سازی تقریبی خطمشی (Proximal Policy Optimization - PPO)	۱.۷
۱۳۳	۲.۷ الگوریتم بهینه‌سازی نسبی خطمشی گروهی (Group Relative Policy Optimization - GRPO)	۲.۷
۱۳۸	۳.۷ الگوریتم بهینه‌سازی توالی گروهی خطمشی (Group Sequence Policy Optimization - GSPO)	۳.۷
	۴.۷ الگوریتم بهینه‌سازی خطمشی با برش مجزا و نمونه‌برداری پویا (Decoupled Clip and Dy-)	۴.۷
۱۴۵	۵.۷ الگوریتم بهینه‌سازی خطمشی تطبیقی نرم (Soft Adaptive Policy Optimization - SAPO)	۵.۷
۱۵۱	۶.۷ الگوریتم بهینه‌سازی خطمشی با ضریب اهمیت برش‌خورده (Clipped IS-weight Policy)	۶.۷
۱۵۷	۷.۷ الگوریتم یادگیری تقویتی با پاداش‌های اعتبارسنجی‌پذیر (Optimization - CISPO Reinforcement Learning with)	۷.۷
۱۶۳	۸.۷ الگوریتم یادگیری تقویتی با پاداش‌های قابل اعتبارسنجی و بهینه‌سازی گروهی (Verifiable Rewards - RLVR OlmoRL:)	۸.۷
۱۶۸	(RLVR + GRPO)	

۱ آموزش (Training)

۱.۱ داده‌ها (Data)

۱.۱.۱ پیش‌آموزش (Pre-Training)

• DeepSeek-V4

مقدمه و ساختار کلی دادگان پیش‌آموزش فاز پیش‌آموزش (Pre-training) در مدل‌های زبانی سری DeepSeek-V4 با هدف شکستن سد محاسباتی در پردازش توالی‌های فوق‌طولانی تا سقف بافت یک میلیون توکن (1M-token context) بازطراحی شده است. در این چارچوب، دو نسخه پایه با مقیاس‌های محاسباتی متمایز آموزش دیده‌اند:

- **مدل DeepSeek-V4-Flash**: دارای ۲۸۴ میلیارد پارامتر کل (۱۳ میلیارد پارامتر فعال در هر توکن) که روی مجموعه‌ای بالغ بر **۳۲ تریلیون توکن** (32T tokens) پیش‌آموزش دیده است.
 - **مدل DeepSeek-V4-Pro**: دارای ۶.۱ تریلیون پارامتر کل (۴۹ میلیارد پارامتر فعال در هر توکن) که فرایند پیش‌آموزش آن بر روی بیش از **۳۳ تریلیون توکن** (33T tokens) صورت پذیرفته است.
- هدف بهینه‌سازی پایه در طول این فرایند، حداقل‌سازی تلفات خودرگرسیو مدل‌سازی زبان (Autoregressive Language Modeling Loss) بر روی توالی توکن‌ها است:

$$\mathcal{L}_{\text{LM}}(\theta) = - \sum_{t=1}^N \log P_{\theta}(x_t | x_1, x_2, \dots, x_{t-1}) \quad (1)$$

ترکیب‌بندی و پالایش پیکره داده‌ها (Data Construction) پیکره متنی پیش‌آموزش بر پایه تجربیات نسخه DeepSeek-V3 [۱] شکل گرفته، اما با هدف ارتقای چگالی دانش، جلوگیری از افت کیفی و پشتیبانی از استدلال عمیق، اصلاحات اساسی در حوزه‌های زیر اعمال شده است:

- **پالایش وب و پیشگیری از فروپاشی مدل (Mitigating Model Collapse)**: به منظور مقابله با پدیده فروپاشی مدل ناشی از انباشت داده‌های بازتولیدشده توسط هوش مصنوعی و متون قالبی در وب باز [۲]، خط لوله‌های فیلترینگ سخت‌گیرانه‌ای تعبیه شد تا محتوای ماشینی، تکراری و قالبی به صورت دسته‌ای شناسایی و پالایش شوند.
- **تزریق داده‌های عامل‌محور در آموزش میانی (Agentic Mid-Training Data)**: پیکره ریاضیات و برنامه‌نویسی به عنوان هسته اصلی تفکر مدل حفظ شده است؛ علاوه بر آن، در فاز میانی آموزش (Mid-Training Phase) داده‌های تعاملی و ابزارمحور (Agentic data) –شامل ردپای خط فرمان، محیط‌های چندمرحله‌ای رفع باگ و بازخورد مفسرها– به مدل تزریق شد تا بازنمایی کد از متن ایستا به کنشگری پویا ارتقا یابد.
- **توسعه داده‌های چندزبانه و دانش حاشیه‌ای (Long-Tail Knowledge)**: برای بازنمایی دقیق فرهنگ‌ها و زبان‌های گوناگون، دامنه دادگان چندزبانه توسعه یافت تا پوشش مدل در بازایی دانش حاشیه‌ای با فراوانی آماری اندک تضمین گردد.
- **تمرکز راهبردی بر اسناد طولانی دانشگاهی (Long-Document Curation)**: به منظور بارورسازی درک زمینه در مقیاس‌های فراتر از چند صدهزار کلمه، مقالات پژوهشی، گزارش‌های تخصصی و اسناد فنی دارای پیوستگی عمیق معنایی با اولویت بالا گزینش شدند.

پیش‌پردازش، توکنایزیشن و مهندسی نمونه‌ها (Data Pre-Processing) فرایند مهندسی داده‌ها جهت بهینه‌سازی ورود توکن‌ها به سازوکار توجه شامل راهکارهای زیر است:

- **واژگان و نشانه‌گذار (Tokenizer):** دایره واژگان در اندازه 128K توکن تثبیت شده و نشانه‌های ویژه‌ای (Special tokens) جهت ساختار بندی و مدیریت بافت‌های متنی طولانی افزوده شده است.
- **تکمیل درون‌متنی (Fill-in-the-Middle - FIM):** جهت تعمیق درک دوطرفه متن، راهبرد FIM [۱] اعمال گردید که طی آن سند متنی به سه بخش پیشوند (P)، میانه (M) و پسوند (S) تفکیک و به فرم زیر بازآرایی می‌شود:

$$\mathcal{D}_{\text{FIM}} = [\text{<PRE>}] \circ P \circ [\text{<SUF>}] \circ S \circ [\text{<MID>}] \circ M \quad (۲)$$

این رویکرد مدل را قادر می‌سازد با شرط‌گذاری هم‌زمان روی ابتدا و انتهای بافت، بخش میانی را پیش‌بینی کند.

- **بسته‌بندی اسناد بدون اتلاف توکن (Document Packing):** با اقتباس از رهیافت دینگ و همکاران [۳]، به جای قطع نامتقارن (Truncation) متون در انتهای پنجره بافت، اسناد برگرفته از منابع گوناگون بر پایه طول دسته‌بندی و در قالب بسته‌های بهینه در کنار یکدیگر قرار گرفتند تا کمترین برش رخ دهد.

- **ماسک توجه در سطح نمونه (Sample-Level Attention Masking):** برخلاف DeepSeek-V3، در این نسخه ماسک‌گذاری توجه در سطح سند فعال شد. ماتریس توجه M به گونه‌ای پیکربندی می‌شود که از سرایت توجه میان اسناد مستقلی که در یک توالی بسته‌بندی شده‌اند جلوگیری شود:

$$M_{ij} = \begin{cases} 0, & \text{if } i \geq j \text{ and DocID}(i) = \text{DocID}(j) \\ -\infty, & \text{otherwise} \end{cases} \quad (۳)$$

برنامه درسی طول بافت و پویایی بهینه‌سازی (Context Curriculum & Optimization) فرایند آموزش مدل روی بافت‌های میلیونی به شیوه گام‌به‌گام و مرحله‌ای (Curriculum Learning) مدیریت شده است:

- **توالی افزایش بافت:** آموزش از طول توالی 4K آغاز شده و به توالی‌های 16K، سپس 64K و در نهایت 1M توکن تعمیم یافته است.
- **مقیاس دسته‌ها (Batch Size Scheduling):** در نسخه Flash اندازه دسته تا سقف 75.5M توکن و در نسخه Pro تا مرز 94.4M توکن در هر گام افزایش یافته است.
- **ورود تدریجی توجه تنک:** در طول ۱ تریلیون توکن نخست، مدل با سازوکار توجه متراکم (Dense Attention) گرم‌سازی شد. سپس در طول بافت 64K، معماری توجه تنک فشرده (CSA) با یک مرحله پایدارسازی کوتاه‌مدت برای شاخص‌گذار Lightning Indexer فعال گردید و تا پایان فاز پیش‌آموزش ادامه یافت.
- **نرخ یادگیری:** مدل‌ها با بهینه‌ساز Muon [۴، ۵] و تنظیمات نرخ یادگیری خطی اولیه و واپاشی کسینوسی نهایی (از 2.7×10^{-4} به 2.7×10^{-5} در مدل Flash و از 2.0×10^{-4} به 2.0×10^{-5} در مدل Pro) به پیش‌آموزش رسانده شدند.

مهار ناپایداری‌های ناشی از توزیع داده‌ها جهت رفع جهش‌های زیان (Loss Spikes) ناشی از داده‌های پرت در لایه‌های MoE، دو تکنیک در خط لوله داده و محاسبات اعمال گردید:

- **مسیریابی پیش‌دستانه (Anticipatory Routing):** شاخص‌های گیتینگ بر اساس وزن‌های با تأخیر تاریخی $\theta_{t-\Delta t}$ روی داده‌های پیش‌واکشی‌شده محاسبه شده تا چرخه هم‌افزایی مثبت مقادیر فرین شکسته شود.
- **تحدید دامنه SwiGLU:** ورودی‌های خطی فعال‌ساز SwiGLU [۶] به بازه $[-10, 10]$ و مؤلفه گیت آن به حداکثر مقدار 10 تحدید شدند.

ارزیابی‌های آماری مدل‌های پایه (Base Model Evaluations) نتایج ارزیابی مدل‌های پایه پیش‌آموزش‌دیده (پیش از هرگونه هم‌ترازسازی یا Post-training) در جدول زیر گزارش شده است. این نتایج نشان می‌دهد که مدل DeepSeek-V4-Flash-Base با وجود دارا بودن تنها ۱۳ میلیارد پارامتر فعال، به برکت کیفیت داده‌ها و راهبردهای پیش‌پردازش، مدل پیشین DeepSeek-V3.2-Base (با ۳۷ میلیارد پارامتر فعال) را در بنچمارک‌های متعددی نظیر C-Eval (92.1 در برابر 90.4)، MultiLoKo (42.2 در برابر 38.7) و LongBench-V2 (44.7 در برابر 40.2) پشت سر گذاشته است. همچنین مدل DeepSeek-V4-Pro-Base در آزمون حقیقت‌سنجی دادگان حاشیه‌ای (FACTS Parametric) به جهش چشمگیر 62.6 (رشد نسبی ۱۳۱٪ نسبت به 27.1) دست یافته است.

جدول ۱: ارزیابی جامع عملکرد مدل‌های پایه DeepSeek-V4 در مقایسه با DeepSeek-V3.2-Base

دسته ارزیابی	بنچمارک (متریک)	پرومپت (Shots)	DeepSeek-V3.2-Base	DeepSeek-V4-Flash-Base	DeepSeek-V4-Pro-Base
مشخصات	معماری	-	MoE	MoE	MoE
	پارامترهای فعال	-	۳۷B	۱۳B	۴۹B
	پارامترهای کل	-	۶۷۱B	۲۸۴B	۶T.۱
دانش جهان (World Knowledge)	AGIEval (EM)	۰-shot	۱.۸۰	۶.۸۲	۱.۸۳
	MMLU (EM)	۵-shot	۸.۸۷	۷.۸۸	۱.۹۰
	MMLU-Redux (EM)	۵-shot	۵.۸۷	۴.۸۹	۸.۹۰
	MMLU-Pro (EM)	۵-shot	۵.۶۵	۳.۶۸	۵.۷۳
	MMMLU (EM)	۵-shot	۹.۸۷	۸.۸۸	۳.۹۰
	C-Eval (EM)	۵-shot	۴.۹۰	۱.۹۲	۱.۹۳
	CMMLU (EM)	۵-shot	۹.۸۸	۴.۹۰	۸.۹۰
	MultiLoKo (EM)	۵-shot	۷.۳۸	۲.۴۲	۱.۵۱
	Simple-QA verified (EM)	۲۵-shot	۳.۲۸	۱.۳۰	۲.۵۵
	SuperGPQA (EM)	۵-shot	۰.۴۵	۵.۴۶	۹.۵۳
	FACTS Parametric (EM)	۲۵-shot	۱.۲۷	۹.۳۳	۶.۶۲
	TriviaQA (EM)	۵-shot	۳.۸۳	۸.۸۲	۶.۸۵
زبان و استدلال (Lang. & Reas.)	BBH (EM)	۳-shot	۶.۸۷	۹.۸۶	۵.۸۷
	DROP (F1)	۱-shot	۲.۸۸	۶.۸۸	۷.۸۸
	HellaSwag (EM)	۰-shot	۴.۸۶	۷.۸۵	۰.۸۸
	WinoGrande (EM)	۰-shot	۹.۷۸	۵.۷۹	۵.۸۱
	CLUEWSC (EM)	۵-shot	۵.۸۳	۲.۸۲	۲.۸۵
کد و ریاضیات (Code & Math)	BigCodeBench (Pass@1)	۳-shot	۹.۶۳	۸.۵۶	۲.۵۹
	HumanEval (Pass@1)	۰-shot	۸.۶۲	۵.۶۹	۸.۷۶
	GSM8K (EM)	۸-shot	۱.۹۱	۸.۹۰	۶.۹۲
	MATH (EM)	۴-shot	۵.۶۰	۴.۵۷	۵.۶۴
	MGSM (EM)	۸-shot	۳.۸۱	۷.۸۵	۴.۸۴
	CMATH (EM)	۳-shot	۶.۹۲	۶.۹۳	۹.۹۰
بافت طولانی (Long Context)	LongBench-V2 (EM)	۱-shot	۲.۴۰	۷.۴۴	۵.۵۱

• GLM-5

مقدمه و ساختار کلان دادگان پایه (Foundational Overview & Token Budget) مدل زبانی GLM-5 [V] با هدف گذار از پارادایم کدنویسی حسی و تعاملی ساده (Vibe Coding) به سوی مهندسی عاملی خودکار و صنعتی (Agentic Engineering) بازطراحی شده است. در این راستا، مدل پایه (Base Model) بر روی پیکره عظیمی به حجم مجموع ۵.۲۸ **تریلیون توکن** (28.5T tokens) آموزش داده شده است. معماری مدل پایه دارای ۷۴۴ میلیارد پارامتر کل و ۴۰ میلیارد پارامتر فعال در هر توکن است که در قالب ساختار تخصص‌یافته با ۲۵۶ متخصص (MoE) پیکربندی شده است.

فرایند تغذیه داده در مدل پایه GLM-5 به شکل یک خط لوله سه‌مرحله‌ای پیوسته مهندسی شده است:

$$\mathcal{D}_{\text{Base}} = \mathcal{D}_{\text{Pre-training}} \cup \mathcal{D}_{\text{Mid-training}} \cup \mathcal{D}_{\text{DSA-Adaptation}} \quad (۴)$$

توزیع بودجه توکن‌ها در طول پنجره‌های بافت (Context Window) به شرح زیر است:

– **پیش‌آموزش اولیه (General Pre-training):** شامل ۲۷ **تریلیون توکن** با طول بافت استاندارد 4K، تفکیک‌شده به ۱۸ تریلیون توکن متون عمومی و چندزبانه و ۹ تریلیون توکن کدهای برنامه‌نویسی و استدلال ریاضی اولیه.

– **آموزش میانی (Mid-training):** شامل ۵۵.۱ **تریلیون توکن** جهت آماده‌سازی شناختی بافت بلند و داده‌های عاملی در سه پله متوالی (32K با حجم 1T، 128K با حجم 500B و 200K با حجم 50B).

– **تطبیق توجه تنک دیپسیک (DSA Adaptation):** شامل ۲۰ میلیارد توکن با طول بافت 200K در قالب پیش‌آموزش پیوسته (Continued Pre-Training).

ترکیب‌بندی و پالایش پیکره پیش‌آموزش اولیه (Pre-Training Data Domains) پیکره متنی فاز پیش‌آموزش اولیه به منظور ارتقای چگالی حقیقت‌سنجی و مهارت در استدلال، دستخوش دگرگونی‌های ساختاری در سه حوزه کلیدی شده است:

– **پالایش وب و استخراج دانش حاشیه‌ای (Web Corpus & Long-tail Knowledge):** افزون بر طبقه‌بندهای آماری مرسوم، یک طبقه‌بند برداری مبتنی بر تعبیه معنایی جملات بر پایه چارچوب DCLM [۸] آموزش داده شد تا متون غنی از لحاظ مفهومی از وب باز استخراج گردند. همچنین با هدف رفع خلأ دانش دم‌بلند (Long-tail Knowledge)، «طبقه‌بند دانش جهان» (World Knowledge edge Classifier) بهینه‌سازی شده با مدخل‌های ویکی‌پدیا و برچسب‌گذاری‌های مدل زبانی تعبیه گردید تا اطلاعات دانشنامه‌ای ارزشمند از صفحات وب با کیفیت متوسط بازیابی شوند.

– **غنی‌سازی پیکره کد و حذف فازی تکرارها (Code Corpus & Fuzzy Deduplication):** مخزن کدهای پیش‌آموزش با برداشت نسخه‌های تازه از پلتفرم‌های میزبانی کد و صفحات وب حاوی کد به‌روزرسانی شد. با اجرای الگوریتم‌های حذف فازی موارد تکراری (Fuzzy Deduplication)، حجم توکن‌های یکتای کد به میزان ۲۸٪ افزایش یافت:

$$\Delta N_{\text{unique}} = \frac{N_{\text{unique}}^{\text{GLM-}\delta} - N_{\text{unique}}^{\text{GLM-}\delta.\text{f}}}{N_{\text{unique}}^{\text{GLM-}\delta.\text{f}}} = +28\% \quad (5)$$

علاوه بر این، ناهماهنگی‌های فراداده‌ای در مخزن Software Heritage تصحیح و طبقه‌بندهای اختصاصی برای زبان‌های برنامه‌نویسی کم‌منبع (Low-resource Languages) نظیر Swift، Scala و Lua جهت نمونه‌برداری آگاه از کیفیت پیاده‌سازی شدند.

– **داده‌های ریاضیات، علوم و پالایش متون ساختگی (Math & Science Curation):** لوله‌های استخراج محتوای وب و پارس فایل‌های چندستونی PDF مقالات علمی و کتاب‌های ریاضی بهبود یافتند. در اسناد و کتب حجیم، یک الگوریتم اختصاصی «تکه‌تکه کردن و تجمیع نمره» (Chunk-and-Aggregate Scoring) به کار رفت تا نمره غنای آموزشی اسناد به درستی برآورد شود. به‌منظور جلوگیری از سقوط مدل (Model Collapse) و حفظ اصالت استدلال، خطوط لوله فیلترینگ به گونه‌ای تنظیم شدند که استفاده از هرگونه داده سنتزی، تولیدشده با هوش مصنوعی یا داده‌های الگومحور (Template-based) در فاز پیش‌آموزش ریاضیات اکیداً حذف شود.

دادگان آموزش میانی و برنامه درسی طول بافت (Mid-Training & Context Scaling) برای تثبیت پایداری مدل در پردازش کدبیس‌های عظیم، اسناد فوق‌طولانی و جریان‌های کاری عاملی، مرحله آموزش میانی با بسط تصاعدی طول بافت انجام پذیرفت:

– **توالی بسط بافت (Progressive Context Expansion):** بافت مدل از طول پایه 4K طی سه گام پیاپی شامل مرحله 32K با ۱ تریلیون توکن، مرحله 128K با ۵۰۰ میلیارد توکن و نهایتاً مرحله 200K با ۵۰ میلیارد توکن ارتقا یافت.

– **داده‌های مهندسی نرم‌افزار در سطح مخزن (Software Engineering Data):** مدل با الحاق ساختار کامل مخزن گیت‌هاب، تاریخچه تغییرات (Commit Diffs)، گزارش باگ‌ها (Issues)، درخواست‌های ادغام (Pull Requests) و فایل‌های مرتبط به صورت یک توالی پیوسته آموزش دید. با تعدیل ضوابط فیلترینگ در سطح مخزن و تشدید نظارت کیفی در سطح تک‌تک Issue‌ها، بالغ بر ۱۰ میلیون جفت Issue-PR استخراج شد که پیکره نهایی آن پس از پالایش شامل ۱۶۰ میلیارد توکن یکتا (160B unique tokens) گردید.

– **مهار پدیده گم‌شدن در میانه (Mitigating Lost-in-the-Middle):** با الهام از ساختارهای NextLong [۹] و EntropyLong [۱۰]، داده‌های سنتزی برای بازتولید وابستگی‌های دوربرد طراحی شدند. متون به شدت مشابه از طریق بسته‌بندی درهم‌تنیده (Interleaved Packing) ترکیب شدند تا مدل ناچار به جست‌وجو در میانه بافت شود. در پله 200K، داده‌های شبیه به MRCC [۱۱] با تنوع بالا جهت تثبیت یادآوری در دیالوگ‌های طولانی تزریق شدند.

داده‌های تطبیق توجه تنک دیپ‌سیک (DSA Continued Pre-Training Data) به جای آموزش پرهزینه توجه از مبدأ، مدل متراکم انتهای فاز آموزش میانی از طریق استراتژی دونشستی «گرم‌کردن متراکم و تطبیق آموزش تنک» به سازوکار DeepSeek Sparse Attention (DSA) [۱۲] مجهز گردید:

- **مرحله گرم‌کردن نمایه‌ساز (Indexer Warm-up):** شاخص‌گذار Lightning Indexer به مدت ۱,۰۰۰ گام آموزش دید. در هر گام ۱۴ توالی به طول ۲۰۲,۷۵۲ توکن (مجموعاً ۸۴.۲ میلیارد توکن) با نرخ یادگیری بیشینه 5×10^{-3} به مدل ارائه شد در حالی که وزن‌های پایه ثابت بودند.
- **مرحله تطبیق تنک (Sparse Adaptation Stage):** آموزش پیوسته کل مدل بر روی ۲۰ میلیارد توکن از توزیع داده‌های فاز آموزش میانی با نرخ یادگیری ثابت 1×10^{-5} صورت پذیرفت. این استراتژی کم‌هزینه توانست عملکرد توجه تنک را بدون اتلاف کارایی بافت بلند، با مدل متراکم اولیه معادل سازد.

ارزیابی‌های آماری مدل‌های پایه (Base Model Evaluations) نتایج ارزیابی مدل پایه پیش‌آموزش‌دیده GLM-5-Base (پیش از ورود به فازهای SFT و RL) در جدول زیر ارائه شده است. در آزمون‌های ارزیابی کد، مدل به برکت تزریق داده‌های یکتای مهندسی نرم‌افزار به امتیاز خیره‌کننده 87.0 در بنچمارک EvalPlus دست یافته است (رشد نسبی ۴٪.۱۱ نسبت به GLM-4.5-Base و ۶٪.۳۲ نسبت به DeepSeek-V3-Base). همچنین در آزمون حقیقت‌سنجی SimpleQA، دستاورد امتیاز 36.0 کارآمدی طبقه‌بندهای دانش وب را اثبات می‌کند. افت مشاهده‌شده در نمرات خام بنچمارک‌های ریاضیاتی نظیر GSM8K، پیامد مستقیم تصمیم آگاهانه تیم توسعه مبنی بر حذف داده‌های سنتزی و قالبی در پیش‌آموزش بوده که این نقص متعاقباً در فاز یادگیری تقویتی استدلالی (Reasoning RL) با کسب نمره برتر 50.4 در HLE جبران گردیده است.

جدول ۲: ارزیابی جامع عملکرد مدل پایه GLM-5-Base در مقایسه با سایر مدل‌های پایه شاخص

دسته ارزیابی	بنچمارک (متریک)	DeepSeek-V3-Base	Kimi-K2-Base	GLM-4.5-Base	GLM-5-Base
مشخصات	معماری	MoE	MoE	MoE	MoE
	پارامترهای فعال	۳۷B	۳۲B	۳۲B	۴۰B
	پارامترهای کل	۶۷۱B	۱۰۴۳B	۳۵۵B	۷۴۴B
انگلیسی (English)	SimpleQA (EM)	۶.۲۶	۳.۳۵	۰.۳۰	۰.۳۶
	BBH (EM)	۴.۸۸	۷.۸۸	۲.۸۶	۴.۸۷
	MMLU (EM)	۲.۸۷	۸.۸۷	۱.۸۶	۳.۸۸
	HellaSwag (EM)	۹.۸۸	۶.۹۴	۱.۸۷	۱.۸۸
	PIQA (EM)	۷.۸۴	—	۳.۸۵	۶.۸۴
	TriviaQA (EM)	۹.۸۲	۱.۸۵	۰.۸۰	۹.۸۰
کدنویسی (Code)	EvalPlus (Pass@1)	۶.۶۵	۳.۸۰	۱.۷۸	۰.۸۷
	LiveCodeBench-Base (Pass@1)	۶.۲۴	۳.۲۶	۱.۲۸	۴.۳۴
ریاضیات (Math)	GSM8K (EM)	۶.۸۷	۱.۹۲	۴.۷۹	۸.۶۸
	MATH (EM)	۶.۶۲	۲.۷۰	۰.۶۱	۴.۵۶
چینی (Chinese)	CLUEWSC (EM)	۷.۸۲	—	۵.۸۳	۲.۸۴
	C-Eval (EM)	۱.۹۰	۵.۹۲	۹.۸۶	۸.۸۸
	C3 (EM)	۶.۷۸	—	۱.۸۳	۳.۸۰
	Chinese-SimpleQA (EM)	۱.۷۲	۶.۷۷	۱.۷۰	۶.۷۴

Kimi K3 •

مقدمه و فلسفه دادگان پیش‌آموزش چندوجهی بومی فاز پیش‌آموزش (Pre-training) مدل Kimi K3 با هدف شکستن مرزهای محاسباتی در مقیاس‌های فراتر از ۱ میلیون توکن (1M-token context) بر پایه معماری تنک ترکیبی از متخصصان (Native Multimodal) با ۷۸.۲ تریلیون پارامتر کل و ۲۱۰۴ میلیارد پارامتر فعال طراحی شده است [۱۳]. برخلاف رویکردهای رایج که از یک مرحله انطباق پسینی (Post-hoc Modality Alignment) جهت اتصال برج بینایی منجمد به مدل زبانی متنی استفاده می‌کنند، در Kimi K3 یک راهبرد یادگیری چندوجهی بومی

اتخاذ شده است که در آن توکن‌های متنی و بصری از همان گام نخست آموزش به صورت درهم‌تنیده تحت هدف واحد پیش‌بینی توکن بعدی (Next-Token Prediction) بهینه‌سازی می‌شوند:

$$\mathcal{L}_{\text{pretrain}}(\theta) = - \sum_{t=1}^N \log P_{\theta}(u_t | u_1, u_2, \dots, u_{t-1}) \quad (6)$$

که در آن u_t نمایانگر یک توکن متنی یا یک توکن بصری فشرده‌شده در فضای برداری مشترک است. ارتقای هم‌زمان خط‌لوله داده، پویایی بهینه‌سازی و بازنویسی متون موجب دستیابی به **بهره‌وری مقیاس‌بندی ۵.۲ برابری** (Scaling Efficiency gain $2.5\times$) در مقایسه با نسل پیشین یعنی **Kimi K2 [۱۴]** روی داده‌های اعتبارسنجی خارج از توزیع (Held-out OOD) شده است.

ترکیب‌بندی و خط‌لوله پالایش پیکره متنی (Textual Corpus Curation) پیکره متنی مدل بر چهار دامنه بنیادین استوار است که با بهره‌گیری از زیرساخت پیشرفته پالایش [۱۴، ۱۵] پردازش شده‌اند:

- **متن وب (Web Text):** پوشش‌دهنده تنوع زبانی عمومی و دانش عام حاکم بر بستر اینترنت.
- **کد (Code):** مخازن سورس‌کد چندزبانه، مستندات فنی و ساختارهای الگوریتمی جهت تقویت توان استدلال صوری.
- **ریاضیات (Mathematics):** اسناد تحلیلی، متون دارای نمادگذاری علمی لاتک (L^AT_EX) و اثبات‌های ریاضیاتی.
- **دانش تخصصی (Knowledge):** دانشنامه‌ها، کتب مرجع، اسناد حقوقی، داده‌های مالی و مقالات دانشگاهی بازبینی‌شده.

فرایند پاک‌سازی داده‌ها از سه گام دقیق عبور می‌کند:

۱. **فیلترهای اکتشافی مبتنی بر قاعده (Rule-based Heuristics):** حذف محتوای باینری، کدهای خراب، لاگ‌های سیستمی بی‌معنی و متون نامتعارف ماشینی.
۲. **امتیازدهی کیفی با طبقه‌بند (Classifier-based Quality Scoring):** تخمین نمره کیفیت اسناد و غربال نمونه‌های با چگالی اطلاعاتی نازل.
۳. **حذف افزونگی چندمرحله‌ای (Deduplication):** تلفیق حذف تکرار دقیق با نگاشت‌های قطعی (Exact Dedup) و حذف تکرار فازی (Fuzzy Dedup) با تحلیل شباهت سطحی اسناد.
۴. **نرخ‌های نمونه‌برداری بهینه (Sampling Rates):** تخصیص بودجه و وزن به هر دامنه بر اساس مطالعات تجربی گسترده بر روی مدل‌های کوچکتری از همان خانواده صورت پذیرفته است.

دستورالعمل بازنویسی داده‌ها با اعتبارسنجی وفاداری (Fidelity-Verified Rephrasing) به منظور برطرف ساختن اطناب کلام و نویزهای ساختاری در متون وب، رویه بازنویسی معرفی‌شده در **Kimi K2 [۱۴]** با سه راهبرد محوری توسعه یافته است:

- **پرامپت‌نویسی با تنوع دیدگاه و سبک (Style and Perspective-Diverse Prompting):** متون تخصصی ریاضیاتی و دانشی با زاویه دیدهای متنوع تحلیلی و آموزشی بازآفرینی می‌شوند.
- **تولید خودهمبسته تکه‌ای (Chunk-wise Autoregressive Generation):** فرایند بازنویسی متن در قالب قطعات منسجم صورت می‌گیرد تا یکدستی ساختار استدلالی تضمین شود.
- **راستی‌آزمایی وفاداری به منبع (Fidelity Verification):** تمامی داده‌های بازنویسی‌شده توسط ممیزهای خودکار ارزیابی می‌شوند تا با انطباق با سند مرجع، از ورود هرگونه توهم یا داده ساختگی به دادگان پیش‌آموزش جلوگیری شود:

$$\text{Fidelity}(D_{\text{rephrased}}, D_{\text{source}}) = \mathbb{I}(\text{FactCheck}(D_{\text{rephrased}}, D_{\text{source}}) \geq \tau_{\text{fidelity}}) \quad (7)$$

پیکره چندوجهی و آموزش رمزگذار بصری از صفر (MoonViT-V2 from Scratch) برخلاف سنت جاری در مدل‌های چندوجهی که رمزگذار تصویر را بر پایه مدل‌های کنتراست‌یو نظیر SigLIP مقارن‌دهی اولیه می‌کنند، رمزگذار بینایی Kimi K3 تحت عنوان MoonViT-V2 (با ۴۰۱ میلیون پارامتر و ۲۷ لایه ViT) به‌طور کامل از صفر (From Scratch) تحت تابع هدف پیش‌بینی توکن بعدی آموزش می‌بیند:

– **پایداری بهینه‌سازی و مهار جهش‌های گرادیان:** آموزش توأم رمزگذارهای کنتراست‌یو با مدل‌های زبانی عظیم، تلاطم‌های شدیدی در نرُم گرادیان برج بینایی پدید می‌آورد. همان‌طور که در شواهد گزارش فنی مشخص است، مدل پیشین با مقارن‌دهی SigLIP دچار جهش‌های مقطعی مکرر در نرُم گرادیان می‌شد، درحالی‌که MoonViT-V2 نرُم‌های گرادیان بسیار پایین‌تر و کاملاً پایداری را تجربه می‌کند.

– **داده‌های برنامه‌نویسی بصری (Programmatic Multimodal Data):** علاوه بر داده‌های کلاسیک تصویر-زیرنویس، اسناد متنی-تصویری درهم‌تنیده و OCR، حجم عظیمی از داده‌های برنامه‌نویسی شامل کدهای منبع به همراه خروجی‌های رندر شده دوبعدی و سه‌بعدی (SVG)، صفحات وب، بازی‌های رایانه‌ای، دارایی‌های سه‌بعدی و نقشه‌های مهندسی (CAD) به پیکره آموزشی تزریق گردید.

– **نظارت مختصات فضایی:** تمام نمونه‌های نیازمند درک مکان به دو صورت مختصات مطلق پیکسلی و نرمال شده در بازه $[0, 1]^2$ برچسب‌گذاری شدند.

– **فشرده‌سازی پیکسلی توکن‌ها (Pixel-Shuffle Downsampling):** تصاویر و فریم‌های ویدئویی تا وضوح بالای 3584×3584 با کاهش نمونه‌برداری 2×2 از طریق عملگر Pixel-Shuffle متراکم شده و تعداد توکن‌های بینایی را با ضریب ۴ کاهش می‌دهند تا گنجایش بافت ۱ میلیون توکنی حفظ شود:

$$T_{\text{visual}} = \frac{1}{4} \cdot \left(\frac{H_{\text{img}}}{P} \times \frac{W_{\text{img}}}{P} \right), \quad P = 14 \quad (8)$$

مهندسی داده‌های بافتار فوق‌بلند و مسائل مصنوعی به منظور تثبیت ظرفیت بازیابی و استدلال در سقف بافت ۱ میلیون توکن:

– **پالایش ویدئوها با هش ادراکی (Perceptual Hashing):** فریم‌های ویدئویی تکراری و ساکن با استفاده از pHash غربال می‌شوند تا از افزونگی بی‌هوده توکن‌های بصری جلوگیری گردد.

– **وزن‌دهی افزایشی در فاز سردسازی (Upsampling during Cooldown):** به سبب کمیابی طبیعی اسناد طولانی منسجم در وب، فراوانی اسناد طولانی و ویدئوها در مراحل پایانی پیش‌آموزش و به‌ویژه در فاز سردسازی (Cooldown Phase) به‌طور چشمگیری تقویت گردید.

– **تولید وظایف ترکیبی با وابستگی سراسری (Synthetic Interleaved Tasks):** برای جلوگیری از فروپاشی سازوکارهای توجه به الگوهای محلی، اسناد و زیروظایف گوناگون به‌گونه‌ای چیده و ادغام شدند که حل مسئله نهایی منوط به تلفیق اطلاعاتی باشد که در سراسر بازه ۱ میلیون توکن پراکنده‌اند:

$$y_T = f(x_{t_1}, x_{t_2}, \dots, x_{t_k}), \quad 0 \ll t_1 \ll t_2 \ll \dots \ll t_k \leq 10^6 \quad (9)$$

برنامه درسی پیشرونده طول بافتار (Progressive Context Curriculum) مدیریت محاسبات پیش‌آموزش بر روی طول توالی‌های بالا از طریق یک برنامه درسی چهارمرحله‌ای انجام گرفته است:

- **مرحله اول (پیش‌آموزش پایه):** آموزش در طول بافت 8K توکن آغاز می‌شود.
- **مرحله دوم (گسترش میانی):** افزایش پنجره بافتار به 64K توکن در ادامه فرایند پیش‌آموزش.
- **مرحله سوم و چهارم (فاز سردسازی):** جهش متوالی طول بافت از 256K به 1M توکن در طول دوره Cooldown.

با اتکا به مکانیزم زوال ذاتی لایه‌های توجه خطی KDA [۱۶] و حذف کامل کدهای موضعی صریح (NoPE) در لایه‌های Gated MLA، مدل بدون نیاز به دستکاری پایه‌های فرکانسی RoPE یا روش‌های برون‌یابی نظیر YaRN [۱۷]، مستقیماً به بافتار ۱ میلیون توکنی تعمیم می‌یابد.

قوانین مقیاس‌پذیری داده‌ها و برنامه واپاشی نرخ یادگیری روابط تجربی حاکم بر مصرف داده و توان پردازشی بر پایه قوانین توان (Power-law Scaling) تدوین شده‌اند:

$$\mathcal{L}_{\text{val}}(C) = \mathcal{L}_{\infty} + \left(\frac{C_0}{C}\right)^{\alpha} \quad (10)$$

برازش منحنی‌های قانون مقیاس‌پذیری حاکی از آن است که **Kimi K3** برای دستیابی به تراز زیان اعتبارسنجی مشابه با **Kimi K2**، به تقریب تنها به ۴۰٪ از حجم پردازش ($C_{K3} \approx 0.4 \cdot C_{K2}$) نیاز دارد. علاوه بر این، در مقایسه زمان‌بند واپاشی کسینوسی (Cosine Decay) با زمان‌بند گرمایش-پایداری-زوال (WSD) [۱۸]، نشان داده شد که با اجرای مستقل جستجوی قوانین مقیاس‌پذیری جهت تعیین نرخ یادگیری اوج و اندازه دسته بهینه برای هر روش، رویکرد **واپاشی کسینوسی با ۱٪ گرمایش خطی** به طور مداوم زیان نهایی پایین‌تری نسبت به WSD ثبت کرده و به عنوان زمان‌بند رسمی پیش‌آموزش تثبیت شد. پارامترهای ماتریسی مدل نیز با بهینه‌ساز تفکیک‌شده Per-Head Muon [۴] و زوال وزن 0.1 آموزش داده شدند.

مشخصات آماری و معماری داده‌محور (Architectural Specifications) جدول ۳ مقایسه مشخصات و پارامترهای پیش‌آموزش مدل **Kimi K3** را در برابر **Kimi K2** نشان می‌دهد. این مشخصات ظرفیت داده‌پذیری شبکه را در سطح ۷۸.۲ تریلیون پارامتر با ۸۹۶ متخصص مسیردهی‌شده تبیین می‌کند.

جدول ۳: مقایسه معماری و مشخصات پیش‌آموزش مدل‌های **Kimi K2** و **Kimi K3**

تغییرات (Δ)	Kimi K3	Kimi K2	ویژگی / مؤلفه معماری
—	MoE	MoE	معماری کلی (Architecture)
↑ 52%	۹۳	۶۱	تعداد کل لایه‌ها (#Layers)
↑ 167%	۷۸۲.۲	۵۴۲.۱	تعداد کل پارامترها (Total Parameters)
↑ 220%	۲۵۱.۰۴	۶۵.۳۲	پارامترهای فعال به ازای هر توکن (Activated Parameters)
=	۷,۱۶۸	۷,۱۶۸	ابعاد پنهان لایه‌ها (Hidden Dimension)
—	(0.5×) ۳,۵۸۴	—	ابعاد لایه فشرده نهفته (Latent MoE Dimension)
↑ 50%	۳,۰۷۲	۲,۰۴۸	ابعاد پنهان به ازای هر متخصص (MoE Hidden Dim per Expert)
↑ 133%	۸۹۶	۳۸۴	تعداد کل متخصصان مسیردهی‌شده (Routed Experts)
↑ 100%	۱۶	۸	تعداد متخصصان فعال در هر توکن (Active Experts per Token)
↑ 100%	۲	۱	تعداد متخصصان اشتراکی (Shared Experts)
↑ 50%	۹۶	۶۴	تعداد سرهای توجه (Attention Heads)
=	۱	۱	تعداد لایه‌های متراکم (Dense Layers)
=	۱۶۰K	۱۶۰K	اندازه دایره واژگان (Vocabulary Size)
↑ 8×	۱M	۱۲۸K	طول بافتار پیش‌آموزش (Training Context Length)
—	Hybrid KDA-MLA	MLA	مکانیزم توجه (Attention Mechanism)
—	MLA ۲۴ + KDA ۶۹	MLA ۶۱	ترکیب‌بندی لایه‌های توجه
—	SiTU-GLU	[۶] SwiGLU	تابع فعال‌ساز (Activation Function)
=	layer ۱	layer ۱	تعداد لایه‌های پیش‌بینی چندتوکنی (MTP Layers)
—	۴۰۱M	—	کل پارامترهای برج بینایی (ViT Total Parameters)
—	layers ۲۷	—	تعداد لایه‌های برج بینایی (#ViT Layers)
—	۱۴	—	اندازه پچ ورودی تصویر (Patch Size)
—	۱۲	—	تعداد سرهای توجه برج بینایی (ViT Attention Heads)

• Magistral

مقدمه و تبیین ماهیت دادگان مدل مدل‌های خانواده **Magistral** به عنوان نخستین مدل‌های استدلالی شرکت **Mistral AI** [۱۹] معرفی شده‌اند. برخلاف رویه سنتی پیش‌آموزش خام بر روی تریلیون‌ها توکن وب، این پژوهش مستقیماً از چک‌پوینت‌های پیش‌آموزش دیده پایه‌ای شامل **Mistral Medium 3 Instruct** و **Mistral Small 3 Instruct** بهره‌جسته است. تمرکز محوری در این مدل، مهندسی و گردآوری داده‌های استدلالی تاییدپذیر (Verifiable Rewards) برای بهینه‌سازی یادگیری تقویتی (RLVR) و فاز راه‌اندازی نظارت‌شده (SFT Bootstrapping) است:

- **مدل Magistral Medium 3:** آموزش‌دیده بر بستر Mistral Medium 3 صرفاً از طریق یادگیری تقویتی خالص (Pure RL) بدون بهره‌گیری از هرگونه تقطیر یا ردپای استدلالی اولیه، که منجر به جهش نزدیک به ۵۰ درصدی در بنچمارک AIME-24 گردیده است.
- **مدل Magistral Small 3:** مدلی ۲۴ میلیارد پارامتری بر پایه Mistral Small 3 که فرایند آموزش آن با تلفیق داده‌های آغازین سرد (Cold-start Data) استخراج‌شده از نسخه Medium و سپس اجرای برخط RL تکمیل شده است.

پالایش چندمرحله‌ای دادگان ریاضی (Math Data Curation) فرایند گردآوری دادگان ریاضی با هدف دستیابی به مسائلی با پاسخ‌های تحلیلی، قطعی و ارزیابی‌پذیر توسط مفسرهای نمادین طراحی شده است:

- **پالایش ساختار و فرمت (Format Filtering):** کار با یک مجموعه بزرگ اما نویزدار شامل حدود 700K مسئله آغاز گردید. به منظور امکان‌پذیر ساختن اعتبارسنجی قطعی، تمامی مسائل اثباتی تشریحی و مسائل چندبخشی که ارزیابی آنها با قواعد الگوریتمی دشوار بود، حذف شدند. همچنین پرسش‌های چندگزینه‌ای به مسائل گزاره‌ای و تشریحی بازنویسی شدند تا احتمال حدس تصادفی خنثی شده و استخراج پاسخ در قالب ساختار جبری SymPy درون جعبه `\boxed{}` مقدور گردد. این گام حجم داده‌ها را به 501K کاهش داد.
- **فیلتر دوسطحی دشواری و ناحیه طلایی (Goldilocks Zone Filtering):** برای جلوگیری از افت گرادیان ناشی از نمونه‌های بسیار آسان یا ناممکن، یک غربالگری دوسطحی اعمال شد:
 ۱. در مرحله نخست، با نمونه‌برداری ۱۶ پاسخ مستقل به ازای هر مسئله توسط مدل Mistral Large 2 [۲۰]، مسائلی با نرخ موفقیت صفر یا صد درصد کنار گذاشته شدند و داده‌های باقی‌مانده صرف آموزش یک چک‌پوینت نمره‌گذار ۲۴ میلیارد پارامتری شدند.
 ۲. در مرحله دوم، این مدل استدلالی ۲۴ میلیارد پارامتری کل دادگان را مجدداً ارزیابی نمود. مسائلی که اکثریت خروجی‌های مدل در آنها بر پاسخی یکسان اجماع داشتند اما با برچسب واقعیت زمینی (Ground Truth) داده اولیه مغایر بودند، به دلیل خطا در برچسب مرجع حذف گردیدند.

در نتیجه این فیلترینگ سخت‌گیرانه، داده‌های نهایی ریاضی به **۳۸ هزار مسئله فوق‌العاده باکیفیت** محدود شد.

گردآوری و مهندسی دادگان برنامه‌نویسی (Code Data Curation) پیکره کدنویسی رقابتی با هدف سنجش دقیق درستی و کارایی الگوریتم‌ها شکل گرفته است:

- **اعتبارسنجی و تصحیح آزمون‌های واحد (Unit Tests):** مسائل فاقد آزمون یا کدهای مرجع معتبر حذف شدند. راه‌حل‌های مرجع بر روی آزمون‌ها اجرا شده و آزمون‌های ناهماهنگ پالایش شدند. در مواردی که تمامی راه‌حل‌ها در یک تست با شکست مواجه می‌شدند، برچسب تست بر مبنای خروجی متداول راه‌حل‌ها تصحیح شد. در صورت نیاز، تست‌های مصنوعی جدیدی نیز تولید و اضافه گردید.
- **پشتیبانی دوزبانه و استانداردسازی کامپایل:** مسائل به گونه‌ای بازطراحی یا تکثیر شدند که پیاده‌سازی به هر دو زبان Python و C++20 پشتیبانی شود. برای تسریع زمان ارزیابی، هدر پرکاربرد `bits/stdc++.h` پیش‌کامپایل گردید.
- **محیط ارزیابی ایمن (Sandbox Execution):** برای هر ارزیابی گروهی، ۲۰ آزمون تصادفی انتخاب و به تمامی اعضای گروه اختصاص یافت. سقف زمان اجرای هر تست ۴ ثانیه و محدودیت حافظه 300MB تعیین گردید. این خط لوله در نهایت به گردآوری **۳۵ هزار مسئله کدنویسی** انجامید.

مهندسی دادگان چندزبانه و پایداری زبان تفکر (Multilingual Strategy) به منظور مهار پدیده سوئیچ ناخواسته زبان در طول زنجیره تفکر (Language Mixing):

- **ترجمه متوازن دادگان:** دقیقاً 10% از مسائل انگلیسی به زبان‌های فرانسوی، اسپانیایی، ایتالیایی، آلمانی، چینی و روسی برگردانده شد.
- **پاداش پایداری زبان (Language Consistency):** پس از پاک‌سازی علائم لاتک و کدهای دستوری، سه‌گانه پرسش، افکار داخل تگ <think> و پاسخ نهایی توسط طبقه‌بند fastText [۲۱] بررسی شده و در صورت یکسانی زبان در هر سه بخش، پاداش افزوده‌ای معادل 0.1 اعمال گردید. این تمهید امکان تولید زنجیره تفکر به زبان بومی کاربر را بدون افت کیفیت استدلال تثبیت کرد.

دادگان راه‌اندازی اولیه و تقطیر برای مدل کوچک (SFT Cold-Start Bootstrapping) در آموزش مدل Magistral Small، برای آماده‌سازی اولیه سیاست مدل:

- **استخراج ردپاهای باکیفیت آموزگار:** نمونه پاسخ‌های صحیح از مراحل پیشرفته آموزش RL مدل Magistral Medium استخراج و ردهای اولیه با تفکر کوتاه فیلتر شدند.
- **غنی‌سازی با داده‌های متن‌باز:** پرومپت‌های متنوع از مجموعه‌های OpenThoughts [۲۲] و OpenR1 [۲۳] گزینش شده و با پاسخ‌های تفکری مدل Medium غنی‌سازی شدند.
- **تزریق داده‌های عمومی دستورپذیری:** برای پیشگیری از فراموشی فاجعه‌بار مهارت‌های عمومی، 10% از حجم داده‌های SFT به دستورات متداول غیراستدلالی اختصاص یافت و مدل به مدت ۴ دوره بر روی این ترکیب آموزش دید.

صورت‌بندی بهینه‌سازی و سیگنال‌های پاداش حاکم بر دادگان فرایند بهینه‌سازی سیاست مدل π_θ بر روی دادگان پردازش‌شده توسط الگوریتم GRPO [۲۴] و با اعمال اصلاحات تثبیت‌کننده به فرم زیر اجرا می‌شود:

(۱۱)

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{q \sim \mathcal{P}(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}^{\text{norm}}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) \hat{A}_{i,t}^{\text{norm}} \right) \right]$$

که در آن $r_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, o_{i,<t})}$ نسبت مزیت استانداردشده در سطح مینی‌بچ به صورت $\hat{A}_{i,t}^{\text{norm}} = \frac{\hat{A}_i - \hat{A}_{\text{std}}}{\hat{A}_{\text{std}}}$ تعریف شده و شرط تفکیک گروه‌های همگن $\exists m < n, r_m \neq r_n$ اعمال می‌شود.

همچنین جهت پیشگیری از رشد مهارت‌گسیخته طول پاسخ و سرریز حافظه، جریمه طول نرم بر داده‌ها حاکم گردید:

$$R_{\text{length}}(y) = \begin{cases} 0, & |y| \leq l_{\text{max}} - l_{\text{cache}} \\ -0.1 \cdot \frac{|y| - l_{\text{max}} + l_{\text{cache}}}{l_{\text{cache}}}, & l_{\text{max}} - l_{\text{cache}} < |y| \leq l_{\text{max}} \\ -0.1, & l_{\text{max}} < |y| \end{cases} \quad (12)$$

تحلیل‌های آماری، پویایی وزن‌ها و ارزیابی جامع دادگان داده‌های آموزشی و اثرات آنها بر روی شاخص‌های کمی در جداول زیر خلاصه شده است. جدول ۴ فرآیند فشرده‌سازی و غربالگری دادگان ریاضی را نشان می‌دهد که در آن تنها ۴.۵% از داده‌های اولیه موفق به عبور از فیلترهای صحت و دشواری شدند. جدول ۵ نیز نشان‌دهنده ارتقای چشمگیر عملکرد استدلالی مدل در حوزه‌های گوناگون تحت آموزش بر روی این دادگان گزینش‌شده است.

یافته‌های انتقال بدون داده و راهبردهای ناموفق (Negative Results) تحلیل پویایی آموزش مدل حاوی دو بینش اساسی در حوزه مهندسی دادگان است:

- **انتقال چندوجهی بدون دادگان تصویر (Multimodal Free Lunch):** علیرغم اینکه آموزش RL کاملاً بر بستر داده‌های متنی محض صورت پذیرفت، مدل قابلیت‌های انکودر بصری پیش‌آموزش‌دیده خود را حفظ کرده و حتی در بنچمارک‌های چندوجهی ارتقا یافت؛ به گونه‌ای که امتیاز MMMU از 65.0% به 70.0% و در MMMU-Pro (Vision) با رشدی چشمگیر از 39.7% به 52.1% رسید.

جدول ۴: مراحل متوالی پالایش کمی دادگان ریاضی در مدل‌های Magistral

شاخص	داده اولیه خام (Initial)	پالایش فرمت و ساختار	پالایش دشواری ناحیه طلایی
تعداد نمونه‌ها	699K	501K	38K
نرخ بقا نسبت به مرحله قبل	-	71.67%	7.58%
نرخ تجمعی بقا از کل	100%	71.67%	۴۴%.۵

جدول ۵: ارزیابی عملکرد مدل‌های Magistral در مقایسه با مبناهای استدلالی تراز اول جهان

بنچمارک (متریک)	Mistral Med. 3	Magistral Med.	DeepSeek-V3	DeepSeek-R1-Zero	DeepSeek-R1
استفاده از SFT قبل از RL	-	خیر	-	خیر	بله
AIME '24 (Pass@1 / Maj@64)	۴.۴۳ / ۸.۲۶	۰.۹۰ / ۶.۷۳	۲.۳۹	- / ۰.۷۱	- / ۸.۷۹
AIME '25 (Pass@1 / Maj@64)	۰.۳۰ / ۲.۲۱	۳.۸۳ / ۹.۶۴	۸.۲۸	-	- / ۰.۷۰
MATH-500	۰.۹۱	۳.۹۴	۲.۹۰	۹.۹۵	۳.۹۷
GPQA Diamond	۶.۵۹	۸.۷۰	۱.۵۹	۳.۷۳	۵.۷۱
LiveCodeBench v5	۱.۲۹	۴.۵۹	۲.۳۶	۰.۵۰	۹.۶۵
Aider Polyglot	۹.۲۸	۱.۴۷	۶.۴۹	-	۳.۵۳
Humanity's Last Exam (Text)	۴.۴	۰.۹	-	-	۶.۸

– **شکست پاداش جزئی در دادگان کد:** فرضیه اعطای پاداش نسبی بر پایه درصد قبولی آزمون‌های واحد به جای پاداش دودویی (0 یا 1)، به افت ۲ درصدی دقت در LiveCodeBench انجامید، زیرا پاداش جزئی منجر به تقویت الگوهای غیربهبینه و ایجاد سیگنال گمراه‌کننده در کدهای دارای باگ می‌شد.

• MiniMax-M2

مقدمه و ساختار کلی دادگان پیش‌آموزش فاز پیش‌آموزش (Pre-training) در مدل زبانی MiniMax-M2 با تکیه بر اصل راهنمای «فعال‌سازی حداقلی برای آزادسازی بیشترین هوش دنیای واقعی» (Mini Activations Unleashing Max Real-World Intelligence) طراحی شده است. معماری این مدل یک ترنسفورمر فقط دکودر با ۹.۲۲۹ میلیارد پارامتر کل است که در هر گام محاسباتی تنها ۸.۹ میلیارد پارامتر فعال می‌گردد (۲۵۶ متخصص ریزدانه با مسیریابی سیگموئید و فعال‌سازی همزمان ۸ متخصص). فرایند پیش‌آموزش پایه بر روی مجموعه‌ای بالغ بر ۲.۲۹ **تریلیون توکن** (29.2T tokens) با سقف بافت بومی ۱۹۲ هزار توکن (192K native context window) صورت پذیرفته است [۲۵]. این بودجه کل توکن‌ها به صورت دومرحله‌ای بهینه‌سازی شده است:

$$|D_{\text{pretrain}}| = |D_{\text{constant}}| + |D_{\text{decay}}| = 19.9T + 9.3T = 29.2T \quad (۱۳)$$

– **فاز نرخ یادگیری ثابت (Constant Phase):** شامل ۹.۱۹ تریلیون توکن (معادل ۱۵٪.۶۸ از کل داده‌ها) که تمرکز آن بر تثبیت بازنمایی‌های دانش عمومی، مبانی استدلال و یادگیری ساختار زبان در طول بافت‌های اولیه (8K) است.

– **فاز زوال و بسط زمینه (Decay Phase):** شامل ۳.۹ تریلیون توکن (معادل ۸۵٪.۳۱ از کل داده‌ها) که ضمن کاهش نرخ یادگیری، با تزریق داده‌های سنتز شده بافت‌بلند، تعمیم مدل تا سقف 192K توکن را محقق می‌سازد.

ترکیب‌بندی و پالایش پیکره داده‌ها (Data Construction & Filtering) پیکره متنی پیش‌آموزش از منابع متعددی شامل متون پالایش شده وب، مقالات دانشگاهی، کتاب‌ها، کدهای برنامه‌نویسی و دادگان ساختاریافته پرسش و پاسخ گردآوری شده است. با توجه به هدف‌گذاری مدل بر روی رفتارهای عاملی (Agentic Workflows)، تدابیر کیفی زیر اعمال گردید:

– **بیش‌نمونه‌برداری راهبردی (Domain Upsampling):** داده‌های مربوط به کد (Code)، ریاضیات (Mathematics) و علوم پایه، فناوری، مهندسی و ریاضیات (STEM) به صورت چشمگیری فراتر از نرخ توزیع طبیعی خود در وب بیش‌نمونه‌برداری شدند تا توانایی استنتاج منطقی ارتقا یابد.

- **پالایش دوبخشی کیفیت داده‌ها (Model-Based Quality Filtering):** اسناد خام ورودی از دو فیلتر ترکیبی عبور می‌کنند: ۱) مدل‌های امتیازدهی پاداش متنی (Model-Based Reward Scoring) جهت سنجش چگالی اطلاعاتی و سبک نگارش؛ ۲) طبقه‌بندهای کمکی چندبعدی (Auxiliary Classifiers) جهت اعتبارسنجی تخصصی و موضوعی اسناد.
- **استراتژی نمونه‌برداری متعادل (Balanced Sampling Strategy):** به منظور پرهیز از افت تنوع موضوعی، داده‌های دارای رتبه کیفی بالا وزن‌دهی مثبت شده (Upweighting)، در حالی که پوشش جامع زبان‌شناختی و دانش حاشیه‌ای جهان به دقت محافظت می‌گردد.

پیش‌بینی چندتوکنی و اهداف آموزشی (Multi-Token Prediction & Objectives) به منظور غنی‌سازی سیگنال‌های نظارتی در طول مصرف توکن‌های پیش‌آموزش و تسریع استنتاج از طریق کدگذاری فرضی (Speculative Decoding) [۲۶]، ماژول پیش‌بینی چندتوکنی (MTP) [۲۷، ۱] در طول آموزش فعال گردیده است:

$$\mathcal{L}_{\text{total}}(\theta) = \mathcal{L}_{\text{NTP}}(\theta) + \lambda_{\text{MTP}} \sum_{k=1}^K \mathcal{L}_{\text{MTP}}^{(k)}(\theta) \quad (14)$$

- **زمان‌بندی وزن زیان (MTP Loss Weight Annealing):** در فاز پیش‌آموزش اولیه با یک ماژول ($K = 1$)، ضریب تلفات ابتدا روی $\lambda_{\text{MTP}} = 0.3$ تنظیم شده و در طول فاز زوال تا سقف 0.1 کاهش می‌یابد.
- **توسعه ماژول با کپی وزن‌ها (Expansion via Weight Copying):** در ادامه پیش‌آموزش، ماژول MTP با کپی وزن‌های مدل اصلی به سه ماژول ($K = 3$) ارتقا می‌یابد. در گام نخست، مدل اصلی فریز شده و فقط ماژول‌های MTP تا تثبیت خطا آموزش می‌بینند و سپس آموزش مشترک کل شبکه از سر گرفته می‌شود.

برنامه درسی طول بافت و داده‌های بلندکانتکت (Context Curriculum & Long-Context Data) فرایند تعمیم مدل به بافت فوق‌طولانی 192K توکنی در طول فاز زوال (9.3T توکن) با برنامه آموزشی تدریجی زیر صورت پذیرفته است:

$$8K \rightarrow 32K \rightarrow 192K \quad (15)$$

- به منظور پوشش بهینه پنجره‌های زمینه گسترده بدون اتلاف محاسباتی، سه رویکرد مهندسی داده پیاده‌سازی شده است:
- **الحاق کدهای پروژه‌ای باکیفیت (Code Concatenation):** تجمیع فایل‌های متنی وابسته در مخازن کد به نحوی که روابط ارجاعی و ساختار پروژه حفظ گردد.
- **اسناد بلند ذاتاً ساختاریافته (Naturally Long-Form PDFs):** انتخاب گزارش‌های تحلیلی، متون قانونی و کتب با پیوستگی استدلالی طبیعی در طول توالی‌های بالا.
- **بسته‌بندی اسناد هم‌موضوع (Thematically Related Document Packing):** ادغام هوشمند اسناد دارای ارتباط معنایی در یک توالی واحد به منظور حذف توکن‌های پرکننده (Padding) و تمرین استدلال بین‌سندی.

ارزیابی‌های تجربی و مطالعات ابطال در مقیاس پیش‌آموزش (Pre-Training Evaluations & Ablations) کیفیت پیکره پیش‌آموزش و انتخاب‌های معماری مدل پایه MiniMax-M2 طی دو ارزیابی جامع سنجیده شده است:

۱. **مطالعه ابطال روی بودجه ۵۰۰ میلیارد توکنی:** در جدول ۶، کارایی یادگیری از داده‌های پیش‌آموزش تحت سه پیکربندی مجزا بر روی ۵۰۰ میلیارد توکن سنجیده شده است. نتایج حاکی از آن است که ترکیب متخصصان ریزدانه (Fine-Grained) [۲۸] و ماژول MTP [۲۷] با ثابت نگه داشتن حجم داده‌ها

جدول ۶: مطالعه ابطال طراحی متخصصان ریزدانه و ماژول MTP بر روی ۵۰۰ میلیارد توکن پیش‌آموزش [۲۵]

مشخصات / بنچمارک	تنظیمات (Shots)	پایه (Baseline)	همراه با MTP	همراه با Fine-Grained
پارامترهای فعال	۲B	۲B	۲B	۲B
کل پارامترها	۸B.۱۷	۸B.۱۷	۸B.۱۷	۸B.۱۷
بودجه توکن‌های آموزش	۵۰۰B	۵۰۰B	۵۰۰B	۵۰۰B
تعداد کل متخصصان (num_experts)	۳۲	۳۲	۳۲	۱۲۸
تعداد متخصصان فعال (topk)	۲	۲	۲	۸
MATH [۲۹]	۴-shot	۶.۱۹	۳.۲۱	۱.۲۴
MMLU [۳۰]	۵-shot	۸.۳۹	۷.۳۹	۲.۴۰
ARC-Challenge [۳۱]	۲۵-shot	۴.۲۷	۵.۲۷	۸.۲۷
KorBench [۳۲]	۳-shot	۱.۱۴	۰.۱۵	۸.۱۴
HumanEval [۳۳]	۰-shot	۷.۲۹	۱.۳۰	۵.۳۲

و پارامترهای فعال (2B)، بازدهی استخراج دانش از داده‌ها را در بنچمارک استدلال ریاضی MATH از 19.6 به 24.1 (رشد نسبی ۹۲٪) و در کدنویسی HumanEval از 29.7 به 32.5 ارتقا داده است.

۲. مقایسه توجه کامل در برابر توجه پنجره‌ای لغزان (Full Attention vs. Hybrid SWA): تیم Min-iMax
 برای بهینه‌سازی پردازش داده‌های بلندکانتکست، مکانیزم توجه پنجره‌ای لغزان ترکیبی (Hybrid SWA) [۳۴] را در مقیاس معماری M2 در برابر توجه کامل چندسری (Full Attention) [۳۵، ۳۶] مورد آزمون قرار داد. مطابق جدول ۷، علیرغم هم‌سطح بودن عملکرد در کانتکست‌های کوتاه (32K)، مکانیزم SWA در بنچمارک‌های بافت بلند نظیر RULER 128K CWE با افت ۱۸ نمره‌ای (90.0 → 72.0) و در ترجمه کانتکست‌محور MTOB با افت شدید مواجه شد. این تحلیل آماری ثابت کرد که بهره‌برداری کامل از داده‌های بلندکانتکست در پیش‌آموزش مستلزم حفظ ساختار توجه کامل است.

جدول ۷: ارزیابی پیش‌آموزش در مقیاس معماری MiniMax-M2: توجه کامل در برابر توجه پنجره‌ای لغزان (Hybrid SWA) [۲۵]

دسته آزمون	بنچمارک	پایه: توجه کامل (Baseline)	همراه با SWA
دانش عمومی و استدلال	HELMET ICL [۳۷]	۸.۷۵	۷.۷۲
	MMLU [۳۰]	۵.۸۵	۶.۸۵
	MATH [۲۹]	۳.۶۰	۳.۶۰
بازیابی در بافت طولانی	RULER 128K CWE [۳۸]	۰.۹۰	۰.۷۲
	RULER 128K MQ [۳۸]	۰.۹۹	۰.۹۳
	RULER 32K CWE [۳۸]	۰.۹۹	۰.۹۹
	RULER 32K MQ [۳۸]	۰.۹۹	۰.۹۹
ترجمه درون‌بافتی	MTOB K-e Bleurt [۳۹]	۰.۶۰	۰.۴۵
	MTOB e-k ChrF [۳۹]	۸.۴۴	۲.۲۷

• MobileLLM-Pro

مقدمه و ساختار چندمرحله‌ای دادگان پیش‌آموزش مدل MobileLLM-Pro [۴۰] یک مدل زبانی بنیادین ۱ میلیارد پارامتری (دقیقاً ۸۴.۱ میلیارد پارامتر) است که با هدف استقرار و استنتاج کارآمد روی دستگاه‌های لبه‌ای (On-Device) طراحی شده است. از آنجا که مدل‌های با مقیاس زیر ۳ میلیارد پارامتر حساسیت بسیار بالایی نسبت به نویز دادگان و پدیده جابجایی توزیع (Distribution Shift) در طول مراحل گوناگون آموزش دارند، فرایند پیش‌آموزش داده‌ها در این مدل بر پایه یک خط‌لوله ۴ فازی مهندسی شده است:

- فاز ۱ (اکتساب زبان پایه - Language Acquisition): تمرکز بر یادگیری عمومی زبان با بودجه آموزشی ۴.۱ تریلیون توکن (1.4T tokens) و طول بافت 2K توکن.
- فاز ۲ (بسط بافت متنی - Context Expansion): توسعه پنجره بافت به ۱۲۸,۰۰۰ توکن (128K context) روی ۲۰ میلیارد توکن بدون تغییر در توزیع متنی فاز ۱.

- فاز ۳ (بازپخت و ادغام متخصصان - Specialist Model Merging): بازپخت مدل با خوشه‌بندی دادگان پیش‌آموزش روی حوزه‌های هدف با بودجه ۶۰ میلیون توکن برای هر شاخه متخصص.
- فاز ۴ (آموزش آگاه از کوانتایش - Quantization-Aware Training): فشرده‌سازی و پایدارسازی وزن‌های مدل تا سطح ۴ بیتی بر روی ۸۰ میلیارد توکن (حدود ۵٪ از بودجه کل آموزش).

در تمامی فازهای پیش‌آموزش، به جای استفاده از اهداف کلاسیک تک‌مقداری (One-hot targets) و تابع زیان انتروپی متقاطع مرسوم، از تقطیر دانش مبتنی بر لاجیت (Logit-based Knowledge Distillation) [۴۱، ۴۲] از مدل معلم قدرتمند Llama 4-Scout با واژگان کامل ۲۰۲،۰۴۸ توکنی استفاده شده است. هدف بهینه‌سازی از طریق حداقل‌سازی واگرایی پیشرو کولبک-لایبلر (Forward KL-Divergence) تعریف می‌شود:

$$\mathcal{L}_{KD}(\theta) = \mathcal{D}_{KL}(P_{\text{Teacher}}(y | x) || P_{\text{Student}}(y | x; \theta)) \quad (16)$$

شبیه‌سازی آفلاین و گزینش بهینه داده‌ها (SDM Data-Mix Simulations) به منظور پرهیز از تصمیم‌گیری‌های شهودی یا وزن‌دهی یکنواخت، ترکیب داده‌های فاز ۱ با استفاده از چهارچوب شبیه‌ساز مقیاس‌پذیر داده (Scalable Data Mixer - SDM) [۴۳، ۴۴] استخراج شده است. در این شیوه، اثرگذاری هر نمونه متنی x بر دامنه‌های گوناگون داده‌ای D (شامل زبان عمومی، دانش، استدلال، کد و ریاضیات) از طریق مدل‌های زبانی آماری سبک‌وزن (SLM) سنجیده می‌شود:

$$\text{Inf}(x, D) = \mathcal{L}_D(\text{SLM}) - \mathcal{L}_D(\text{SLM} \leftarrow x) \quad (17)$$

که در آن $\mathcal{L}_D$ زیان انتروپی متقاطع روی دامنه D را قبل و بعد از آموزش یک‌گامه با نمونه x نشان می‌دهد. این امتیازها در قالب یک بردار تأثیر $\Delta_x = [\text{Inf}(x, D_1), \dots, \text{Inf}(x, D_k)]^T$ تجمیع شده و توسط یک رگرسور عصبی سبک‌وزن، مطلوبیت پایین‌دستی (Downstream Utility) $\hat{y}_D$ پیش‌بینی می‌شود. در نهایت، با یک بار پیمایش آفلاین کل پیکره در طول ۱ میلیون گام، وزن‌های ایستای نمونه‌برداری w_i متناسب با مطلوبیت انتظاری $\mathbb{E}_{x \in D_i}[\hat{y}]$ به دست می‌آیند به طوری که $\sum_i w_i = 1.0$. آمار تفکیکی دادگان پالایش‌شده برای پیش‌آموزش فاز ۱ و ۲ در جدول زیر خلاصه شده است:

جدول ۸: مشخصات آماری دادگان فاز ۱ و فاز ۲ پیش‌آموزش مدل MobileLLM-Pro

مجموعه داده (Dataset)	مرجع علمی	سطرها (میلیون)	حجم توکن (میلیارد)	وزن در آمیزه (%)
Fineweb-EDU (2024)	[۴۵] al. et Allal	۱.۱۲۷۹	۰.۱۳۰۰	۷۵٪.۸۹
Starcode (2023)	[۴۶] al. et Li	۶.۲۰۶	۸.۲۶۳	۶۶٪.۴
Open Web Math (2023)	[۴۷] al. et Paster	۱.۶	۶.۱۲	۹۲٪.۱
Arxiv (2023)	-	۵.۱	۰.۲۸	۳۵٪.۱
Wikipedia	-	۲.۷	۷.۳	۰۲٪.۱
Stack Exchange (2023)	[۴۸] Computer Together	۲.۲۹	۶.۱۹	۰۲٪.۱
Algebraic Stack (2023)	[۴۹] al. et Azerbayev	۴.۳	۶.۱۲	۲۴٪.۰
مجموع کل (Total)		۰.۱۵۰۰	۳.۱۶۴۰	۰۰٪.۱۰۰

این توزیع آماری نشان می‌دهد که مدل بیشترین سهم خود (۷۵٪.۸۹) را از متون آموزشی و منسجم وب دریافت کرده و تخصیص متوازن ۸۲٪.۶ از کل آمیزه به داده‌های استدلالی، برنامه‌نویسی و ریاضیات، ظرفیت محاسباتی مدل ۱ میلیارد پارامتری را بدون اشباع یا نویزپذیری پایدار ساخته است. این مرحله با اندازه دسته موثر ۲ میلیون توکن در ۶۴۰،۰۰۰ گام به‌روزرسانی و با نرخ یادگیری اولیه 4×10^{-4} آموزش داده شده است.

بسط بافت متن بدون جابجایی توزیع (Implicit Positional Distillation) یکی از نوآوری‌های بنیادین در سازمان‌دهی داده‌های پیش‌آموزش MobileLLM-Pro، حذف نیاز به پیکره‌های متنی بلند مرسوم در فاز دوم است. تزریق متون فوق‌طولانی معمولاً تعادل زبانی مدل‌های فشرده را برهم می‌زند و به افت

یادگیری منجر می‌شود. در این پژوهش، از تکنیک «تقطیر موقعیتی پنهان» بر بستر تعبیه موقعیتی چرخشی (RoPE) استفاده شده است:

$$\begin{bmatrix} x'_i \\ x'_{i+1} \end{bmatrix} = \begin{bmatrix} \cos(\theta_i p) & -\sin(\theta_i p) \\ \sin(\theta_i p) & \cos(\theta_i p) \end{bmatrix} \begin{bmatrix} x_i \\ x_{i+1} \end{bmatrix}, \quad \theta_i = 10000^{-\frac{2i}{d}} \quad (18)$$

با استفاده از اتصال اسناد کوتاه قبلی و پوشش علیتی بلوکی (Block Causal Masking)، مدل دانشجو توزیع لاجیت معلم را دریافت می‌کند. از آنجا که مدل معلم قبلاً روی توالی‌های بلند آموزش دیده، لاجیت‌های آن رفتار چرخش زاویه‌ای کامل (تا سقف ۳۶۰ درجه معادل بافت ۱۲۸K) را به صورت پنهان بازتاب می‌دهند. در نتیجه، بدون مواجهه مستقیم مدل دانشجو با متون طولانی اختصاصی و تنها با آموزش روی ۲۰ میلیارد توکن مضاعف از همان توزیع داده‌ای فاز اول (طی ۱۰۰,۰۰۰ گام با بیشینه نرخ یادگیری 4×10^{-5})، مدل به پنجره بافت ۱۲۸K دست پیدا می‌کند.

خوشه‌بندی داده‌ها و ادغام متخصصان (Specialist Model Merging) در فاز سوم، داده‌های بدون ساختار پیش‌آموزش خوشه‌بندی شده و به زیرمجموعه‌های متمرکز بر حوزه‌های خاص تفکیک می‌شوند. به جای آموزش هم‌زمان که موجب رقابت مخرب بین قابلیت‌ها (نظیر حفظ حقایق در برابر توانایی استدلال) می‌شود، n مدل متخصص موازی $(b_1, \dots, b_n)$ هر کدام به طور مستقل روی دامنه متنی اختصاصی خود D_i به میزان ۶۰ میلیون توکن طی ۵۰۰ گام آموزش می‌بینند. در نهایت، پارامترهای متخصصان از طریق ادغام گیریکنواخت وزنی تلفیق می‌شوند:

$$M = \frac{1}{n} \sum_{b=1}^n \theta_b \cdot w_b, \quad \sum_{b=1}^n w_b = 1.0 \quad (19)$$

این رویکرد داده‌محور، مدل پایه MobileLLM-Pro-base را حاصل می‌آورد که در آن ویژگی‌های مجزای حوزه‌ای به شکل هم‌افزا پیوند خورده‌اند.

بودجه داده‌ها در فاز کوانتایش (QAT Phase) در مرحله چهارم، به منظور انطباق نهایی وزن‌ها و فعال‌سازها برای استقرار روی پردازنده‌های کم‌مصرف CPU و شتاب‌دهنده‌های NPU (مانند Apple ANE و Qualcomm HTP)، مدل با بودجه متنی معادل ۸۰ میلیارد توکن با روش تقطیر از خود (Self-Distillation) از نسخه اعشاری فاز ۳، تحت یادگیری بازه کوانتایش قرار می‌گیرد.

ارزیابی‌های تجربی و تحلیل آماری اثرگذاری داده‌ها جدول‌های زیر اثرات تجربی راهبردهای انتخاب، پالایش و عدم جابجایی توزیع داده‌ها را بر عملکرد نهایی مدل اثبات می‌کنند:

جدول ۹: مقایسه عملکرد آمیزه داده بهینه‌شده با SDM در برابر آمیزه یکنواخت (Uniform)

مرحله آموزش	بودجه توکن	منبع آمیزه داده	میانگین عملکرد (%) (Avg. Score)
پیش‌آموزش (Pre-training)	۴T.۱	یکنواخت (Uniform) SDM (پیشنهادی)	۷۰٪.۳۸ ۳۱٪.۴۹
آموزش دستورپذیری (IFT)	۸۰B	یکنواخت (Uniform) SDM (پیشنهادی)	۹۴٪.۱۷ ۲۳٪.۴۵

بر اساس نتایج جدول فوق، بهینه‌سازی داده‌ها از طریق SDM موجب ارتقای مطلق ۶۱٪.۱۰ در مرحله پیش‌آموزش نسبت به توزیع یکنواخت شده است.

همچنین جدول زیر، مزیت ثابت نگه داشتن توزیع داده در فاز ۲ را در مقایسه با تزریق متون طولانی متداول اثبات می‌کند:

همان‌طور که مشاهده می‌شود، استفاده از دادگان متنی طولانی اختصاصی موجب افت ۸۸٪.۵ در عملکرد عمومی مدل گردیده، در حالی که روش تقطیر پنهان با حفظ توزیع داده‌های فاز ۱، نمره بازیابی NIH را به ۷۸٪.۹۹ رسانده و از افت عملکرد عمومی ممانعت نموده است.

جدول ۱۰: ارزیابی راهبردهای دادگان فاز ۲ در آزمون سوزن در انبار کاه (NIH) و میانگین تسک‌های عمومی

شاخص NIH (%)	میانگین عملکرد عمومی (بدون NIH)	پیکربندی داده‌ای فاز ۲
۷۰٪.۶	۷۴٪.۵۳	فاز ۱ (طول بافت کوتاه 2K)
۲۲٪.۸۰	۸۶٪.۴۷ (افت ۸۸٪.۵)	فاز ۲ با متون طولانی متعارف
۷۸٪.۹۹	۵۷٪.۵۳ (حفظ ثبات کیفی)	فاز ۲ با تقطیر پنهان (توزیع داده‌های فاز ۱)

در نهایت، جدول زیر نشان‌دهنده تأثیر خوشه‌بندی داده‌های پیش‌آموزش روی دامنه‌های تخصصی مستقل و سپس ادغام وزنی آن‌ها است:

جدول ۱۱: تأثیر خوشه‌بندی دامنه‌ها روی متخصصان مجزا و هم‌افزایی حاصل از ادغام وزنی نهایی (Weight Avg)

بنچمارک (متریک)	پیش از بازیخت	متخصص ۱	متخصص ۲	متخصص ۳	متخصص ۴	ادغام نهایی (Weight Avg.)
HellaSwag (acc_char)	۷۷.۶۵	۶۹.۶۶	۸۷.۶۶	۳۱.۶۶	۵۴.۶۷	۵۸.۶۷
BoolQ (acc_char)	۲۸.۷۱	۵۱.۷۶	۹۴.۷۶	۶۴.۷۳	۴۷.۷۸	۸۲.۷۶
PIQA (acc_char)	۵۷.۷۵	۱۴.۷۵	۵۰.۷۶	۴۶.۷۵	۱۷.۷۶	۵۵.۷۶
SIQA (acc_char)	۲۹.۴۷	۹۰.۴۷	۹۷.۵۰	۸۸.۴۶	۳۱.۵۰	۲۳.۵۱
TriviaQA (em)	۶۱.۳۶	۷۸.۳۶	۵۷.۴۰	۴۸.۳۷	۹۱.۳۹	۱۸.۴۰
Natural Questions (em)	۵۲.۱۲	۲۲.۱۲	۸۴.۱۵	۸۳.۱۱	۵۱.۱۶	۲۹.۱۶
ARC-Challenge (acc_char)	۶۴.۵۰	۵۵.۵۳	۱۹.۵۲	۳۳.۵۱	۵۵.۵۳	۱۶.۵۴
ARC-Easy (acc_char)	۳۷.۷۱	۲۲.۷۵	۴۵.۷۶	۶۶.۷۳	۷۴.۷۶	۹۶.۷۶
WinoGrande (acc_char)	۳۰.۶۳	۵۶.۶۳	۱۴.۶۳	۹۰.۶۲	۵۶.۶۳	۵۴.۶۳
OBQA (acc_char)	۸۰.۴۱	۴۰.۴۱	۴۰.۴۳	۸۰.۴۱	۴۰.۴۳	۵۰.۴۴
NIH (em)	۵۰.۱۰۰	۵۰.۱۰۰	۵۰.۱۰۰	۵۰.۱۰۰	۵۰.۱۰۰	۵۰.۱۰۰
میانگین (بدون NIH)	۵۷.۵۳	۸۰.۵۴	۲۴.۵۶	۱۳.۵۴	۴۲.۵۶	۷۳.۵۶

این آمار مؤید آن است که آموزش شاخه‌ای روی داده‌های تفکیک‌شده و ادغام متعاقب پارامترها، امتیاز مدل را از ۵۷.۵۳ به ۷۳.۵۶** ارتقا داده که حتی از بهترین متخصص منفرد (۴۲.۵۶) نیز فراتر رفته و هم‌افزایی بازنمایی دادگان را ثابت می‌کند.

• Nemotron 3

مقدمه و ساختار مقیاس دادگان پیش‌آموزش خانواده مدل‌های زبانی Nemotron 3 (شامل نسخه‌های Nano، Super و Ultra) با تمرکز بر تعاملات کارگزارمحور (Agentic AI)، پنجره زمینه فوق‌طولانی تا سقف ۱ میلیون توکن (1M Context Length) و بیشینه‌سازی توان عملیاتی استنتاج طراحی شده‌اند. زیرساخت داده‌های پیش‌آموزش (Pre-training) این خانواده بر اساس مقیاس‌های محاسباتی و داده‌ای زیر سازمان‌دهی شده است:

– **مقیاس پیش‌آموزش پایدار با فرمت عددی NVFP4:** معماری پیوندی مانبا-متخصصان (Mamba-) MoE این مدل با پایداری کامل تا سقف ۲۵ تریلیون توکن (25T tokens) با فرمت عددی NVFP4 آموزش داده شده است.

– **سبد داده‌های بازنشر عمومی:** انویدیا متعهد به انتشار وزن‌ها، نرم‌افزارهای آموزش و مجموعه‌ای بالغ بر ۱۰ تریلیون توکن (>10T tokens) از دادگان پیش‌آموزش تحت مجوزهای باز شده است.

– **دادگان ارزیابی و آزمایش‌های مقایسه‌ای (Ablation Baselines):** برای سنجش دقیق نوآوری‌هایی نظیر معماری LatentMoE و پیش‌بینی چندتوکنی (MTP)، مدل‌های مقایسه‌ای با ۸ میلیارد پارامتر فعال و ۷۳ میلیارد پارامتر کل بر روی یک پیکره همگن به حجم ۱ تریلیون توکن (1T tokens) پیش‌آموزش دیده‌اند.

تابع هدف پایه در فاز پیش‌آموزش، کمینه‌سازی میانگین منفی لگاریتم درست‌نمایی (NLL) برای

پیش‌بینی توکن‌های آتی است:

$$\mathcal{L}_{\text{LM}}(\theta) = -\frac{1}{N} \sum_{t=1}^N \log P_{\theta}(x_t | x_1, x_2, \dots, x_{t-1}) \quad (20)$$

ترکیب‌بندی، گونه‌شناسی و دادگان ساختگی (Data Typology & Synthetic Data) با توجه به ماهیت استدلالی و لزوم پردازش زمینه‌های چند صد هزار توکنی، داده‌های پیش‌آموزش شامل شاخه‌های متمایز زیر هستند:

- **کدهای منبع در سطح مخزن (Repository-Level Code):** بهره‌گیری از توالی‌های کامل پروژه‌های نرم‌افزاری با طول فراتر از ۱ میلیون توکن جهت ایجاد فهم عمیق از ساختارهای چندفایلی، وابستگی‌های متقابل و مهندسی نرم‌افزار.
- **پیکره‌های طولانی گفت‌وگو و بازیابی (RAG & Dialogue):** آماده‌سازی و چینش اسناد تخصصی چندگانه و تاریخچه‌های طولانی تعامل کارگزاران.
- **تزریق داده‌های مصنوعی هدفمند (Targeted Synthetic Data):** برای فاز پیش‌آموزش مداوم (CPT)، داده‌های مصنوعی سنتز شده با تمرکز بر چهار محور کلیدی طراحی شدند:
 ۱. بازیابی اطلاعات در فواصل دوربرد (Long-Range Retrieval)
 ۲. استنتاج و استدلال چندمرحله‌ای (Multi-Hop Reasoning)
 ۳. تجمیع و خلاصه‌سازی داده‌ها از چندین سند مستقل (Multi-Document Aggregation)
 ۴. تفکر ترکیبی پیوسته در بافت‌های گسترده

راهبرد پیش‌آموزش مداوم و مهندسی طول بافت (Continued Pre-training - CPT) برای گسترش پنجره بافت به ۱ میلیون توکن در مدل Nemotron 3 Nano، پروتکل داده‌ای ویژه‌ای به کار گرفته شد:

- **طول توالی در پیش‌آموزش مداوم:** فاز CPT مستقیماً روی توالی‌هایی به طول 512K توکن پیاده‌سازی شده است.
- **حذف برنامه‌ریزی مرحله‌ای طول توالی (No Staged Schedule):** برخلاف روال‌های مرسوم که طول توالی به تدریج از 8K به مقادیر بالاتر ارتقا می‌یابد، در معماری پیوندی این مدل داده‌های بافت 512K بدون نیاز به افزایش گام‌به‌گام به شبکه تزریق شدند.
- **حذف نشانه‌گذاری موقعیتی دوار (RoPE Elimination):** با توجه به اینکه لایه‌های Mamba-2 به صورت ذاتی و ساختاری اطلاعات موقعیت نسبی توکن‌ها را درون متغیرهای حالت پنهان کدگذاری می‌کنند [50]، نیازی به تعبیه RoPE در لایه‌های توجه وجود نداشته و در نتیجه پدیده واگرایی ناشی از خروج از توزیع طول توالی (OOD RoPE issues) به کلی حذف شده است [51].

تحلیل آماری و مدل‌سازی رفتار ریاضی دادگان طولانی (Statistical Modeling & Power Law) کارایی دادگان طولانی از طریق اندازه‌گیری میانگین تجمعی لگاریتم منفی درست‌نمایی (Cumulative Average NLL) به عنوان تابعی از موقعیت توکن (t) روی کدهای بزرگ‌تر از ۱ میلیون توکن ارزیابی شده است:

$$\overline{\text{NLL}}(t) = -\frac{1}{t} \sum_{i=1}^t \log P(x_i | x_1, x_2, \dots, x_{i-1}) \quad (21)$$

توزیع داده‌ها و برازش ریاضی نشان می‌دهد که رابطه میان طول دنباله ورودی و افت خطای پیش‌بینی، به دقت از یک رابطه قانون توان (Power Law) تبعیت می‌کند:

$$\overline{\text{NLL}}(t) \approx \alpha \cdot t^{-\beta} + \gamma \quad (22)$$

برازش رگرسیونی این رابطه روی داده‌های کد به ضریب تبیین فوق‌العاده $R^2 = 0.883$ دست یافته است. مقدار NLL از تراز اولیه ≈ 1.2 در فواصل ابتدایی ($t \approx 128$) با روندی پیوسته به مجاورت ≈ 0.4 در فواصل انتهایی ($t \approx 1\text{M}$) تقلیل می‌یابد که دال بر توانایی مدل در بهره‌برداری مؤثر از داده‌های پس‌زمینه در سراسر پنجره ۱ میلیون توکنی است.

قالب‌بندی عددی دادگان و پایداری در کوانتایزیشن NVFP4 آموزش تانسورهای داده‌ای بر روی فرمت NVFP4 با بهره‌گیری از میکروبلوک‌های ۱۶ عنصری، فاکتور مقیاس‌بندی E4M3 و مقیاس سراسری FP32 انجام شد [۵۲].

– در مدل Nano با ۳ میلیارد پارامتر فعال (A3B)، شکاف اتلاف داده‌ها بین آموزش NVFP4 و فرمت BF16 به کمتر از ۱٪ تقلیل یافت.

– در مدل‌های بزرگ‌تر با ۸ میلیارد پارامتر فعال (A8B)، شکاف اتلاف به کمتر از ۶٪ محدود گردید که نشان‌دهنده کاهش خطای داده‌ها با افزایش اندازه مدل مطابق با قوانین مقیاس‌پذیری کوانتایزیشن است [۵۳].

ارزیابی‌های آماری مدل‌های پایه بر روی دادگان پیش‌آموزش (Base Model Evaluations) کیفیت پیکره و معماری داده‌های پیش‌آموزش در قالب جداول زیر بررسی شده است. جدول ۱۲ عملکرد داده‌ای معماری LatentMoE را در مقایسه با ساختار استاندارد روی ۱ تریلیون توکن نشان می‌دهد. همچنین جدول ۱۳ نشان‌دهنده ارتقای ۴.۲ درصدی بهره‌وری از دادگان در صورت بهره‌گیری از ماژول پیش‌بینی چندتوکنی (MTP) [۲۷] است. در نهایت، جدول ۱۴ تاب‌آوری استخراج داده در بافت‌های فوق‌طولانی بنچمارک RULER [۳۸] را پس از فاز CPT گزارش می‌کند.

جدول ۱۲: مقایسه دقت بر روی داده‌های ارزیابی پس از آموزش روی ۱ تریلیون توکن بین Standard MoE و LatentMoE

معماری مدل	MMLU-Pro (%)	MMLU (%)	کد (Code) (%)	ریاضی (Math) (%)	درک شهودی (Commonsense) (%)
Standard MoE (8.09B active / 72.6B total)	۳۰.۴۸	۱۰.۷۰	۹۵.۵۱	۳۲.۷۸	۷۳.۸۱
LatentMoE (8.02B active / 72.8B total)	۸۷.۵۲	۱۱.۷۲	۱۴.۵۵	۱۹.۸۰	۱۰.۸۲

جدول ۱۳: ارزیابی تأثیر نظارت متراکم دادگان با پیش‌بینی چندتوکنی (MTP) بر مدل پایه 8B MoE (آموزش روی ۱ تریلیون توکن)

دسته و بنچمارک ارزیابی	مدل پایه (8B MoE Base)	پایه به همراه MTP (Base + MTP)
دانش عمومی (General Knowledge) MMLU (5-shot, acc) MMLU-Pro (5-shot, CoT EM)	۰۶.۷۰ ۰۵.۴۵	۲۶.۷۱ ۸۴.۴۷
کدنویسی (Code) MBPP-Sanitized (3-shot)	۵۸.۶۵	۸۹.۶۶
درک عمومی (Commonsense Understanding) ARC-Challenge (25-shot, acc_norm) WinoGrande (0-shot, acc)	۴۳.۸۶ ۵۹.۷۴	۰۵.۸۸ ۴۵.۷۵
درک مطلب (Reading Comprehension) RACE (0-shot, acc)	۰۲.۸۴	۳۶.۸۵
ریاضیات (Math) GSM8K (8-shot, acc)	۴۹.۸۲	۴۶.۸۴

جدول ۱۴: نتایج محک RULER جهت سنجش اکستراپولاسیون بافت پس از فاز CPT در طول توالی 512K

مدل	۱۲۸k	۲۵۶k	۵۱۲k	۱M
(Dense Hybrid) Nemotron-Nano-12B-v2-Base	۱۳.۸۵	۸۵.۷۹	۱۲.۷۵	۴۳.۲۳
(MoE Hybrid) Nemotron-3-Nano-30B-A3B-Base	۴۸.۷۴	۶۷.۷۱	۰۲.۶۶	۱۹.۵۴

حاکمیت داده، شفافیت و عوامل مشارکت‌کننده انویدیا راهبردهای مهندسی داده، پایپ‌لاین‌های آماده‌سازی و بیش از ۱۰ تریلیون توکن از پیکره آموزشی را به شکل عمومی آزاد کرده است. طراحی و فیلترینگ این مجموعه داده عظیم توسط تیم توسعه داده‌های پیش‌آموزش شامل Abhinav Khattar،

پژوهشگر ارشد دیگر هدایت شده است. Mohammad Shoeybi, Eileen Long, Brandon Norick, Alisa Liu, Aleksander Ficek و بیش از ۵۰

• Qwen3

مقدمه و ساختار کلی دادگان پیش‌آموزش فاز پیش‌آموزش (Pre-training) در مدل‌های زبانی خانواده Qwen3 با هدف جهش در کارایی محاسباتی، تعمیق قابلیت‌های استدلال ریاضی و برنامه‌نویسی و ارتقای شگرف پوشش چندزبانه طراحی شده است. در این نسخه، مدل‌ها بر روی مقیاس بی‌سابقه‌ای بالغ بر **۳۶ تریلیون توکن** (36T tokens) آموزش دیده‌اند که نمایانگر رشد دو برابری نسبت به نسل پیشین (Qwen2.5) است:

$$\rho_{\text{tokens}} = \frac{T_{\text{Qwen3}}}{T_{\text{Qwen2.5}}} = \frac{36 \times 10^{12}}{18 \times 10^{12}} = 2.0 \quad (23)$$

همچنین گستره زبانی دادگان از ۲۹ زبان در نسخه پیشین به **۱۱۹ زبان و گویش** بسط یافته است که حاکی از افزایش بیش از چهار برابری در تنوع زبان‌شناختی است:

$$\rho_{\text{lang}} = \frac{N_{\text{lang}}^{\text{Qwen3}}}{N_{\text{lang}}^{\text{Qwen2.5}}} = \frac{119}{29} \approx 4.103 \quad (24)$$

پیکره پیش‌آموزش به‌گونه‌ای توازن یافته است که از ۶ مدل متراکم (Dense) در مقیاس‌های 0.6B، 1.7B، 4B، 8B، 14B و 32B و دو مدل مبتنی بر ترکیب متخصصان (MoE) شامل Qwen3-30B-A3B (با ۳ میلیارد پارامتر فعال) و مدل پرچم‌دار Qwen3-235B-A22B (دارای ۲۳۵ میلیارد پارامتر کل و ۲۲ میلیارد پارامتر فعال به ازای هر توکن) پشتیبانی نماید. هدف بهینه‌سازی در این مرحله، کمینه‌سازی خطای پیش‌بینی خودبازگشتی توکن بعدی بر روی توالی‌های متنی است:

$$\mathcal{L}_{\text{pretrain}}(\theta) = - \sum_{t=1}^T \log P_{\theta}(x_t | x_1, x_2, \dots, x_{t-1}) \quad (25)$$

گردآوری، استخراج چندوجهی و سنتز هدفمند داده‌ها (Data Sourcing & Synthesis) برای تحقق پیکره ۳۶ تریلیون توکنی با چگالی دانشی بالا، از یک خط لوله سه‌گانه و ترکیبی بهره گرفته شده است:

– استخراج متن اسنادی بر پایه مدل‌های چندوجهی (Multimodal Document Extraction):

بخش وسیعی از اسناد علمی، دانشگاهی و کتاب‌ها در قالب پرونده‌های PDF متراکم محبوس مانده‌اند. برای بازیابی دقیق و ساختاریافته متون، ابتدا مدل بینایی-زبانی Qwen2.5-VL [۵۴] بازتنظیم شد تا نویسه‌خوانی و درک چیدمان بصری اسناد را با دقت بالا انجام دهد. سپس خروجی حاصل با استفاده از مدل Qwen2.5 [۵۵] بازبینی و پالایش زبانی شد. این فرایند دومرحله‌ای به آزادسازی تریلیون‌ها توکن متنی باکیفیت و با ساختار صحیح انجامید.

– سنتز داده‌های تخصصی توسط مدل‌های خبره (Domain-Specific Synthetic Data):

تعمیق توانایی‌های استدلالی، تریلیون‌ها توکن سنتزی در قالب کتاب‌های درسی، جفت‌های پرسش‌وپاسخ استدلالی، دستوراتعمل‌ها و قطعه‌کدهای برنامه‌نویسی به مجموعه افزوده شد. در این مسیر، داده‌های ریاضی به طور ویژه توسط مدل تخصصی Qwen2.5-Math [۵۶] و کدهای چندزبانه به همراه تحلیل الگوریتمی توسط مدل Qwen2.5-Coder [۵۷] سنتز گردیدند.

– توسعه چندزبانه متوازن (Multilingual Expansion):

پوشش زبانی از ۲۹ به ۱۱۹ زبان گسترش یافت؛ داده‌های زبان‌های دارای منابع متوسط و کم با راهبردهای ترجمه معکوس و اعتبارسنجی کیفی تقویت شدند تا نمایش چندزبانه در لایه‌های بازنمایی مدل متوازن گردد.

حاشیه‌نویسی چندزبانه و بهینه‌سازی توزیع داده در سطح نمونه (Instance-Level Data Mixture) مدیریت و مهندسی این حجم از داده نیازمند گزینش کیفی فراتر از فیلترینگ‌های سنتی است:

– **سامانه حاشیه‌نویسی چندبعدی:** یک سیستم خودکار برچسب‌گذاری بر روی بیش از ۳۰ تریلیون توکن اعمال شد. این سامانه داده‌ها را بر اساس چهار بعد کلیدی ارزیابی و برچسب‌گذاری می‌کند: ارزش آموزشی (Educational Value)، شاخه علمی (Field)، دامنه تخصصی (Domain) و انطباق با شاخص‌های ایمنی (Safety).

– **بهینه‌سازی توزیع در سطح نمونه (Instance-Level Optimization):** برخلاف رویکردهای پیشین نظیر DoREMI [۵۸]، DoGE [۵۹] و RegMix [۶۰] که وزن‌دهی به داده‌ها را در سطح منبع داده یا حوزه کلی بهینه‌سازی می‌کردند، در Qwen3 ترکیب داده‌ها بر پایه برچسب‌های ریزدانه در سطح تک‌تک نمونه‌ها تنظیم شد. این فرایند با اجرای مطالعات ابلیشن گسترده بر روی مدل‌های پروکسی کوچک (Small Proxy Models) انجام گرفت تا بردار ضرایب ترکیب بهینه w^* حاصل شود:

$$w^* = \arg \min_w \mathbb{E}_{x \sim \mathcal{D}_{\text{eval}}} [\mathcal{L}_{\text{proxy}}(x; \theta^*(w))] \quad (۲۶)$$

برنامه درسی سه‌مرحله‌ای پیش‌آموزش (Three-Stage Pre-training Curriculum) فرآیند پیش‌آموزش در قالب سه فاز زمان‌بندی‌شده و ساختاریافته به اجرا درآمد:

– **فاز ۱: مرحله عمومی (General Stage - S1):** آموزش بر روی بیش از ۳۰ تریلیون توکن با طول زمینه $L = 4,096$ توکن اجرا شد. این مرحله پایه دانش زبانی، استنتاج عمومی جهان و تعمیم‌پذیری متقابل در ۱۱۹ زبان و گویش را شکل داد.

– **فاز ۲: مرحله استدلال (Reasoning Stage - S2):** مدل‌ها با حدود ۵ تریلیون توکن گلچین‌شده و بسیار غنی با محوریت علوم مهندسی، فناوری، ریاضیات (STEM)، مسائل الگوریتمی و داده‌های سنتزی با طول توالی 4,096 آموزش دیدند. در این فاز، نرخ اضمحلال یادگیری (Learning Rate Decay) تسریع گردید تا مدل در فضاهای استدلالی همگرا شود.

– **فاز ۳: مرحله زمینه طولانی (Long Context Stage):** مدل‌ها با صدها میلیارد توکن بلند تا سقف طول توالی $L = 32,768$ توکن پیش‌آموزش دیدند. ساختار طول اسناد در این فاز شامل ۷۵٪ داده‌ها با طول بین ۱۶,۳۸۴ تا ۳۲,۷۶۸ توکن و ۲۵٪ داده‌ها با طول بین ۴,۰۹۶ تا ۱۶,۳۸۴ توکن بوده است. در این فاز بسامد پایه فشرده‌سازی موقعیتی دورانی (RoPE) [۳۶] با تکنیک ABF [۶۱] از ۱۰,۰۰۰ به ۱,۰۰۰,۰۰۰ افزایش یافت و با سازوکارهای YaRN [۱۷] و توجه چندتکه‌ای دوگانه (DCA) [۶۲] ادغام شد تا پنجره بافت حین استنتاج تا سقف ۱۲۸,۰۰۰ توکن (128K) با حفظ پایایی بسط یابد.

توکنایزیشن و بازنمایی زیرکلمات (Tokenization) در مدل‌های Qwen3 از توکنایزر اختصاصی مبتنی بر کدگذاری جفت‌بایت در سطح بایت (BBPE) [۶۳، ۶۴، ۶۵، ۶۶] با اندازه واژگان 151,669 استفاده شده است. این اندازه واژگان، ضریب فشرده‌سازی توکن به کلمه را در متون غیرانگلیسی به خصوص خطوط خاورمیانه و آسیایی بهینه ساخته و سربار محاسباتی طول توالی را تعدیل می‌کند.

ارزیابی‌های آماری و مقایسه‌ای مدل‌های پایه (Base Model Evaluations) اثربخشی داده‌های پیش‌آموزش و راهبردهای پالایش آن، بر روی ۱۵ بنچمارک استاندارد در ۴ حوزه وظایف عمومی (MMLU [۳۰]، MMLU-Redux [۶۷]، MMLU-Pro [۶۸]، BBH [۶۹]، SuperGPQA [۷۰])، ریاضیات و علوم پایه (GPQA [۷۱]، GSM8K [۷۲]، MATH [۲۹])، کدنویسی (EvalPlus [۷۳]، MultiPL-E [۷۴]، MBPP [۷۵])، CRUX-O [۷۶]) و چندزبانه (MGSM [۷۷]، MMMLU [۷۸]، INCLUDE [۷۹]) مورد ارزیابی دقیق قرار گرفت.

جداول ۱۵ تا ۲۰ عملکرد کمی مدل‌های پایه را در برابر رقبای هم‌رده و پرچم‌دار نشان می‌دهند. مهم‌ترین یافته‌های آماری به شرح زیر است:

– **برتری مدل پرچم دار Qwen3-235B-A22B-Base:** این مدل با دارا بودن تنها ۲۲ میلیارد پارامتر فعال در هر توکن (تقریباً 60% پارامترهای فعال و 35% پارامترهای کل DeepSeek-V3 [8])، در ۱۴ آزمون از ۱۵ آزمون ارزیابی شده رتبه اول را کسب کرده است؛ از جمله در آزمون استدلال پیشرفته MATH با ثبت امتیاز 71.84 در مقایسه با مدل DeepSeek-V3، رشد نسبی 14.72% + را محقق ساخته است.

– **انتقال تراز کارایی در مدل‌های متراکم (Dense Models):** مدل Qwen3-32B-Base با کمتر از نیمی از پارامترهای مدل پرچم دار پیشین Qwen2.5-72B-Base، در ۱۰ بنچمارک از ۱۵ بنچمارک بر آن غلبه کرده و در کدنویسی (EvalPlus با امتیاز 72.05 در برابر 65.93) و آزمون MMLU-Pro (امتیاز 65.54 در برابر 58.07) برتری قاطعی به ثبت رسانده است. همچنین مدل‌های سبک‌تر Qwen3-8B، 4B و 1.7B توانسته‌اند مدل‌های مقیاس‌های ۲ تا ۳ برابری نسل قبل خود (Qwen2.5-14B، 7B و 3B) را در اکثر حوزه‌ها پشت سر بگذارند.

– **بهره‌وری فوق‌العاده مدل‌های MoE کوچک:** مدل Qwen3-30B-A3B-Base با تنها ۳ میلیارد پارامتر فعال، در تمامی شاخص‌ها مدل متراکم Qwen2.5-14B-Base (با ۱۴ میلیارد پارامتر فعال) را مغلوب کرده و به کارایی نزدیک به مدل متراکم ۳۲ میلیارد پارامتری با بیش از ۱۰ برابر هزینه محاسباتی کمتر دست یافته است.

جدول ۱۵: مقایسه عملکرد مدل پایه پرچم دار Qwen3-235B-A22B-Base با مدل‌های قدرتمند متن‌باز

شاخص / بنچمارک	Qwen2.5-72B-Base	Qwen2.5-Plus-Base	Llama-4-Maverick-Base	DeepSeek-V3-Base	Qwen3-235B-A22B-Base
معماری	Dense	MoE	MoE	MoE	MoE
تعداد کل پارامترها	۷۲B	۲۷۱B	۴۰۲B	۶۷۱B	۲۳۵B
پارامترهای فعال	۷۲B	۳۷B	۱۷B	۳۷B	۲۲B
وظایف عمومی (General Tasks)					
MMLU	۵۶.۸۶	۵۲.۸۵	۱۶.۸۵	۱۹.۸۷	۸۱.۸۷
MMLU-Redux	۹۱.۸۳	۶۹.۸۲	۵۵.۸۴	۱۴.۸۶	۴۰.۸۷
MMLU-Pro	۵۷.۵۸	۵۲.۶۳	۹۱.۶۳	۸۴.۵۹	۱۸.۶۸
SuperGPQA	۲۰.۳۶	۱۸.۳۷	۸۵.۴۰	۵۳.۴۱	۵۶.۴۴
BBH	۳۰.۸۶	۶۰.۸۵	۶۲.۸۳	۲۲.۸۶	۸۷.۸۸
ریاضیات و علوم مهندسی (Math & STEM)					
GPQA	۸۸.۴۵	۹۲.۴۱	۹۴.۴۳	۹۲.۴۱	۴۷.۴۷
GSM8K	۵۰.۹۱	۸۹.۹۱	۷۲.۸۷	۵۷.۸۷	۳۹.۹۴
MATH	۱۲.۶۲	۷۸.۶۲	۳۲.۶۳	۶۲.۶۲	۸۴.۷۱
کدنویسی (Coding)					
EvalPlus	۹۳.۶۵	۴۳.۶۱	۳۸.۶۸	۷۵.۶۳	۶۰.۷۷
MultiPL-E	۷۰.۵۸	۱۶.۶۲	۲۸.۵۷	۲۶.۶۲	۹۴.۶۵
MBPP	۵۵.۷۶	۶۰.۷۴	۴۰.۷۵	۲۰.۷۴	۴۰.۸۱
CRUX-O	۲۰.۶۶	۵۰.۶۸	۵۰.۷۷	۶۰.۷۶	۵۰.۷۹
چندزبانه (Multilingual)					
MGSM	۴۰.۸۲	۲۱.۸۲	۶۹.۷۹	۶۸.۸۲	۵۳.۸۳
MMMLU	۴۰.۸۴	۴۹.۸۳	۵۹.۸۳	۸۸.۸۵	۷۰.۸۶
INCLUDE	۵۵.۶۹	۹۷.۶۶	۴۷.۷۳	۱۷.۷۵	۴۶.۷۳

• OLMo 3

مقدمه و فلسفه بنیادین دادگان پیش‌آموزش (Pre-Training Data Philosophy) در چارچوب چرخه کامل و شفاف مدل‌های زبانی سری OLMo 3 (Model Flow)، فاز پیش‌آموزش با هدف برپایی زیربنایی مستحکم جهت شکوفایی قابلیت‌های استدلال عمیق گام‌به‌گام (Thinking) و تعامل با ابزارها (Tool Use) در مراحل پس‌آموزش طراحی شده است [9]. به این منظور، پیکره عظیم Dolma 3 در قالب یک استخر داده جامع به وسعت ۳۱.۹ تریلیون توکن (شامل ۹۷.۹ میلیارد سند) گردآوری شده و ترکیب بهینه‌سازی شده نهایی آن موسوم به Dolma 3 Mix با حجم ۹۳.۵ تریلیون توکن (شامل ۸۷.۳ میلیارد سند) مبنای پیش‌آموزش مدل‌های پایه در دو مقیاس ۷ و ۳۲ میلیارد پارامتر قرار گرفته است.

با توجه به این‌که بیش از ۹۰ درصد کل توان محاسباتی چرخه حیات مدل در فاز پیش‌آموزش مصرف می‌شود، استراتژی تدوین این پیکره بر دو اصل راهبردی استوار است:

جدول ۱۶: مقایسه عملکرد مدل پایه متراکم Qwen3-32B-Base با مدل‌های هم‌رده

شاخص / بنچمارک	Qwen2.5-32B-Base	Qwen2.5-72B-Base	Gemma-3-27B-Base	Llama-4-Scout-Base	Qwen3-32B-Base
معماری	Dense	Dense	Dense	MoE	Dense
تعداد کل پارامترها	۳۲B	۷۲B	۲۷B	۱۰۹B	۳۲B
پارامترهای فعال	۳۲B	۷۲B	۲۷B	۱۷B	۳۲B
وظایف عمومی (General Tasks)					
MMLU	۳۲.۸۳	۵۶.۸۶	۶۹.۷۸	۲۷.۷۸	۶۱.۸۳
MMLU-Redux	۹۷.۸۱	۹۱.۸۳	۵۳.۷۶	۵۹.۷۱	۴۱.۸۳
MMLU-Pro	۱۰.۵۵	۵۷.۵۸	۸۸.۵۲	۱۳.۵۶	۵۴.۶۵
SuperGPQA	۵۵.۳۳	۲۰.۳۶	۸۷.۲۹	۵۱.۲۶	۷۸.۳۹
BBH	۴۸.۸۴	۳۰.۸۶	۹۵.۷۹	۴۰.۸۲	۳۸.۸۷
ریاضیات و علوم مهندسی (Math & STEM)					
GPQA	۹۷.۴۷	۸۸.۴۵	۲۶.۲۶	۴۰.۴۰	۴۹.۴۹
GSM8K	۸۷.۹۲	۵۰.۹۱	۲۰.۸۱	۳۷.۸۵	۴۰.۹۳
MATH	۷۰.۵۷	۱۲.۶۲	۷۸.۵۱	۶۶.۵۱	۶۲.۶۱
کدنویسی (Coding)					
EvalPlus	۲۵.۶۶	۹۳.۶۵	۷۸.۵۵	۹۰.۵۹	۵۵.۷۲
MultiPL-E	۳۰.۵۸	۷۰.۵۸	۵۳.۴۵	۳۸.۴۷	۵۶.۶۷
MBPP	۶۰.۷۳	۵۰.۷۶	۴۰.۶۸	۶۰.۶۸	۲۰.۷۸
CRUX-O	۸۰.۶۷	۲۰.۶۶	۵۰.۶۰	۹۰.۶۱	۵۰.۷۲
چندزبانه (Multilingual)					
MGSM	۱۲.۷۸	۴۰.۸۲	۷۴.۷۳	۹۳.۷۹	۵۶.۸۳
MMMLU	۴۰.۸۲	۴۰.۸۴	۶۲.۷۷	۸۳.۷۴	۸۳.۸۳
INCLUDE	۳۵.۶۴	۵۵.۶۹	۹۴.۶۸	۵۹.۶۸	۸۷.۶۷

جدول ۱۷: مقایسه عملکرد مدل‌های Qwen3-14B-Base و Qwen3-30B-A3B-Base با مدل‌های هم‌رده

شاخص / بنچمارک	Gemma-3-12B	Qwen2.5-14B	Qwen2.5-32B	Qwen2.5-Turbo	Qwen3-14B	Qwen3-30B-A3B
معماری	Dense	Dense	Dense	MoE	Dense	MoE
تعداد کل پارامترها	۱۲B	۱۴B	۳۲B	۴۲B	۱۴B	۳۰B
پارامترهای فعال	۱۲B	۱۴B	۳۲B	۶B	۱۴B	۳B
وظایف عمومی (General Tasks)						
MMLU	۸۷.۷۳	۶۶.۷۹	۳۲.۸۳	۵۰.۷۹	۵۵.۸۱	۳۸.۸۱
MMLU-Redux	۷۰.۷۰	۶۴.۷۶	۹۷.۸۱	۱۱.۷۷	۸۸.۷۹	۱۷.۸۱
MMLU-Pro	۹۱.۴۴	۱۶.۵۱	۱۰.۵۵	۶۰.۵۵	۵۳.۶۱	۴۹.۶۱
SuperGPQA	۶۱.۲۴	۶۸.۳۰	۵۵.۳۳	۱۹.۳۱	۲۷.۳۴	۷۲.۳۵
BBH	۲۸.۷۴	۱۸.۷۸	۴۸.۸۴	۱۰.۷۶	۵۷.۸۱	۵۴.۸۱
ریاضیات و علوم مهندسی (Math & STEM)						
GPQA	۳۱.۳۱	۸۳.۳۲	۹۷.۴۷	۴۱.۴۱	۹۰.۳۹	۹۴.۴۳
GSM8K	۵۱.۷۸	۲۲.۹۰	۸۷.۹۲	۳۲.۸۸	۴۹.۹۲	۸۱.۹۱
MATH	۴۳.۴۴	۶۴.۵۵	۷۰.۵۷	۶۰.۵۵	۵۲.۶۲	۵۴.۵۹
کدنویسی (Coding)						
EvalPlus	۶۵.۵۲	۷۰.۶۰	۲۵.۶۶	۲۳.۶۱	۲۳.۷۲	۴۵.۷۱
MultiPL-E	۵۳.۴۳	۷۹.۵۴	۳۰.۵۸	۲۴.۵۳	۶۹.۶۱	۵۳.۶۶
MBPP	۶۰.۶۰	۵۰.۶۹	۶۰.۷۳	۶۰.۶۷	۴۰.۷۳	۴۰.۷۴
CRUX-O	۵۵.۵۲	۱۰.۶۱	۸۰.۶۷	۲۰.۶۰	۶۰.۶۸	۲۰.۶۷
چندزبانه (Multilingual)						
MGSM	۳۵.۶۴	۶۸.۷۴	۱۲.۷۸	۴۵.۷۰	۲۰.۷۹	۱۱.۷۹
MMMLU	۵۰.۷۲	۳۴.۷۸	۴۰.۸۲	۷۶.۷۹	۶۹.۷۹	۴۶.۸۱
INCLUDE	۳۴.۶۳	۲۶.۶۰	۳۵.۶۴	۲۵.۵۹	۵۵.۶۴	۵۰.۶۷

جدول ۱۸: مقایسه عملکرد مدل پایه Qwen3-8B-Base با مدل‌های هم‌رده

شاخص / بنچمارک	Llama-3-8B-Base	Qwen2.5-7B-Base	Qwen2.5-14B-Base	Qwen3-8B-Base
معماری	Dense	Dense	Dense	Dense
تعداد کل پارامترها	۸B	۷B	۱۴B	۸B
پارامترهای فعال	۸B	۷B	۱۴B	۸B
وظایف عمومی (General Tasks)				
MMLU	۶۰.۶۶	۱۶.۷۴	۶۶.۷۹	۸۹.۷۶
MMLU-Redux	۵۹.۶۱	۰۶.۷۱	۶۴.۷۶	۱۷.۷۶
MMLU-Pro	۳۶.۳۵	۰۰.۴۵	۱۶.۵۱	۷۳.۵۶
SuperGPQA	۵۴.۲۰	۳۴.۲۶	۶۸.۳۰	۶۴.۳۱
BBH	۷۰.۵۷	۴۰.۷۰	۱۸.۷۸	۴۰.۷۸
ریاضیات و علوم مهندسی (Math & STEM)				
GPQA	۸۰.۲۵	۳۶.۳۶	۸۳.۳۲	۴۴.۴۴
GSM8K	۳۰.۵۵	۳۶.۸۵	۲۲.۹۰	۸۴.۸۹
MATH	۵۰.۲۰	۸۰.۴۹	۶۴.۵۵	۸۰.۶۰
کدنویسی (Coding)				
EvalPlus	۱۳.۴۴	۱۸.۶۲	۷۰.۶۰	۶۵.۶۷
MultiPL-E	۴۵.۳۱	۷۳.۵۰	۷۹.۵۴	۷۵.۵۸
MBPP	۴۰.۴۸	۴۰.۶۳	۰۰.۶۹	۸۰.۶۹
CRUX-O	۸۰.۳۶	۵۰.۴۸	۱۰.۶۱	۰۰.۶۲
چندزبانه (Multilingual)				
MGSM	۹۲.۳۸	۶۰.۶۳	۶۸.۷۴	۰۲.۷۶
MMMLU	۶۵.۵۹	۳۴.۷۱	۳۴.۷۸	۷۲.۷۵
INCLUDE	۹۴.۴۴	۹۸.۵۳	۲۶.۶۰	۴۰.۵۹

جدول ۱۹: مقایسه عملکرد مدل پایه Qwen3-4B-Base سبک با مدل‌های هم‌رده

شاخص / بنچمارک	Gemma-3-4B-Base	Qwen2.5-3B-Base	Qwen2.5-7B-Base	Qwen3-4B-Base
معماری	Dense	Dense	Dense	Dense
تعداد کل پارامترها	۴B	۳B	۷B	۴B
پارامترهای فعال	۴B	۳B	۷B	۴B
وظایف عمومی (General Tasks)				
MMLU	۵۱.۵۹	۶۲.۶۵	۱۶.۷۴	۹۹.۷۲
MMLU-Redux	۹۱.۵۶	۶۸.۶۳	۰۶.۷۱	۷۹.۷۲
MMLU-Pro	۲۳.۲۹	۶۱.۳۴	۰۰.۴۵	۵۸.۵۰
SuperGPQA	۶۸.۱۷	۳۱.۲۰	۳۴.۲۶	۴۳.۲۸
BBH	۷۰.۵۱	۳۰.۵۶	۴۰.۷۰	۵۹.۷۲
ریاضیات و علوم مهندسی (Math & STEM)				
GPQA	۲۴.۲۴	۲۶.۲۶	۳۶.۳۶	۸۷.۳۶
GSM8K	۹۷.۴۳	۰۸.۷۹	۳۶.۸۵	۷۹.۸۷
MATH	۱۰.۲۶	۶۴.۴۲	۸۰.۴۹	۱۰.۵۴
کدنویسی (Coding)				
EvalPlus	۲۳.۴۳	۲۸.۴۶	۱۸.۶۲	۵۳.۶۳
MultiPL-E	۰۶.۲۸	۶۵.۳۹	۷۳.۵۰	۱۳.۵۳
MBPP	۴۰.۴۶	۶۰.۵۴	۴۰.۶۳	۰۰.۶۷
CRUX-O	۰۰.۳۴	۵۰.۳۶	۵۰.۴۸	۰۰.۵۵
چندزبانه (Multilingual)				
MGSM	۱۱.۳۳	۵۳.۴۷	۶۰.۶۳	۷۴.۶۷
MMMLU	۶۲.۵۹	۵۵.۶۵	۳۴.۷۱	۴۲.۷۱
INCLUDE	۰۶.۴۹	۹۰.۴۵	۹۸.۵۳	۲۹.۵۶

جدول ۲۰: مقایسه عملکرد مدل‌های لبه‌ای Qwen3-0.6B-Base و Qwen3-1.7B-Base با مدل‌های هم‌رده

شاخص / بنچمارک	Qwen2.5-0.5B	Qwen3-0.6B	Gemma-3-1B	Qwen2.5-1.5B	Qwen3-1.7B
معماری	Dense	Dense	Dense	Dense	Dense
تعداد کل پارامترها	۵B.۰	۶B.۰	۱B	۵B.۱	۷B.۱
پارامترهای فعال	۵B.۰	۶B.۰	۱B	۵B.۱	۷B.۱
وظایف عمومی (General Tasks)					
MMLU	۵۰.۴۷	۸۱.۵۲	۲۶.۲۶	۹۰.۶۰	۶۳.۶۲
MMLU-Redux	۱۰.۴۵	۲۶.۵۱	۹۹.۲۵	۴۶.۵۸	۶۶.۶۱
MMLU-Pro	۶۹.۱۵	۷۴.۲۴	۷۲.۹	۵۳.۲۸	۷۶.۳۶
SuperGPQA	۳۰.۱۱	۰۳.۱۵	۱۹.۷	۶۴.۱۷	۹۲.۲۰
BBH	۳۰.۲۰	۴۷.۴۱	۱۳.۲۸	۱۰.۴۵	۴۷.۵۴
ریاضیات و علوم مهندسی (Math & STEM)					
GPQA	۷۵.۲۴	۷۷.۲۶	۷۵.۲۴	۲۴.۲۴	۲۸.۲۸
GSM8K	۶۲.۴۱	۵۹.۵۹	۲۰.۲	۵۴.۶۸	۴۴.۷۵
MATH	۴۸.۱۹	۴۴.۳۲	۶۶.۳	۰۰.۳۵	۵۰.۴۳
کدنویسی (Coding)					
EvalPlus	۸۵.۳۱	۲۳.۳۶	۹۸.۸	۸۰.۴۴	۷۰.۵۲
MultiPL-E	۷۰.۱۸	۵۸.۲۴	۱۵.۵	۱۰.۳۳	۷۱.۴۲
MBPP	۸۰.۲۹	۶۰.۳۶	۲۰.۹	۶۰.۴۳	۴۰.۵۵
CRUX-O	۱۰.۱۲	۰۰.۲۷	۸۰.۳	۶۰.۲۹	۴۰.۳۶
چندزبانه (Multilingual)					
MGSM	۰۷.۱۲	۹۹.۳۰	۷۴.۱	۸۲.۳۲	۷۱.۵۰
MMMLU	۵۳.۳۱	۱۶.۵۰	۵۷.۲۶	۲۷.۶۰	۲۷.۶۳
INCLUDE	۷۴.۲۴	۲۶.۳۴	۶۲.۲۵	۵۵.۳۹	۵۷.۴۵

– **کفایت مقیاس داده‌ها (Scale Sufficiency):** یک منبع داده تنها در صورتی شایسته ورود به فاز پیش‌آموزش تلقی می‌شود که پتانسیل تولید حجم کافی از توکن‌ها را برای اثرگذاری در مقیاس تریلیونی دارا باشد؛ داده‌های کیفی ولی کم‌حجم به‌طور کامل برای مرحله میان‌آموزش (Mid-training) ذخیره می‌شوند.

– **پرهیز از داده‌های تکلیفی ساختاریافته (Exclusion of Task-Structured Data):** برای جلوگیری از مخدوش شدن نتایج ابلیشن و سوگیری‌های زودرس ارزیابی، داده‌های جفت پرسش‌وپاسخ (QA) و مکالمات دستوری از مرحله پیش‌آموزش حذف و به مراحل بعدی موکول شده‌اند.

ترکیب‌بندی و مشخصات آماری پیکره پیش‌آموزش (Dolma 3 Mix Composition) پیکره متنی پیش‌آموزش Dolma 3 Mix از شش منبع کلیدی به شرح جدول ۲۱ استخراج، پالایش و متوازن شده است. در این فرآیند، استخر اولیه (9T Pool) با اعمال راهبردهای نمونه‌برداری به ترکیب نهایی (6T Mix) و همچنین یک نسخه سبک جهت پژوهش‌های مقیاس‌کوچک (150B Mix) تبدیل شده است.

جدول ۲۱: ترکیب‌بندی و مشخصات آماری منابع مجموعه‌داده Dolma 3 در استخر داده و ترکیب‌های آموزشی

منبع داده		نوع محتوا		استخر داده (9T Pool)		ترکیب نهایی (6T Mix)		ترکیب آزمایشی (150B Mix)	
				توکن	اسناد	توکن (درصد)	اسناد	توکن (درصد)	اسناد
Common Crawl	صفحات وب باز	۱۴۲.۸	۶۷۵.۹	۵۱۲.۴ (۱٪.۷۶)	۱۵۵.۳	۱۲۱.۵ (۹٪.۷۶)	۵۸۴.۵		
olmOCR Science PDFs	اسناد علمی و مقالات	۹۷۲.۵	۱۰۱.۸	۸۰۵.۵ (۶٪.۱۳)	۸۸.۳	۹۵.۱ (۶٪.۱۳)	۲۵۸.۲		
StackEdu (Rebalanced)	کدهای برنامه‌نویسی گیت‌هاب	۱۳۷.۵	۱۶۷.۸	۴۰۹.۵ (۸۹٪.۶)	۵۲۶.۸	۱۵.۱ (۰۶٪.۷)	۳۸.۱		
arXiv	مقالات علمی ساختاریافته با لاتک	۴۵.۳	۹۵۸.۳	۸۵.۰ (۸۶٪.۰)	۱۰۸.۹	۲۹۵.۱ (۸۲٪.۰)	۲۴۷.۵		
FineMath 3+	متون آموزشی ریاضیات در وب	۱۵.۳	۴۸.۲	۱۵۲.۵ (۵۶٪.۲)	۵۸.۹	۱۰۵.۴ (۶۰٪.۲)	۵۷۸.۲		
Wikipedia & Wikibooks	متون دانشنامه‌ای مرجع	۶۹۵.۳	۶۷۸.۶	۵۱۵.۲ (۰۴٪.۰)	۲۴۸.۴	۶۸.۴ (۰۴٪.۰)	۱۱۹.۵		
مجموع کل (Total)		۳۱۲.۹	۹۷۵.۹	۹۳۲.۵ (۱۰۰٪)	۸۷۵.۳	۱۵۷.۵ (۱۰۰٪)	۱۰۴۸		

خط لوله مهندسی و پالایش دادگان وب (Web Data Pipeline) بخش اصلی استخر وب از ۱۰۴ دامپ (Dump) پایگاه Common Crawl (از سال ۲۰۱۳ تا پایان دسامبر ۲۰۲۴) گردآوری شده است. استخراج ساختار متنی و پیاده‌سازی متون عاری از برچسب‌های HTML با استفاده از کتابخانه Resiliparse [۸۲] بر روی فایل‌های WARC انجام گرفت که به حجم خام اولیه ۶.۲۵۲ میلیارد سند انجامید. فرایند فیلترینگ اکتشافی (Heuristic Filtering) با اقتباس و بهینه‌سازی خط لوله DCLM [۸۳] در چند لایه پیاده‌سازی شد:

– **فیلتر نشانی‌های وب (URL Filtering):** مسدودسازی دامنه‌ها و لینک‌های غیراخلاقی و بدافزار بر مبنای لیست سیاه مجموعه‌های FineWeb [۸۴] و RefinedWeb [۸۵] (حذف حدود ۱٪ اسناد).

– **فیلترهای اکتشافی متن:** حذف اسناد نامتعارف از حیث طول (بسیار کوتاه یا بسیار بلند)، متون با نسبت پایین کاراکترهای الفبایی-عددی و محتوای دچار تکرار مفرط درونی.

– **پالایش خطوط و عبارات کلیشه‌ای (Line Modifiers):** حذف سطرها و بندهای آلوده به هرزنامه‌های پرتکرار نظیر «items in cart» یا «read more...» و حذف اسنادی که بخش عمده ساختار خود را در این اصلاح از دست دادند.

– **جداسازی زبانی (FastText Language Filter):** به‌کارگیری مدل طبقه‌بند زبانی با آستانه اطمینان 0.65 برای گزینش زبان انگلیسی.

– **قواعد کیفی MADLAD-400:** اعمال قواعد گزینش ۲ و ۵ برگرفته از پژوهش کودوگوتا و همکاران [۸۶] جهت پالایش جملاتی با تعداد کلمات تمام‌بزرگ یا الگوهای منظم غیرعادی (Cursed regex).

این مراحل در مجموع با صرف ۱۰۳۰ ساعت محاسباتی روی ماشین‌های i4i.32xlarge ابری (معادل ۱۱،۳۰۰ دلار هزینه) منجر به نرخ حذف کلی ۸۴.۹٪ و بقای ۷.۳۸ میلیارد سند گردید (جدول ۲۲).

جدول ۲۲: ریز تفکیک مراحل پالایش اکتشافی پیکره وب Common Crawl

مرحله پالایش (Pipeline Step)	اسناد حذف شده (میلیارد)	درصد حذف از کل استخر	درصد زمان پردازش
فیلترهای URL	۳.۲	۹۰٪.۰	۶۸٪.۱
فیلترهای طول سند	۴.۱۰۳	۴۲٪.۴۰	۰۳٪.۸
فیلترهای نماد و تراکم کاراکتر	۵.۵۶	۱۰٪.۲۲	۱۳٪.۴
تکرار درونی (Internal Repetition)	۱.۳۲	۵۳٪.۱۲	۴۱٪.۳۱
نمادهای خطوط (Line Modifiers)	۱.۷	۷۹٪.۲	۰۰٪.۱۰
فیلتر زبان انگلیسی (FastText)	۲.۶	۴۴٪.۲	۳۰٪.۱۴
فیلترهای MADLAD-400	۳.۹	۶۵٪.۳	۸۷٪.۵
طبقه‌بندهای کیفیت	۰.۰	۰۰٪.۰	۵۸٪.۲۴
مجموع کل (Total)	۹.۲۱۳	۹۰.۸۴٪ حذف (باقی ۱۵٪)	۱۰۰٪ (۱۰۳۰ ساعت)

معماری سه‌سطحی حذف تکرار مقیاس‌بالا (Three-Stage Deduplication) به منظور افزایش بهره‌وری مصرف توکن [۸۷]، حذف هم‌پوشانی‌های ضعیف به عنوان شاخص کیفیت نادقیق [۸۸]، و پیشگیری از افت کارایی ناشی از تکرار بیش از حد متون [۸۹]، یک راهبرد سه‌سطحی با ابزار اختصاصی Duplodocus (توسعه‌یافته به زبان Rust) و bsade به کار رفت:

– **حذف تکرار دقیق سراسری (Exact Deduplication):** در دو گام پی‌درپی با بهره‌گیری از هش متنی ۱۲۸ بیتی؛ ابتدا درون هر یک از ۱۰۴ دامپ (حذف ۲۴٪ اسناد) و سپس به‌طور سراسری در میان کل دامپ‌ها (حذف ۴۳٪ اسناد باقی‌مانده). در نتیجه، ۶۶٪ از اسناد اولیه حذف و استخر به ۷.۱۲ میلیارد سند کاهش یافت.

– **حذف تکرار فازی در سطح سند (MinHash Fuzzy Deduplication):** افزاز داده‌ها به ۳۲ قطعه (Shard)، توکنایزیشن با مدل p50k و استخراج ۵-گرم‌ها. الگوریتم MinHash LSH با ۲۶ باند به اندازه ۱۱ برای هدف‌گذاری تشابه جاکارد $J \geq 0.80$ پیاده شد. در مرحله بعد، اعتبارسنجی دوبه‌دو برای کنترل مثبت کاذب بر پایه ۳-گرم‌ها صورت پذیرفت؛ برای خوشه‌های ۵۰۰ سند یا بیشتر، ۲۰۰ باند به اندازه ۳۱ اعمال شد و برای خوشه‌های کوچک‌تر، فاصله جاکارد به صورت دقیق محاسبه گردید. با نگهداشتن جدیدترین نسخه سند بر مبنای تاریخ خزش، ۲۴٪ اسناد حذف و استخر به ۸.۹ میلیارد سند رسید.

– **حذف زیررشته‌های تکراری با آرایه پسوندی (Fuzzy Suffix Array Deduplication):** با استفاده از bsade در ۵۶ بخش، تمام زیررشته‌های دارای طول ۵۰۰ بایت یا بیشتر که حداقل دو بار تکرار شده بودند نشانه‌گذاری شدند. طبق یک قاعده نوآورانه فازی، هرگاه یک بخش متنی از دو سو با توالی‌های تکراری ۵۰۰ بایتی محصور شده بود و بیش از ۸۰٪ آن بخش هم‌پوشانی تکراری داشت، کل توالی حذف شد تا قطعات ریز و ناقص از بین بروند. این گام موجب حذف ۱۴٪ از بایت‌های متنی شده و پیکره نهایی وب را به ۷.۹ میلیارد سند (۵.۳۶ ترابایت متن، معادل ۸ تریلیون توکن) رساند.

دسته‌بندی موضوعی، کیفی و ساختار ۴۸۰گانه سطرها پس از حذف تکرار، استخر داده‌ها در یک ماتریس دوبعدی از موضوع و کیفیت افزاز شد:

– **طبقه‌بندی موضوعی (Topic Classification):** نگاشت متون به ۲۴ رده ساختاریافته برگرفته از WebOrganizer [۹۰]. جهت مقرون‌به‌صرفه بودن پردازش تریلیونی، یک طبقه‌بند FastText بر روی نمونه‌های نشاندار با GPT-4.1 و o4-mini آموزش داده شد که به دقت و فراخوانی متوازن 0.762 در جامعه آماری آزمون دست یافت.

– **ارزیابی کیفی (Quality Tiering):** با استفاده از مدل FastText آموزش‌دیده بر نمونه‌های مثبت شامل OpenHermes-2.5 [۹۱]، ELI5 [۹۲]، UltraChat [۹۳] و WildChat [۹۴]، اسناد به ۲۰ بازه صدکی کیفی ۵ درصدی (Vigintile) تقسیم شدند.

تلاقی ۲۴ رده موضوعی و ۲۰ طبقه کیفی، ۴۸۰ سطل مجزا و متعامد را شکل داد که دستمایه بهینه‌سازی توزیع در مرحله ترکیب گردید.

پیکره مقالات و اسناد آکادمیک (olmOCR Science PDFs) در یک پیشرفت شاخص نسبت به دادگان peS2o [۹۵]، مدل OLMo 3 از اسناد علمی پردازش‌شده توسط خط لوله نوین olmOCR [۹۶] بهره می‌برد:

– **استخراج متن با مدل‌های بینایی-زبانی:** از میان ۲۳۸ میلیون سند PDF آکادمیک اولیه (تا تاریخ دسامبر ۲۰۲۴)، اسناد با ابزار olmOCR (نسخه‌های ۴۹.۱.۰ تا ۵۳.۱.۰) تبدیل به متن خطی و تمیز شدند و کتابخانه Poppler فقط در موارد اضطراری به کار رفت. این گام ۱۶۰ میلیون سند تحویل داد.

– **حذف داده‌های هویتی بافت‌آگاه (Context-Aware PII Removal):** برای جداسازی داده‌های هویتی خصوصی از موارد عمومی، یک خط لوله مدل‌محور دو سطحی طراحی شد: مدل Gemma-3-12B صفحه اول سند را برای یافتن هویت‌های حساس پایش می‌کرد و مدل Gemma-3-4B با تحلیل ۵۰۰۰ کاراکتر ابتدایی، ماهیت سند را بازشناسی می‌نمود. این تفکیک هوشمند منجر به پالایش ۹۰.۴٪ اسناد و صیانت از حریم شخصی شد.

– **پالایش نهایی و پروانه نشر:** حذف اسناد با تراکم بیش از ۳٪ جدول، متون دارای بیش از ۲۰٪ محتوای صرفاً عددی، تبدیل جداول Markdown به کدهای ساختاریافته HTML و فیلترینگ سخت‌گیرانه برای حفظ اسناد دارای پروانه‌های آزاد و تجاری، مجموعه‌ای شامل ۱۰۸ میلیون سند علمی (۹۷۲ میلیارد توکن) به بار آورد.

صورت‌بندی ریاضی ترکیب داده‌ها و نمونه‌برداری آگاه از کیفیت (Olmix & Upsampling) انتخاب داده‌ها از میان ۴۸۰ سطل استخر وب و سایر منابع، از طریق حل یک مسئله بهینه‌سازی مقید ریاضی دو بخشی انجام پذیرفت:

۱. **چارچوب ترکیب داده‌های مقید (Olmix Framework):** با الهام از روش‌های ازدحامی [۶۰، ۹۷]، ۹۸٪ یک کلونی از مدل‌های پروکسی ۳۰ میلیون پارامتری با بودجه محاسباتی بهینه چینجیلا ($5 \times$ معادل ۳ میلیارد توکن) روی توزیع‌های دیریکله نمونه‌برداری‌شده از حوزه‌ها آموزش دیده و عملکرد آن‌ها بر حسب معیار بیت بر بایت (Bits-per-Byte - BPB) در آزمون Base Easy Suite اندازه‌گیری شد. سپس یک مدل خطی تعمیم‌یافته (GLM) برای هر تسک برازش گردید:

$$\min_{\mathbf{w}} \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} g_t(\mathbf{w}) \quad \text{to subject} \quad \sum_i w_i = 1, \quad w_i \leq \frac{M \cdot X_i}{Z_{\text{total}}} \quad (27)$$

که در آن $\mathbf{w}$ بردار وزن دامنه‌ها، $g_t(\cdot)$ مدل برآورد BPB تسک t ، X_i تعداد کل توکن‌های در دسترس در دامنه i ، $Z_{\text{total}} = 5.93T$ کل بودجه توکن و $M \in [4, 7]$ سقف مجاز فاکتور تکرار هر حوزه است. فرآیند در سه راند ترکیب شرطی (Conditional Mixing) تثبیت شد تا سهم وب به ۷۵٪ مقید شده و زبان‌های کدهای StackEdu [۹۹، ۱۰۰] و موضوعات مقالات علمی بهینه‌سازی شوند.

۲. **نمونه‌برداری افزایشی بر مبنای توابع توانی-نمایی بریده‌شده (Quality-Aware Upsampling):** به جای فیلترینگ ایستا (Flat Filtering) که اسناد را تنها به صورت دودویی حذف یا تک‌نسخه‌ای حفظ می‌کند، از خانواده توابع تحلیلی پیوسته و محدب زیر برای وزن‌دهی صدک‌های کیفی داده‌های وب استفاده شد:

$$f_{p,\lambda}(x) = \begin{cases} 0, & x < a \\ C(x-a)^p \cdot e^{\lambda(x-a)}, & x \geq a \end{cases} \quad (28)$$

به طوری که پارامترهای $p \geq 0$ ، $\lambda \geq 0$ و ضریب مقیاس C از طریق حل عددی دستگاه معادلات مقید زیر استخراج می‌شوند:

$$\int_0^1 f_{p,\lambda}(x) dx = \frac{Z}{X}, \quad \frac{1}{b} \int_{1-b}^1 f_{p,\lambda}(x) dx \leq M \quad (29)$$

در این پیکربندی، آستانه $a = 0.40$ تعیین شد (دور ریختن ۴۰٪ داده‌های ضعیف)، Z/X نسبت توکن تخصیص یافته توسط Olmix، و سقف تکرار برای b درصد از مرغوب‌ترین داده‌های انتهایی برابر با $M = 7$ لحاظ گردید. در نهایت، فاکتور بازنمونه‌برداری هر سطل صدکی $[q^-, q^+]$ از رابطه زیر به دست آمد:

$$\text{Factor Upsampling}_q = \frac{1}{q^+ - q^-} \int_{q^-}^{q^+} f_{p,\lambda}(x) dx \quad (30)$$

اعتبارسنجی تجربی و نتایج ابلیشن دادگان پیش‌آموزش صحت کارایی روش‌های فوق با آموزش مدل‌های ۱ میلیارد پارامتری روی ۱۰۰ میلیارد توکن در بنچمارک Base Easy Suite اعتبارسنجی شد (کاهش معیار BPB بیانگر بهبود کیفیت است). نتایج جدول ۲۳ برتری قاطع رویکرد تلفیقی پیشنهادی را به اثبات می‌رساند.

جدول ۲۳: نتایج مطالعات حذف (Ablation) در انتخاب استراتژی ترکیب داده و نمونه‌برداری کیفی

استراتژی پیکربندی داده	(BPB) QA Easy	(BPB) Math Easy	(BPB) Code Easy
توزیع طبیعی داده‌ها (Natural Distribution)	۷۰.۱۰۰	۸۷.۷۱	۲۰.۵۹
ترکیب چندهدفه متوازن Olmix	۵۴.۹۹	۶۹.۶۱	۹۴.۴۸
فیلترینگ ایستا ۵۰٪ برتر (تکرار ۱.۱ برابر)	۱۹.۱۰۴	۲۸.۸۶	۳۴.۹۴
فیلترینگ ایستا ۵٪ برتر (تکرار ۱.۱۱ برابر)	۵۳.۱۰۶	۳۱.۸۴	۵۲.۹۳
نمونه‌برداری کیفی پیوسته OLMo 3	۹۵.۹۹	۵۴.۷۴	۸۸.۷۱
تلفیق با میانگین هندسی (Geometric Mean)	۴۲.۱۰۰	۱۸.۷۸	۳۴.۸۱
تلفیق با تابع نمایی ساده ($Ce^{\lambda(x-a)}$)	۱۷.۱۰۰	۲۴.۷۸	۷۲.۷۸
تلفیق توانی-نمایی بریده‌شده (OLMo 3 Mix)	۳۱.۹۹	۸۱.۷۵	۲۶.۷۸

پیکربندی محاسباتی و هایپرپارامترهای پیش‌آموزش آموزش مدل‌های پایه بر بستر زیرساخت پرسرعت OLMo-core در قالب مخزن توزیع‌پذیر PyTorch FSDP2 اجرا گردید. مشخصات فنی این مرحله در جدول ۲۴ گزارش شده است. جهت ارزیابی پیوسته کیفیت مدل ۳۲ میلیارد پارامتری بدون نیاز به توقف‌های پرهزینه بازپخت، روش میانگین‌گیری دوره‌ای وزن‌ها از ۴ چک‌پوینت متوالی با فاصله ۱۰۰۰ گام [۱۰۱] به کار گرفته شد.

۲.۱.۱ پس‌آموزش (Post-Training)

• DeepSeek-V4

مقدمه و پارادایم نوین دادگان پس‌آموزش فاز پس‌آموزش (Post-Training) در سری مدل‌های DeepSeek-V4 شامل دو نگارش DeepSeek-V4-Flash (با ۲۸۴ میلیارد پارامتر کل و ۱۳ میلیارد پارامتر فعال) و DeepSeek-V4-Pro (با ۶.۱ تریلیون پارامتر کل و ۴۹ میلیارد پارامتر فعال) —شاهد یک دگرگونی بنیادین روش‌شناختی نسبت به نسل‌های پیشین بوده است. در این نسخه، رویکرد متداول یادگیری تقویتی ترکیبی (Mixed Reinforcement Learning) که با چالش رقابت‌گرایان‌ها و تضعیف هم‌زمان مهارت‌های ناهمگن روبرو بود، کاملاً با یک پارادایم دومرحله‌ای جایگزین گردید:

جدول ۲۴: هایپرپارامترهای فاز پیش‌آموزش مدل‌های پایه OLMo 3

OLMo 3 Base-32B	OLMo 3 Base-7B	پارامتر تنظیماتی (Hyperparameter)
۶۴ ۵۱۲۰	۳۲ ۴۰۹۶	تعداد لایه‌ها (Layers)
۴۰ سر ۸ / Q سر ۸ (GQA)	۳۲ سر ۳۲ / Q سر ۳۲	بعد پنهان (d_{model})
۸،۱۹۲ توکن	۸،۱۹۲ توکن	سازوکار توجه (Attention Heads)
پنجره ۴۰۹۶ در ۳/۴ لایه‌ها	پنجره ۴۰۹۶ در ۳/۴ لایه‌ها	طول پنجره زمینه (Sequence Length)
۷۰.۵ تریلیون توکن	۹۳.۵ تریلیون توکن	توجه پنجره لغزان (Sliding Window Attention)
کسینوسی منقطع در ۷T.۵	کسینوسی تعدیل‌شده تا ۹T.۵	کل توکن‌های آموزش فاز اول
6.0×10^{-4}	3.0×10^{-4}	برنامه نرخ یادگیری (LR Schedule)
6.21×10^{-5}	3.0×10^{-5}	اوج نرخ یادگیری (Peak Learning Rate)
۸،۳۸۸،۶۰۸ توکن	۴،۱۹۴،۳۰۴ توکن	حداقل نرخ یادگیری نهایی (Final LR)
4.292×10^{-14}	2.146×10^{-14}	اندازه دسته در سطح توکن (Batch Size)
10^{-5}	10^{-5}	دمای اوج آموزش (LR^2 / bsz)
NVIDIA H100 کارت ۱۰۲۴	NVIDIA H100 کارت ۱۰۲۴	ضریب Z-Loss
۱،۹۰۰ توکن/ثانیه (MFU ۴۱%)	۷،۷۰۰ توکن/ثانیه (MFU ۴۳%)	سخت‌افزار پردازشی
		توان عملیاتی به ازای هر پردازنده

۱. **پرورش مستقل متخصصان حوزه‌ای (Specialist Training):** بهینه‌سازی مدل‌های تخصصی مستقل در حوزه‌های هدف از طریق تلفیق تنظیم دقیق نظارت‌شده (SFT) و یادگیری تقویتی حوزه‌ای (Domain-Specific RL).

۲. **تجمیع یکپارچه از طریق تقطیر برخط خط‌مشی (On-Policy Distillation - OPD):** ادغام دانش و توزیع خروجی بیش از ۱۰ مدل معلم متخصص در یک مدل نهایی دانش‌آموز بر روی خطوط سیر تولیدشده توسط خود دانش‌آموز [۱۰۲].

مرحله اول: آموزش متخصصان حوزه‌ای و مهندسی داده‌های SFT و RL در فاز نخست، مدل پایه با بهره‌گیری از داده‌های حوزه‌ای دست‌چین‌شده با چگالی اطلاعاتی بالا در چهار محور کلیدی آموزش داده می‌شود:

– **داده‌های تنظیم دقیق نظارت‌شده (SFT Data):** شامل نمونه‌های غنی و گام‌به‌گام استدلال زنجیره تفکر (CoT) در ریاضیات، داده‌های تعاملی حل مسائل چندمرحله‌ای نرم‌افزاری و متون دقیق نگارشی.

– **یادگیری تقویتی با الگوریتم GRPO:** بهینه‌سازی خط‌مشی با الگوریتم بهینه‌سازی نسبی خط‌مشی گروهی (GRPO) [۱۰۳] صورت می‌پذیرد که بدون نیاز به مدل نقاد مستقل، مزیت نسبی خروجی‌ها را از میان یک گروه G تایی از پاسخ‌های هم‌پرومپت محاسبه می‌کند:

$$A_i = \frac{R_i - \text{mean}(\{R_1, \dots, R_G\})}{\text{std}(\{R_1, \dots, R_G\})} \quad (۳۱)$$

شرط‌گذاری داده‌ها بر پایه تلاش استنتاجی (Reasoning Effort) توزیع خروجی و طول استدلال مدل از طریق تعیین جریمه‌های متغیر طول (Length Penalties) و پنجره‌های بافت در فاز RL به سه حالت رفتاری متمایز کالبره شده است (جدول ۲۵).

جدول ۲۵: مقایسه حالات سه‌گانه تلاش استنتاجی و الزامات ساختاری داده‌ها در DeepSeek-V4

حالت استدلال (Mode)	ویژگی‌های رفتاری داده	سناریوی کاربردی	قالب پاسخ (Response Format)
غیرتفکری (Non-think)	پاسخ‌های شهودی و سریع بر پایه عادات آماری	وظایف روزمره و تصمیم‌گیری کم‌ریسک	</think> summary
تفکر عمیق (Think High)	تحلیل منطقی و کندتر با تمرکز بر دقت بالا	حل مسئله پیچیده و برنامه‌ریزی	<think> thinking tokens </think> summary
حداکثر تفکر (Think Max)	کشن استدلال تا نهایت مرزهای تحلیلی مدل	کاوش در دشوارترین مسائل منطقی	<think> ... </think> summary + ویژه پرامپت سیستمی ویژه

در حالت Think Max، پرامپت با تزریق یک دستورالعمل الزام‌آور سیستمی هدایت می‌شود:

Injected Instruction: Reasoning Effort: Absolute maximum with no shortcuts permitted. You MUST be very thorough in your thinking and comprehensively decompose the problem to resolve the root cause, rigorously stress-testing your logic against all potential paths, edge cases, and adversarial scenarios. Explicitly write out your entire deliberation process, documenting every intermediate step, considered alternative, and rejected hypothesis to ensure absolutely no assumption is left unchecked.

مدل پاداش زایشی (GRM) بر پایه داده‌های هدایت‌شده با شیوه‌نامه در تکالیف فاقد آزمون‌گر عینی، مدل‌های سنتی پاداش اسکالر که مبتنی بر ترجیحات انسانی (RLHF) آموزش می‌دیدند کنار گذاشته شده‌اند:

– **داده‌های روباریک‌محور (Rubric-Guided Data):** برای هر دسته از وظایف باز، شیوه‌نامه‌های تفصیلی تدوین گردید.

– **یگانگی ارزیاب و عامل زایا:** شبکه عامل اصلی (Actor Network) خود هم‌زمان در نقش مدل پاداش زایشی (GRM) عمل می‌کند. بهینه‌سازی تقویتی مستقیم بر روی رفتار قضاوت‌گری GRM، قوه استدلال درونی مدل را در فرایند امتیازدهی ادغام کرده و اتکا به داده‌های برچسب‌خورده انسانی را به حداقل رسانده است.

پروتکل‌های ساختاری داده: ابزارها، تفکر متناوب و دستورات سریع مدیریت بافت متنی عظیم یک میلیون توکنی در محیط‌های تعاملی نیازمند قالب‌بندی‌های داده‌ای دقیق است:

– **شمای فراخوانی ابزار با نشانگر |DSML|:** برای پیشگیری از نقص‌های متداول در قالب JSON، ساختاری بر پایه نشانه‌گذاری XML و توکن ویژه |DSML| توسعه یافت:

```
<|DSML|tool_calls>
<|DSML|invoke name="$TOOL_NAME">
<|DSML|parameter name="$PARAM_NAME" string="true|false">$PARAM_VALUE</|DSML|parameter>
</|DSML|invoke>
</|DSML|tool_calls>
```

– **استدلال متناوب (Interleaved Thinking):** برخلاف رویکردهای پیشین، در سناریوهای ابزارمحور کلیه ردپاهای فکری (Thinking Traces) در خلال نوبت‌های متوالی کاربر حفظ می‌گردد تا زنجیره استدلال در افق‌های زمانی بلند گسسته نشود؛ در حالی که در گفتگوهای عمومی جهت حفظ ظرفیت بافت، تاریخچه تفکر نوبت‌های قبلی حذف می‌شود.

– **توکن‌های دستور سریع (Quick Instruction):** جهت حذف سربار مدل‌های کوچک کمکی و جلوگیری از بازپردازش پرهزینه پیش‌تکمیل (Prefill)، توکن‌های اختصاصی نظیر <|action|> (تشخیص نیاز به وب‌گردی)، <|title|> (ساخت عنوان)، <|query|> (تولید کلیدواژه جستجو)، <|authority|> (سنجش اعتبار مرجع)، <|domain|> (شناسایی دامنه) و <|read_url|> (تصمیم‌گیری خواندن آدرس وب) مستقیماً درون بافت پردازش می‌شوند.

مرحله دوم: تقطیر برخط خط‌مشی (On-Policy Distillation - OPD) به‌منظور تثبیت یکپارچه دانش N مدل معلم تخصصی ($\pi_{E_1}, \dots, \pi_{E_N}$ با $N > 10$) در قالب مدل واحد π_θ ، تابع هزینه تقطیر برخط بر مبنای دیورژانس کولبک-لایبلر معکوس بر روی نمونه‌های مشتق‌شده از توزیع خود دانش‌آموز بهینه‌سازی می‌شود:

$$\mathcal{L}_{\text{OPD}}(\theta) = \sum_{i=1}^N w_i \cdot \mathbb{D}_{\text{KL}}(\pi_\theta \parallel \pi_{E_i}) = \sum_{i=1}^N w_i \cdot \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(\cdot|x)} \left[\log \frac{\pi_\theta(y|x)}{\pi_{E_i}(y|x)} \right] \quad (32)$$

که در آن w_i وزن تخصیص‌یافته به تخصص معلم i -ام است. برخلاف تقریب‌های تک‌توکنی مرسوم:

$$\text{sg} \left[\log \frac{\pi_{E_i}(y_t | x, y_{<t})}{\pi_\theta(y_t | x, y_{<t})} \right] \quad (33)$$

که نوسان شدید شیب ایجاد می‌کردند، در DeepSeek-V4 تقطیر بر روی لاجیت‌های کل دایره واژگان ($|V| > 100K$) پیاده‌سازی شده است. همچنین جهت جلوگیری از ارباب آماری طول توالی (Length Bias) در صورت بروز وقفه حین تولید بافت‌های میلیونی، سازوکار ثبت پیش‌نویس توکن‌محور (Token-Granular WAL) مستقر گردیده تا رمزگشایی دقیقاً از توکن متوقف‌شده از سر گرفته شود.

ارزیابی‌های تجربی روی بنچمارک‌های استاندارد (Standard Evaluations) نتایج ارزیابی مدل نهایی پس‌آموزش‌دیده DeepSeek-V4-Pro-Max در جدول ۲۶ و بررسی اثر حالات تفکر در جدول ۲۷ آورده شده است. ارقام گویای آن است که مدل در استدلال رقابتی به ریتینگ کدفرسز 3206 (رتبه ۲۳ انسانی در جهان) و دقت 93.5 در LiveCodeBench دست یافته و در آزمون حقیقت‌سنجی SimpleQA-Verified با امتیاز 57.9، رکورد مدل‌های متن‌باز را به میزان ۲۰ درصد مطلق جابجا کرده است.

جدول ۲۶: مقایسه عملکرد DeepSeek-V4-Pro-Max در برابر مدل‌های رقیب متن‌باز و تجاری

DS-V4-Pro-Max	GLM-5.1-Thinking	K2.6-Thinking	Gemini-3.1-Pro	GPT-5.4-xHigh	Opus-4.6-Max	بنچمارک (متریک)	دسته ارزیابی
۵.۸۷	۰.۸۶	۱.۸۷	۰.۹۱	۵.۸۷	۱.۸۹	MMLU-Pro (EM)	دانش و استدلال
۹.۵۷	۱.۳۸	۹.۳۶	۶.۷۵	۳.۴۵	۲.۴۶	SimpleQA-Verified (Pass@1)	
۴.۸۴	۰.۷۵	۹.۷۵	۹.۸۵	۸.۷۶	۴.۷۶	Chinese-SimpleQA (Pass@1)	
۱.۹۰	۲.۸۶	۵.۹۰	۳.۹۴	۰.۹۳	۳.۹۱	GPQA Diamond (Pass@1)	
۷.۳۷	۷.۳۴	۴.۳۶	۴.۴۴	۸.۳۹	۰.۴۰	HLE (Pass@1)	
۵.۹۳	—	۶.۸۹	۷.۹۱	—	۸.۸۸	LiveCodeBench (Pass@1)	
۳۲۰۶	—	—	۳۰۵۲	۳۱۶۸	—	Codeforces (Rating)	
۲.۹۵	۴.۸۹	۷.۹۲	۷.۹۴	۷.۹۷	۲.۹۶	HMMT 2026 Feb (Pass@1)	
۸.۸۳	۸.۸۳	۰.۸۶	۰.۸۱	۴.۹۱	۳.۷۵	IMOAnswerBench (Pass@1)	
۲.۹۰	۴.۷۲	۵.۷۵	۱.۸۹	۱.۷۸	۹.۸۵	Apex Shortlist (Pass@1)	
۵.۸۳	—	—	۳.۷۶	—	۹.۹۲	MRCR 1M (MMR)	بافت طولانی
۰.۶۲	—	—	۸.۵۳	—	۷.۷۱	CorpusQA 1M (ACC)	
۹.۶۷	۵.۶۳	۷.۶۶	۵.۶۸	۱.۷۵	۴.۶۵	Terminal Bench 2.0 (Acc)	عملکرد عاملی
۶.۸۰	—	۲.۸۰	۶.۸۰	—	۸.۸۰	SWE-Verified (Resolved)	
۴.۵۵	۴.۵۸	۶.۵۸	۲.۵۴	۷.۵۷	۳.۵۷	SWE-Pro (Resolved)	
۴.۸۳	۳.۷۹	۲.۸۳	۹.۸۵	۷.۸۲	۷.۸۳	BrowseComp (Pass@1)	
۶.۷۳	۸.۷۱	۶.۶۶	۲.۶۹	۲.۶۷	۸.۷۳	MCPAtlas Public (Pass@1)	
۸.۵۱	۷.۴۰	۰.۵۰	۸.۴۸	۶.۵۴	۲.۴۷	Toolathlon (Pass@1)	

جدول ۲۷: مقایسه تاثیر حالات تلاش تفکر بر نسخه‌های Flash و Pro مدل DeepSeek-V4

DeepSeek-V4-Pro			DeepSeek-V4-Flash			بنچمارک (متریک)
Max	High	Non-Think	Max	High	Non-Think	
۵.۸۷	۱.۸۷	۹.۸۲	۲.۸۶	۴.۸۶	۰.۸۳	MMLU-Pro (EM)
۹.۵۷	۲.۴۶	۰.۴۵	۱.۳۴	۹.۲۸	۱.۲۳	SimpleQA-Verified (Pass@1)
۴.۸۴	۷.۷۷	۸.۷۵	۹.۷۸	۲.۷۳	۵.۷۱	Chinese-SimpleQA (Pass@1)
۱.۹۰	۱.۸۹	۹.۷۲	۱.۸۸	۴.۸۷	۲.۷۱	GPQA Diamond (Pass@1)
۷.۳۷	۵.۳۴	۷.۷	۸.۳۴	۴.۲۹	۱.۸	HLE (Pass@1)
۵.۹۳	۸.۸۹	۸.۵۶	۶.۹۱	۴.۸۸	۲.۵۵	LiveCodeBench (Pass@1-COT)
۳۲۰۶	۲۹۱۹	—	۳۰۵۲	۲۸۱۶	—	Codeforces (Rating)
۲.۹۵	۰.۹۴	۷.۳۱	۸.۹۴	۹.۹۱	۸.۴۰	HMMT 2026 Feb (Pass@1)
۵.۸۳	۳.۸۳	۷.۴۴	۷.۷۸	۹.۷۶	۵.۳۷	MRCR 1M (MMR)
۰.۶۲	۵.۵۶	۶.۳۵	۵.۶۰	۳.۵۹	۵.۱۵	CorpusQA 1M (ACC)
۶.۸۰	۴.۷۹	۶.۷۳	۰.۷۹	۶.۷۸	۷.۷۳	SWE-Verified (Resolved)

ارزیابی‌های کیفی بر روی دادگان کاربردی جهان واقعی به‌منظور پر کردن شکاف میان بنچمارک‌های ایستا و تجربه واقعی کاربران، مجموعه داده‌های داخلی زیر ارزیابی گردیدند:

– **نگارش عملکردی زبان چینی (۳،۱۷۰ نمونه):** طبق جدول ۲۸، مدل در برابر Gemini-3.1-Pro به نرخ برد کلی 62.65% دست یافت.

- **نگارش خلاقانه چینی (۲,۸۳۷ نمونه):** مطابق جدول ۲۹، مدل در کیفیت نویسندگی به نرخ برتری چشمگیر 77.48% در برابر رقیب رسید.
- **دستورات پیچیده و نگارش چندنوبته (۱۹۶ پرامپت چالش برانگیز):** طبق جدول ۳۰، رقابت فشرده‌ای میان DeepSeek-V4-Pro با نرخ 45.9% و Claude-Opus-4.5 با 52.0% ثبت شد.
- **ارزیابی جستجوی عاملی در برابر RAG:** آزمون بر روی ۸۶۹ پرامپت (جدول ۳۱) نشان داد که جستجوی عاملی با 61.7% برد، رویکرد RAG را پشت سر گذاشته است؛ در حالی که طبق ارزیابی ۹۵۶ پرامپت جستجو، مدل V4 با برتری 28.1% در برابر 10.4% نسبت به DeepSeek-V3.2 غلبه دارد.
- **تکالیف اداری-تخصصی سفیدپوشان (White-Collar Tasks):** ارزیابی انسانی ۳۰ سناریوی پیشرفته اداری در ۱۳ صنعت حاکی از نرخ عدم باخت 63% نسبت به Opus-4.6-Max و برتری در تکمیل تسک (98.32 در برابر 96.68) و غنای محتوا (83.32 در برابر 78.00) است.
- **عامل‌های مهندسی نرم‌افزار در محیط R&D:** طبق جدول ۳۲، ارزیابی روی ۳۰ تسک استانداردسازی‌شده از مسائل واقعی مهندسان داخلی نشان داد DeepSeek-V4-Pro-Max با نرخ موفقیت 67%، مدل Claude Sonnet 4.5 (47%) را قاطعانه پشت سر گذاشته و در مجاورت Opus 4.5 (70%) قرار گرفته است.

جدول ۲۸: خلاصه نتایج نگارش عملکردی چینی در برابر Gemini-3.1-Pro (۳,۱۷۰ نمونه)

دسته نوشتاری	تعداد (#)	برد DS	برد Gem	درصد برد DS	درصد برد Gem	درصد مساوی
متون اداری و تجاری (Business)	۱۳۴۹	۸۷۹	۴۳۶	۱۶%.۶۵	۳۲%.۳۲	۵۲%.۲
متون رسانه‌ای و تبلیغاتی (Media)	۶۶۶	۳۸۶	۲۵۶	۹۶%.۵۷	۴۴%.۳۸	۶۰%.۳
نگارش روزمره و ارتباطی (Everyday)	۳۹۰	۲۷۱	۱۰۱	۴۹%.۶۹	۹۰%.۲۵	۶۲%.۴
متون گفتاری و سخنرانی (Oral)	۳۱۹	۱۸۷	۱۲۰	۶۲%.۵۸	۶۲%.۳۷	۷۶%.۳
اسناد رسمی و نامه‌های دولتی (Official)	۲۳۰	۱۲۶	۹۷	۷۸%.۵۴	۱۷%.۴۲	۵۴%.۳
متون آکادمیک و ترویج علم (Academic)	۲۱۶	۱۳۷	۷۱	۴۳%.۶۳	۸۷%.۳۲	۷۰%.۳
مجموع کل	۳۱۷۰	۱۹۸۶	۱۰۸۱	۶۵%.۶۲	۱۰%.۳۴	۲۵%.۳

جدول ۲۹: ارزیابی نگارش خلاقانه چینی در برابر Gemini-3.1-Pro (۲,۸۳۷ نمونه)

محور ارزیابی	آمار شمارشی			درصد آماری		
	برد DS	برد Gem	مساوی	% برد DS	% برد Gem	% مساوی
پیروی از دستورالعمل (Instruction Following)	۱۷۰۳	۱۱۱۹	۱۵	۵۳%.۶۰	۴۴%.۳۹	۵۳%.۰
کیفیت ادبی و نویسندگی (Writing Quality)	۲۱۹۸	۶۳۴	۵	۴۸%.۷۷	۳۵%.۲۲	۱۸%.۰

جدول ۳۰: ارزیابی دستورات فوق‌پیچیده و نگارش چندنوبته در برابر Claude Opus 4.5

دسته‌بندی	تعداد (#)	برد DS	برد Opus	درصد DS	درصد Opus	درصد مساوی
پیروی از دستورات پیچیده (Complex Instructions)	۴۹	۲۳	۲۶	۹%.۴۶	۱%.۵۳	۰%.۰
نگارش چندنوبته (Multi-Turn Writing)	۱۴۷	۶۷	۷۶	۶%.۴۵	۷%.۵۱	۷%.۲
مجموع کل	۱۹۶	۹۰	۱۰۲	۹%.۴۵	۰%.۵۲	۰%.۲

• GLM-5

مقدمه و پارادایم داده‌های پس‌آموزش فاز پس‌آموزش (Post-Training) در مدل GLM-5 با هدف گذار ساختاری از پارادایم «کدنویسی حسی» (Vibe Coding) — که مبتنی بر پرامپت‌نویسی انسانی است — به سمت «مهندسی عامل‌محور» (Agentic Engineering) بازطراحی شده است؛ جایی که مدل به عنوان یک عامل خودکار، وظایف برنامه‌ریزی، پیاده‌سازی، اجرا و خوداصلاحی را در افق‌های زمانی طولانی بر

جدول ۳۱: سنجش کارایی جستجوی عاملی در مقایسه با RAG سنتی در DeepSeek-V4-Pro

سطح مسئله	نوع پرسش	تعداد	برد عامل	برد RAG	% برد عامل	% برد RAG	% مساوی
آسان (Easy)	عینی (Objective)	۱۹۶	۱۱۰	۴۳	۱٪.۵۶	۹٪.۲۱	۹٪.۲۱
	تحلیلی (Subjective)	۳۲۱	۱۹۸	۵۶	۷٪.۶۱	۴٪.۱۷	۹٪.۲۰
دشوار (Hard)	عینی (Objective)	۱۶۸	۱۰۲	۳۳	۷٪.۶۰	۶٪.۱۹	۶٪.۱۹
	تحلیلی (Subjective)	۱۸۴	۱۲۶	۲۷	۵٪.۶۸	۷٪.۱۴	۸٪.۱۶
جمع کل	—	۸۶۹	۵۳۶	۱۵۹	۷٪.۶۱	۳٪.۱۸	۵٪.۲۰

جدول ۳۲: مقایسه نرخ موفقیت در حل وظایف مهندسی نرم افزار واقعی (R&D Benchmark)

مدل	Haiku 4.5	Sonnet 4.5	DS-V4-Pro-Max	Opus 4.5	Opus 4.5 (Think)	Opus 4.6 (Think)
نرخ حل (Pass Rate %)	۱۳٪	۴۷٪	۶۷٪	۷۰٪	۷۳٪	۸۰٪

عهده می‌گیرد. برای این منظور، خط لوله داده‌های پس‌آموزش با بسط طول بافت تا سقف ۲۰۲،۷۵۲ توکن در قالب یک زنجیره چندمرحله‌ای شامل تنظیم دقیق بانظارت (SFT)، یادگیری تقویتی استدلال (Reasoning RL)، یادگیری تقویتی عامل‌محور (Agentic RL)، یادگیری تقویتی عمومی (General RL) و تقطیر هم‌خط بین‌مرحله‌ای (On-Policy Cross-Stage Distillation) سازمان‌دهی شده است.

ترکیب‌بندی و پالایش پیکره داده‌های تنظیم دقیق بانظارت (SFT Data) پیکره داده‌های SFT در GLM-5 نسبت به نسل‌های پیشین به شکل چشمگیری در حوزه‌های کدنویسی و تعاملات عاملی گسترش یافته و در سه محور ساختار یافته است:

– **گفت‌وگوی عمومی (General Chat):** شامل داده‌های پرسش و پاسخ، نگارش، ترجمه، تعاملات طولانی و بازی نقش (Role-playing) چندزبانه. داده‌های بازی نقش بر پایه پنج بعد کیفی (پیروی از دستور، بیان‌گری زبانی، خلاقیت، انسجام منطقی و پایداری در مکالمات طولانی) توسط ارزیاب‌های خودکار و متخصصان انسانی پالایش شدند. سبک پاسخ‌ها نیز به سوی ساختاری منطقی‌تر و موجزتر بهینه‌سازی شد.

– **داده‌های استدلال تحلیلی (Reasoning Data):** در حوزه استدلال منطقی، داده‌ها از مسائل قابل راستی‌آزمایی عینی با روش نمونه‌برداری حذفی (Rejection Sampling) استخراج شدند. در مسائل ریاضی و علوم، فیلتر مبتنی بر دشواری (Difficulty-based Filtering) اعمال گردید تا تنها مسائلی حفظ شوند که مدل GLM-4.7 توانایی حل آن‌ها را نداشته است.

– **داده‌های کدنویسی و عاملی (Coding & Agent Data):** شامل کدهای فرانت‌اند و بک‌اند، فراخوانی ابزارها و ردپای عامل‌های حل مسئله در محیط‌های واقعی. داده‌ها با الگوریتم‌های یادگیری تقویتی خبره و نمونه‌برداری حذفی استخراج شدند. بخش‌های اشتباه در مسیر اجرای عامل حذف نشدند، بلکه در تابع زیان آموزش ماسک‌گذاری شدند (Masked out):

$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{t \in \mathcal{T}_{\text{valid}}} \log \pi_{\theta}(y_t | x, y_{<t}) \quad (34)$$

این رویکرد به مدل می‌آموزد که الگوهای تصحیح خطا (Error Correction) را بدون بازتولید یا تقویت اقدامات غلط فراگیرد.

قالب‌بندی داده‌ها و حالات سه‌گانه تفکر (Thinking Modes) قالب پرامپت‌ها در داده‌های پس‌آموزش به‌گونه‌ای مهندسی شده است که مدل را به سه الگوی رفتاری ساختاریافته مجهز می‌سازد:

– **تفکر درهم‌تنیده (Interleaved Thinking):** تعبیه بلوک‌های استدلال پیش از هر پاسخ متنی و پیش از هر فراخوانی ابزار (Tool Call) جهت بهبود دقت عملیاتی.

- **تفکر حفظ شده (Preserved Thinking):** در تعاملات چندنوبته مهندسی نرم افزار، زنجیره تفکر نوبت های پیشین در زمینه ذخیره می شود تا از استدلال مجدد از نقطه صفر و ایجاد تناقض های منطقی در وظایف طولانی جلوگیری شود.
- **تفکر در سطح نوبت (Turn-level Thinking):** قابلیت تنظیم فعال/غیرفعال بودن تفکر در هر نوبت بر اساس میزان پیچیدگی درخواست به منظور کاهش تأخیر زمانی.

داده ها و فرمولاسیون یادگیری تقویتی استدلال (Reasoning RL) در مرحله استدلال تحلیلی، داده ها در چهار حوزه متعادل توزیع شده اند:

- **ریاضیات و علوم:** گردآوری از دادگان متن باز معتبر نظیر Nemotron-Math [۱۰۴] و راهکار برنده رقابت AIMO-2 با پایگاه داده OpenMathReasoning [۱۰۵]. مسائل به گونه ای فیلتر شدند که برای GLM-4.7 غیرقابل حل بوده، اما معلمان قدرتمند نظیر GPT-5.2 (xhigh) [۱۰۶] و Gemini 3 Pro Preview [۱۰۷] توانایی حل گام به گام آن ها را داشته باشند.
 - **کدنویسی رقابتی و علمی:** مسائل مسابقات برنامه نویسی از پلتفرم Codeforces، مجموعه داده های TACO [۱۰۸] و SYNTHETIC-2-RL [۱۰۹].
 - **استدلال یکپارچه با ابزار (Tool-Integrated Reasoning - TIR):** نمونه مسائل ریاضی و مهندسی که مستلزم فراخوانی مفسر پایتون و ابزارهای محاسباتی بیرونی هستند.
- آموزش بر پایه نسخه اصلاح شده الگوریتم GRPO [۲۴] و تکنیک IcePop [۱۱۰] برای حذف واگرایی میان سیاست استنتاج و سیاست گرادیان صورت گرفته است:

$$\mathcal{L}(\theta) = -\mathbb{E}_{x \sim \mathcal{D}, \{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}^{\text{infer}}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \text{pop}(\rho_{i,t}, 1/\beta, \beta) \cdot \min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}) \hat{A}_{i,t} \right) \right] \quad (35)$$

که در آن نسبت عدم انطباق استنتاج-آموزش و عملگر سرکوب خطای pop عبارتند از:

$$\rho_{i,t} = \frac{\pi_{\theta_{\text{old}}}^{\text{train}}(y_{i,t} \mid x, y_{i,<t})}{\pi_{\theta_{\text{old}}}^{\text{infer}}(y_{i,t} \mid x, y_{i,<t})}, \quad \text{pop}(\rho, 1/\beta, \beta) = \begin{cases} \rho, & \text{if } 1/\beta \leq \rho \leq \beta \\ 0, & \text{otherwise} \end{cases} \quad (36)$$

آموزش این بخش با اندازه گروه $G = 32$ ، اندازه دسته ۳۲ و هایپرپارامترهای $\epsilon_{\text{low}} = 0.2$ ، $\beta = 2$ و $\epsilon_{\text{high}} = 0.28$ انجام شده است.

محیط های اجرایی و ساخت دادگان عامل محور (Agentic RL Environments) برای آموزش مدل در نقش عامل مهندسی، داده ها از متن های ایستا فراتر رفته و در بستر بیش از ۱۰ هزار محیط اجرایی ابطال پذیر تعاملی تولید شدند:

- **محیط های مهندسی نرم افزار (SWE Environments):** با اقتباس از چارچوب RepoLaunch [۱۱۱]، بیش از ۱۰،۰۰۰ محیط اجرایی بر پایه مخازن گیت هاب در ۹ زبان برنامه نویسی (Go, Java, Python, C, C++, JavaScript, TypeScript, PHP و Ruby) ایجاد شد. آزمون های شکست-به-موفقیت (Fail-to-Pass - F2P) و پایداری (Pass-to-Pass - P2P) توسط لاگ خوان های مبتنی بر مدل زبانی استخراج شدند.

- **محیط های ترمینال (Terminal Environments):** تولید داده ها در ساختار استاندارد کانتینری Harbor [۱۱۲] انجام گرفت. این فرآیند از دو مسیر انجام شد: ۱) سنتز سه مرحله ای از وظایف بذر مهندسی نرم افزار با دقت ساخت داکر بیش از ۹۰٪ (۲) استخراج خودکار و حلقه-بسته از صفحات وب فنی که در آن عامل با اجرای اسکریپت های اعتبارسنجی Harbor به صورت خودکار وظیفه تولیدی را اصلاح و نهایی می کرد.

- **وظایف جستجوی عمیق چندمرحله‌ای (Deep-Search Tasks):** پایگاه داده‌ای از گراف دانش وب (WKG) بر پایه ۲ میلیون صفحه با چگالی اطلاعاتی بالا ساخته شد. سوالات از روی زنجیره‌های چندموجودیتی استخراج و از یک فیلتر سه‌مرحله‌ای عبور داده شدند: ۱) حذف سوالات قابل حل بدون ابزار (در ۱ تلاش از ۸ اجرا)، ۲) حذف سوالات قابل حل با جستجوی تک‌مرحله‌ای، ۳) اعتبارسنجی دوطرفه تطابق شواهد وب با پاسخ مرجع توسط عامل داور.

- **محیط تولید اسلاید متنی-بصری (Slide Generation):** مدلسازی داده‌ها بر پایه ساختار HTML با پاداش سه‌سطحی: سطح ۱ (ویژگی‌های نشانه‌گذاری استایل، رنگ و حذف تصاویر توهمی)، سطح ۲ (ویژگی‌های رندریگ زمان اجرا در DOM نظیر ابعاد و جلوگیری از هک پاداش با قطع نامتقارن متن)، و سطح ۳ (ارزیابی بصری توزیع فضاهای خالی). در این فرایند انطباق ساختاری با نسبت ابعاد ۱۶:۹ از ۴۰٪ به ۹۲٪ افزایش یافت.

پایدارسازی آماری داده‌ها در یادگیری تقویتی ناهمگام (Asynchronous Stability) تولید برون‌خط و هم‌زمان مسیرهای اجرایی عامل‌ها نیازمند کنترل آماری عدم انطباق سیاست‌ها بود:

- **دروازه توکن‌به‌توکن (TITO Gateway):** ثبت مستقیم شناسه‌های توکن و فراداده‌ها در خروجی موتور استنتاج به منظور رفع خطاهای ناشی از توکن‌ایزیشن مجدد در سمت آموزش.

- **نمونه‌برداری اهمیتی دوطرفه مستقیم (Direct Double-sided Importance Sampling):** کنترل بازه گرادیان در محدوده $[1 - \epsilon_\ell, 1 + \epsilon_h]$ بدون نیاز به فراخوانی پرهزینه سیاست قدیمی:

$$\mathcal{L}(\theta) = \mathbb{E}_t \left[f(r_t(\theta), \epsilon_\ell, \epsilon_h) \hat{A}_t \log \pi_\theta(a_t | s_t) \right] \quad (37)$$

$$r_t(\theta) = \exp(\log \pi_\theta(a_t | s_t) - \log \pi_{\text{rollout}}(a_t | s_t)) \quad (38)$$

$$f(x; \epsilon_\ell, \epsilon_h) = \begin{cases} x, & \text{if } 1 - \epsilon_\ell < x < 1 + \epsilon_h \\ 0, & \text{otherwise} \end{cases} \quad (39)$$

- **پالایش داده‌های بیات و خطاهای محیطی:** حذف مسیرهایی که اختلاف نسخه مدل تولیدکننده آن‌ها با نسخه جاری آموزش بیش از حد آستانه بود ($w' - w_0 > \tau$). همچنین حذف داده‌های حاصل از فروپاشی کانتینر داکر و تکمیل داده‌های گروهي (Padding) در صورت وجود حداقل نیمی از نمونه‌های معتبر.

یادگیری تقویتی عمومی و تقطیر هم‌خط بین‌مرحله‌ای در فاز یادگیری عمومی، اهداف بهینه‌سازی در سه بعد صحت بنیادین (کاهش توهم و خطاهای ساختاری)، هوش هیجانی (همدلی و گفت‌وگوی روان) و کیفیت تخصصی وظایف تنظیم شدند. برای نظارت بر این ابعاد، سیستمی ترکیبی از پاداش‌های قانون‌محور، مدل‌های پاداش پیامد (ORMs) و مدل‌های پاداش زاینده‌گی (GRMs) به کار رفت. افزون بر این، به منظور ممانعت از تولید خروجی‌های بیش‌ازحد کلیشه‌ای و ماشینی، پاسخ‌های تدوین‌شده توسط متخصصان برجسته انسانی (Human-authored Responses) به عنوان لنگرهای کیفی سبک وارد جریان آموزش شدند.

در نهایت، برای رفع افت تدریجی توانمندی‌های پیشین (Catastrophic Forgetting)، تقطیر هم‌خط بین‌مرحله‌ای بر روی توزیع داده‌های مراحل استدلال و عمومی با اندازه دسته ۱۰۲۴ و اندازه گروه $G = 1$ اجرا شد:

$$\hat{A}_{i,t} = \text{sg} \left[\log \frac{\pi_{\theta_{\text{teacher}}}^{\text{infer}}(y_{i,t} | x, y_{i,<t})}{\pi_{\theta}^{\text{train}}(y_{i,t} | x, y_{i,<t})} \right] \quad (40)$$

جدول ۳۳: توزیع سناریوهای کاربردی فرانت‌اند و واحدهای اعتبارسنجی در CC-Bench-V2

دسته‌بندی	شرح سناریو	تعداد وظایف (# Tasks)	تعداد چک‌لیست‌ها (# Checkitems)
سامانه‌های سازمانی (Business Systems)	مدیریت فرآیندها و داده‌های تجاری	۴۲	۱۶۷
بازی‌های تعاملی وب (Web Games)	تعاملات گرافیکی و برنامه‌های سرگرمی	۴۰	۱۶۳
رندرینگ برداری (SVG/Canvas)	ترسیمات پویا و مصورسازی‌های تعاملی	۳۲	۱۶۶
ابزارهای خلاقانه (Creative Tools)	ابزارهای ویرایش و تولید محتوای برخط	۲۸	۱۶۰
صفحات معرفی (Showcase Pages)	بازنمایی اطلاعات و طراحی صفحات فرود	۲۷	۱۱۵
فرم‌ها و جداول (Forms & Tables)	ساختارهای ورود داده و اعتبارسنجی ورودی	۲۶	۹۳
مصورسازی داده (Data Visualization)	نمودارهای تحلیلی و گرافیکی وب	۲۵	۸۵
مجموع کل وظایف فرانت‌اند پوشش کامل پشته‌های HTML/JS (۱۱۳)، React (۵۸) و Vue (۴۹)			
۲۲۰			
۹۶۹			

جدول ۳۴: ارزیابی عملکرد مدل در بخش‌های فرانت‌اند، بک‌اند و افق طولانی بنچمارک CC-Bench-V2

حوزه مهندسی	پشته یا نوع وظیفه	متریک ارزیابی	GLM-5	GLM-4.7	Claude Opus 4.5
فرانت‌اند (Frontend)	HTML/CSS/JS	(%) ISR / CSR	۳.۷۶ / ۹.۳۸	۹.۶۴ / ۴.۳۵	۲.۸۲ / ۲.۵۲
	React	(%) ISR / CSR	۰.۷۱ / ۶.۳۴	۴.۴۹ / ۲.۱۷	۷.۷۰ / ۷.۳۹
	Vue	(%) ISR / CSR	۱.۷۷ / ۷.۳۲	۸.۵۳ / ۵.۲۴	۳.۷۴ / ۹.۴۶
صحت ساخت (Build)	React / Vue / Svelte / Next	(%) BSR	۰.۹۵ / ۱۰۰ / ۱۰۰ / ۱۰۰	۰.۷۰ / ۰.۶۰ / ۰.۷۰ / ۰.۶۵	۰.۸۰ / ۰.۹۰ / ۱۰۰ / ۰.۹۵
بک‌اند (Backend)	مهندسی نرم‌افزار (۸۵ تسک در ۶ زبان)	(%) Pass@1	۸.۲۵	۶.۱۹	۹.۲۶
افق طولانی (Long-horizon)	ناوبری مخازن بزرگ (Repo Exploration)	(%) Pass@1	۶.۶۵	۸.۴۷	۵.۶۴
	وظایف زنجیره‌ای متوالی (Chained Tasks)	(%) Pass@1	۳.۵۲	۰.۴۳	۶.۶۱

ارزیابی‌های تجربی روی مجموعه داده‌های عامل‌محور و دنیای واقعی به منظور ارزیابی کارایی داده‌های پس‌آموزش در شرایط واقعی مهندسی، بنچمارک داخلی جامع CC-Bench-V2 طراحی گردید. آمار ساختار داده‌ها و نتایج عملکردی مدل در جدول‌های زیر خلاصه شده است.

همچنین مدل GLM-5 بر روی مجموعه داده‌های عملیاتی ارزیابی گردید که دستاوردهای زیر حاصل شد:

- **ترجمه ماشینی واقعی (ZMultiTransBench):** شامل ۱,۲۲۰ نمونه از سناریوهای متداول کاربری در ۷ جفت‌زبان از مبدا چینی به اسپانیایی (۳۰۰)، روسی (۲۵۰)، فرانسوی (۲۲۰)، کره‌ای (۲۰۰)، ژاپنی (۱۵۰)، عربی (۵۰) و آلمانی (۵۰). امتیاز الو مدل از ۱۰۱۶ در GLM-4.7 به ۱۰۵۰ در GLM-5 افزایش یافت.
- **ترجمه زبانی دشوار (MENT-SNS [۱۱۳]):** ۷۵۳ جفت‌جمله انگلیسی-چینی دارای کنایه و استعاره؛ امتیاز الو از ۹۹۳ به ۱۰۱۳ ارتقا یافت.
- **گفت‌وگوی چندزبانه (ZMultiDialBench):** ۱۴۱ سناریوی چندزبانه ارزیابی‌شده توسط متخصصان؛ نمره میانگین از ۴۴.۸ به ۵۷.۸ بهبود یافت.
- **پیروی از دستورات پیچیده (IF-Badcase):** ۴۵۰ نمونه پرامپت با محدودیت‌های چندگانه استخراج‌شده از محیط استقرار؛ نرخ موفقیت از ۵۷.۷۸٪ به ۲۷.۸۳٪ رسید.
- **فراخوانی ابزار (ToolCall-Badcase):** ۲۰۰ نمونه استخراج‌شده از موارد شکست کاربران در محیط عملیاتی؛ دقت تطابق ساختار و آرگومان‌ها با جهشی خیره‌کننده از ۸٪.۶۰ به ۸۷.۹۵٪ رسید.

• Kimi K3

مقدمه و ساختار کلان دادگان پس‌آموزش (Post-Training Paradigm) فاز پس‌آموزش در مدل زبانی چندوجهی Kimi K3 [۱۳] (با ۸.۲ تریلیون پارامتر کل و ۱۰۴ میلیارد پارامتر فعال در هر توکن) بر پایه یک پارادایم نوین برای مقیاس‌پذیری محاسبات زمان آزمون (Test-Time Scaling) در پنجره بافت فوق‌طولانی یک میلیون توکن (1M-token context) طراحی شده است. این فرآیند بر یک زنجیره سه‌مرحله‌ای یکپارچه استوار است:

- **تنظیم دقیق تحت نظارت (SFT):** ایجاد یک سیاست راه‌انداز سرد (Cold-Start Policy) با کیفیت فوق‌العاده بالا جهت تثبیت رفتارهای تعاملی و عاملی.
- **یادگیری تقویتی چندسطحی (Multi-Effort RL):** آموزش متخصصان حوزه‌ای در ۳ دامنه کلان و ۳ سطح تلاش استدلالی (Reasoning Effort) شامل {low, high, max} که به پیدایش ۹ مدل متخصص مجزا منجر می‌شود.

- **تقطیر هم‌سیاست چندمعلمه (Multi-Teacher On-Policy Distillation - MOPD):** تجمیع و ادغام قابلیت‌های ۹ متخصص حوزه‌ای درون یک مدل واحد سراسری.

سریال‌سازی و ساختار بازنمایی داده‌ها: قالب گفتگوی XHTML جهت استانداردسازی تعاملات پیچیده عاملی، داده‌ها با قالب نشانه‌گذاری اختصاصی XHTML (eXtensible Token Markup Language) فرمت‌بندی شده‌اند. این ساختار با جایگزینی نشانه‌های متداول XML با نشانه‌های رزرو شده ساختاری شامل [open]، [sep]، [close] و [end_of_msg]، ابهام ناشی از توکنایزیشن در مرز المان‌ها را از بین می‌برد و بار مالیات هم‌ترازی (Alignment Tax) را به حداقل می‌رساند:

- **تفکیک زون‌های داده (Zoning & Caching):** پیام‌های گزینه‌ای سراسری (Global Options) نظیر اعلان ابزارها (tool-declare) و تعیین بودجه تلاش استدلالی (thinking-effort) پیش از تمامی پیام‌های ورودی قرار می‌گیرند تا ساختار حافظه نهان کلید-مقدار (KV Cache) ابطال نشود. در مقابل، گزینه‌های گذرا (One-Shot) مانند tool_choice و response_format در انتهای پیام‌ها الصاق می‌شوند.

- **معماری سه‌کاناله دستیار (Channels):** پاسخ مدل دستیار در سه کانال مجزا سازمان‌دهی می‌شود:

۱. کانال استدلال و تفکر خام ([open] think [sep]).
۲. کانال پاسخ نهایی کاربر ([open] response [sep]).
۳. کانال فراخوانی ساختاریافته ابزارها ([open] tools [sep]).

در این قالب، سازوکار **تفکر حفظ‌شده** (Preserved Thinking) اعمال می‌گردد؛ به‌طوری‌که حتی در صورت خالی بودن کانال استدلال، ساختار آن در تاریخچه حفظ می‌شود.

- **فراخوانی ابزار با آرگومان‌های تایپ‌شده (Typed Arguments):** هر فراخوانی حامل صفت tool و شناسه index برای تطبیق دقیق نتایج فراخوانی‌های موازی است. آرگومان‌های متنی و کدها به صورت متن خام تزریق شده و از ساختارهای پیچیده و فرارداشته‌شده JSON اجتناب می‌گردد. همچنین ماسک‌گذاری زیان (Loss Masking) بر روی ورودی‌های پشتیبان JSON اعمال می‌شود.

دادگان پیش‌تنظیم تحت نظارت (Supervised Fine-Tuning - SFT): مجموعه داده SFT به منظور ایجاد پایه رفتاری قدرتمند برای فاز یادگیری تقویتی گردآوری شده است:

- **سنتز مسیرهای عاملی (Trajectory Synthesis):** داده‌های عاملی با استفاده از مدل‌های تخصصی حوزه‌ای نسل‌های پیشین Kimi K2 [۱۴] و Kimi K2.5 [۱۱۴] شبیه‌سازی و تولید شده‌اند.
- **پالایش و اعتبارسنجی چندمرحله‌ای:** تمامی خط سیرهای تولیدشده از فیلترهای چندمرحله‌ای صحت‌سنجی خودکار و حاشیه‌نویسی انسانی در حلقه (Human-in-the-loop) عبور داده شدند تا هرگونه انحراف و توهم رفتاری پالایش گردد.
- **انطباق داده‌ها با آموزش آگاه از کوانتایزیشن (QAT):** داده‌های ورودی همگام با استراتژی کوانتایزیشن مدل در فاز استقرار تنظیم شده‌اند؛ وزن‌های متخصصان MoE در فرمت MXFP4 و فعال‌سازها در فرمت MXFP8 [۱۱۵] شبیه‌سازی می‌شوند تا مدل در برابر خطای دقت پایین مقاوم گردد.

سنتز داده‌های یادگیری تقویتی با هدایت گراف دانش (KG-Guided Task Synthesis): جهت پوشش جامع حوزه‌های دانشی با عمق مفهومی بالا و اجتناب از داده‌های سطحی، از یک **گراف جهت‌دار بدون دور (DAG)** خودتوسعه‌دهنده استفاده شده است:

- **کاوش بازگشتی عامل‌ها (Agentic Graph Construction):** فرآیند با گره‌های هسته در حوزه‌های اصلی (شیمی، فیزیک، ریاضی، علوم کامپیوتر، برنامه‌نویسی و علوم زیستی) آغاز می‌شود. عامل‌ها با وب‌گردی مستقل مفاهیم مرتبط را کشف کرده و یال‌های سلسله‌مراتبی از مفاهیم عام به اتمیک رسم می‌کنند تا یک گراف عمیق شکل گیرد.

- **بازیابی چندسطحی و سنتز وظایف:** با نمونه برداری از گره های گراف در سطوح دانه بندی گوناگون و ادغام با مفاهیم والد، کوثری های پیچیده ای استخراج شده و با بازیابی مقالات علمی، مخازن کد و اسناد واقعی وب، وظایف استدلالی چالش برانگیز تولید می شوند.

محیط جعبه سفید یکپارچه و تنوع چارچوب ها (Unified White-Box RL Environment) برای مهار بیش برارزش مدل به یک قالب یا سیستم پرامپت ثابت، یک محیط چندماژوله جعبه سفید طراحی شده که می تواند رفتار چارچوب های نام آشنایی نظیر Kimi Code [۱۱۶]، Claude Code [۱۱۷]، Codex [۱۱۸]، OpenClaw [۱۱۹] و Hermes [۱۲۰] را شبیه سازی کند. ترکیب پویای ابزارها، مهارت ها و حافظه ها، استواری مدل را در مواجهه با توزیع های مختلف تضمین می نماید.

حوزه های تخصصی وظایف و داده های یادگیری تقویتی داده های تقویتی در بسترهای تعاملی و ابزارمحور با ویژگی های زیر جمع آوری و اعمال شده اند:

- **بهینه سازی کرنل های محاسباتی GPU (Kernel Tasks):** داده ها از مخازن سطح بالای گیت هاب نظیر Flash Linear Attention [۱۲۱] استخراج شده و شامل پیاده سازی های CUDA، Triton [۱۲۲]، ThunderKittens، CuTe DSL [۱۲۳] و TileLang [۱۲۴] در فرمت های FP4 و FP8، BF16 هستند. تابع پاداش بر مبنای تطابق دقیق خروجی با نسخه مرجع PyTorch (پاداش صفر در صورت خطای عددی) و نزدیکی به سقف مدل سقف شیشه ای سخت افزار (Hardware Roofline) بین 0.5 تا 1.0 تنظیم شده و سیستم های ضدهک پاداش، ترفندهایی مانند CUDA Graph Replay را جریمه می کنند.

- **دستیار شخصی در محیط های پایدار (Personal Assistant Workflows):** با پیاده سازی ماک های کامل نرم افزارهای Gmail، Notion، Slack و Canvas، سناریوهای شغلی چندروزه با ده ها رویداد درهم تنیده شبیه سازی شده اند که هر مسیر اجرایی می تواند شامل **هزاران فراخوانی ابزار** و **میلیون ها توکن زمینه** باشد.

- **وظایف اجرای خودمختار (Autonomous Execution Tasks - AET):** مدل ها با پارادایم تأیید در حلقه (Verify-in-the-Loop) هدایت می شوند. پاداش صرفاً بر اساس بررسی وضعیت نهایی محیط توسط تأییدگرهای مستقل اعطا می شود (نه گزارش متنی خود مدل). نمونه این وظایف، مهندسی معکوس و بازسازی سامانه های نرم افزاری جعبه سیاه از طریق ارسال کوثری به اوراکل است.

- **توسعه وب و صحنه های تعاملی (Web Development):** تولید سایت های کامل، انیمیشن های 3D/WebGL، رابط های کاربردی و کدهای SVG. پاداش شامل آزمون های عملکردی قطعی و قضاوت مدل پاداش در بررسی تعاملی و بصری صفحات رندر شده است.

- **استدلال بصری تأییدپذیر (Verifiable Visual Reasoning):** مدل به مفسر پایتون در سندباکس متصل است و می تواند با نوشتن کد، تصاویر مسائل علمی و نمودارها را برش دهد، بزرگ نمایی کند و تبدیل های هندسی روی آن اعمال نماید تا با دریافت تصاویر حاصله به عنوان مشاهدات جدید، پاسخ را گام به گام استخراج کند.

فرمول بندی های ریاضی بودجه، مهار اطناب و تقطیر داده ها جهت مدیریت طول توکن ها و همگرایی پایدار داده ها، معادلات زیر بر فرآیند آموزش حاکم شده اند:

- **کنترل بودجه استدلال (Reasoning Effort):** به هر مسئله x یک بودجه توکن اولیه $b_0(x)$ تخصیص یافته و پاداش در صورت فراتر رفتن از حد آستانه با مقدار -1 جریمه می شود:

$$R_{\text{effort}}(x, y) = \begin{cases} R_{\text{task}}(x, y), & \text{if } T(y) \leq \tau \cdot b_0(x) \\ -1, & \text{if } T(y) > \tau \cdot b_0(x) \end{cases} \quad (41)$$

که در آن $T(y)$ در وظایف استدلالی تعداد توکن های تفکر و در وظایف عاملی کل توکن های خروجی است و ضریب τ در طول برنامه درسی کاهش می یابد.

- **مهار اطناب در مدل پاداش عاملی (GRM):** اگر طول متن خروجی کاندیدا از $\sigma \cdot \ell_0$ تجاوز کند (که ℓ_0 طول پاسخ اولیه مدل پایه است)، کاندیدا به صورت قطعی در داوری می‌بازد:

$$\text{Length}(y) > \sigma \cdot \ell_0 \implies \text{باخت قطعی در داوری} \quad (۴۲)$$

- **پاداش تقطیر هم‌سیاست چندمعلمه (MOPD):** هدایت مدل دانشجو π_θ توسط ۹ مدل معلم $\pi_{\text{teacher}}^{(d,e)}$ با پاداش متراکم توکنی زیر انجام می‌شود:

$$r_{\text{opd}}^d(y_t | e, x, y_{<t}) = \text{clip} \left(\text{sg} \left(\log \frac{\pi_{\text{teacher}}^{(d,e)}(y_t | x, y_{<t})}{\pi_\theta(y_t | e, x, y_{<t})} \right), -R_{\max}, R_{\max} \right) \quad (۴۳)$$

که در آن $\text{sg}(\cdot)$ عملگر توقف گرادین و $R_{\max}$ کران تثبیت است.

- **مدیریت بیات‌شدگی داده‌ها (Data Staleness):** در فرآیند اجرای جزئی (Partial Rollout)، به محض اتمام نسبت $\lambda \in (0, 1)$ از کل $N \times K$ مسیر نمونه‌برداری‌شده، داده‌ها وارد بهینه‌سازی سیاست می‌شوند و اثر بیات‌شدگی داده‌های معلق با یک منظم‌سازی موضعی در سطح توکن مهار می‌گردد.

آمار زیرساختی و شواهد تجربی ارزیابی دادگان پس‌آموزش مقیاس تولید داده و کارایی آن در محیط‌های عملیاتی به شرح زیر ثبت شده است:

- در فرآیند پس‌آموزش مدل، در مجموع ۵۱,۲۱۹,۷۴۱ سندباکس در گستره ۱,۵۰۵,۶۷۸ ایمیج سیستمی منحصربه‌فرد اجرا شده است.

- مقیاس‌دهی محاسبات RL افزایش هم‌زمان و معنادار طول گام‌های تعاملی دستیار (Avg. Steps) و نرخ موفقیت (Score %) را در هر ۸ حوزه عملکردی اصلی نشان می‌دهد.

- در آزمون‌های ارزیابی کیفی کورکورانه توسعه وب (Kimi Webdev Bench) در برابر Claude Opus 4.8، مدل Kimi K3 در مجموع به برتری قاطع +۰.۳۱٪ (با پیروزی در ۶۰.۵۸٪ پرامپت‌ها) و در حوزه تخصصی گرافیک 3D/WebGL به برتری +۱.۵۹٪ دست یافته است (جدول ۳۵).

جدول ۳۵: نتایج داوری کورکورانه کارشناسان در بنچمارک توسعه وب (Kimi Webdev Bench) بر بستر چارچوب Claude Code

حوزه ارزیابی (Domain)	درصد برد (Win)	درصد مساوی (Tie)	درصد باخت (Lose)	تفاضل برد (Lose – Win)
بازی‌ها (Games)	۶۰.۵۵	۷.۰۳	۷.۴۰	۹۰.۱۴+
گرافیک سه‌بعدی و شیدر (3D / WebGL / Shader)	۷۰.۷۲	۷.۱۳	۶.۱۳	۱۰۰.۵۹+
شبیه‌سازی رابط کاربری و سایت (Website / UI Clone)	۶۰.۵۲	۱.۰۲۱	۳.۰۲۶	۳۰.۲۶+
عملکرد کل (Overall)	۶۰.۵۸	۸.۰۱۳	۶.۰۲۷	۰.۳۱+

مطالعات موردی و توانمندی‌های تعاملی عمیق (Case Studies) شواهد تجربی نشان‌دهنده عمق نفوذ داده‌های آموزشی پس‌آموزش در رفتارهای دنیای واقعی مدل است:

- **بهینه‌سازی بلادرنگ کرنل‌های سخت‌افزاری:** مدل تاخیر اجرای کرنل AttnRes را از ۶.۲۸۳ میلی‌ثانیه به ۴.۱۱۴ میلی‌ثانیه تقلیل داد (بهبود +۷.۵۹٪) و زمان اجرای KDA را تا ۶۰.۷۳٪ کاهش بخشید.

- **توسعه مستقل کامپایلر MiniTriton:** مدل به صورت خوداتکا یک کامپایلر کامل شبیه Triton به همراه کدهای اسمبلی PTX و زمان اجرای CUDA ساخت که در ضرب ماتریسی به ۹۰٪ توان تئوری سخت‌افزار (cuBLAS) رسید.

- **طراحی خودکار چیپ Nano-KPU:** در یک اجرای ۴۸ ساعته خودمختار، مدل یک مدار مجتمع کامل سخت‌افزاری را در کتابخانه ۴۵ نانومتری طراحی، شبیه‌سازی و اعتبارسنجی کرد که در فرکانس ۱۰۰ مگاهرتز با توان عملیاتی بیش از ۸,۷۰۰ توکن بر ثانیه کار می‌کند.

جدول ۳۶: ارزیابی جامع عملکرد مدل Kimi K3 در بنچمارک‌های حوزه‌ای درون‌سازمانی در مقایسه با مدل‌های تجاری و باز

دسته بنچمارک	چارچوب (Harness)	(max) Kimi K3	(max) Fable 5	(max) GPT-5.6 Sol	(max) Opus 4.8	(xhigh) GPT-5.5	(max) GLM-5.2
تجربه و مهارت کدنویسی (Coding Experience)							
Kimi Code Bench 2.0	Claude Code	۷.۷۳	۹.۷۶	-	۷.۷۱	-	۲.۶۴
	Kimi Code	۹.۷۲	-	-	-	۰.۶۶	-
	Codex	-	-	۸.۶۴	-	۰.۶۹	-
Coding Experience	Claude Code	۹.۵۹	۸.۵۹	-	۰.۵۸	-	۳.۵۳
	Kimi Code	۶.۵۶	-	-	-	-	-
	Codex	-	-	۳.۵۹	-	۸.۵۶	-
تجربه عاملی عمومی (General Agent Experience)							
24/7 ClawBench 2.0	OpenClaw	۳.۴۸	۴.۴۷	۰.۵۲	۲.۴۷	۵.۴۸	۲.۴۳
MIRA Bench	MIRA	۱.۶۴	۹.۷۲	۲.۶۲	۸.۵۹	۶.۵۴	-
KAET	Kimi Code	۵.۸۳	-	۴.۸۵	۷.۷۸	۷.۷۹	۷.۷۴
CLIF Bench	Kimi Code	۴.۵۲	-	۶.۵۰	۸.۴۸	۳.۵۲	۲.۳۹
Agentic Vision Bench	Kimi Code	۳.۷۸	۱.۸۱	۹.۸۲	۸.۸۲	۹.۷۶	-
Swarm Bench	Kimi Agent	۳.۷۶	-	۲.۷۳	۶.۷۲	۸.۶۱	۵.۵۸
Online Experience	Kimi Agent	۹.۷۷	۲.۷۴	۰.۸۴	۴.۶۹	۷.۷۳	۰.۶۴
Deep Research Bench	Kimi Agent	۰.۹۰	-	۳.۸۵	۲.۸۷	۹.۸۱	۰.۸۴
Finance Bench	N/A	۶.۶۲	-	۷.۶۲	۷.۶۰	۴.۵۸	۴.۵۵
KWV Bench	N/A	۷.۶۴	۶.۶۳	۹.۶۶	۶.۶۱	۸.۶۵	-
DECK Bench	N/A	۵.۷۳	۰.۷۳	۷.۷۴	۹.۶۶	۲.۶۸	۶.۶۸
Agent Behavior Bench	Kimi Work	۰.۶۵	۵.۷۵	۴.۷۶	۷.۶۵	۱.۷۰	-
تجربه گفتگو و دقت (Conversational Experience)							
(1 – Hallucination) Faithfulness	N/A	۵.۸۵	-	۸.۸۴	۶.۸۳	۵.۸۶	۸.۷۴
Chat All-in-One Bench	Kimi Work	۲.۸۵	۰.۸۸	۰.۷۹	۸.۸۳	۸.۷۱	-

– **پژوهش‌های کلان علمی و تحلیلی:** تحلیل ۳۹۱ رویداد امواج گرانشی با سازمان‌دهی همزمان بیش از ۲۰ ساب‌عامل موازی (Swarm)، و همچنین پردازش بیش از ۱۱,۰۰۰ صفحه گزارش مالی جهت تدوین تاریخچه ۴۲ ساله تراشه‌های ASIC.

• Magistral

مقدمه و پارادایم داده‌ای پس‌آموزش (Post-Training Data Paradigm) فاز پس‌آموزش (Post-Training) در مدل‌های استدلالی خانواده Magistral با هدف ارتقای قابلیت‌های زنجیره تفکر عمیق (Chain-of-Thought - CoT) بدون اتکا به تقطیر از مدل‌های انحصاری پیشین توسعه یافته است [۱۰۳، ۱۲۵]. در این چارچوب، دو مدل با راهبردهای داده‌ای متمایز آموزش دیده‌اند:

– **مدل Magistral Medium:** مبتنی بر وزن‌های پایه Mistral Medium 3 [۱۲۶] که فرایند پس‌آموزش آن صرفاً با یادگیری تقویتی آنلاین (Pure RLVR) و بدون هیچ‌گونه داده راه‌اندازی اولیه استدلالی (Cold-Start) به انجام رسیده است.

– **مدل Magistral Small (24B):** مبتنی بر Mistral Small 3 که فرایند پس‌آموزش آن شامل یک فاز تنظیم دقیق تحت نظارت (SFT) با ردپاهای استدلالی پالایش‌شده و سپس یادگیری تقویتی تکمیلی (RL) است.

در این چارچوب، یک دوگانگی بنیادین در ویژگی‌های آماری داده‌ها شناسایی شده است: الگوریتم‌های بهینه‌سازی تقویتی مبتنی بر پاداش‌های قابل راستی‌آزمایی (RLVR) نیازمند مجموعه داده‌ای با حجم کم، خلوص فوق‌العاده بالا و سختی بسیار زیاد هستند؛ در حالی که فاز تنظیم نظارتی (SFT) به تنوع گسترده پرامپت‌ها (Prompt Diversity) برای حفظ آنتروپی و توزیع طول استدلال نیاز دارد.

خط‌لوله پالایش و گزینش داده‌های ریاضی (Math Data Curation) داده‌های حوزه ریاضیات طی یک خط‌لوله پالایش دوسطحی شامل فیلترینگ صوری و فیلترینگ سختی مبتنی بر مدل غربال‌گری شدند:

– **پالایش صوری و اعتبارسنجی قطعی (Format Filtering):** از میان مجموعه داده اولیه شامل ۶۹۹ هزار نمونه، تمامی مسائل اثباتی کیفی (Proof-based) و چندبخشی که ارزیابی ماشینی آن‌ها با ابزارهای قطعی میسر نبود حذف شدند. همچنین مسائل چندگزینه‌ای به مسائل گزاره‌ای با پاسخ صریح عددی یا عبارتی تبدیل شدند تا احتمال پاسخ‌دهی تصادفی به صفر برسد و امکان

استفاده از موتور محاسبات نمادین SymPy برای انطباق معنایی پاسخ‌ها فراهم گردد. این مرحله حجم داده‌ها را به ۵۰۱ هزار نمونه تقلیل داد.

– **غربالگری سختی دو مرحله‌ای در منطقه گلدیلوکس (Goldilocks Filtering):** برای جلوگیری از نمونه‌های بسیار ساده (با مزیت صفر) یا غیرقابل حل (بدون سیگنال یادگیری)، فرایند ارزیابی دو مرحله‌ای پیاده‌سازی شد:

۱. در مرحله نخست، با استفاده از مدل Mistral Large 2 [۲۰] به ازای هر مسئله ۱۶ راه‌حل نمونه‌گیری شد و مسائل دارای نرخ موفقیت ۱۰۰٪ یا ۰٪ حذف شدند. داده‌های حاصل برای آموزش یک مدل ۲۴ میلیارد پارامتری ارزیاب سختی به کار رفت.

۲. در مرحله دوم، مدل ارزیاب ۲۴B آموزش‌دیده با RL کل مجموعه ۵۰۱ هزارتایی را مجدداً با ۱۶ پاسخ به ازای هر مسئله باز-ارزیابی کرد تا از حذف اشتباه مسائل دشوار توسط مدل عمومی جلوگیری شود.

– **پالایش بر پایه تضاد اجماع (Consensus-Disagreement Filtering):** مسائلی که در آن‌ها اکثریت پاسخ‌های تولیدی مدل بر سر یک جواب به اجماع می‌رسیدند اما با پاسخ برچسب‌گذاری‌شده (Ground Truth) تضاد داشت، به عنوان خطای برچسب مبنا شناسایی و از مجموعه داده حذف شدند:

$$\text{mode}(\{y_i\}_{i=1}^{16}) \neq y_{\text{GT}} \quad \wedge \quad \frac{1}{16} \sum_{i=1}^{16} \mathbb{I}(y_i = \text{mode}) \geq \tau \quad (44)$$

در پایان این فرآیند، تنها ۳۸ هزار مسئله فوق‌العاده خالص و چالش‌برانگیز برای فاز یادگیری تقویتی گزینش گردید (جدول ۳۷).

جدول ۳۷: مراحل پالایش و حجم دادگان آموزش ریاضی مدل Magistral

مرحله فیلترینگ	تعداد داده‌ها	درصد بقا نسبت به کل
داده‌های اولیه خام (Initial Raw Data)	۶۹۹,۰۰۰	۱۰۰٪
پس از پالایش صوری و اعتبارسنجی (Format Filtering)	۵۰۱,۰۰۰	۷۱٪
پس از ارزیابی سختی و اجماع (Difficulty Filtering)	۳۸,۰۰۰	۵٪

مهندسی داده‌های کدنویسی و آزمون‌های ارزیابی (Code Data Engineering) پیکره کدنویسی بر پایه مسائل رقابتی برنامه‌نویسی با الزامات اعتبارسنجی زیر طراحی شد:

– **پالایش و اصلاح آزمون‌ها با اجماع اجرا (Test-Case Agreement):** مسائل فاقد آزمون جامع یا راه‌حل‌های مرجع حذف شدند. راه‌حل‌های معتبر روی تمامی آزمون‌ها اجرا شده و آزمون‌های مبهم حذف گردیدند. چنانچه تمامی راه‌حل‌ها روی یک آزمون با خروجی یکسان مردود می‌شدند، خروجی آزمون بر اساس اجماع راه‌حل‌ها اصلاح گردید.

– **تولید آزمون‌های سنتتیک (Synthetic Test Generation):** برای مسائلی که پوشش تست محدودی داشتند، موارد آزمون تکمیلی به صورت خودکار تولید و صحت‌سنجی شدند.

– **تکثیر زبانی مسائل (Language Duplication):** مسائل به‌گونه‌ای تنظیم شدند که پیاده‌سازی را به دو زبان پرکاربرد Python و C++20 (با استفاده از هدر از پیش کامپایل‌شده `bits/stdc++.h`) بطلبند. این فرایند مجموعه‌ای متشکل از ۳۵ هزار مسئله برنامه‌نویسی تمیز را شکل داد.

چندزبانگی و راهبرد مهار جابه‌جایی زبانی (Multilingual Data Strategy) به منظور جلوگیری از پدیده اختلاط ناخواسته زبان‌ها (Code-Switching) در طول زنجیره تفکر:

– **ترجمه متوازن مسائل:** ۱۰ درصد از کل مسائل ریاضی و کدنویسی انگلیسی به ۶ زبان فرانسوی، اسپانیایی، ایتالیایی، آلمانی، چینی و روسی ترجمه شد.

- **پاداش‌دهی بر پایه طبقه‌بند FastText:** با بهره‌گیری از طبقه‌بند زبانی [۲۱]، سه‌گانه صورت مسئله (Q) ، افکار درونی (C) و پاسخ نهایی (A) پس از حذف نشانه‌های ساختاری و کدهای برنامه‌نویسی اعتبارسنجی شد:

$$R_{\text{lang}}(Q, C, A) = \begin{cases} +0.1, & \text{if } \mathcal{C}_{\text{FastText}}(Q) = \mathcal{C}_{\text{FastText}}(C) = \mathcal{C}_{\text{FastText}}(A) \\ 0, & \text{otherwise} \end{cases} \quad (۴۵)$$

داده‌های راه‌اندازی سرد (Cold-Start SFT Data) برای مدل کوچک برای مدل Magistral Small (24B)، فاز راه‌اندازی اولیه با ترکیب داده‌های زیر اجرا گردید:

- **ردپاهای استخراج‌شده از Magistral Medium:** راه‌حل‌های صحیح ثبت‌شده در طول آموزش RL مدل بزرگ‌تر، با فیلتر کردن گام‌های ابتدایی و کوتاه، گزینش شدند. برای جلوگیری از سوگیری به سمت مسائل ساده، تعداد تولیدها به ازای هر مسئله محدود شد و مسائل دشوارتر بیش‌نمونه‌گیری (Upsample) شدند.

- **پرامپت‌های متنوع خارجی:** استفاده از مخازن متنی متنوع شامل مجموعه‌های OpenThoughts [۲۲] و OpenR1 [۱۲۷، ۱۲۸] که راه‌حل‌های آن‌ها توسط Magistral Medium تولید و غربال شدند.

- **داده‌های عمومی دستورالعمل (General Alignment):** تزریق ۱۰ درصد داده‌های مکالمه عمومی و پیروی از دستورات به پیکره SFT جهت حفظ توانمندی‌های غیر استدلالی نظیر فراخوانی ابزار (Tool Calling).

مدل پایه Mistral Small 3 Instruct برای مدت ۴ دوره (Epochs) روی این ترکیب آموزش دید و سپس وارد فاز RL شد.

ردپاهای متن‌باز در مقیاس بزرگ (Large-Scale OSS Traces) در یک سناریوی پژوهشی مستقل، مدل Mistral Medium 3 با ۳.۱ میلیون ردپای استدلالی برآمده از مدل DeepSeek-R1 (برگرفته از OpenThoughts و OpenR1) تنظیم نظارتی گردید. سپس یادگیری تقویتی صرفاً روی دشوارترین زیرمجموعه مسائل اعمال شد که موجب جهش بیش از ۱۰ واحد درصدی در بنچمارک AIME'25 و ۵ واحد درصدی در LiveCodeBench شد و سطح عملکردی هم‌تراز با مدل‌های پیشرو ایجاد نمود.

تدریج داده‌ای و پویایی طول بافت (Curriculum & Length Dynamics) فرآیند آموزش تقویتی به شیوه برنامه درسی مرحله‌ای (Curriculum) مدیریت شد:

- **پویایی سختی داده‌ها:** همگام با تسلط مدل، مسائل کاملاً حل‌شده از چرخه خارج و مسائل دشوارتر جایگزین گردیدند.

- **برنامه درسی طول تولید:** سقف طول تولید بدون جریمه $(l_{\text{max}} - l_{\text{cache}})$ در سه گام متوالی از 16K به 24K و سپس به 32K توکن افزایش یافت.

- **مقیاس دسته‌ها:** به منظور مدیریت بار حافظه جدول KV-Cache همگام با افزایش طول توالی‌ها، اندازه دسته دنباله‌ها (n_{batch}) در سه مرحله از 8K به 4K و سپس به 2K کاهش داده شد.

فرمولاسیون ریاضی راستی‌آزمایی و پاداش‌دهی داده‌ها (Verifiable Reward Formulation) در خط لوله بهینه‌سازی سیاست گروهی نسبی (GRPO) [۲۴، ۱۲۹]، امتیاز هر نمونه بر اساس رابطه زیر تخصیص می‌یابد:

$$r_i = R_{\text{format}} + R_{\text{correctness}} + R_{\text{lang}} + R_{\text{length}} \quad (۴۶)$$

که در آن پاداش قالب‌بندی $R_{\text{format}} \in \{0, 0.1\}$ شرط ورود به تصحیح پاسخ است. پاداش درستی $R_{\text{correctness}} \in \{0, 0.9\}$ در صورت موفقیت کامل محاسباتی یا عبور از آزمون‌های کدنویسی اعطا می‌شود و تابع پیوسته جریمه طول به فرم زیر محاسبه می‌گردد:

$$R_{\text{length}}(y) = \begin{cases} 0, & |y| \leq l_{\text{max}} - l_{\text{cache}} \\ -0.1 \cdot \frac{|y| - (l_{\text{max}} - l_{\text{cache}})}{l_{\text{cache}}}, & l_{\text{max}} - l_{\text{cache}} < |y| \leq l_{\text{max}} \\ -0.1, & |y| > l_{\text{max}} \end{cases} \quad (47)$$

تعمیم‌پذیری بین‌حوزه‌ای و چندوجهی ناشی از داده‌های متنی (Data Generalization) تحلیل رفتار مدل آموزش‌دیده با داده‌های تفکیک‌شده حقایق تجربی مهمی را آشکار ساخت:

- **انتقال بین ریاضی و کد (Cross-Domain Transfer):** مدل ۲۴B آموزش‌دیده صرفاً با داده‌های ریاضی توانست عملکرد خود در بنچمارک کدنویسی LiveCodeBench را از ۷٪.۲۲ به ۳٪.۳۸ (+۶.۱۵ واحد درصد ارتقای برون‌دامنه) برساند؛ همچنین آموزش صرفاً با داده‌های کد، دقت ریاضی در AIME'24 را ۵.۱۷+ واحد درصد بهبود بخشید (جدول ۳۸).
- **ارتقای رایگان درک چندوجهی (Multimodal Free Lunch):** علی‌رغم این‌که فرایند RL تنها بر روی داده‌های متنی محض اجرا شد، مدل به واسطه گسترش زنجیره تفکر توانست عملکرد در آزمون‌های استدلال چندوجهی نظیر MMMU را از ۰.۶۵٪ به ۰.۷۰٪ و در MMMU-Pro (Vision) را از ۷٪.۳۹ به ۱٪.۵۲ (+۴.۱۲ واحد درصد ارتقا) برساند [۱۳۰، ۱۳۱].

جدول ۳۸: تعمیم‌پذیری بین‌حوزه‌ای در آموزش‌های تک‌دامنه‌ای مدل Mistral Small 24B

پیکربندی آموزش داده	AIME'24 (Pass@1)	LiveCodeBench v5 (Pass@1)
چک‌پوینت اولیه (Starting Checkpoint)	۲٪.۳۲	۷٪.۲۲
آموزش صرفاً با داده‌های ریاضی (RL Math only)	۵٪.۶۲	۳٪.۳۸ (+۶٪.۱۵)
آموزش صرفاً با داده‌های کدنویسی (RL Code only)	۷٪.۴۹ (+۵٪.۱۷)	۷٪.۴۲

رویکردهای ناموفق در مهندسی پاداش داده‌ها (Negative Results) دو راهبرد پیشنهادی در فاز پردازش پاداش داده‌ها با شکست مواجه شدند:

- **پاداش متناسب برای آزمون‌های کدنویسی (Proportional Rewards):** اعطای پاداش بر اساس نسبت تست‌های پاس‌شده منجر به افت ۲ درصدی در بنچمارک LiveCodeBench و مهار رشد طول زنجیره تفکر شد؛ چرا که سیگنال‌های کاذب به کدهای واجد خطاهای الگوریتمی اختصاص می‌یافت.
- **جریمه آنتروپی در تلفات (Entropy Bonus):** افزودن ترم آنتروپی به تابع زیان پایداری آموزش را برهم زد (افت شدید آنتروپی در ریاضی و انفجار آنتروپی در کد). در مقابل، تنظیم مستقیم حد بالای برش $\varepsilon_{\text{high}}$ در بازه $[0.26, 0.28]$ پایداری بهینه‌سازی را تضمین کرد.

ارزیابی آماری جامع پیکربندی‌های داده‌ای پس‌آموزش جدول ۳۹ عملکرد نهایی مدل‌ها تحت استراتژی‌های گوناگون داده‌های پس‌آموزش را مقایسه می‌کند. این نتایج اثبات می‌کنند که مدل **Magistral Medium** صرفاً با اتکا بر ۳۸ هزار داده ریاضی و ۳۵ هزار داده کدنویسی به جهش چشمگیر در AIME'24 (از ۸٪.۲۶ به ۶٪.۷۳ در سناریوی Pass@1 و ۰.۹۰٪ در سناریوی Maj@64) دست یافته است.

• MiniMax-M2

جدول ۳۹: مقایسه عملکردی مدل‌های Magistral بر اساس پیکربندی‌های مختلف داده‌های پس‌آموزش

مدل	ترکیب داده SFT	ترکیب داده RL	AIME'24 (Pass@1)	AIME'25 (Pass@1)	MATH-500	LCB v5
Mistral Medium 3 Magistral Medium	داده عمومی چت فاقد SFT	فاقد RL ۳۸k ریاضی + ۳۵k کد	۸٪.۲۶ ۶٪.۷۳	۲٪.۲۱ ۹٪.۶۴	۰٪.۹۱ ۳٪.۹۴	۱٪.۲۹ ۴٪.۵۹
Mistral 24B (SFT only) Mistral 24B (RL only)	ردپاهای Medium + مخازن وب فاقد SFT	فاقد RL ۳۸k ریاضی + ۳۵k کد	۴٪.۶۵ ۸٪.۶۵	۶٪.۵۵ ۹٪.۵۱	۲٪.۹۳ ۴٪.۹۵	۲٪.۵۲ ۴٪.۴۶
Magistral Small (24B)	ردپاهای Medium + عمومی (۴ دوره)	۳۸k ریاضی + ۳۵k کد	۷٪.۷۰	۸٪.۶۲	۹٪.۹۵	۸٪.۵۵

مقدمه و فلسفه بنیادین داده‌های پس‌آموزش عاملی سری مدل‌های MiniMax-M2 (شامل نسخه‌های M2.5، M2 و نگارش خودتکامل‌یافته M2.7) بر پایه دکتترین «فعال‌سازی‌های کمینه، آزادسازی بیشینه هوش در دنیای واقعی» (Mini Activations Unleashing Max Real-World Intelligence) پایه‌ریزی شده‌اند. معماری پایه مدل یک ترنسفورمر دیکودر محور با ۹.۲۲۹ میلیارد پارامتر کل است که با بهره‌گیری از سازوکار خبرگان ریزدانه (Fine-Grained MoE) [۲۸]، در هر گام محاسباتی تنها ۸.۹ میلیارد پارامتر را به ازای هر توکن فعال می‌نماید (فعال‌سازی ۸ خبره از میان ۲۵۶ خبره از طریق دروازه‌بانی سیگموئید با بایاس یادگیرنده بدون نیاز به زیان کمکی [۱۳۲]).

اگرچه مدل پایه روی ۲.۲۹ تریلیون توکن پیش‌آموزش دیده است، قابلیت‌های پیشرفته آن در سناریوهای استدلال بلندمدت، وظایف عاملی (Agentic workflows) و حل مسائل پیچیده صنعتی، تماماً در فاز پس‌آموزش (Post-training) شکل گرفته است. هسته اصلی مهندسی داده‌های پس‌آموزش این مدل، ارجحیت قاطع «کیفیت و تاییدپذیری پاداش مسیرها بر حجم داده‌ها» است. در این راستا، کلیه خطوط لوله بر پایه محیط‌های اجرایی واقعی و ایزوله (Executable Workspaces) و سیگنال‌های پاداش تاییدپذیر و منسجم با مصنوع نهایی (Artifact-Aligned Verifiable Rewards) سازمان‌دهی شده‌اند.

خط لوله مهندسی نرم‌افزار سازمانی (SWE-Scaling Pipeline) برای آموزش عامل‌های مهندسی نرم‌افزار سازمانی در مقیاس بالا و رفع نویز ذاتی مخازن گیت‌هاب، یک خط لوله شش‌مرحله‌ای خودکار و عامل‌محور توسعه یافته است [۱۳۳]:

- **گردآوری و پالایش درخواست‌های ادغام (PR Collection & Filtering):** خزش در مخازن عمومی گیت‌هاب با مجوزهای آزاد، استخراج جفت‌های PR و Issue ادغام‌شده و فیلترگذاری مبتنی بر قواعد سخت‌گیرانه همراه با الزام حضور آزمون‌های واحد معتبر.
- **سنتز محیط‌های داکر چندزبانه توسط عامل (Agent-Synthesized Docker):** در زبان‌های کامپایلری مانند Rust، Go، Java، C++ و ++C، یک عامل خودکار در یک چرخه تکرارشونده، اسکریپت‌های ساخت (Build Scripts) را تنظیم، در محیط کانتینری اجرا و خطاهای وابستگی را تا حصول محیط پایدار خود-اصلاح می‌کند. این فرآیند بیش از ۱۰ زبان برنامه‌نویسی را پوشش می‌دهد.
- **برچسب‌گذاری و مسیریابی وظایف (PR Tagging & Routing):** تفکیک وظایف به دسته‌های رفع باگ (Bug Fix)، افزودن قابلیت (Feature Add)، بهینه‌سازی کارایی (Performance Optimization) و بازسازی کد به منظور طراحی توابع پاداش متمایز.
- **طراحی پاداش تاییدپذیر آزمون‌محور (Verifiable Reward Construction):** در سناریوی رفع باگ، آزمون‌های شکست‌به-موفقیت (Fail-to-Pass - F2P) و موفقیت‌به-موفقیت (Pass-to-Pass - P2P) استخراج می‌شوند تا عدم بازگشت باگ‌های جانبی تضمین گردد. در افزودن قابلیت، آزمون‌های جدید برای ارزیابی مستقیم مؤلفه اضافه می‌شوند و در بهینه‌سازی کارایی، پایداری تفاوت کارایی قبل و بعد از اعمال تغییرات اندازه‌گیری می‌شود.
- **اعتبارسنجی وظیفه با مدل (Model-based Task Validation):** مدل ارزیاب، سازگاری میان شرح مسئله و آزمون‌ها را بررسی و اطلاعات ناقص را جهت خودبسنده‌سازی مسئله بازتولید می‌کند.
- **دگرگونی و افزایش تنوع دادگان (Task Transformations):** شامل تزریق عمدی باگ (Bug Injection)، ادغام کامیت‌های مجاور جهت ساخت مسائل چندمرحله‌ای [۱۳۴]، وارونه‌سازی مسئله به آزمون‌نویسی (SWE-Test Conversion) و وظایف مرور ایستا و تحلیل نقایص کد (Code Review).

خط لوله توسعه نرم افزار با هدایت خبرگان (AppDev Pipeline) توسعه اپلیکیشن از صفر مستلزم ارزیابی رفتار زمان اجرا و کیفیت طراحی است. در این حوزه از چارچوب ترکیبی زیر بهره گرفته شده است:

- **سنتز کوئری با حضور خبره در حلقه (Expert-in-the-Loop):** مهندسان خبره قالب های متاروش (Meta Queries) شامل معماری ها و پشته های فناوری مدرن (نظیر React + Zustand + Tailwind) را تدوین می کنند. پس از نمونه برداری با دمای بالا، داده های تکراری با الگوریتم MinHash در زمان خطی $O(N)$ حذف شده و توسط قاضی مدل زبانی بر اساس سه معیار عقلانیت پشته، امکان پذیری فنی و وضوح الزامات اعتبارسنجی می شوند.
- **تقطیر پرامپت (Prompt Distillation Asymmetry):** جهت حذف عادات نامطلوب طراحی (مانند پس زمینه های گرادیانی قالبی)، پرامپت های غنی به عامل آموزش می دهند که پیش از پیاده سازی، سند مشخصات بنویسد و فهرست TODO تهیه کند. در زمان نمونه برداری مسیرها، پرامپت کامل اعمال می شود اما در زمان آموزش، بخش هایی از آن تعمداً حذف می گردد تا مدل این رفتارهای بهینه را درونی سازی کند.
- **عامل به مثابه اعتبارسنج (Agent-as-a-Verifier - AaaV):** اپلیکیشن در محیط ایزوله مستقر شده و با کتابخانه Playwright در سه لایه سلسله مراتبی بررسی می شود:
 ۱. لایه اجرا (Execution Layer): بررسی نصب پکیج ها، بیلد بدون خطا و نبود خطاهای JavaScript در کنسول (عدم قبولی در این لایه موجب رد فوری است).
 ۲. لایه تعامل (Interaction Layer): راستی آزمایی کارکرد دکمه ها، ارسال فرم ها و اجرای موفقیت آمیز سناریوهای کاربری.
 ۳. لایه زیبایی شناسی بصری (Visual Aesthetics Layer): امتیازدهی به توازن چیدمان، هارمونی رنگ ها و ارگونومی رابط کاربری.

چارچوب پایانه تعاملی (Terminal-Gym) برای شبیه سازی سیستم عامل و تعاملات خط فرمان، پایگاه داده استک اورفلو پالایش شده و پست های اسکریپت پذیر، تاییدپذیر و سازگار با لینوکس استخراج شدند [۱۳۵]. این خط لوله با تولید خودکار Dockerfile، آزمون های یکپارچه و انتزاع سرخ های متنی، پلتفرم پایداری را برای سناریوهای پیشرفته نظیر CVE-Factory [۱۳۶] و ابزارهای مهندسی خودکار فراهم می سازد.

خط لوله های داده های همکاری عاملی (Agentic Cowork) این بخش شامل چهار حوزه با محیط های کاری اجرایی و شبیه سازی شده است:

- **جستجوی عمیق و وب پژوهی (Deep Search):** استفاده از راهبرد هدایت-و-بازنویسی (Guide-and-Rewrite) که در آن موجودیت های سوال پنهان می شوند تا مدل ناچار به ناوبری چندمرحله ای در وب گردد. مسیرها تنها در صورتی تایید می شوند که پاسخ نهایی مستقیماً بر مبنای شواهد بازیابی شده مستند باشد نه حافظه پارامتریک مدل.
- **وظایف اداری و کارکنان دانشی (Office Tasks):** با الهام از بنچمارک GDPval [۱۳۷]، وظایف متنوع حرفه ای سنتز شده و با فیلتر دقیق ارجاعات، از تولید داده های ساختگی و توهم جلوگیری می شود.
- **تحلیل مالی و صفحات گسترده (Financial & Spreadsheets):** شامل دو شیوه سنتز داده است: سنتز مبتنی بر شواهد [۱۳۸] که طی آن ابتدا ابزار مالی اجرا و سپس مسئله بر مبنای خروجی آن نگاشته می شود؛ و شیوه پیمایش کاربرگ [۱۳۹] که با اعمال تغییرات متوالی روی اکسل، وضعیت های میانی ذخیره و تطابق قطعی محاسبات ارزیابی می گردد.
- **تولید و ویرایش اسلاید (Slide Generation):** شامل طراحی افزایشی اسلایدها در سطوح عنصری و سندی با اعتبارسنجی بصری رندر توسط مدل های بینایی ماشین.

داده‌های استدلال، مکالمه و نقش‌آفرینی برای وظایف استدلال عمیق ریاضی و علمی، مقیاس‌گذاری در سه محور دنبال شده است: تنوع مسائل (Query-Side)، تولید چندین مسیر حل معتبر به ازای هر مسئله جهت تقویت تعمیم‌پذیری خارج از دامنه (Response-Side) و تنظیم پویا و بهینه نسبت ترکیب داده‌ها (Training-Side). در مکالمه همه‌منظوره، داده‌های زنجیره تفکر طولانی (Long CoT) با یک سیستم فایل تلفیق شده‌اند تا مهارت کار با اسناد تقویت شود. در بخش نقش‌آفرینی (Role-Play) [۱۴۰]، تولید شرطی روی فضای $\{\text{داستان‌ها}\} \times \{\text{جهان‌ها}\}$ تحت قید اولویت‌های کاربر مدل‌سازی شده و از الگوریتم‌های RLHF مبتنی بر استنتاج علی و پایش آنتروپی برای رفع هک پاداش استفاده گردیده است.

فرمول‌بندی تفکر متناوب در داده‌های SFT در فاز تنظیم دقیق با نظارت (SFT)، داده‌ها به شیوه تفکر متناوب (Interleaved Thinking) مدل‌سازی می‌شوند که در آن توکن‌های استدلال a_t ، اقدامات o_t و مشاهدات محیطی o_t در یک چرخه تکرار می‌شوند:

$$\tau = (r_1, a_1, o_1, r_2, a_2, o_2, \dots, r_T, a_T, o_T) \quad (۴۸)$$

ویژگی کلیدی این داده‌ها، تداوم حالت استدلال (Reasoning State Persistence) است که در آن کل خروجی‌های تفکر نوبت پیشین در تاریخچه مکالمه $\mathcal{H}$ باقی می‌مانند:

$$\mathcal{H}_{t+1} = \mathcal{H}_t \oplus [\text{assistant}(r_t, a_t)] \oplus [\text{tool}(o_t)] \quad (۴۹)$$

برخلاف ساختارهای فاقد حالت (Stateless) که تفکر پیشین حذف شده و مدل دچار خطای انباشته در استنتاج می‌گردد، این ساختار چرخه شناختی سه‌گانه «برنامه‌ریزی، اقدام و بازاندیشی» (Plan-Act-Reflect) را تقویت می‌نماید.

مدل‌سازی داده‌ها در سیستم یادگیری تقویتی Forge تعامل عامل با محیط به عنوان یک فرآیند تصمیم‌گیری مارکوف $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R}, \gamma)$ با تابع انتقال $s_{t+1} = f_{\text{trans}}(s_t, a_t, o_t)$ مدل می‌شود. بهینه‌سازی از طریق الگوریتم CISPO [۱۴۱] با نسبت اهمیت بریده‌شده نامتقارن صورت می‌پذیرد:

$$J_{\text{CISPO}}(\theta) = \mathbb{E}_{\substack{(q,a) \sim \mathcal{D} \\ \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}}} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \text{sg}(\hat{r}_{i,t}(\theta)) \hat{A}_{i,t} \log \pi_{\theta}(o_{i,t} | q, o_{i,<t}) \right] \quad (۵۰)$$

که در آن عملگر برش نسبت اهمیت به صورت زیر اعمال می‌شود:

$$\hat{r}_{i,t}(\theta) = \text{clip} \left(\frac{\pi_{\theta}(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})}, 0, 1 + \epsilon_{\text{high}}^{\text{IS}} \right) \quad (۵۱)$$

تابع پاداش ترکیبی گام‌ها به فرم زیر تدوین شده است که پاداش ساختاری فرآیند، سرعت اجرا بر پایه تابع نزولی $h(\cdot)$ و صحت دستاورد نهایی را یکپارچه می‌سازد:

$$r_t = \alpha \cdot r_t^{\text{process}} + \beta \cdot h \left(\frac{T_{\text{completion}}}{T_{\text{baseline}}} \right) + r_t^{\text{perf}} \quad (۵۲)$$

در زیرساخت توزیع داده‌ها، از استراتژی زمان‌بندی پنجره‌ای خروج به ترتیب ورود (Windowed FIFO) با اندازه پنجره $W = 0.3N$ و ادغام درخت پیشوند (Prefix Tree Merging) استفاده شده است. این نوآوری با محاسبه تنها یک‌بار بافت‌های طولانی مشترک در طول انتشار رو به جلو، ضمن انطباق ریاضی کامل، **شتاب بخشی تا ۴۰ برابر** را در پردازش داده‌های آموزش تقویتی به ارمغان می‌آورد.

خودتکاملی داده‌ای و اسکلت‌بندی (Self-Evolution) در مدل MiniMax-M2.7، چرخه تولید و تحلیل داده‌های شکست با اتکا بر سامانه تکرار مدل (Model Iteration System) خودکارسازی شده است. اسکلت تعاملی عامل کاملاً توسط نسخه درونی مدل بدون دخالت برنامه‌نویس انسانی پیاده‌سازی شده است. مدل به طور مداوم لاگ‌های آموزشی و ناهنجاری متریک‌ها را ریشه‌یابی کرده و با اصلاح کدهای پایپ‌لاین و فایل‌های تنظیمات، ۳۰ تا ۵۰ درصد بار کاری توسعه را خودکار نموده است. این سامانه در یک ارزیابی ۱۰۰ مرحله‌ای خودمختار، کارایی اسکلت ابزاری خود را تا ۳۰ درصد ارتقا داد.

ارزیابی‌های آماری و تجربی فاز پس‌آموزش جدول ۴۰ نشان‌دهنده ارزیابی داده‌های SFT در مقیاس معماری مدل M2 میان سازوکار توجه کامل (Full Attention) و پنجره لغزان ترکیبی (Hybrid SWA) است. نتایج اثبات می‌کند که با افزایش طول بافت به بیش از ۳۲ هزار توکن در وظایف عاملی، توجه کامل به دلیل پوشش جامع حافظه عملکرد بسیار برتری را به ثبت می‌رساند.

جدول ۴۰: ارزیابی داده‌های SFT در مقیاس مدل MiniMax-M2: مقایسه توجه کامل و پنجره لغزان

دامنه ارزیابی	بنچمارک (Benchmark)	خط پایه (Full Attention)	پنجره لغزان (w/ SWA)
استدلال عمومی و دانش	AIME 2025	۷.۸۶	۷.۸۶
	ARC-AGI-1	۹.۳۸	۶.۳۹
	GPQA-Diamond	۳.۷۵	۷.۷۲
	MMLU-Pro	۵.۸۰	۱.۸۰
	IFBench	۱.۲۳	۲.۲۷
وظایف عاملی بافت طولانی	SWE-verified	۷.۵۴	۲.۵۰
	Terminal-Bench	۷.۲۶	۸.۲۳
	BrowseComp-zh	۸.۳۲	۷.۲۸
	GAIA-103	۴.۵۳	۵.۵۱
	XBench-ds	۰.۵۸	۰.۶۳
	τ^2 -Bench retail	۳.۶۲	۵.۶۷
	τ^2 -Bench telecom	۵.۳۲	۰.۲۱

جدول ۴۱ عملکرد نهایی مدل پس‌آموزش‌دیده MiniMax-M2.7 (تنها با ۱۰ میلیارد پارامتر فعال در هر گام) را در مقایسه با قدرتمندترین مدل‌های مرزی جهان گزارش می‌کند. این داده‌ها حاکی از رقابت‌پذیری مستقیم این مدل با سامانه‌های بسیار حجیم‌تر تجاری در دامنه‌های کدنویسی، وب‌پژوهی، وظایف اداری و استدلال عمیق است.

جدول ۴۱: مقایسه عملکرد MiniMax-M2.7 در برابر مدل‌های مرزی متن‌بسته

دسته مهارتی	بنچمارک (Benchmark)	M2.7	M2.5	Claude Opus 4.6	Claude Sonnet 4.6	GPT 5.4	Gemini 3.1 Pro
عاملی کدنویسی	SWE-bench Pro	۲.۵۶	۴.۵۵	۳.۵۷	۲.۵۷	۷.۵۷	۲.۵۴
	SWE-bench Multilingual	۵.۷۶	۱.۷۴	۸.۷۷	۹.۷۵	۵.۷۰	—
	Multi-SWE-bench	۷.۵۲	۳.۵۱	۳.۵۰	۰.۵۱	۰.۴۹	—
	NL2Repo	۸.۳۹	۶.۲۶	۷.۴۳	۳.۴۳	۸.۴۶	۹.۳۵
	Terminal-Bench 2.0	۰.۵۷	۷.۵۱	۴.۶۵	۱.۵۹	۱.۷۵	۵.۶۸
	MLE Bench Lite	۶.۶۶	۵.۵۱	۷.۷۵	۷.۷۲	۲.۷۱	۶.۶۶
توسعه کاربردی	VIBE-Pro	۶.۵۵	۲.۵۴	۶.۵۵	۱.۵۶	—	۰.۴۱
	HyperTask	۶.۶۷	۴.۵۹	۷.۷۵	۱.۷۴	—	۹.۵۰
جستجوی عمیق	BrowseComp	۸.۷۷	۳.۷۶	۰.۸۴	۷.۷۴	۷.۸۲	۹.۸۵
	Wide Search	۲.۷۵	۳.۷۰	۴.۷۹	۸.۷۵	۹.۷۷	—
	RISE	۳.۶۴	۲.۵۰	۵.۶۸	۸.۵۸	۳.۶۳	—
ابزار و امور اداری	GDPval-AA	۰.۵۰	۰.۳۵	۰.۵۵	۰.۵۷	۰.۵۸	۰.۴۱
	Toolathlon	۳.۴۶	۳.۳۸	۲.۴۷	۸.۴۴	۶.۵۴	۸.۴۸
	MM Claw	۷.۶۲	۶.۵۷	۴.۷۵	۲.۶۴	۶.۷۳	۸.۶۱
	MEWC v2	۳.۶۳	۸.۴۹	۰.۶۲	۲.۷۷	۵.۷۶	۲.۴۲
	Finance Modeling Pro	۰.۵۷	۸.۳۳	۰.۶۹	۲.۶۶	۳.۷۵	۶.۳۵
استدلال و دانش	AIME 2026	۲.۹۴	۲.۸۷	۵.۹۲	۷.۹۲	۰.۹۷	۷.۸۸
	GPQA-Diamond	۸.۸۹	۲.۸۵	۶.۸۹	۵.۸۷	۰.۹۲	۱.۹۴
	SciCode	۰.۴۷	۰.۴۳	۹.۵۱	۸.۴۶	۶.۵۶	۹.۵۸
	IFBench	۰.۷۶	۰.۷۲	۱.۵۳	۶.۵۶	۹.۷۳	۱.۷۷
	AA-LCR	۰.۷۲	۰.۶۵	۷.۷۰	۷.۷۰	۰.۷۴	۷.۷۲
	HLE	۰.۲۸	۰.۱۹	۷.۳۶	۰.۳۰	۶.۴۱	۷.۴۴
	MMLU-Pro	۸.۸۱	۲.۸۵	۱.۸۹	۳.۸۷	۵.۸۷	۲.۹۱

بررسی مسیر تکامل درون‌نسلی مدل نشان می‌دهد که ورود داده‌های تخصصی جدید در نگارش‌های M2.5 و M2.7 بیشترین جهش‌های خطی را ایجاد کرده است؛ من‌جمله ارتقای چشمگیر در بنچمارک

BrowseComp از 44.0 در مدل اولیه M2 به 76.3 در M2.5 و سپس 77.8 در M2.7 (+33.8 امتیاز رشد)، جهش نرخ مدال در MLE Bench Lite از 40.0 به 66.6 (+26.6 امتیاز رشد که در آن بهترین اجرای مدل موفق به کسب ۹ مدال طلا، ۵ نقره و ۱ برنز شد) و رشد امتیاز وظایف اسناد اداری در GDPval-AA از 34.0 به 50.0 (+16.0 امتیاز رشد).

• MobileLLM-Pro

مقدمه و ساختار کلان فاز پس‌آموزش (Post-Training) در مدل زبانی MobileLLM-Pro یک مدل کارآمد در مقیاس ۱ میلیارد پارامتر (1.08B) توسعه‌یافته برای استقرار بر روی پردازنده‌ها (CPUs) و شتاب‌دهنده‌های عصبی تراشه‌های تلفن همراه (NPU/HTP) —مرحله پس‌آموزش (Post-Training) نقش‌حیاتی در دگرگونی مدل پایه به یک دستیار هوشمند محلی (On-Device Assistant) ایفا می‌کند [۴۰]. اهداف کاربردی مدل در این فاز شامل درک دستور، خلاصه‌سازی (Summarization)، بازنویسی متون (Rewriting)، پاسخ به پرسش‌های منطقی، بازیابی درون‌متنی و فراخوانی توابع و ابزارها (Tool/Function Calling) است.

در طول این فرایند، مدل پنجره بافت فوق‌طولانی 128K توکنی خود را همراه با سازوکار بهینه توجه ترکیبی محلی-سراسری (Local-Global Attention) حفظ می‌نماید. برخلاف مرحله پیش‌آموزش که بر پایه تقطیر لاجیت (Logit KD) از مدل معلم بزرگ Llama 4-Scout بهینه‌سازی شده بود، در فاز تنظیم دستوری (IFT) هدف آموزشی به بهینه‌سازی زبان استاندارد آنتروپی متقاطع (Cross-Entropy Loss) تغییر می‌یابد:

$$\mathcal{L}_{CE}(\theta) = - \sum_{t=1}^T \log P_{\theta}(y_t | y_{<t}, x) \quad (۵۳)$$

که در آن x توالی دستور ورودی، y توالی پاسخ مطلوب دستیار و T طول توالی هدف است. کل خط لوله پس‌آموزش در قالب یک سازوکار منسجم سه‌مرحله‌ای با بودجه توکنی نزولی (Decaying Budget) پیکربندی شده است.

مرحله اول: تنظیم دستوری مبتنی بر تنوع حداکثری (Diversity-First IFT) در گام نخست، ارزیابی‌های اولیه نشان داد که در مدل‌های زبانی فشرده زیر ۲ میلیارد پارامتر، تنوع داده‌ها (Data Diversity) بالاترین همبستگی مثبت را با عملکرد کل مدل دارد. به دلیل ظرفیت پارامتری محدود، بیش‌نمونه‌برداری مصنوعی (Oversampling) از مجموعه‌داده‌های کوچک نه تنها مزیتی ایجاد نمی‌کند، بلکه تعادل گرادیان را برهم زده و اثر منفی بر پایداری مدل می‌گذارد. از این رو، راهبرد این فاز بر پایبندی به توزیع طبیعی (Natural Distribution) داده‌های منبع‌باز بنا نهاده شد.

مجموع نمونه‌های گردآوری‌شده در این مرحله بالغ بر **۶۴.۷ میلیون نمونه** (7.64M) از هفت مجموعه‌داده استاندارد است. جدول ۶۰ آمار دقیق، منابع و سهم درصدی هر یک را نشان می‌دهد:

جدول ۴۲: مشخصات آماری پیکره داده‌های مرحله اول تنظیم دستوری (Diversity-First IFT) در مدل MobileLLM-Pro

نام مجموعه‌داده (Dataset)	حوزه تخصصی (Domain)	سال انتشار	تعداد نمونه‌ها (میلیون)	سهم از کل دادگان (%)
Nemotron Math [۱۴۲]	ریاضیات و استدلال تحلیلی	۲۰۲۵	2.70M	35.34%
Nemotron Safety [۱۴۲]	ایمنی و مهار محتوای مخرب	۲۰۲۵	0.03M	0.39%
Nemotron Code [۱۴۲]	برنامه‌نویسی و سنتز کد	۲۰۲۵	0.65M	8.51%
Nemotron Chat [۱۴۲]	تعامل و مکالمه انسانی	۲۰۲۵	0.04M	0.52%
Nemotron Science [۱۴۲]	علوم پایه و پرسش‌های دانشگاهی	۲۰۲۵	0.48M	6.28%
Flan [۱۴۳]	دستورالعمل‌های چندوظیفه‌ای متنوع	۲۰۲۱	2.80M	36.65%
Tülu 3 [۱۴۴]	هم‌ترازی نوین و تنظیم دستوری باز	۲۰۲۴	0.94M	12.30%
مجموع کل (Total)				100.00%
				7.64M

بررسی تحلیلی این توزیع نشان می‌دهد که دو پیکره Flan و Nemotron Math در مجموع بالغ بر 71.99% (حدود ۷۲ درصد) حجم نمونه‌ها را به خود اختصاص داده‌اند:

$$\text{Share}(\text{Flan} + \text{NemoMath}) = \frac{2.80\text{M} + 2.70\text{M}}{7.64\text{M}} \times 100 \approx 71.99\% \quad (۵۴)$$

همچنین، در آزمایش‌های شبیه‌سازی ترکیب داده (SDM) در حجم ۸۰ میلیارد توکن پسا-آموزش [۴۳]، استفاده از توزیع داده‌های تنوع‌محور بهینه‌شده امتیاز میانگین بنچمارک مدل را از ۱۷.۹۴٪ (در ترکیب تصادفی یکنواخت) به ۴۵.۲۳٪ رساند که بیانگر جهش مطلق ۲۷.۲۹٪ ناشی از مهندسی دقیق دادگان است.

مرحله دوم: تنظیم شکاف دامنه‌ها با تحلیل حذفی (LOO Continued Tuning) در مرحله دوم، برای انطباق ترکیب داده‌ها با نیازهای خاص مدل، تحلیل تجربی حذفی یک‌به‌یک (Leave-One-Out - LOO) بر روی هر یک از ۷ منبع داده اعمال شد. اگر مجموعه کل منابع داده را $D = \{d_1, d_2, \dots, d_7\}$ بنامیم، اثر حذف هر دامنه بر روی بردارهای مهارتی (شامل ریاضیات، استدلال، خلاصه‌سازی، بازنویسی، دانش، پیروی از دستور و فراخوانی ابزار) با آموزش مدل روی پیکره $D \setminus \{d_k\}$ به دست آمد. بر اساس شواهد برآمده از تحلیل نمودار راداری حذفی:

- حذف داده‌های Tulu 3 (Tulu 3) عمیق‌ترین افت عملکرد سراسری، به‌ویژه در توانمندی پیروی از دستورات (Instruction Following) را به همراه داشت.
- حذف داده‌های Nemotron Science (Nemotron Science) بیشترین ضربه را به مهارت‌های استدلال منطقی و حل مسائل علمی وارد نمود.

در نتیجه این ارزیابی، داده‌های فاز دوم به منظور رفع نواقص مهارتی مدل (Domain Gaps) بازآرایی و سهم داده‌های کلیدی تقویت گردید.

مرحله سوم: هم‌ترازی ایمنی، خود-شناسایی و بهینه‌سازی ترجیحات (Safety & Self-ID) فاز نهایی پس‌آموزش به تثبیت مرزهای ایمنی اخلاقی و رفتار هویتی مدل بدون نقض استانداردهای سیستمی اختصاص یافت. در این مرحله، از رویکرد داده‌های سنتزی (Synthetic Data) در پیوند با دو سازوکار استفاده شد:

۱. **تنظیم نظارت‌شده سنتزی (Synthetic SFT):** برای القای چارچوب پاسخ‌دهی ایمن و رد درخواست‌های خطرآفرین.

۲. **بهینه‌سازی مستقیم ترجیحات (DPO):** بهره‌گیری از الگوریتم DPO [۱۴۵] با استفاده از جفت داده‌های ترجیحی سنتزی (x, y_w, y_l) :

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}_{\text{pref}}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right] \quad (55)$$

که در آن y_w پاسخ ایمن هم‌تراز با هویت مدل، y_l خروجی آسیب‌رسان یا ناهماهنگ و π_{ref} نداشت مدل در انتهای فاز دوم است.

نویسندگان تصریح نموده‌اند که در مدل‌های ۱ میلیارد پارامتری، دستیابی به سطوح بالای ایمنی مستلزم پرداخت «مالیات هم‌ترازی» (Alignment Tax) و پذیرش افتی اندک در بنچمارک‌های دانش عمومی است.

ارزیابی‌های تجربی و اعتبارسنجی کارایی دادگان پس‌آموزش کیفیت پیکره پسا-آموزش در دو سطح آزمون‌های استاندارد و ارزیابی مقایسه‌ای انسانی سنجیده شد. جدول ۶۲ عملکرد نسخه دستوری را در برابر رقبای هم‌رده شامل Gemma 3-1B [۱۴۶] و Llama 3.2-1B [۱۴۷] نشان می‌دهد.

برتری چشمگیر مدل در آزمون‌های کدنویسی نظیر HumanEval (۵۹.۸ در مقایسه با ۳۷.۸ در Llama 3.2-1B) و فراخوانی ابزار برکلی (BFCL v2) گواه مستقیم اثربخشی دادگان مهندسی‌شده است.

علاوه بر این، نتایج ارزیابی‌های کیفی انسانی روی ۱۰۰ پرامپت تصادفی در جدول ۴۴ خلاصه شده است. در وظیفه فراخوانی ابزار (Tool Calling)، به دلیل نیاز به راستی‌آزمایی دقیق کد و خروجی‌های ساختاریافته، مدل قدرتمند Llama 3-70B به عنوان داور جایگزین ارزیاب انسانی شده است.

جدول ۴۳: مقایسه عملکرد بنچمارک‌های تنظیمی مدل MobileLLM-Pro (Instruct) با مدل‌های هم‌رده

حوزه آزمون	بنچمارک (متریک)	ابعاد مهارت	MobileLLM-Pro	Gemma 3-1B	Llama 3.2-1B
دانش عمومی	MMLU (macro avg/acc)	درک چندوظیفه‌ای زبانی	۸.۴۴	۹.۲۹	۳.۴۹
پیروی از دستور	IFEval (acc*)	پایبندی به قیود دقیق پرامپت	۰.۶۲	۲.۸۰	۵.۵۹
برنامه‌نویسی	MBPP (pass@1)	حل مسائل پایه‌ای کدنویسی	۸.۴۶	۲.۳۵	۶.۳۹
	HumanEval (pass@1)	حل توابع الگوریتمی پیشرفته	۸.۵۹	۵.۴۱	۸.۳۷
پرسش و پاسخ	ARC-Challenge (acc)	استدلال علمی استنتاجی	۷.۶۲	—	۴.۵۹
	HellaSwag (acc)	استنتاج عقل سلیم در تکمیل متن	۴.۵۸	—	۲.۴۱
عامل هوشمند	BFCL v2 (acc)	فراخوانی ساختاریافته ابزارها	۴.۲۹	—	۷.۲۵
بازنویسی	Open Rewrite (rougeL)	ویرایش، تصحیح و تبدیل متن	۰.۵۱	—	۶.۴۱
خلاصه‌سازی	TLDR9+ (rougeL)	چکیده‌سازی پست‌ها و اسناد	۸.۱۶	—	۸.۱۶

جدول ۴۴: نتایج ارزیابی مقایسه‌ای ترجیحات انسانی و داوری خودکار روی ۱۰۰ پرامپت تصادفی در هر دسته

مقایسه با Gemma 3-1B				مقایسه با Llama 3.2-1B			
وظیفه ارزیابی	برد MobileLLM	برد رقیب	مساوی	تحلیل برتری	برد MobileLLM	برد رقیب	مساوی
خلاصه‌سازی (Summarization)	۴۷	۵۱	۲	رقابت نزدیک (برتری جزئی رقیب)	۴۲	۳۰	۲۸
بازنویسی (Rewrite)	۴۵	۴۹	۶	رقابت نزدیک (برتری جزئی رقیب)	۵۳	۳۰	۱۶
بازیابی (Recall)	۴۷	۳۰	۲۳	برتری قاطع (+17)	۵۶	۸	۳۷
فراخوانی ابزار (Tool Calling*)	۵۳	۲۴	۲۳	برتری چشمگیر (+29)	۴۰	۳۵	۲۵

مقدمه و پارادایم داده‌های پس‌آموزش (Post-Training Paradigm) فاز پس‌آموزش (Post-training) در خانواده مدل‌های Nemotron-3 (شامل نسخه‌های Nano، Super و Ultra) بر پایه یک معماری پیوندی متشکل از لایه‌های تنک MoE و بلوک‌های حالت خطی Mamba-2 به همراه تعداد اندکی لایه توجه بازطراحی شده است [۱۴۸، ۵۰]. تمرکز بنیادین در گردآوری و طراحی داده‌های پس‌آموزش، ارتقای ظرفیت مدل در سه حوزه کلیدی است:

- استدلال عمیق چندمرحله‌ای (Multi-Step Reasoning) در ریاضیات و کدنویسی رقابتی.
 - عاملیت هوشمند و تعامل پیشرفته با ابزارها (Agentic Multi-Step Tool Use).
 - مدیریت بلادرنگ و دانه‌بندی شده بودجه استدلال در زمان استنتاج (Reasoning Budget Control).
- برخلاف خطوط لوله متداول که فاز پس‌آموزش را به صورت پله‌ای و مجزا برای هر توانمندی اجرا می‌کنند، در Nemotron-3 بهینه‌سازی هم‌زمان در محیط‌های چندگانه (Multi-Environment Simultaneous RL) اتخاذ شده است تا از پدیده تخریب قابلیت‌ها (Capability Degradation) و هک پاداش (Reward Hacking) پیشگیری شود [۱۴۹، ۱۵۰].

داده‌های سنتزی و بافت فوق‌طولانی در تنظیم دقیق (Long-Context SFT Data) به منظور آماده‌سازی مدل برای سناریوهای تحلیل اسناد حجیم و گفتگوی طولانی، داده‌های مرحله تنظیم دقیق نظارت‌شده (SFT) با ویژگی‌های ساختاری زیر تدوین شده‌اند:

- **طول پنجره داده‌های نظارت‌شده:** داده‌های فاز SFT در مدل Nemotron-3-Nano در پنجره بافت 256K توکن پیکربندی شده‌اند.
- **عدم وابستگی به RoPE:** از آنجا که لایه‌های Mamba-2 اطلاعات مکانی توکن‌ها را به شیوه ضمنی و پیوسته در بردار حالت ثبت می‌کنند، در لایه‌های توجه از تعبیه مکانی دورانی (RoPE) استفاده نشده است؛ از این رو داده‌های بافت طولانی با چالش برون‌یابی توزیع زاویه‌ای مواجه نمی‌شوند [۵۱].
- **تولید داده‌های سنتزی هدفمند (Synthetic Data Generation):** پیکره داده‌ها در مراحل آموزش پیوسته و تنظیم دقیق به سه دسته داده سنتزی مجهز شده است:
 ۱. **بازیابی دوربرد (Long-Range Retrieval):** جانمایی گزاره‌های کلیدی در فواصل مکانی بسیار دور برای سنجش پایداری توجه.
 ۲. **استدلال چندجهشی (Multi-Hop Reasoning):** مسائلی که پاسخ نهایی آن‌ها منوط به زنجیره‌سازی منطقی داده‌های مستقر در بخش‌های نامتقارن متن است.

۳. **تجمیع چندسندی (Multi-Document Aggregation):** متون ترکیبی برگرفته از گزارش‌های گوناگون جهت تولید برآیند و خلاصه‌سازی تحلیلی.

پویایی داده‌های محیطی در یادگیری تقویتی (Multi-Environment RL Data) در مرحله یادگیری تقویتی، داده‌ها صرفاً به پرومپت‌های ایستا محدود نبوده، بلکه از طریق تعامل پویا با ۸ محیط یادگیری فعال به مدل بازخورد داده می‌شود:

- **المپیاد و استدلال ریاضی (AIME25):** تولید و پایش زنجیره‌های طولانی استدلال کلامی و نمادین ریاضی بدون راهنمایی مستقیم.
- **استدلال علوم پایه سطح تخصص (GPQA و SciCode):** مسائل دشوار در فیزیک، شیمی و محاسبات علمی ترکیبی با پیاده‌سازی الگوریتمی.
- **کدنویسی زنده و مهندسی نرم‌افزار (SWE-Bench و LiveCodeBench):** داده‌های مبتنی بر تعامل با خط فرمان و حل مسائل مخازن واقعی نرم‌افزار.
- **پیروی دقیق از دستورالعمل‌ها (IFBench):** دستورات دارای قیود منفی و چارچوب‌های سخت‌گیرانه شکلی.
- **ابزارورزی و عاملیت چندگانه (T^2 -Bench):** ایجاد ردپای تعامل مدل با API‌ها و مفسرهای کد.
- **تحلیل متنی جامع (AALCR و MMLU-Pro):** آزمون‌های چندگزینه‌ای دشوار با گزینه‌های فریبنده به منظور جلوگیری از سوگیری سطحی.
- **محیط بافت طولانی در RL:** تزریق ورودی‌های تعاملی تا سقف 32K توکن در حین تولید نمونه‌های یادگیری تقویتی.

فرمول‌بندی الگوریتمی و نمونه‌برداری با اهمیت ماسک‌شده فرایند بهینه‌سازی سیاست با استفاده از داده‌های جمع‌آوری‌شده توسط نسخه ناهمگام الگوریتم GRPO [۲۴] انجام می‌پذیرد. برای مقابله با انحراف توزیع نمونه‌ها بین سیاست جمع‌آوری‌کننده داده و سیاست در حال آموزش، تابع هدف با سازوکار نمونه‌برداری با اهمیت ماسک‌شده (Masked Importance Sampling) فرمول‌بندی شده است:

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{q \sim \mathcal{D}_{\text{prompts}}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \mathcal{M}_{i,t} \mathcal{L}_{i,t}^{\text{clip}}(\theta) - \beta \mathbb{D}_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right] \quad (56)$$

که در آن ترم کران‌دار به صورت زیر تعریف می‌شود:

$$\mathcal{L}_{i,t}^{\text{clip}}(\theta) = \min \left(r_{i,t}(\theta) \hat{A}_i, \text{clip}(r_{i,t}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i \right) \quad (57)$$

نسبت وزنی اهمیت توکن برابر است با:

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})} \quad (58)$$

عملگر ماسک‌گذاری داده‌های پرت به منظور تضمین ثبات شیب بر مبنای حدود مجاز $[c_{\min}, c_{\max}]$ تعریف می‌گردد:

$$\mathcal{M}_{i,t} = \mathbb{I}(c_{\min} \leq r_{i,t}(\theta) \leq c_{\max}) \quad (59)$$

و مزیت نسبی درون‌گروهی بدون نیاز به شبکه نقاد مجزا از طریق نرمال‌سازی پاداش‌های گروهی به دست می‌آید:

$$\hat{A}_i = \frac{R_i - \mu_{\{R_1, \dots, R_G\}}}{\sigma_{\{R_1, \dots, R_G\}} + \epsilon_{\text{stab}}} \quad (60)$$

مهندسی داده در کنترل دانه‌بندی‌شده بودجه تفکر (Reasoning Budget Control) در خلال پس‌آموزش، مدل برای پذیرش نشانه توقف تفکر میانی آموزش داده شده است. در صورت تعریف سقف توکن توسط کاربر، توکن کنترلی به توالی استدلال نیمه‌کاره تزریق می‌شود:

$$\mathcal{S}_{\text{input}} = [\text{Prompt}, \text{Partial_Thinking_Trace}, \text{</think>}] \quad (61)$$

این ساختار داده به مدل می‌آموزد که بلافاصله پس از مشاهده توکن پایانی، فرایند تعمق را قطع کرده و پاسخ نهایی را بر مبنای استدلال‌های تا آن لحظه تدوین نماید.

تحلیل احتمال منفی لگاریتمی (NLL) و برون‌یابی بافت ارزیابی احتمال منفی لگاریتمی انباشته (Cu-) (mulative Average NLL) بر روی مخازن کدهای پیوسته با طول بیش از یک میلیون توکن نشان‌دهنده انطباق بر رابطه قانون توان (Power Law) است:

$$\text{NLL}(s) \propto s^{-\alpha}, \quad R^2 = 0.883 \quad (62)$$

میزان ضریب تعیین $R^2 = 0.883$ اثبات می‌کند که با افزایش طول کانتکست تا سقف 1M توکن، میزان خطای پیش‌بینی به شکل پیوسته و معنادار کاهش می‌یابد.

ارزیابی‌های تجربی مدل پس‌آموزش‌دیده (Post-Trained Evaluations) عملکرد مدل نهایی -Neomtron-3-Nano-30B-A3B در مقایسه با مدل‌های هم‌رده در جدول زیر خلاصه شده است. این نتایج حاکی از برتری قاطع در ابزارورزی (49.0% در T^2 -Bench)، استدلال ریاضی با ابزار (99.2% در AIME25) و گذردهی استنتاج ($3.3\times$ سریع‌تر در توالی‌های طولانی) است.

جدول ۴۵: مقایسه عملکرد بنچمارک‌های پس‌آموزش و گذردهی استنتاج در مدل‌های استدلالی

شاخص / تسک	بنچمارک (متریک)	حالت اجرایی	Neomtron-3-Nano-30B-A3B	Qwen3-30B-A3B-Thinking	GPT-OSS-20B-A4B
مشخصات	پارامترهای فعال / کل نرخ گذردهی نسبی	- 8k ISL / 16k OSL	۳۰B / ۳B $\times 3.3$	۳۰B / ۳B $\times 0.1$	۲۰B / ۴B $\times 0.1$
ریاضیات (Math)	AIME25 AIME25	بدون ابزار به همراه ابزار (+tools)	۱%.۸۹ ۲%.۹۹	۰%.۸۵ -	۷%.۹۱ ۷%.۹۸
کدنویسی (Coding)	LCB v6 SWE-Bench	Pass@1 حل خطای مخزن	۲%.۶۸ ۸%.۳۸	۰%.۶۶ ۰%.۲۲	۰%.۶۱ ۰%.۳۴
گفتگو (Chat)	Arena-Hard-v2	امتیاز میانگین	۷%.۶۷	۸%.۵۷	۵%.۴۸
دستورپذیری (Inst. Following)	IFBench	اجرای دقیق قیود	۵%.۷۱	۰%.۵۱	۰%.۶۵
ابزارورزی (Tool Use)	T^2 -Bench	فراخوانی توابع	۰%.۴۹	۷%.۴۷	۵%.۴۷
بافت طولانی (Long Context)	RULER @ 1M	بازیابی در ۱ میلیون توکن	۳%.۸۶	۵%.۷۷	N/A

جدول زیر پایداری مدل پایه را در برون‌یابی طول بافت تا مرز یک میلیون توکن بر اساس بنچمارک RULER در مقایسه با نسخه پیشین متراکم نشان می‌دهد:

جدول ۴۶: مقایسه مقاومت در برابر برون‌یابی طول بافت (RULER Score) در مدل‌های پایه با آموزش تا سقف 512K

مدل	۱۲۸k	۲۵۶k	۵۱۲k	۱M (برون‌یابی)
Neomtron-Nano-12B-v2-Base (ترکیبی متراکم)	۱۳%.۸۵	۸۵%.۷۹	۱۲%.۷۵	۴۳%.۲۳
Neomtron-3-Nano-30B-A3B-Base (ترکیبی تنک MoE)	۴۸%.۷۴	۶۷%.۷۱	۰۲%.۶۶	۱۹%.۵۴

زیرساخت متن‌باز و دسترس‌پذیری دادگان (Open Software Stack) فرایند پس‌آموزش و کلیه ابزارهای تولید داده به صورت آزاد و تحت مجوز Apache 2.0 منتشر شده‌اند:

- **کتابخانه NeMo-RL**: زیرساخت توزیع‌شده و بهینه برای اجرای آموزش هم‌زمان GRPO در مقیاس‌های بزرگ.

- **محیط تعاملی NeMo-Gym**: جعبه‌ابزار استاندارد شبیه‌سازی محیط‌های عامل‌محور، اجرای کد و تولید مسیرهای بازخورد تعاملی.

مقدمه و اهداف دوگانه دادگان پس‌آموزش (Post-Training Objectives) فاز پس‌آموزش (Post-training) در خانواده مدل‌های زبانی Qwen3 با دو رویکرد راهبردی و زیربنایی بازطراحی شده است:

- **کنترل و یکپارچه‌سازی فرآیند تفکر (Thinking Control):** ادغام ساختاری دو حالت عملیاتی متمایز—شامل «حالت تفکر عمیق و چندمرحله‌ای» (Thinking Mode) برای مسائل استدلالی پیچیده و «حالت پاسخ‌دهی مستقیم و بافت‌محور» (Non-Thinking Mode) برای تعاملات متنی سریع—در یک مدل واحد؛ این رویکرد نیاز به جابه‌جایی میان مدل‌های چت نظیر GPT-4o و مدل‌های تخصصی تفکر نظیر QwQ-32B [۱۵۱] را مرتفع ساخته و قابلیت تنظیم پویای بودجه محاسباتی تفکر (Thinking Budget) را در زمان استنتاج فراهم می‌آورد.
- **تقطیر دانش از قوی به ضعیف (Strong-to-Weak Distillation):** حذف خط لوله‌های پرهزینه آموزش چهارمرحله‌ای برای مدل‌های سبک‌وزن (شامل مدل‌های متراکم 0.6B، 1.7B، 4B، 8B، 14B و مدل تنک Qwen3-30B-A3B) از طریق انتقال مستقیم توزیع لاگیت‌ها از مدل‌های پرچمدار معلم (Qwen3-32B و Qwen3-235B-A22B).

مرحله اول: دادگان آغاز سرد زنجیره تفکر طولانی (Long-CoT Cold Start Data) برای پیریزی قابلیت استدلال نمادین و جلوگیری از اتکای مدل به حدس‌های سطحی، پیکره‌ای از مسائل حوزه‌های ریاضیات، برنامه‌نویسی و الگوریتم، منطق صوری و علوم مهندسی (STEM) گردآوری شد که هر نمونه با پاسخ‌های مرجع قطعی یا تست‌کیس‌های نرم‌افزاری اعتبارسنجی جفت شده بود. پالایش این دادگان طی یک فرآیند دو فازی صورت پذیرفت:

- **فاز اول (پالایش پرسش‌ها با Qwen2.5-72B-Instruct):** پرسش‌های غیرقابل راستی‌آزمایی، دارای چند زیرمسئله پراکنده یا با ماهیت صرفاً تولید متن حذف شدند. همچنین مسائلی که مدل ارزیاب قادر بود بدون استفاده از زنجیره تفکر به آن‌ها پاسخ صحیح دهد کنار گذاشته شدند. دامنه‌ها نیز به دقت برچسب‌گذاری شدند تا تعادل توزیعی حفظ شود.
- **فاز دوم (پالایش پاسخ‌ها با QwQ-32B و نظارت انسانی):** برای پرسش‌های منتخب، تعداد N پاسخ توسط مدل استدلالی QwQ-32B [۱۵۱] تولید و در صورت ناتوانی مدل، توسط ارزیابان انسانی تصحیح شد. روی پاسخ‌هایی با متریک مثبت $\text{Pass}@N$ ، شش شرط حذفی سخت‌گیرانه اعمال گردید:

۱. تولید پاسخ نهایی نادرست؛
۲. وجود تکرارهای فرساینده در مسیر استدلال؛
۳. نشانه‌های حدس تصادفی بدون استدلال منطقی؛
۴. ناهمخوانی میان بخش تفکر درون تگ `<think>` و پاسخ نهایی؛
۵. اختلاط نامناسب زبانی (Code-Switching) یا نوسان لحن؛
۶. شباهت غیرطبیعی به آزمون‌ها و خطر نشت دادگان (Contamination).

به منظور حفظ پتانسیل کاوش و یادگیری در مراحل بعدی، حجم دادگان و گام‌های آموزش در این مرحله در کمترین سطح ممکن محدود شد.

مرحله دوم: جفت‌های پرسش-ارزیاب در یادگیری تقویتی استدلالی (Reasoning RL Data) در این فاز، پارامترهای مدل با استفاده از الگوریتم بهینه‌سازی سیاست نسبی گروهی (GRPO) [۲۴] ارتقا یافتند. دادگان مورد استفاده شامل دقیقاً ۳،۹۹۵ **جفت پرسش-ارزیاب** (Query-Verifier Pairs) با ۴ معیار بود: (۱) عدم هم‌پوشانی با داده‌های آغاز سرد، (۲) یادگیری‌پذیر بودن برای مدل، (۳) داشتن بالاترین درجه دشواری و (۴) پوشش عمیق زیرشاخه‌های علمی.

در سازوکار GRPO، به ازای هر پرسش $q \sim D$ ، گروهی از خروجی‌ها $\{o_1, o_2, \dots, o_G\}$ توسط مدل فعلی نمونه‌برداری شده و مزیت هر پاسخ $(\tilde{A}_i)$ بدون نیاز به مدل منتقد (Critic) محاسبه می‌گردد:

$$\tilde{A}_i = \frac{r_i - \text{Mean}(\{r_1, \dots, r_G\})}{\text{Std}(\{r_1, \dots, r_G\})} \quad (۶۳)$$

تابع هدف بهینه‌سازی به صورت زیر بیشینه‌سازی می‌شود:

(۶۴)

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(q)} \left[\frac{1}{G} \sum_{i=1}^G \left(\min \left(\frac{\pi_{\theta}(o_i | q)}{\pi_{\theta_{\text{old}}}(o_i | q)} \tilde{A}_i, \text{clip} \left(\frac{\pi_{\theta}(o_i | q)}{\pi_{\theta_{\text{old}}}(o_i | q)}, 1 - \epsilon, 1 + \epsilon \right) \tilde{A}_i \right) - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right) \right]$$

توزیع داده‌های بازپخش برون‌پالیسی (Off-policy Rollouts) همراه با دسته‌های محاسباتی بزرگ، بازدهی نمونه‌ها را ارتقا داد؛ به‌طوری‌که نمره مدل پرچمدار Qwen3-235B-A22B در بنچمارک AIME'24 تنها در عرض ۱۷۰ گام آموزشی از ۷۰.۱ به ۸۵.۱ رسید.

مرحله سوم: دادگان تلفیق حالت تفکر و بودجه‌بندی محاسباتی (Thinking Mode Fusion) این فاز با هدف یکپارچه‌سازی حالت‌های با تفکر و بدون تفکر از طریق تنظیم دقیق پیوسته (Continual SFT) اجرا شد. دادگان آموزشی این مرحله از دو جریان متمایز تشکیل شده بود:

- **دادگان با تفکر (Thinking Data):** با روش نمونه‌برداری پس‌زنجی (Rejection Sampling) از پرسش‌های مرحله ۱ با خودِ مدل مرحله ۲ استخراج گردید.
- **دادگان بدون تفکر (Non-thinking Data):** شامل گستره‌ای از وظایف کدنویسی، ریاضیات، پیروی از دستورات، نگارش خلاقانه، پرسش و پاسخ و ایفای نقش که کیفیت آن‌ها با چک‌لیست‌های خودکار کنترل شد. همچنین سهم دادگان ترجمه برای زبان‌های کم‌منبع (Low-Resource) به شدت افزایش یافت.

ساختار نمونه‌ها بر اساس قالب‌های استاندارد چت در جدول زیر پیاده‌سازی شده است:

جدول ۴۷: قالب نمونه‌های دادگان SFT جهت تلفیق حالات تفکر و بدون تفکر در مدل‌های Qwen3

حالت تفکر (Thinking Mode - پیش‌فرض)	حالت بدون تفکر (Non-Thinking Mode)
< im_start >user	< im_start >user
/think< im_end > {query}	/no_think< im_end > {query}
< im_start >assistant	< im_start >assistant
<think>	<think>
{thinking_content}	</think>
</think>	{response}< im_end >
{response}< im_end >	

پدیداری قابلیت بودجه تفکر (Thinking Budget): تلفیق این دادگان باعث پدیداری طبیعی مهارت جمع‌بندی بر مبنای تفکر ناتمام شد. در صورت محدودسازی بودجه تفکر، فرآیند استدلال متوقف شده و رشته مداخله‌ای زیر در توالی درج می‌گردد:

thinking the on based solution the give to have I user, the by time limited the “Considering now.\n</think>.\n\n” directly

سپس مدل ادامه پاسخ نهایی را بر پایه استدلال انباشته‌شده تولید می‌کند.

مرحله چهارم: دادگان یادگیری تقویتی عمومی (General RL Data & Rewards) در این فاز، یک سیستم پاداش مشتمل بر بیش از ۲۰ وظیفه متنوع در ۵ بعد اصلی تعبیه شد: (۱) پیروی از دستورات، (۲) تبعیت از فرمت نشانه‌گذاری تفکر، (۳) هم‌راستایی با ترجیحات انسانی، (۴) قابلیت‌های عاملی در تعامل چندنوبته با ابزارها و (۵) سناریوهای تخصصی مانند RAG. دادگان بازخورد در ۳ دسته طراحی شدند:

۱. پاداش‌های قاعده‌محور (Rule-based Rewards): تطابق خروجی با الزامات نحوی و کدهای خروجی بدون ریسک هک پاداش.
۲. پاداش‌های مدل‌محور با پاسخ مرجع: ارزیابی پاسخ توسط Qwen2.5-72B-Instruct در مقایسه با جواب مبنا.
۳. پاداش‌های مدل‌محور بدون پاسخ مرجع: آموزش مدل‌های پاداش (Reward Models) بر پایه ترجیحات انسانی جهت اعطای امتیاز کیفی.

دادگان تقطیر قوی به ضعیف (Strong-to-Weak Distillation Data) جهت بهینه‌سازی مدل‌های کوچک‌تر خانواده Qwen3، پایپ‌لاین تقطیر دو مرحله‌ای زیر پیاده‌سازی گردید:

- **تقطیر برون‌پالیسی (Off-policy Distillation):** تلفیق خروجی‌های معلمان حاوی هر دو برچسب /think و /no_think برای آموزش نظارت‌شده اولیه مدل‌های سبک‌وزن.
- **تقطیر درون‌پالیسی (On-policy Distillation):** تولید پاسخ توسط مدل دانش‌آموز و به‌روزرسانی وزن‌ها بر اساس حداقل‌سازی واگرایی کولبک-لایبیلر (KL-Divergence) نسبت به لاگیت‌های توزیع احتمالاتی مدل معلم:

$$\mathcal{L}_{\text{distill}}(\theta) = \mathbb{E}_{x \sim \mathcal{D}_{\text{prompts}} \atop y \sim \pi_{\theta}(\cdot|x)} [D_{\text{KL}}(\pi_{\text{teacher}}(\cdot | x, y_{<t}) || \pi_{\theta}(\cdot | x, y_{<t}))] \quad (65)$$

جدول زیر برتری قطعی بهره‌وری محاسباتی و کیفیت دادگان تقطیر درون‌پالیسی را نسبت به یادگیری تقویتی مستقیم بر روی مدل Qwen3-8B نشان می‌دهد:

جدول ۴۸: مقایسه اثربخشی دادگان تقطیر درون‌پالیسی در برابر یادگیری تقویتی روی مدل Qwen3-8B

روش آموزش	AIME'24	AIME'25	MATH-500	LiveCodeBench v5	MMLU-Redux	GPQA-Diam.	هزینه (GPU Hours)
Off-policy Distillation	55.0 (90.0)	42.8 (83.3)	92.4	42.0	86.4	55.6	—
+ Reinforcement Learning	67.6 (90.0)	55.5 (83.3)	94.8	52.9	86.9	61.3	17,920
+ On-policy Distillation	74.4 (93.3)	65.5 (86.7)	97.0	60.3	88.3	63.3	1,800

این ارزیابی اثبات می‌کند که تقطیر بر مبنای توزیع لاگیت نه تنها هزینه آموزش را به یک‌دهم کاهش داده است ($\frac{1,800}{17,920} \approx 10.04\%$)، بلکه شاخص پتانسیل کاوش استدلال (Pass@64) را در آزمون AIME'24 از 90.0 به 93.3 و در AIME'25 از 83.3 به 86.7 گسترش داده است:

$$\text{Pass}@k = \mathbb{E} \left[1 - \frac{\binom{n-c}{k}}{\binom{n}{k}} \right] \quad (66)$$

تحلیل آماری اثرات مرحله‌به‌مرحله دادگان بر مدل Qwen3-32B جدول زیر روند پیشرفت مهارت‌ها و همچنین اثرات تبدالی دادگان مراحل ۳ و ۴ را بر روی نسخه Qwen3-32B نشان می‌دهد:

تحلیل مصالحه آماری (Performance Trade-off): دادگان مراحل ۳ و ۴ موجب ارتقای چشمگیر درک دستورات (+12.0 نمره در IFEval)، کار با ابزار (+22.2 نمره در ToolUse*) و تثبیت کامل کنترل تفکر با نمره 98.9 در بنچمارک ThinkFollow* شده‌اند. در نقطه مقابل، تعریض توزیع داده‌ها منجر به افت اندکی در آزمون‌های فوق‌تخصصی ریاضی (-2.4 در AIME'24) و برنامه‌نویسی (-2.7 در LCB) گردیده است که به عنوان هزینه‌ای پذیرفته‌شده در ازای چندمنظورگی مدل تلقی می‌شود.

توزیع زبانی دادگان ارزیابی چندزبانه (Multilingual Evaluation Data) برای ارزیابی تعمیم‌پذیری فراابومی قابلیت‌های پس‌آموزش، ارزیابی‌های گسترده‌ای با دادگان چندزبانه مطابق جدول زیر انجام پذیرفت:

این پیکره به همراه ارزیابی درک زبانی طبیعی بر روی ۸۰ زبان در بنچمارک Belebele [۱۵۶] نشان می‌دهد که بهینه‌سازی داده‌ها در فاز تلفیق حالتی، ثبات رفتار استدلالی مدل را حتی در زبان‌های کم‌منبع تضمین کرده است.

جدول ۴۹: ارزیابی تفکیکی اثر دادگان مراحل ۲، ۳ و ۴ پس‌آموزش بر روی مدل Qwen3-32B

دسته وظایف	بنچمارک ارزیابی	مرحله ۲ (Reasoning RL)		مرحله ۳ (Mode Fusion)		مرحله ۴ (General RL)	
		تفکر (Think)		بدون تفکر (No-Think)		بدون تفکر (No-Think)	
عمومی	LiveBench (2024-11-25)	68.6	70.9 (+2.3)	57.1	74.9 (+4.0)	59.8 (+2.8)	
	Arena-Hard	86.8	89.4 (+2.6)	88.5	93.8 (+4.4)	92.8 (+4.3)	
	CounterFactQA*	50.4	61.3 (+10.9)	64.3	68.1 (+6.8)	66.4 (+2.1)	
دستور و قالب	IFEval strict prompt	73.0	78.4 (+5.4)	78.4	85.0 (+6.6)	83.2 (+4.8)	
	Multi-IF	61.4	64.6 (+3.2)	65.2	73.0 (+8.4)	70.7 (+5.5)	
	LengthCtrl*	62.6	70.6 (+8.0)	84.9	73.5 (+2.9)	87.3 (+2.4)	
	ThinkFollow*	—	88.7	—	98.9 (+10.2)	—	
عامل‌ها	BFCL v3	69.0	68.4 (-0.6)	61.5	70.3 (+1.9)	63.0 (+1.5)	
	ToolUse*	63.3	70.4 (+7.1)	73.2	85.5 (+15.1)	86.5 (+13.3)	
دانش و STEM	MMLU-Redux	91.4	91.0 (-0.4)	86.7	90.9 (-0.1)	85.7 (-1.0)	
	GPQA-Diamond	68.8	69.0 (+0.2)	50.4	68.4 (-0.6)	54.6 (+4.3)	
ریاضی و کد	AIME'24	83.8	81.9 (-1.9)	28.5	81.4 (-0.5)	31.0 (+2.5)	
	LiveCodeBench v5	68.4	67.2 (-1.2)	31.1	65.7 (-1.5)	31.3 (+0.2)	

جدول ۵۰: پیکره‌های ارزیابی پس‌آموزش چندزبانه در Qwen3 و زبان‌های تحت پوشش

مجموعه داده / بنچمارک	تعداد زبان	فهرست کدهای زبانی استاندارد (ISO 639-3 / ISO 15924)
[۱۵۲] Multi-IF	8	zh ru, pt, it, hi, fr, es, en,
[۷۹] INCLUDE	44	ja, it, id, hy, hu, hr, hi, he, fr, fi, fa, eu, et, es, el, de, bn, bg, be, az, ar, uz, ur, uk, tr, tl, te, ta, sr, sq, ru, pt, pl, nl, ne, ms, ml, mk, lt, ko, kk, ka, zh vi,
[۷۸] MMMLU	14	zh sw, pt, ko, ja, it, id, hi, fr, es, en, de, bn, ar,
[۱۵۳] MT-AIME2024	55	hu, hr, hi, he, gu, fr, fi, fa, et, es, en, el, de, da, cy, cs, ca, bn, bg, ar, af, so, sl, sk, ru, ro, pt, pl, pa, no, nl, ne, mr, ml, mk, lv, lt, ko, kn, ja, it, id, zh-Hant zh-Hans, vi, ur, uk, tr, tl, th, te, ta, sw, sv, sq,
[۱۵۴] PolyMath	18	zh vi, th, te, sw, ru, pt, ms, ko, ja, it, id, fr, es, en, de, bn, ar,
[۱۵۵] MLogiQA	10	zh vi, th, pt, ko, ja, fr, es, en, ar,

مقدمه و ساختار کلان خط لوله پس‌آموزش فاز پس‌آموزش (Post-Training) در خانواده مدل‌های OLMo 3 با هدف ارتقای قابلیت‌های استدلال چندمرحله‌ای، مکالمه مستقیم، تعامل با ابزارها و پیروی از دستورات تدوین شده است. بر خلاف مدل‌های وزن‌بسته یا نیمه‌شفاف، خط لوله پس‌آموزش OLMo 3 به همراه تمام داده‌ها، چک‌پوینت‌های میانی و ابزارهای پالایش با نام پیکره داده **دولچی (Dolci)** عرضه شده است. این توسعه در سه مسیر مجزا پیگیری می‌شود:

- **مدل تفکرگر (OLMo 3 Think):** تولید ردپای تفکر درونی طولانی (Thinking Traces) پیش از پاسخ نهایی در قالب تگ‌های ساختاریافته اختصاصی.
- **مدل دستوری (OLMo 3 Instruct):** بهینه‌سازی شده برای پاسخ‌دهی موجز و سریع، بدون تولید توکن‌های زائد فکری و با توانمندی بالا در فراخوانی ابزارها.
- **مدل یادگیری تقویتی از پایه (OLMo 3 RL-Zero):** اعمال مستقیم الگوریتم‌های RLVR بر روی مدل پایه بدون گذر از فاز تنظیم دقیق تحت نظارت (SFT).

مسیر کلی بهینه‌سازی پس‌آموزش در این مدل‌ها از زنجیره سه‌مرحله‌ای زیر تبعیت می‌کند:

$$\begin{array}{ccccc} \text{Model Base} & \xrightarrow{\text{SFT}} & \text{Model SFT} & & \\ & \xrightarrow{\text{DPO}} & \text{Model DPO} & \xrightarrow{\text{RLVR}} & \text{Model Final} \end{array} \quad (67)$$

داده‌های تنظیم دقیق تحت نظارت تفکرگر (Dolci Think SFT) مجموعه داده Dolci Think SFT با ترکیب بیش از ۱.۲ میلیون پرامپت چندحوزه‌ای و پاسخ‌های مجهز به زنجیره تفکر عمیق ایجاد شده است [۱۰۹، ۲۲]:

- **ریاضیات (Mathematics):** پرامپت‌ها از OpenThoughts3 و دادگان راستی‌آزمایی شده SYNTHETIC-2 استخراج شدند. نمونه‌های ناقص با استفاده از مدل استدلالی QwQ-32B [۱۵۷] تا سقف بافت ۳۲،۷۶۸ توکن مجدداً تولید شدند.

- **کدنویسی (Coding):** پرامپت‌های الگوریتمی از منابع AceCoder [۱۵۸]، The Algorithms [۱۵۹]، Llama-Nemotron [۱۶۰] و OpenCodeReasoning [۱۶۱] اخذ شدند. برای هر پرامپت تا ۱۶ پاسخ با QwQ-32B تولید و با تست‌کیس‌های ساخته شده توسط GPT-4.1 اعتبارسنجی گردید.

- **گفتگو و ایمنی (Chat & Safety):** پرامپت‌های استخراج شده از WildChat [۹۴]، OpenAssistant [۱۶۲] و Tulu 3 [۱۶۳] به همراه ردپاهای فکری مدل DeepSeek-R1 [۱۶۴] بازتولید شدند.

- **دستورات دقیق (Precise Instruction Following):** پرامپت‌های IF-RLVR [۱۶۵] و پرامپت‌های شخصیت‌محور [۱۶۶] پس از آزمون موفق در راستی‌آزمای‌های خودکار به مجموعه افزوده شدند.

داده‌های ابزارمحور و فراخوانی توابع (Tool Use & Function Calling) در مدل OLMo 3 Instruct، هدف ارتقای کارایی و سرعت تعامل با محیط‌های بیرونی با استفاده از پروتکل Model Context Protocol (MCP) است. داده‌های تعاملی بر پایه استاندارد OpenAPI و کدهای پایتونی سازمان‌یافته‌اند:

- **تعاملات واقعی در محیط‌های MCP:** شامل مجموعه Science QA با ۶.۲۲ هزار مسیر تعاملی برای واکنشی متون علمی و گراف ارجاعات از طریق سرور ASTA، و مجموعه Web Search QA با ۶.۶ هزار مسیر تعاملی در وب با استفاده از Serper API.

- **تعاملات شبیه‌سازی شده (SimFC):** شامل ۲۰۰ هزار مسیر تعاملی با ۶.۴۲ هزار تابع یکتا برای پوشش رفتارهای چندنوبته، فراخوانی‌های موازی و رفتارهای امتناع هوشمندانه (Refusals).

جدول ۵۱: ترکیب‌بندی منابع پرامپت در مجموعه داده Dolci Think SFT

دسته‌بندی موضوعی	مجموعه پرامپت	تعداد نمونه	مرجع
گفتگو و دستورات دقیق	WildChat	۷۶,۲۰۹	[۹۴]
	OpenAssistant	۶,۶۴۷	[۱۶۲]
	Dolci Think Persona Precise IF	۲۲۰,۵۳۰	[۱۶۶]
	Dolci Think Precise IF	۱۳۵,۷۲۲	[۱۶۵]
ریاضیات	Dolci Think OpenThoughts 3+ Math	۷۵۲,۹۹۷	[۲۲]
	Dolci Think OpenThoughts 3+ STEM	۹۹,۲۶۸	[۲۲]
	SYNTHETIC-2-SFT-Verified	۱۰۴,۵۴۸	[۱۰۹]
کدنویسی	Nemotron Post-Training Code	۱۱۳,۷۷۷	[۱۶۰]
	Dolci Think OpenThoughts 3+ Code	۸۸,۸۹۹	[۲۲]
	Dolci Think Python Algorithms	۴۶۶,۶۷۶	[۱۶۱, ۱۵۸]
ایمنی (Safety)	CoCoNot	۹,۵۴۹	[۱۶۷]
	WildGuardMix	۳۶,۶۷۳	[۱۶۸]
	WildJailbreak	۴۰,۰۰۲	[۱۶۹]
چندزبانه سایر حوزه‌ها	Aya	۹۷,۱۵۶	[۱۷۰]
	TableGPT	۴,۹۷۳	[۱۷۱]
مجموع کل	Dolci Think Thinking Datasets	۲,۱۵۳,۶۰۷	-

جدول ۵۲: ویژگی‌های آماری دادگان فراخوانی توابع در OLMo 3

مجموعه دادگان	نوع محیط	تعداد مسیرها	توابع یکتا	درصد چندنوبته	درصد چندمرحله‌ای
Science QA	واقعی (Real MCP)	۲۲,۶۰۰	۸	-	۳٪.۴۲
Web Search QA	واقعی (Real MCP)	۶,۶۰۰	۳	-	۱٪.۷۶
SimFC	شبیه‌سازی‌شده (Simulated)	۲۰۰,۰۰۰	۴۲,۶۰۰	۳٪.۴۲	۸٪.۲۳

خط لوله پالایش چندمرحله‌ای و آلودگی‌زدایی (Filtering & Decontamination) جهت حذف نویزها و صیانت از تعمیم‌پذیری مدل، تمامی داده‌های پس‌آموزش از خط لوله فیلترینگ عبور کردند:

۱. پالایش ساختاری (Format Filtering): حذف زنجیره‌های فکری ناقص که پیش از بستن تگ تفکر قطع شده بودند و همچنین پاسخ‌های تهی.
۲. پالایش حوزه و موضوع (Domain Filtering): غربال موضوعات نامطلوب و احوالپرسی‌های پرتکرار وب با رده‌بندی موضوعی OpenAI.
۳. پالایش محتوایی و ایمنی (Content Filtering): حذف تاریخ انقضای دانش مدل‌ها (Cutoff Dates) و نام شرکت‌های توسعه‌دهنده جهت حفظ هویت مستقل مدل.
۴. مهار تکرار و غلبه زبان چینی: حذف داده‌هایی با بیش از ۵٪ کاراکتر چینی و مهار زنجیره‌های با تکرار افراطی عبارات.
۵. آلودگی‌زدایی از بنج‌مارک‌ها (Decontamination): بهره‌گیری از تطابق ۸-گرامی با حد آستانه اشتراک ۵۰٪ نسبت به داده‌های آزمون.

جدول ۵۳: آمار تفکیکی مراحل فیلترسازی و درصد داده‌های پالایش‌شده در مجموعه Dolci Think SFT

نام دادگان	حجم اولیه	فیلتر فرمت	فیلتر موضوع	فیلتر محتوا	فیلتر تکرار	فیلتر چینی	حجم نهایی
WildChat (Tulu 3)	۵۷,۴۰۷	۶۱٪.۱	۵۷٪.۱۴	۱۰٪.۳	-	۰۹٪.۱	۴۵,۹۱۷
WildChat (New)	۷۴,۹۹۷	۵۳٪.۱	۰۹٪.۴۸	۱۳٪.۳	۰۲٪.۰	۱۶٪.۱	۳۶,۴۱۷
OpenAssistant 1	۷,۰۹۴	۰۸٪.۰	-	-	-	۸۶٪.۳	۶,۸۰۰
OpenThoughts3-Regen	۱,۲۰۰,۰۰۰	۲۲٪.۳	-	-	۰۱٪.۰ >	۰۴٪.۰	۱,۱۶۰,۹۷۲
Persona Precise IF	۲۲۴,۴۴۸	۱۹٪.۰	-	۲۹٪.۰	۰۱٪.۰ >	۰۸٪.۰	۲۲۳,۱۲۳
Val Precise IF (QwQ)	۲۸۶,۰۰۳	-	-	۶۲٪.۰	۰۱٪.۰ >	۱۷٪.۱	۱۳۵,۸۵۱
Synthetic-2-SFT-Verified	۱۰۴,۹۱۳	۰۱٪.۰	-	-	۰۱٪.۰ >	۳۲٪.۰	۱۰۴,۵۶۹
Saurabh Code Mix	۸۸۴,۷۶۷	-	-	-	۰۱٪.۰ >	۰۱٪.۰ >	۸۸۴,۵۷۰
CoCoNot	۱۰,۴۶۰	۵۷٪.۰	-	-	-	۱۰٪.۰	۱۰,۲۲۷
WildGuard	۳۸,۷۹۴	۳۷٪.۰	-	۵۴٪.۰	۰۱٪.۰ >	۱۲٪.۰	۳۸,۳۱۵
WildJailbreak	۴۱,۴۲۰	۱۳٪.۰	-	۶۱٪.۰	-	۰۱٪.۰ >	۴۱,۱۰۰
Aya	۹۸,۸۶۳	۱۵٪.۰	-	-	۰۱٪.۰ >	۶۲٪.۵	۹۸,۵۹۸
TableGPT	۴,۹۸۲	۰۲٪.۰	-	-	-	۰۶٪.۰	۴,۹۸۱

بهینه‌سازی ترجیحات بر پایه یادگیری تفاضلی (Preference Tuning & Delta Learning) مرحله DPO در OLMo 3 بر اساس «فرضیه یادگیری تفاضلی» [۱۷۲] اجرا شد. بر مبنای این اصل، آنچه موجب یادگیری مؤثر در بهینه‌سازی ترجیحی می‌شود، وسعت و وضوح شکاف کیفی میان پاسخ برگزیده (y_c) و پاسخ نامطلوب (y_r) است. تابع زیان با نرمال‌سازی طول به صورت زیر فرموله شده است:

$$\mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_c, y_r) \sim \mathcal{D}} \left[\log \sigma \left(\frac{\beta}{|y_c|} \log \frac{\pi_{\theta}(y_c | x)}{\pi_{\text{ref}}(y_c | x)} - \frac{\beta}{|y_r|} \log \frac{\pi_{\theta}(y_r | x)}{\pi_{\text{ref}}(y_r | x)} \right) \right] \quad (۶۸)$$

که در آن $\beta = 5$ تنظیم شده است. در داده‌های Dolci Think DPO، خروجی‌های برگزیده از Qwen3-32B و پاسخ‌های مردود از مدل ضعیف Qwen3-0.6B استخراج شدند. همچنین در مدل دستوری، به منظور مقابله با تمایل ذاتی مدل‌ها به درازگویی (Length Bias)، اختلاف طول پاسخ‌های برگزیده و مردود در پرامپت‌های چت محدود شد:

$$|y_c| - |y_r| \leq 100 \quad (۶۹)$$

یادگیری تقویتی با پاداش‌های قابل‌راستی‌آزمایی (RLVR & OlmoRL) فاز نهایی آموزش با زیرساخت توزیع‌شده OlmoRL بر مبنای الگوریتم GRPO [۲۴] اجرا شد. در این فرمولاسیون، جریمه KL حذف شده، مزیت بدون نرمال‌سازی انحراف معیار محاسبه گردیده و از تصحیح نمونه‌برداری اهمیت کوتاه‌شده (TIS) [۱۷۳] استفاده شده است:

$$J(\theta) = \frac{1}{\sum_{i=1}^G |y_i|} \sum_{i=1}^G \sum_{t=1}^{|y_i|} \min \left(\frac{\pi_{\theta}(y_{i,t} | x, y_{i,<t})}{\pi_{\text{vllm}}(y_{i,t} | x, y_{i,<t})}, \rho \right) \times \min(r_{i,t} A_{i,t}, \text{clip}(r_{i,t}, 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) A_{i,t}) \quad (70)$$

که در آن مزیت به صورت $A_{i,t} = r(x, y_i) - \frac{1}{G} \sum_{j=1}^G r(x, y_j)$ بوده و پارامترهای برش به صورت $\varepsilon_{\text{low}} = 0.20$ و $\varepsilon_{\text{high}} = 0.272$ تنظیم شده‌اند. در دادگان ریاضی، راستی‌آزمایی پاسخ با کتابخانه SymPy انجام می‌شود؛ در حوزه برنامه‌نویسی، کدهای تولیدشده در توابع ابری ایزوله AWS Lambda اجرا و ارزیابی می‌گردند؛ و در حوزه دستورات، شروط متنی به صورت قطعی سنجیده می‌شوند. همچنین پرامپت‌هایی که در فیلترینگ اولیه بیش از ۵۲.۶٪ نرخ موفقیت داشتند حذف شدند تا تمرکز مدل روی نمونه‌های چالش‌برانگیز حفظ شود.

جدول ۵۴: ترکیب آماری منابع پرامپت در مجموعه دادگان Dolci Instruct RL و Dolci Think RL

حوزه موضوعی	مجموعه پرامپت	تعداد در Think RL	تعداد در Instruct RL	مرجع
دستورات دقیق	IF-RLVR	۳۰,۱۸۶	۳۸,۰۰۰	[۱۶۵]
ریاضیات	Open-Reasoner-Zero	۳,۰۰۰	۱۴,۰۰۰	[۱۷۴]
	DAPO-Math	۲,۵۸۴	۷,۰۰۰	[۱۲۹]
	AceReason-Math	۶,۶۰۲	-	[۱۷۵]
	Polaris-Dataset	-	۱۴,۰۰۰	[۱۷۶]
	OMEGA-train	۱۵,۰۰۰	۲۰,۰۰۰	[۱۷۷]
کدنویسی	AceCoder	۹,۷۶۷	۲۰,۰۰۰	[۱۵۸]
	KlearReasoner-Code	۸,۰۴۰	-	[۱۷۸]
	Nemotron Post-Training Code	۲,۳۰۳	-	[۱۶۰]
	SYNTHETIC-2	۳,۰۰۰	-	[۱۰۹]
گفتگوی عمومی	Tulu 3 SFT	۷,۱۲۹	۱۸,۹۵۵	[۱۶۳]
	Wildchat-4.8M	۷,۱۲۹	۱۸,۷۶۱	[۹۴]
	Multi-Subject RLVR	۷,۱۲۹	۱۲,۲۳۴	[۱۷۹]
مجموع کل	OLMo 3 Datasets	۱۰۴,۸۶۹	۱۷۱,۹۵۰	-

مسیر یادگیری تقویتی مستقیم از مدل پایه (Dolci RL-Zero) در مسیر OLMo 3 RL-Zero، یادگیری تقویتی بدون عبور از مرحله SFT اعمال شده است:

- با فیلترسازی و خوشه‌بندی معنایی، مجموعه‌ای شامل ۱۳,۳۱۴ پرامپت ریاضیات دست‌چین شد که مدل پایه قادر به پاسخ‌دهی به همه آن‌ها در ۸ نمونه‌برداری اولیه نبود.
- **آزمایش کنترل منفی پاداش کاذب (Spurious Rewards):** برای اطمینان از اینکه عملکرد مدل ناشی از یادگیری استدلال است و نه حفظ‌کردن داده‌ها، آزمایش پاداش تصادفی بر اساس متدولوژی شائو و همکاران [۱۸۰] اجرا شد. نتایج نشان داد که مدل با پاداش‌های تصادفی به هیچ پیشرفتی در آزمون‌های AIME دست نمی‌یابد؛ این امر اثبات کرد که پیکره آموزشی فاقد هرگونه آلودگی داده‌ای نسبت به پنج‌مارک‌ها بوده است.

۲.۱ روش (Method)

۱.۲.۱ پیش‌آموزش (Pre-Training)

DeepSeek-V4 •

مبانی تئوری اطلاعات و تابع هدف پیش‌آموزش فرایند پیش‌آموزش مدل‌های پایه در مقیاس‌های مدرن، بر بهینه‌سازی توزیع احتمالاتی روی دنباله‌ای از متغیرهای تصادفی گسسته $X = (x_1, x_2, \dots, x_T)$ استوار است. بر پایه قضیه شانون برای آنتروپی متقاطع و با فرض اینکه توزیع تجربی داده‌ها برابر با $P(X)$ و توزیع برآوردشده توسط پارامترهای شبکه برابر با $P_\theta(X)$ باشد، انحراف کل میان دو توزیع با استفاده از واگرایی کولبک-لایبلر (KL-Divergence) توصیف می‌شود:

$$D_{KL}(P \parallel P_\theta) = \sum_{X \in \mathcal{X}} P(X) \log \frac{P(X)}{P_\theta(X)} = \mathbb{E}_{X \sim P}[\log P(X)] - \mathbb{E}_{X \sim P}[\log P_\theta(X)] \quad (۷۱)$$

از آنجا که عبارت اول بیانگر آنتروپی ذاتی داده‌ها ($H(P)$) و مقداری ثابت است، کمینه‌سازی واگرایی کولبک-لایبلر معادل با کمینه‌سازی آنتروپی متقاطع و حداکثرسازی لگاریتم درست‌نمایی (Log-Likelihood) خواهد بود. با اعمال قاعده زنجیره‌ای احتمال بر روی دنباله‌های زبانی خودرگرسیو، تابع هدف پیش‌آموزش حاصل می‌شود:

$$\mathcal{L}_{CE}(\theta) = -\frac{1}{T} \sum_{t=1}^T \log P_\theta(x_t \mid x_1, \dots, x_{t-1}) \quad (۷۲)$$

در مدل‌های مدرن نظیر DeepSeek و معماری‌های برآمده از آن، شاخص ارزیابی بیت بر بایت (-Bits/Per-Byte - BPB) به عنوان مقیاسی مستقل از ساختار نشانه‌گذار تعریف می‌گردد:

$$\text{BPB}(X) = \frac{\mathcal{L}_{CE}(\theta) \cdot T}{\ln(2) \cdot B(X)} \quad (۷۳)$$

که در آن $B(X)$ بیانگر تعداد کل بایت‌های خام UTF-8 تشکیل‌دهنده دنباله X است.

معماری توجه با متغیر مکنون چندگانه (Multi-Head Latent Attention - MLA) در پردازش کانتکست‌های فوق‌طولانی، بار حافظه‌ای کش کلید-مقدار (KV-Cache) به مهم‌ترین مانع توان عملیاتی تبدیل می‌شود. در مکانیزم توجه استاندارد، حجم ذخیره‌سازی به شکل خطی با طول توالی T و بعد مدل d رشد می‌کند. مکانیسم MLA با بهره‌گیری از فشردگی کم‌رتبه ماتریسی، این مشکل را حل می‌کند. بردار ورودی $x_t \in \mathbb{R}^d$ به یک بردار فشرده مکنون $c_t^{KV} \in \mathbb{R}^{d_c}$ که در آن $d_c \ll d_h \cdot n_{\text{head}}$ است تصویر می‌گردد:

$$c_t^{KV} = W_{DKV} x_t, \quad W_{DKV} \in \mathbb{R}^{d_c \times d} \quad (۷۴)$$

سپس کلیدها و مقادیر محتوایی برای سر شماره i ($i \in \{1, \dots, n_{\text{head}}\}$) از طریق ماتریس‌های فراافکنش بازسازی می‌شوند:

$$k_{t,i}^C = W_{UK,i} c_t^{KV}, \quad v_{t,i}^C = W_{UV,i} c_t^{KV}, \quad W_{UK,i}, W_{UV,i} \in \mathbb{R}^{d_h \times d_c} \quad (۷۵)$$

برای ممانعت از اختلال اثر موقعیت مکانی در فشردگی، بردار مکانی کلید با استفاده از تعبیه دورانی (RoPE) [۳۶] به صورت مستقل از بردار ورودی تولید و به بردار محتوایی الحاق می‌گردد:

$$k_t^R = \text{RoPE}(W_{KR} x_t), \quad k_{t,i} = \begin{bmatrix} k_{t,i}^C \\ k_t^R \end{bmatrix} \quad (۷۶)$$

این ساختار اجازه می‌دهد در مرحله استنتاج تنها c_t^{KV} و بردار مکانی مشترک در حافظه ذخیره شوند که موجب صرفه‌جویی بیش از ۷۵ درصدی در حافظه نهان می‌شود.

مکانیزم توجه تنک محتوامحور (DeepSeek Sparse Attention - DSA) برای دستیابی به مقیاس کانتکست‌های یک میلیون توکنی، پیچیدگی زمانی $\mathcal{O}(T^2)$ توجه کامل با سازوکار تنک محتوامحور DSA جایگزین می‌گردد. در این ساختار، شاخص‌گذار پرسرعت (Lightning Indexer) ابتدا امتیاز تطابق توکن پرسش q_t با توکن‌های گذشته را در فضایی کم‌بعد برآورد می‌کند:

$$s_{t,j} = \text{ReLU} \left(q_t^{\text{idx}} \cdot (k_j^{\text{idx}})^T \right), \quad j \leq t \quad (77)$$

سپس k توکن دارای بالاترین امتیاز گزینش شده و توجه استاندارد صرفاً بر روی این زیرمجموعه برگزیده محاسبه می‌شود:

$$\mathcal{I}_t = \text{argTopK}_{j \leq t}(s_{t,j}), \quad |\mathcal{I}_t| = k \ll T \quad (78)$$

$$\text{Attn}(q_t, K, V) = \sum_{j \in \mathcal{I}_t} \frac{\exp \left(\frac{q_t k_j^T}{\sqrt{d_k}} \right)}{\sum_{m \in \mathcal{I}_t} \exp \left(\frac{q_t k_m^T}{\sqrt{d_k}} \right)} v_j \quad (79)$$

این تبدیل هوشمندانه، پیچیدگی محاسباتی توجه را به صورت محلی خطی نموده و امکان پردازش بافت‌های فوق‌طولانی را با حفظ پیوستگی معنایی فراهم می‌آورد.

• GLM-5

معماری مدل و مقیاس‌پذیری متخصصان (Architecture & MoE Scaling) مدل GLM-5 [۱۸] به عنوان مدل پرچمدار با ساختار ترکیبی از متخصصان (MoE) با ۲۵۶ متخصص تفکیک‌شده و ۱ متخصص اشتراکی طراحی شده است. از میان متخصصان، در هر گام محاسباتی به ازای هر توکن ۸ متخصص فعال می‌شوند ($K = 8$). ابعاد هندسی مدل به گونه‌ای تراز شده است که توازن بهینه میان ارتباطات بینابینی و توان پردازشی برقرار شود:

- **تعداد کل پارامترها:** ۷۴۴ میلیارد پارامتر (744B) با ۴۰ میلیارد پارامتر فعال در هر گام محاسباتی (40B active).
- **تعداد لایه‌ها:** ۸۰ لایه ترانسفورمر دکودر شامل ۳ لایه کاملاً متراکم (Dense) در ابتدای شبکه و ۷۵ لایه مبتنی بر MoE و ۲ لایه پیش‌بینی چندتوکنی (MTP).
- **ابعاد پنهان:** بعد مخفی $d = 6144$ ، بعد میانی لایه‌های متراکم ۱۲۲۸۸ و بعد میانی هر لایه متخصص ۲۰۴۸ است.

بهینه‌سازی Muon Split و ساختار MLA-256 در ترکیب مکانیزم توجه MLA با بهینه‌ساز ماتریسی Muon [۴]، ناسازگاری ابعادی میان ماتریس‌های فرافکنی بزرگ منجر به تضعیف یادگیری می‌شد. روش ارتوگونال‌سازی نیوتن-شولتز (Newton-Schulz Iteration) برای یک ماتریس عمومی $M \in \mathbb{R}^{n \times m}$ که مقادیر ویژه تکی آن درون بازه $(0, \sqrt{3})$ مقیاس شده‌اند، به صورت تکرار زیر تعریف می‌گردد:

$$X_{k+1} = \frac{1}{2} X_k (3I - X_k^T X_k) \quad (80)$$


به منظور جلوگیری از غلبه مقیاس یک سر خاص بر کل ماتریس در فرافکنی‌های فراگیر، در GLM-5 روش **Muon Split** ابداع شد: ماتریس‌های فرافکنی W_{UQ}, W_{UK}, W_{UV} در راستای بعد سرها خرد شده و متعامدسازی به شکل مستقل بر هر زیرماتریس اعمال می‌گردد:

$$W_U = \begin{bmatrix} W_U^{(1)} \\ W_U^{(2)} \\ \vdots \\ W_U^{(H)} \end{bmatrix} \implies W_U^{(h)} \leftarrow \text{Orthogonalize} \left(W_U^{(h)} \right) \quad (81)$$

علاوه بر این، بعد هر سر از ۱۹۲ به ۲۵۶ افزایش و تعداد سرها با ضریب یک‌سوم کاهش داده شد (MLA-256) تا هزینه ضرب داخلی ۵۷۶ بعدی در زمان رمزگشایی متوازن گردد.

پیش‌بینی چندتوکنی با اشتراک پارامتر (Shared-Parameter MTP) به جای آموزش ماژول‌های مجزا به ازای پیش‌بینی N توکن آتی که منجر به مصرف خطی حافظه پنهان می‌گردد، در GLM-5 پارامترهای ۳ لایه MTP با یکدیگر به اشتراک گذاشته شده‌اند. تابع اتلاف مجموع حاصل از گام‌های همزمان به شکل زیر بیان می‌شود:

$$\mathcal{L}_{\text{MTP}}(\theta) = \mathcal{L}_{\text{Main}}(\theta) + \sum_{k=1}^3 \lambda_k \mathcal{L}_{\text{CE}} \left(P_{\theta}^{(k)}(x_{t+k} \mid x_{\leq t}), x_{t+k} \right), \quad \text{شرط } \theta_{\text{MTP}}^{(1)} \equiv \theta_{\text{MTP}}^{(2)} \equiv \theta_{\text{MTP}}^{(3)}$$



شکل ۱: جریان فنی پیش‌آموزش GLM-5 شامل مکانیزم‌های Muon Split، توجه تنک DSA و لایه‌های MTP.

پیش‌آموزش ادامه‌دار با توجه تنک و مقیاس کانتکست مدل با یک رژیم دو مرحله‌ای از توجه متراکم به توجه تنک انتقال یافته است:

- **گرم‌سازی شاخص‌گذار:** در طول ۱۰۰۰ گام، نرخ یادگیری تا 5×10^{-3} تنظیم شد تا پارامترهای شاخص‌گذار بدون تغییر در مدل اصلی یادگیری را تثبیت کنند.
- **تطبیق تنک:** با بودجه ۲۰ میلیارد توکن، شبکه اصلی بر مبنای استخراج $k = 2048$ کلید برتر کالیبره شد.
- **بسط طول کانتکست در فاز میانی (Mid-Training):** پنجره کانتکست طی سه مرحله تدریجی گسترش یافت: 32K (۱ تریلیون توکن)، 128K (۵۰۰ میلیارد توکن) و 200K (۵۰ میلیارد توکن).

• Kimi K3

معماری چندوجهی ۸.۲ تریلیون پارامتری و ابعاد پایه مدل Kimi K3 [۱۸۲] به عنوان بزرگ‌ترین مدل وزن‌باز جهان با ساختار ترکیبی از متخصصان (MoE) با مشخصات فنی زیر پایه‌گذاری شده است:

- **مقیاس پارامتری:** ۷۸.۲ تریلیون پارامتر کل (2.78T) با ۲.۱۰۴ میلیارد پارامتر فعال در هر توکن (104.2B active).
- **عمق و بعد مدل:** ۹۳ لایه ترانسفورمر دکودر با بعد پنهان $d = 7168$ و حداکثر طول بافت ۱ میلیون توکن (1M tokens).
- **ترکیب لایه‌ای توجه هیبرید:** هر بلوک از ۳ لایه Kimi Delta Attention (KDA) و ۱ لایه Gated MLA تشکیل شده است (نسبت ۳ به ۱).

تحلیل ریاضی بازگشتی و زوال کران‌دار در KDA مکانیزم KDA فرمول‌بندی قانون دلتا را با گیت فراموشی کانالی ترکیب می‌کند. بردار حالت بازگشتی ماتریسی $S_t \in \mathbb{R}^{d_k \times d_v}$ به شکل زیر به‌نگام‌سازی می‌شود:

$$S_t = (I - \beta_t k_t k_t^T) \text{Diag}(\alpha_t) S_{t-1} + \beta_t k_t v_t^T, \quad \tilde{o}_t = S_t^T q_t \quad (۸۳)$$

در پیاده‌سازی‌های گذشته، لگاریتم زوال به صورت نامحدود در بازه $(-\infty, 0)$ تعریف می‌شد که معکوس تجمعی آن $(1/T)$ در ممیزهای شناور دچار سرریز عددی می‌گشت. در **Kimi K3**، زوال لگاریتمی به صورت کران‌دار با سیگموئید مقیاس‌شده فرمول‌بندی شده است:

$$g_t^h = g_{\min} \text{Sigmoid}(e^{A_h} z_t^h) \in (g_{\min}, 0)^{d_k}, \quad g_{\min} = -5 \quad (84)$$

$$\alpha_t^h = \exp(g_t^h) \in (e^{-5}, 1)^{d_k} \implies \alpha_{t,j}^h > e^{-5} \approx 6.7 \times 10^{-3} \quad (85)$$

بنابراین، بر روی هر بلوک کاشی ۱۶ توکنی، زوال تجمعی همواره در بازه $(-80, 0)$ محصور شده و وارون آن کمتر از e^{80} باقی می‌ماند که کاملاً در محدوده دینامیکی BF16 است. این نوآوری امکان اجرای محاسبات ضرب ماتریسی متراکم را مستقیماً روی هسته‌های تانسوری فراهم ساخته و گلوگاه محاسباتی قطری را مرتفع می‌سازد.

پسماندهای توجه در عمق شبکه (Block Attention Residuals - AttnRes) به جای اتصالات پسماند کلاسیک $(h_l = h_{l-1} + f_l(h_{l-1}))$ ، مدل **Kimi K3** از مکانیزم AttnRes در لایه‌ها استفاده می‌کند. به منظور کنترل سربار حافظه از $\mathcal{O}(Ld)$ به $\mathcal{O}(Nd)$ ، لایه‌ها به $N = 8$ بلوک با اندازه ۱۲ لایه تقسیم شده‌اند. با تعریف بازنمایی خلاصه‌شده هر بلوک به صورت $b_n = \sum_{j \in B_n} f_j(h_j)$ ، توجه لایه l روی بردار شبه‌پرسش w_l محاسبه می‌شود:

$$\alpha_{i \rightarrow l} = \frac{\exp(w_l^T \text{RMSNorm}(k_i))}{\sum_{j=0}^{l-1} \exp(w_l^T \text{RMSNorm}(k_j))}, \quad h_l = \sum_{i=0}^{l-1} \alpha_{i \rightarrow l} v_i \quad (86)$$

متخصصان مکنون پایدار (Stable LatentMoE) و فعال‌ساز SiTU-GLU تعداد متخصصان به ۸۹۶ متخصص افزایش یافته که ۱۶ متخصص در هر گام فعال می‌شوند. بردار ورودی ابتدا به فضای مکنون $\ell = 3584$ فشرده می‌شود ($W_{\downarrow}$) و پس از تجمیع خروجی متخصصان، پیش از فرافکنی بالا لایه RMSNorm اعمال می‌گردد:

$$u = \sum_{i \in \mathcal{T}_k(x)} p_i E_i^{\text{routed}}(W_{\downarrow} x), \quad y = \sum_{j=1}^{N_s=2} E_j^{\text{shared}}(x) + W_{\uparrow} \text{RMSNorm}(u) \quad (87)$$

برای مهار فعال‌سازی‌های فرین، تابع SiTU-GLU با تحدید دوطرفه شاخه‌ها پیاده‌سازی شده است:

$$\text{SiTU-GLU}(x) = \left[\beta_1 \tanh\left(\frac{W_g x}{\beta_1}\right) \odot \text{Sigmoid}(W_g x) \right] \odot \left[\beta_2 \tanh\left(\frac{W_u x}{\beta_2}\right) \right] \quad (88)$$

با انتخاب $\beta_1 = 4$ و $\beta_2 = 25$ ، خروجی در بی‌نهایت محدود به کران قطعی است:

$$\|\text{SiTU-GLU}(x)\|_{\infty} \leq \beta_1 \beta_2 = 100 \quad (89)$$

تعادل بار کوانتالی (Quantile Balancing - QB) تخصیص بهینه توکن‌ها با حل مسئله دوگان برقراری توازن بار انجام می‌گیرد. با کمینه‌سازی متناوب متغیرهای دوگان، مقدار انحراف بهینه متخصص j به صورت تحلیلی به عنوان کوانتایل حاشیه‌ها حاصل می‌گردد:

$$\beta_j^{(t+1)} \leftarrow \text{quantile}_{1-k/n}(s_{:,j} - \alpha^{(t)}), \quad b^{(t+1)} = -\beta^{(t+1)} - \text{mean}(-\beta^{(t+1)}) \quad (90)$$

این مقدار با یک تخمین‌گر هیستوگرامی با ۱۰۰۰ بازه و با سربار ارتباطی زیر ۱٪ در سطح خوشه‌ها همگام می‌گردد.

موازی سازی کانتکست KDA (KCP) و چارچوب MoonEP در موازی سازی بافت، ماتریس های گذار ضربی به همراه حالت تولید شده محلی از رابطه بازگشتی زیر در رتبه ها ترکیب می شوند:

$$S_{[i+1]}^t = \tilde{S}_{[i+1]}^t + M_{[i+1]}^{t \leftarrow 1} S_{[i]}^{T_i}, \quad M_{[i+1]}^{t \leftarrow 1} = \prod_{r \leftarrow 1}^t M_r \quad (91)$$

چارچوب MoonEP اثبات می کند که با تخصیص حداکثر E/R متخصص مازاد به ازای هر رتبه، توازن بار کامل پردازش توکن ها با ارتباطات بدون کپی (Zero-Copy) و بدون وقفه سنکرون تضمین می گردد.

• Magistral

جایگاه مدل های پایه و هندسه فضای وزن ها مدل های Magistral [۱۸۳] (شامل نسخه Small با ۲۴ میلیارد پارامتر و Medium) نشان می دهند که چگونه قابلیت های بنیادین زبانی، استدلال و درک چندوجهی در مرحله پیش آموزش می توانند بستری پایدار برای رفتارهای پیشرفته فراهم آورند. مدل های پایه مورد استفاده در این پروژه، نسخه های پیش آموزش دیده متراکم Mistral و Mistral Small 3 Medium هستند.

تحلیل مؤلفه های اصلی (PCA) در زیر فضای وزن های پیش آموزش برای درک چگونگی رفتار بازنمایی های پیش آموزش در مواجهه با فرآیندهای بهینه سازی استدلالی، تغییرات بردار وزن های مدل در طول بهینه سازی تحلیل شده است. ماتریس وزن های چک پوینت های متوالی به صورت $X \in \mathbb{R}^{T \times W}$ گردآوری گردید (T تعداد گام های ذخیره شده و W تعداد کل وزن های شبکه). با اعمال الگوریتم لانچوس-آرنولد (Lanczos-Arnoldi Iteration)، دو بردار ویژه اول ماتریس کوواریانس $X^T X$ محاسبه و بهنجار شدند (c_1, c_2):

$$w(\alpha_1, \alpha_2) = w^* + \alpha_1 c_1 + \alpha_2 c_2 \quad (92)$$

با سنجش تغییرات برازش بر روی این ابرصفحه دو بعدی، مشاهده شد که یادگیری استدلال یک خط سیر پیوسته و جهت دار در امتداد یک بُعد به نام «طول استدلال» را طی می کند. میزان پاداش خام به دست آمده ارتباط مستقیمی با طول توالی تولیدی نشان می دهد:

$$R(y) = a \cdot \ln(\text{Length}(y)) + b \quad (93)$$

این تحلیل اثبات می کند که ساختار هندسی فضای وزن های حاصل از پیش آموزش به هیچ عنوان دچار تخریب یا تغییرات فاز ناگهانی نمی شود، بلکه قابلیت های مدل در راستای بردارهای ویژه کم بعد فعال می گردد.

ماندگاری توانایی های چندوجهی (Multimodal Free Lunch) مدل های پایه با انکودرهای تصویری پیش آموزش دیده تلفیق شده اند. ارزیابی ها نشان داد که حتی اگر آموزش های بعدی صرفاً بر روی دادگان متنی متمرکز باشند، ساختار بازنمایی چندوجهی نه تنها دست نخورده باقی می ماند، بلکه به دلیل عمق تفکر استنتاجی، توانایی استدلال روی تصاویر در بنچمارک هایی نظیر MMMU-Pro-Vision تا ۱۲ درصد بهبود می یابد.

• MiniMax-M2

فلسفه فعال سازی حداقلی (Mini Activations) سری مدل های MiniMax-M2 [۱۸۴] بر مبنای اصل بیشینه سازی کارایی پیش آموزش طراحی شده اند:

- تعداد کل پارامترها: ۹.۲۲۹ میلیارد پارامتر (229.9B).
- پارامترهای فعال به ازای توکن: تنها ۸.۹ میلیارد پارامتر (9.8B active).
- پیکربندی پایه: ۶۲ لایه دکودر ترانسفورمر، بعد پنهان ۳۰۷۲، دایره واژگان ۲۰۰،۰۶۴ توکن.
- طول کانتکست پیش آموزش: ۱۹۲،۰۰۰ توکن (192K context).

انتخاب راهبردی توجه کامل در برابر رد فرضیه SWA آزمایش‌های پیش‌آموزش گسترده در مقیاس تریلیون توکن بر روی مدل‌های هیبرید توجه پنجره لغزان (Hybrid SWA) [۱۸۴] نشان داد که الگوهای متناوب توجه محلی باعث زوال شدید توانایی بازیابی اطلاعات در کانتکست‌های بلند و استدلال چندمرحله‌ای می‌شوند (افت امتیاز بازیابی RULER در طول 128K از ۹۰ به ۷۲). بر این اساس، مدل MiniMax-M2 فرضیه استفاده از لایه‌های تنک پنجره‌ای را کنار گذاشته و از سازوکار توجه متراکم با پرسش‌های گروهی (GQA) با ۴۸ سر پرسش و ۸ سر کلید-مقدار در تمام لایه‌ها به همراه تعبیه دورانی RoPE بهره می‌برد.

متخصصان ریزدانه با گیتینگ سیگموئید و بایاس یادگیرنده لایه‌های FFN شامل ۲۵۶ متخصص ریزدانه هستند که ۸ متخصص به ازای هر توکن گزینش می‌شوند. برخلاف روش‌های سنتی مبتنی بر Softmax، امتیازدهی از طریق تابع سیگموئید مستقل محاسبه می‌گردد:

$$s_i = \text{Sigmoid}(W_r x + b_i) \quad (94)$$

این ساختار قید مجموع-صفر (Zero-Sum) را حذف کرده و امکان انتخاب همزمان چندین متخصص برجسته را بدون تداخل مقیاسی فراهم می‌کند. پارامترهای بایاس b_i به طور مشترک با وزن‌های شبکه بهینه‌سازی شده و به صورت ضمنی توازن بار متخصصان را بدون نیاز به توابع اتلاف کمکی سنگین تضمین می‌نمایند.

پیش‌بینی چندتوکنی (MTP) و تکامل با کپی وزن‌ها در فاز اولیه پیش‌آموزش، مدل به یک ماژول MTP ($K = 1$) مجهز است که با ضریب اتلاف اولیه 0.3 شروع شده و در فاز زوال به 0.1 می‌رسد. در فاز زوال آموزش ادامه‌دار، ماژول MTP به $K = 3$ تعمیم می‌یابد. به جای مقداردهی اولیه تصادفی، پارامترهای لایه‌ها مستقیماً از شبکه اصلی کپی می‌شوند:

$$\theta_{\text{MTP},k}^{(0)} \leftarrow \theta_{\text{Block Main}} \quad (95)$$

این راهبرد انحراف بازنمایی لایه‌ها را به حداقل رسانده و سرعت همگرایی ماژول پیش‌بینی را تا چندین برابر افزایش می‌دهد. فرایند پیش‌آموزش روی ۲.۲۹ تریلیون توکن (۹T.۱۹ در فاز نرخ ثابت و ۳T.۹ در فاز زوال) با بسط تدریجی طول توالی از 8K به 32K و در نهایت 192K توکن تکمیل گردید.

• MobileLLM-Pro

معماری فشرده ۱ میلیارد پارامتری مدل MobileLLM-Pro [۱۸۵] برای عملکرد بالا در دستگاه‌های همراه با منابع حافظه‌ای و محاسباتی محدود بهینه‌سازی شده است:

- **ابعاد مدل:** ۳۰ لایه ترانسفورمر دکودر، بعد مخفی ۱۲۸۰، ۲۰ سر توجه با بعد ۶۴، مکانیزم GQA با ۴ زوج کلید-مقدار و ضریب گسترش لایه FFN معادل $4.8 \times$.
- **اشتراک کامل تعبیه و لایه خروجی (Tied Embeddings):** با اشتراک وزن‌های ماتریس تعبیه ورودی و سر نگاشت واژگان ۲۰۰،۰۴۸ توکنی، ۲۶۰ میلیون پارامتر (حدود ۲۵٪ از کل ظرفیت مدل) صرفه‌جویی شده و حجم پارامترها روی ۰.۸۱ میلیارد تثبیت می‌گردد.
- **توجه محلی-سراسری متناوب:** نسبت ۳ لایه توجه محلی پنجره لغزان (با پهنای پنجره ۵۱۲ توکن) به ۱ لایه توجه سراسری، که ضمن حفظ کارایی محاسباتی، پردازش کانتکست تا سقف ۱۲۸،۰۰۰ توکن را ممکن می‌سازد.

فاز ۱: یادگیری زبان بر مبنای تقطیر لاجیت و شبیه‌سازی داده (SDM) آموزش روی ۴.۱ تریلیون توکن با طول توالی ۲۰۴۸ توکن و با استفاده از تقطیر دانشی لاجیت‌ها (Logit-based KD) از مدل معلم Llama 4-Scout اجرا شد:

$$\mathcal{L}_{\text{KD}}(\theta) = \sum_{v \in \mathcal{V}} P_{\text{teacher}}(v | x) \log \left(\frac{P_{\text{teacher}}(v | x)}{P_{\theta}(v | x)} \right) \quad (96)$$

ترکیب بهینه داده‌ها از طریق چارچوب Scalable Data Mixer (SDM) تعیین گردید: با استفاده از مدل‌های زبانی آماری سبک (SLM) اثر هر داده بر کاهش اتلاف تخمین زده شده و با برآزش یک رگرسیون عصبی، وزن بهینه زیرمجموعه‌ها پیش از آموزش اصلی به دست آمد.

فاز ۲: بسط کانتکست با تقطیر مکانی ضمنی (Implicit Positional Distillation) برای دستیابی به بافت ۱۲۸K بدون نیاز به متون طولانی کمیاب، روش Implicit Positional Distillation معرفی شد. تبدیل دورانی RoPE در صفحات دوبعدی به فرم زیر است:

$$R_{\Theta,p}^{2d} = \begin{pmatrix} \cos(p\theta_i) & -\sin(p\theta_i) \\ \sin(p\theta_i) & \cos(p\theta_i) \end{pmatrix} \quad (97)$$

در آموزش با اسناد کوتاه، زوایای بزرگ‌تر از $\theta_i L_{\text{short}}$ کاوش نمی‌شوند. اما لاجیت‌های مدل معلم آموزش دیده روی کانتکست‌های بزرگ، توزیع همبستگی مکانی در کل فضای زاویه‌ای ۳۶۰ درجه را به صورت ضمنی حمل می‌کنند. آموزش دانشجو صرفاً با لاجیت‌های معلم در طول ۲۰ میلیارد توکن اضافی، بدون هیچ‌گونه تغییر در توزیع محتوایی داده‌ها، توانایی بافت ۱۲۸K را به مدل اعطا نمود.

فاز ۳: ادغام مدل‌های متخصص (Specialist Model Merging) در فاز بازپخت نهایی طی ۶۰ میلیون توکن، n شاخه موازی از مدل پایه منشعب شده و هر شاخه به طور مستقل روی یک دامنه مشخص (استدلال، کدنویسی، دانش موضوعی) با نرخ یادگیری نزولی آموزش دید. در نهایت پارامترها با میانگین‌گیری غیریکنواخت تلفیق شدند:

$$\theta_{\text{unified}} = \sum_{b=1}^n w_b \theta_b, \quad \sum_{b=1}^n w_b = 1.0 \quad (98)$$

فاز ۴: آموزش آگاه از کمی‌سازی ۴ بیتی (4-bit QAT) در ۸۰ میلیارد توکن نهایی، کمی‌سازی ۴ بیتی متقارن گروهی با اندازه گروه ۳۲ برای وزن‌ها و ۸ بیتی پویا برای اکتیویشن‌ها شبیه‌سازی شد. بازه‌های کمی‌سازی $(w_{\min}, w_{\max})$ با پس‌انتشار گرادیان به متغیرهای یادگیرنده تبدیل شدند:

$$Q(W_g) = s_w \times \text{clip} \left(\left\lfloor \frac{W_g}{s_w} \right\rfloor, -8, 7 \right), \quad s_w = \frac{1}{7.5} \max(-w_{\min}, w_{\max}) \quad (99)$$

• Nemotron 3

معماری پیوندی Mamba-Transformer MoE سری Nemotron 3 [۱۸۶] (شامل مدل‌های Nano-، Ultra و Super، 30B-A3B) با تلفیق لایه‌های فضای حالت (SSM) و ترانسفورمر، توازن سرعت و کیفیت را ارتقا داده است. در مدل پایه، بیشتر لایه‌ها از نوع Mamba-2 هستند که با لایه‌های MoE جفت شده‌اند و تنها تعداد انگشت‌شماری لایه توجه کامل در شبکه تعبیه شده است. لایه‌های Mamba-2 حالت مخفی بازگشتی با اندازه ثابت $h_t \in \mathbb{R}^{d_{\text{state}}}$ را نگهداری می‌کنند:

$$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t, \quad y_t = C_t h_t + D x_t \quad (100)$$

حذف نیاز به کش رو به رشد KV در اکثر لایه‌ها، توان عملیاتی استنتاج را در دنباله‌های طولانی تا بیش از ۳.۳ برابر نسبت به مدل‌های تمام‌ترانسفورمر افزایش می‌دهد.

طراحی متخصصان مکنون (LatentMoE) برای شکستن گلوگاه پهنای باند و ارتباطات All-to-All که مستقیماً با بعد مدل d و تعداد متخصصان فعال K مقیاس می‌شود ($\mathcal{O}(K \cdot d)$)، معماری LatentMoE توکن‌ها را به بعد مکنون $\ell \approx d/4$ فشرده می‌سازد:

$$z = W_{\text{down}} x \in \mathbb{R}^{\ell}, \quad W_{\text{down}} \in \mathbb{R}^{\ell \times d} \quad (101)$$

محاسبات متخصصان در این فضای مکنون اجرا شده و سپس به بعد اصلی بازگردانده می‌شود:

$$u = \sum_{i \in \text{TopK}} p_i \text{FFN}_i(z), \quad y = W_{\text{up}} u \in \mathbb{R}^d \quad (102)$$

ظرفیت آزادشده پهنای باند صرف افزایش تعداد کل متخصصان از ۱۲۸ به ۵۱۲ و تعداد متخصصان فعال از ۶ به ۲۲ شده است، که ظرفیت غیرخطی مدل را به شدت بالا می‌برد.

پیش‌آموزش بومی با فرمت NVFP4 پیش‌آموزش روی ۲۵ تریلیون توکن با بهره‌گیری بومی از محاسبات ممیز شناور ۴ بیتی انویدیا (NVFP4) صورت پذیرفته است:

- **فرمت میکروبلوک:** ساختار ۱۶ عنصری با فاکتورهای مقیاس $E4M3$ و عناصر $E2M1$ همراه با مقیاس سراسری ممیز شناور ۳۲ بیتی.
- **تبدیل تصادفی هادامارد (RHT):** اعمال تبدیل RHT بر تنسورهای ورودی به منظور محو کردن نقاط تکین فرین و پایداری محاسبات گرادیان وزن (w_{grad}).
- **حفاظت از لایه‌های حساس:** ۱۵٪ لایه‌های انتهایی مدلی به همراه لایه‌های فزافکنی مکنون در دقت BF16 حفظ شده و لایه‌های خروجی Mamba به دلیل حساسیت به صفر شدن زود هنگام در فرمت MXFP8 آموزش دیدند.

مدل از مکانیزم موقعیتی بومی لایه‌های فضای حالت بهره‌برده و فاقد تعبیه دورانی در لایه‌های توجه است (No-RoPE)، که گسترش طول یافت به ۱ میلیون توکن را در فاز CPT تسهیل می‌کند.

Qwen3


ساختار معماری متراکم و MoE خانواده مدل‌های Qwen3 [۱۸۷] در دو دسته متراکم (شامل نسخه‌های ۶B، ۷B، ۴B، ۸B، ۱۴B و ۳۲B) و مدل‌های مبتنی بر متخصصان (نسخه A۳B-A۳۰B و مدل پرچمدار (A۲۲B-A۲۳۵B) طراحی شده‌اند. در مدل پرچمدار Qwen3-235B-A22B:

- **لایه‌ها و پیکربندی توجه:** ۹۴ لایه ترانسفورمر مجهز به پرسش گروهی (GQA با ۶۴ سر پرسش و ۴ سر کلید-مقدار) و بعد زمینه تا سقف ۱۲۸K توکن.
- **متخصصان:** ۱۲۸ متخصص ریزدانه که ۸ متخصص به ازای هر توکن فعال می‌گردند ($K = 8$). برای بیشینه‌سازی تخصص‌گرایی، متخصصان اشتراکی حذف شده و تابع اتلاف توازن بار سراسری درون دسته (Global-Batch Load Balancing Loss) اعمال شده است.
- **پایداری محاسباتی:** حذف کامل بایاس از لایه‌های تصویر QKV و اعمال هم‌نرمال‌سازی QK-Norm روی هر سر توجه:

$$q_{\text{norm}} = \frac{q}{\|q\|_2} \odot \gamma_q, \quad k_{\text{norm}} = \frac{k}{\|k\|_2} \odot \gamma_k \quad (103)$$

خط لوله دادگان ۳۶ تریلیون توکنی
۱۱۹ زبان و گویش اجرا شده است:

- **استخراج متن با مدل‌های بینایی-زبانی:** تنظیم دقیق Qwen2.5-VL جهت شناسایی متن در اسناد اسکن‌شده PDF و بازبینی توسط Qwen2.5، که تریلیون‌ها توکن متنی باکیفیت تولید کرد.
- **تولید داده‌های سنتزی:** بهره‌گیری از مدل‌های تخصصی Qwen2.5-Math و Qwen2.5-Coder جهت سنتز متون درسی و کدهای برنامه‌نویسی.
- **سیستم نشانه‌گذاری ریزدانه در سطح نمونه:** درجه‌بندی داده‌ها از منظر ارزش آموزشی، حوزه دانش و ایمنی و انتخاب ترکیب بهینه داده‌ها بر روی مدل‌های پروکسی در سطح نمونه منفرد.



شکل ۲: سازوکار لایه LatentMoE در مدل‌های Nemotron 3.

مراحل سه‌گانه پیش‌آموزش (Three-Stage Pre-training) پیش‌آموزش طبق برنامه زیر به انجام رسید:

- **مرحله عمومی (S1):** آموزش روی بیش از ۳۰ تریلیون توکن با طول توالی ۴,۰۹۶ توکن برای یادگیری ساختار زبان و دانش عام.
- **مرحله استدلال (S2):** آموزش تکمیلی روی ۵ تریلیون توکن با غلظت بالای ریاضیات، کد و داده‌های علمی، همراه با زوال شتاب‌یافته نرخ یادگیری.
- **مرحله کانتکست بلند (S3):** آموزش روی صدها میلیارد توکن در طول توالی ۳۲,۷۶۸ توکن (شامل ۷۵٪ متون بین ۱۶K تا ۳۲K فرکانس پایه RoPE از ۱۰,۰۰۰ به ۱,۰۰۰,۰۰۰ افزایش یافته و از روش‌های YaRN [۱۷] و Dual Chunk Attention (DCA) جهت تعمیم طول زمینه در زمان استنتاج استفاده شد.

• OLMo 3

معماری کاملاً شفاف مدل پایه (Olmol 3 Base) مدل‌های پایه OLMo 3 [۱۸۸] در دو نسخه کاملاً باز ۷B (۳۲ لایه، بعد پنهان ۴,۰۹۶، ۳۲ سر توجّه) و ۳۲B (۶۴ لایه، بعد پنهان ۵,۱۲۰، ۴۰ سر پرسش و ۸ سر کلید-مقدار GQA) عرضه شده‌اند. در سه لایه از هر چهار لایه، سازوکار توجّه پنجره لغزان (SWA) با پهنای ۴,۰۹۶ توکن به کار گرفته شده و لایه چهارم به همراه لایه انتهایی مدل از توجّه متراکم کامل بهره می‌برند. فرکانس پایه تعبیه دورانی روی $\theta = 500,000$ تنظیم شده است.

پالایش چندمرحله‌ای و تئوری اطلاعاتی دادگان Dolma 3 آماده‌سازی پیکره ۹.۵ تریلیون توکنی Dolma 3 Mix از میان ۶.۲۵۲ میلیارد سند وب با سه فاز متمایز پالایش گردید:

- **پالایش اکتشافی و زبانی:** حذف نشانی‌های اینترنتی هرزنامه، پالایش طول، حذف متون با نمادهای تکراری و اعمال فیلتر زبان انگلیسی FastText با آستانه ۶۵.۰ (کاهش ۶.۸۴ درصدی اسناد).
- **حذف افزونگی سه‌گانه با ابزار Duplodocus:** (۱) حذف کپی‌های دقیق هشت ۱۲۸ بیتی متن اسناد با کاهش ۶۶ درصدی اسناد، (۲) حذف فازی بر مبنای MinHash در ۳۲ بخش با هدف‌گیری شباهت ژاکارد ≥ 0.80 با کاهش ۲۴ درصدی، (۳) حذف زیررشته‌های تکراری با آرایه‌های پسوندی فازی (Suffix Array) برای دنباله‌های بالای ۵۰۰ بایت با کاهش ۱۴ درصدی بایت‌ها.
- **پالایش اسناد علمی با olmOCR:** استخراج متون از ۱۰۸ میلیون سند علمی PDF و پالایش کیفی بر اساس فشرده‌پذیری gzip (حذف ۲۰٪ داده‌های بسیار فشرده‌پذیر و ۲۰٪ داده‌های کم‌فشرده‌پذیر به عنوان داده‌های پرت).

ترکیب بهینه مقید داده‌ها (Constrained Mixing - Olmix) ترکیب داده‌ها با هدف کمینه‌سازی شاخص بیت بر بایت (BPB) بر مبنای یک کلونی از مدل‌های کوچک ۳۰ میلیون پارامتری آموزش‌دیده روی توزیع‌های دیریکله نمونه‌برداری‌شده از سهم دامنه‌ها بهینه‌سازی شد. برای هر وظیفه k ، یک مدل رگرسیون خطی تعمیم‌یافته برازش داده شد:

$$\widehat{\text{BPB}}_k(w) = \beta_0^{(k)} + \sum_j \beta_j^{(k)} w_j \quad (104)$$


سپس مسئله بهینه‌سازی مقید زیر با اعمال سقف تکرار برای هر دامنه حل گردید:

$$\min_w \frac{1}{K} \sum_{k=1}^K \widehat{\text{BPB}}_k(w) \quad \text{s.t.} \quad \sum_j w_j = 1, \quad 0 \leq w_j \leq \frac{M \cdot X_j}{Z} \quad (105)$$

بازنمونه‌برداری کیفی با توابع نمایشی-توانی بریده‌شده برای نمونه‌برداری ترجیحی از متون باکیفیت بدون حذف ناگهانی، توابع بازنمونه‌برداری زیر به ازای صدک کیفیت x برازش داده شدند:

$$f_{p,\lambda}(x) = \begin{cases} 0, & x < a \\ C(x-a)^p e^{\lambda(x-a)}, & x \geq a \end{cases} \quad (106)$$

با تنظیم آستانه حذف $a = 0.40$ (حذف ۴۰٪ داده‌های بی‌کیفیت) و سقف تکرار $M = 7$ ، مقادیر پارامترها به صورت عددی محاسبه شدند.



شکل ۳: چرخه پیش‌آموزش سه‌مرحله‌ای مدل‌های پایه OLMo 3.

بسط طول کانتکست به ۶۴K توکن در فاز نهایی بسط کانتکست (۵۰ میلیارد توکن برای مدل VB و ۱۰۰ میلیارد توکن برای (۳۲B) الگوریتم YaRN منحصراً بر روی لایه‌های توجه کامل اعمال شد و لایه‌های SWA دست‌نخورده باقی ماندند. بسته‌بندی اسناد با بهترین تطابق (Best-Fit Packing) به همراه ماسک‌گذاری توجه درون‌سندی (Intra-Document Masking) از ایجاد پیوندهای کاذب میان متون مستقل جلوگیری نمود. در پایان، چک‌پوینت‌های انتهایی مدل ۳۲B با یکدیگر ادغام (Model Souping) شدند.

۲.۲.۱ پس‌آموزش (Post-Training)


• DeepSeek-V4

مقدمه و پارادایم نوین پس‌آموزش (Post-Training Paradigm) مرحله پس‌آموزش (Post-Training) در مدل‌های سری DeepSeek-V4 دستخوش یک دگرگونی بنیادین شده است. در نسل‌های پیشین (نظیر DeepSeek-V3.2 [۱۲])، ارتقای هم‌زمان قابلیت‌های چندگانه از طریق یک مرحله یادگیری تقویتی ترکیبی (Mixed Reinforcement Learning) انجام می‌شد. این رویکرد به دلیل تداخل گرادیان‌ها (Gradient Interference) و رقابت سیگنال‌های پاداش میان حوزه‌های مختلف، به پدیده فراموشی فاجعه‌بار و افت کیفیت در برخی وظایف منجر می‌گردید.

در DeepSeek-V4، مرحله یادگیری تقویتی ترکیبی به‌طور کامل با یک خط‌لوله دومرحله‌ای جایگزین شده است:

۱. **پرورش مستقل مدل‌های متخصص (Specialist Training):** بهینه‌سازی مستقل مدل پایه برای هر دامنه (ریاضیات، برنامه‌نویسی، کنشگری عاملی و پیروی از دستورات) از طریق تنظیم دقیق نظارت‌شده (SFT) و سپس یادگیری تقویتی متمرکز با الگوریتم GRPO [۱۰۳].

۲. ادغام یکپارچه با تقطیر حین خطمشی چندمعلمه (Multi-Teacher On-Policy Distillation - OPD): تجمیع هوشمندی متخصصان در یک مدل واحد دانش‌آموز از طریق تقطیر دقیق توزیع لاجیت‌های کل دایره واژگان (Full-Vocabulary Logit Distillation) بر مبنای واگرایی کولبک-لایبلر معکوس (Reverse KL) [۱۸۹].



شکل ۴: جریان کاری دومرحله‌ای پس‌آموزش در DeepSeek-V4: پرورش متخصصان مجزا و ادغام برخط با تقطیر واژگان کامل.

فاز اول: پرورش مستقل مدل‌های متخصص (Specialist Training) در این فاز، چندین مدل متخصص به موازات هم برای دامنه‌های گوناگون تربیت می‌شوند:

– **تنظیم دقیق نظارت‌شده (SFT):** هر متخصص با مجموعه داده‌های باکیفیت و ساختاریافته در دامنه هدف مقداردهی اولیه می‌شود تا شالوده رفتاری و دانش پایه را کسب نماید.

– **یادگیری تقویتی با GRPO:** الگوریتم «بهینه‌سازی خطمشی نسبی گروهی» (Group Relative Policy Optimization - GRPO) [۱۰۳] برای ارتقای توانایی حل مسئله اعمال می‌شود. بر خلاف PPO، این الگوریتم مدل نقاد (Critic) را حذف کرده و مزیت هر خروجی را از روی میانگین و انحراف معیار گروهی از پاسخ‌های نمونه‌برداری‌شده برآورد می‌کند. فرض کنید به ازای پرامپت $q \sim \mathcal{D}$ ، دسته‌ای شامل G پاسخ $\{o_1, o_2, \dots, o_G\}$ توسط خطمشی پیشین $\pi_{\theta_{\text{old}}}$ تولید شود. مزیت بهنجارشده پاسخ i -ام به صورت زیر تعریف می‌شود:

$$A_i = \frac{r_i - \frac{1}{G} \sum_{j=1}^G r_j}{\sqrt{\frac{1}{G} \sum_{j=1}^G \left(r_j - \frac{1}{G} \sum_{k=1}^G r_k \right)^2} + \epsilon} \quad (107)$$

سپس تابع هدف بهینه‌سازی خطمشی به صورت زیر پیشنهاد می‌گردد:

(۱۰۸)

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \min \left(\frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})} A_i, \right. \right. \\ \left. \left. \text{clip} \left(\frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) \right. \\ \left. - \beta \mathbb{D}_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right]$$

تنظیمات سطوح تلاش استدلالی (Reasoning Efforts) عملکرد مدل در حل مسائل عمیقاً وابسته به میزان توان محاسباتی اختصاص یافته در زمان آزمون (Test-Time Compute) است. بدین منظور، سه حالت استدلالی با جریمه‌های طول و پنجره‌های بافت متفاوت در طول آموزش RL توسعه داده شده است (جدول ۵۵).

جدول ۵۵: مشخصات و فرمت پاسخ‌دهی حالات مختلف تلاش استدلالی در DeepSeek-V4

حالت استدلال (Mode)	ویژگی‌های رفتاری	کاربردهای معمول	فرمت پاسخ (Response Format)
غیرتفکری (Non-think)	سریع و شهودی بر مبنای عادات زبانی	وظایف روتین روزمره، تصمیمات کم‌ریسک	</think> summary
تفکر عمیق (Think High)	تحلیل منطقی آگاهانه، دقیق‌تر و زمان‌بر	حل مسائل تحلیلی، برنامه‌ریزی	<think> thinking tokens </think> summary
حد اکثر تفکر (Think Max)	واکاوی کامل مرزهای استدلال مدل	مسائل ریاضی المپیادی، اثبات‌های صوری	<think> ... </think> summary + پرامپت ویژه

برای فعال‌سازی حالت Think Max، دستورالعمل زیر به ابتدای پرامپت سیستمی مدل اضافه می‌گردد:

Max: Think for Instruction Injected

thor- very be MUST You permitted. shortcuts no with maximum Absolute Effort: "Reasoning cause, root the resolve to problem the decompose comprehensively and thinking your in ough sce- adversarial and cases, edge paths, potential all against logic your stress-testing rigorously intermediate every documenting process, deliberation entire your out write Explicitly narios. left is assumption no absolutely ensure to hypothesis rejected and alternative, considered step, unchecked."

مدل پاداش زایشی (Generative Reward Model - GRM) در وظایف پیچیده که بازبین‌های قاعده‌محور (Rule-based verifiers) برای آن‌ها وجود ندارد، سیستم‌های پیشین به مدل‌های پاداش اسکالر (Scalar RMs) وابسته بودند که نیازمند حجم بالایی از برچسب‌گذاری انسانی بوده و توانایی تحلیل گام‌به‌گام استدلال‌ها را نداشتند. در DeepSeek-V4، مدل پاداش اسکالر حذف شده و نوآوری‌های زیر جایگزین شده است:

- داده‌های مبتنی بر اصول ارزیابی دقیق (Rubric-guided RL) تدوین گردید.
- **آموزش مستقیم RL بر روی خود مدل پاداش زایشی:** شبکه عصبی بازیگر (Actor Network) در عین حال نقش GRM را نیز بر عهده دارد. با تلفیق وظیفه تولید پاسخ و ارزیابی پاسخ‌ها درون یک معماری واحد، توانمندی استدلال درونی مدل در دایره کیفی دخیل شده و با کمترین برچسب‌گذاری انسانی، ارزیابی‌هایی با ثبات فوق‌العاده بالا به دست می‌آید.

اسکیمای فراخوانی ابزار و تفکر درهم‌تنیده (Interleaved Thinking) به منظور برقراری تعامل استاندارد و مقاوم در برابر خطا در محیط‌های عاملی، پروتکل‌های زیر تعبیه شده‌اند:

- **اسکیمای مبتنی بر XML و نشانه |DSML|:** استفاده از تگ‌های صریح XML به همراه توکن اختصاصی |DSML| مانع از خطاهای گریز نویسه‌ها (Escaping failures) در مفسر ابزارها می‌شود:

```

</DSML|tool_calls>
</DSML|invoke name="$TOOL_NAME">
</DSML|parameter name="$PARAM" string="true|false">$VALUE</DSML|parameter>
</DSML|invoke>
</DSML|tool_calls>

```

– **تفکر درهم‌تنیده در بافت‌های یک میلیون توکنی:** بر خلاف روش‌های سنتی که با ارسال پیام جدید توسط کاربر کل تاریخچه تفکر مراحل قبل را دور می‌ریختند، در سناریوهای فراخوانی ابزار در **DeepSeek-V4**، تمامی ردپاهای تفکر (CoT) در سراسر طول مکالمه حفظ می‌شوند تا زنجیره استدلال پیوسته در حل مسائل طولانی حفظ گردد. در سناریوهای گفتگوی عمومی، برای فشردگی بافت، ردپای تفکر پس از دریافت پیام جدید کاربر حذف می‌گردد.

مکانیزم دستورالعمل سریع (Quick Instruction) به منظور حذف سربار مدل‌های فرعی کمکی برای اموری نظیر تشخیص وب‌گردی یا نام‌گذاری مکالمه، نشانه‌های اختصاصی مستقیماً به بافت متنی الصاق شده و از حافظه میانگیر پیش‌محاسبه‌شده (KV Cache) به صورت بلادرنگ و موازی استفاده می‌کنند (جدول ۵۶).

جدول ۵۶: نشانه‌های اختصاصی دستورالعمل سریع (Quick Instruction) در DeepSeek-V4

نشانه اختصاصی (Token)	شرح وظیفه	فرمت قرارگیری در توالی
< action >	تعیین لزوم انجام جستجوی وب یا پاسخ مستقیم	...< User >prompt< Assistant ><think>< action >
< title >	تولید خلاصه عنوان پس از اولین پاسخ سیستم	...< Assistant >response< end_of_sentence >< title >
< query >	استخراج عبارت‌های جستجوی دقیق از متن کاربر	...< User >prompt< query >
< authority >	ارزیابی درجه اعتبار مورد نیاز برای منابع پاسخ	...< User >prompt< authority >
< domain >	رده‌بندی حوزه موضوعی سوال کاربر	...< User >prompt< domain >
< read_url > / < extracted_url >	بررسی لزوم واکنشی و خواندن پیوندهای وب	...< User >prompt< extracted_url >url< read_url >

فاز دوم: تقطیر حین خط‌مشی چندمعلمه (On-Policy Distillation - OPD) برای ادغام توانایی متخصصان مستقل $\{\pi_{E_1}, \pi_{E_2}, \dots, \pi_{E_N}\}$ (شامل بیش از ده مدل معلم با صدها میلیارد یا تریلیون‌ها پارامتر) درون مدل دانش‌آموز واحد π_θ ، از روش تقطیر حین خط‌مشی استفاده می‌شود [۱۸۹]. تابع هدف تقطیر با ضرایب وزنی w_i به صورت زیر تعریف می‌گردد:

$$\mathcal{L}_{\text{OPD}}(\theta) = \sum_{i=1}^N w_i \cdot \mathbb{D}_{\text{KL}}(\pi_\theta \parallel \pi_{E_i}) \quad (109)$$

تحلیل تئوری اطلاعات و برتری واگرایی KL معکوس در تئوری اطلاعات، واگرایی کولبک-لایبلر مستقیم (Forward KL) به صورت $\mathbb{D}_{\text{KL}}(\pi_E \parallel \pi_\theta) = \mathbb{E}_{y \sim \pi_E} \left[\log \frac{\pi_E(y)}{\pi_\theta(y)} \right]$ یک سنجه میانگین‌طلب (Mean-Seeking) است؛ بدین معنا که اگر معلم احتمالی بزرگ‌تر از صفر به خروجی تخصیص دهد، دانش‌آموز ناچار است برای دوری از جریمه نامتناهی، چگالی خود را پخش کند که به تاری و عدم قطعیت در مدل می‌انجامد.

در مقابل، **واگرایی کولبک-لایبلر معکوس (Reverse KL):**

$$\mathbb{D}_{\text{KL}}(\pi_\theta \parallel \pi_E) = \sum_{y \in \mathcal{V}} \pi_\theta(y \mid x) \log \left(\frac{\pi_\theta(y \mid x)}{\pi_E(y \mid x)} \right) \quad (110)$$

دارای خاصیت مدجوبی (Mode-Seeking) است. هرگاه $\pi_E(y) \rightarrow 0$ باشد، مدل دانش‌آموز اکیداً مقید می‌شود که احتمال خود را صفر کند ($\pi_\theta(y) \rightarrow 0$). این ویژگی سبب می‌شود مدل دانش‌آموز خروجی‌های دقیق و قاطع در مسائل ریاضی و کد تولید کند. افزوده بر این، امید ریاضی نسبت به توزیع خود دانش‌آموز تعریف شده و امکان نمونه‌برداری حین خط‌مشی (On-Policy) را فراهم می‌سازد.

اشتقاق ریاضی و دیفرانسیلی گرادیان OPD برای اشتقاق گرادیان تابع اتلاف یک معلم منفرد $L(\theta) = \mathbb{D}_{\text{KL}}(\pi_\theta \parallel \pi_E)$ نسبت به بردار پارامترهای $\theta \in \mathbb{R}^d$ ، بسط مشتق ضربی را می‌نویسیم:

$$\nabla_\theta L(\theta) = \nabla_\theta \sum_{y \in \mathcal{V}} \pi_\theta(y | x) [\log \pi_\theta(y | x) - \log \pi_E(y | x)] \quad (111)$$

با اعمال قاعده ضرب در دیفرانسیل‌گیری:

$$\nabla_\theta L(\theta) = \sum_{y \in \mathcal{V}} \left\{ \nabla_\theta \pi_\theta(y | x) \left[\log \frac{\pi_\theta(y | x)}{\pi_E(y | x)} \right] + \pi_\theta(y | x) \nabla_\theta [\log \pi_\theta(y | x) - \log \pi_E(y | x)] \right\}$$

از آنجا که توزیع معلم π_E به پارامترهای دانش‌آموز وابسته نیست، $\nabla_\theta \log \pi_E(y | x) = 0$ است. برای جمله دوم داریم:

(113)

$$\sum_{y \in \mathcal{V}} \pi_\theta(y | x) \nabla_\theta \log \pi_\theta(y | x) = \sum_{y \in \mathcal{V}} \pi_\theta(y | x) \frac{\nabla_\theta \pi_\theta(y | x)}{\pi_\theta(y | x)} = \sum_{y \in \mathcal{V}} \nabla_\theta \pi_\theta(y | x) = \nabla_\theta \left(\sum_{y \in \mathcal{V}} \pi_\theta(y | x) \right)$$

چون مجموع احتمالات روی فضای گسسته واژگان برابر یک است $(\sum_{y \in \mathcal{V}} \pi_\theta(y | x) = 1)$:

$$\nabla_\theta(1) = 0 \quad (114)$$

لذا مشتق به فرم بسته تحلیلی زیر درمی‌آید:

$$\nabla_\theta L(\theta) = \sum_{y \in \mathcal{V}} \nabla_\theta \pi_\theta(y | x) \log \left(\frac{\pi_\theta(y | x)}{\pi_E(y | x)} \right) \quad (115)$$

با استفاده از هویت تابع امتیاز (Score Function Trick) یعنی $\nabla_\theta \pi_\theta(y | x) = \pi_\theta(y | x) \nabla_\theta \log \pi_\theta(y | x)$ عبارت گرادیان به فرم امید ریاضی تبدیل می‌شود:

$$\nabla_\theta L(\theta) = \mathbb{E}_{y \sim \pi_\theta(\cdot | x)} \left[\nabla_\theta \log \pi_\theta(y | x) \log \left(\frac{\pi_\theta(y | x)}{\pi_E(y | x)} \right) \right] \quad (116)$$

تحلیل واریانس: تقطیر واژگان کامل در برابر برآورد توکنی در کارهای قبلی، برای گریز از محاسبات سنگین واژگان، گرادیان فوق را با یک نمونه تصادفی $y_t \sim \pi_\theta$ تقریب می‌زدند و متغیر مزیت را به صورت $A_t = \text{sg} \left[\log \frac{\pi_E(y_t)}{\pi_\theta(y_t)} \right]$ درون چارچوب RL قرار می‌دادند.

اما واریانس این تخمین‌گر نمونه‌برداری شده $\hat{g}_{\text{sample}}$ به صورت زیر است:

$$\mathbb{V}_{\pi_\theta}[\hat{g}_{\text{sample}}] = \sum_{y \in \mathcal{V}} \pi_\theta(y | x) \left(\log \frac{\pi_\theta(y | x)}{\pi_E(y | x)} \right)^2 \|\nabla_\theta \log \pi_\theta(y | x)\|^2 - \|\nabla_\theta L(\theta)\|^2 \quad (117)$$

در یک واژگان با ابعاد فراتر از صد هزار توکن ($|\mathcal{V}| > 100K$)، برای توکن‌هایی که تحت توزیع یکی از مدل‌ها احتمال بسیار ناچیزی دارند، عبارت $\left(\log \frac{\pi_\theta(y)}{\pi_E(y)} \right)^2$ می‌تواند به مقادیر فوق‌العاده بزرگی میل کند که موجب انفجار واریانس گرادیان و ناپایداری در آموزش مدل‌های تریلیونی می‌شود.

راهکار DeepSeek-V4: با پیاده‌سازی تقطیر دقیق روی کل واژگان (Full-Vocabulary Logit Distillation)، گرادیان مستقیماً نسبت به بردار لاجیت‌های لایه آخر دانش‌آموز $(z^\theta \in \mathbb{R}^{|\mathcal{V}|})$ مشتق‌گیری می‌شود:

$$\frac{\partial \mathbb{D}_{\text{KL}}(\pi_\theta \parallel \pi_E)}{\partial z_j^\theta} = \pi_\theta(y_j) - \pi_E(y_j) + \pi_\theta(y_j) \left(\log \frac{\pi_\theta(y_j)}{\pi_E(y_j)} - \sum_{k \in \mathcal{V}} \pi_\theta(y_k) \log \frac{\pi_\theta(y_k)}{\pi_E(y_k)} \right) \quad (118)$$

از آنجا که این گرادیان به صورت دقیق روی تمامی مولفه‌های واژگان ارزیابی می‌شود، واریانس نمونه‌برداری واژگان به صفر تقلیل یافته ($\mathbb{V}_{\text{Vocab}} = 0$) و آموزش با نهایت پایداری انجام می‌گیرد.

زیرساخت‌های مقیاس‌پذیر RL و OPD (System Infrastructures) بهینه‌سازی و اجرای این خط‌لوله بر روی مدل‌های تریلیونی و بافت‌های یک میلیون توکنی، با ابتکارات زیرساختی زیر محقق شده است:

– **یکپارچه‌سازی کوانتایزاسیون FP4 QAT:** کوانتایزاسیون آگاه از آموزش [۱۹۰] با قالب میکرواسکیلینگ MXFP4 [۱۹۱] بر روی وزن‌های متخصصان MoE و مسیر پرسش-کلید (QK) در نمایه‌ساز CSA اعمال گردید. دکوانتایزاسیون FP4-to-FP8 کاملاً بدون اتلاف (Lossless) است؛ زیرا ساختار FP8 (E4M3) دارای دو بیت توان بیشتر از FP4 (E2M1) است و می‌تواند دامنه مقیاس‌های ریزبلوک‌ها را جذب کند. در پس‌انتشار، گرادیان‌ها بر پایه برآوردگر مستقیم عبور (STE) بدون تغییر اعمال می‌شوند. همچنین امتیازات نمایه‌ساز I_{FP4} به BF16 تبدیل شده که سرعت انتخاب‌گر را دو برابر کرده و نرخ بازیابی (Recall) را در سطح ۷۷.۹۹٪ حفظ می‌نماید.

– **زمان‌بندی بهینه معلمان در تقطیر واژگان کامل:** برای مدیریت بیش از ده مدل معلم تریلیونی و واژگان $|\mathcal{V}| > 100K$ ، وزن معلمان روی حافظه توزیع‌شده قرار گرفته و با شاردینگ شبیه به ZeRO لود می‌شوند. به منظور جلوگیری از اشغال صدها گیگابایت حافظه توسط لاجیت‌ها، تنها **بردار حالت‌های مخفی لایه آخر معلمان ذخیره می‌گردد** و لاجیت‌ها در زمان محاسبه اتلاف به صورت بلادرنگ بازسازی می‌شوند. همچنین نمونه‌های آموزشی بر اساس شاخص معلم مرتب شده تا در هر زمان حداکثر یک سر پیش‌بینی در حافظه کارت گرافیک باشد. محاسبه واگرایی KL نیز با کرنل اختصاصی در زبان TileLang [۱۹۲] شتاب‌دهی شده است.

– **سرویس نمونه‌برداری ضدوقفه و مهار سوگیری طول (WAL & Length Bias):** در صورت توقف ناگهانی ماشین‌ها در خوشه‌های ابری، شروع مجدد تولید نمونه از ابتدا خطای آماری ایجاد می‌کند؛ زیرا طبق مدل احتمالاتی بقای توالی‌ها تحت فرآیند پواسون با نرخ وقفه λ :

$$P(\text{Survival} | L) = \exp(-\lambda \cdot \tau \cdot L) \quad (119)$$

توالی‌های کوتاه‌تر شانس بقای بیشتری دارند و تولید مجدد از ابتدا موجب پیدایش سوگیری به سوی طول‌های کوتاه (Length Bias) در مدل می‌شود. برای رفع این چالش، سیستم لاگ پیش‌نویس توکنی (Token-granular WAL) پیاده‌سازی شده که وضعیت هر توکن تولیدشده را بلادرنگ ثبت می‌کند و هنگام وقفه، فرآیند رمزگشایی با بارگذاری KV Cache پایدارشده بدون نیاز به تولید مجدد ادامه می‌یابد.

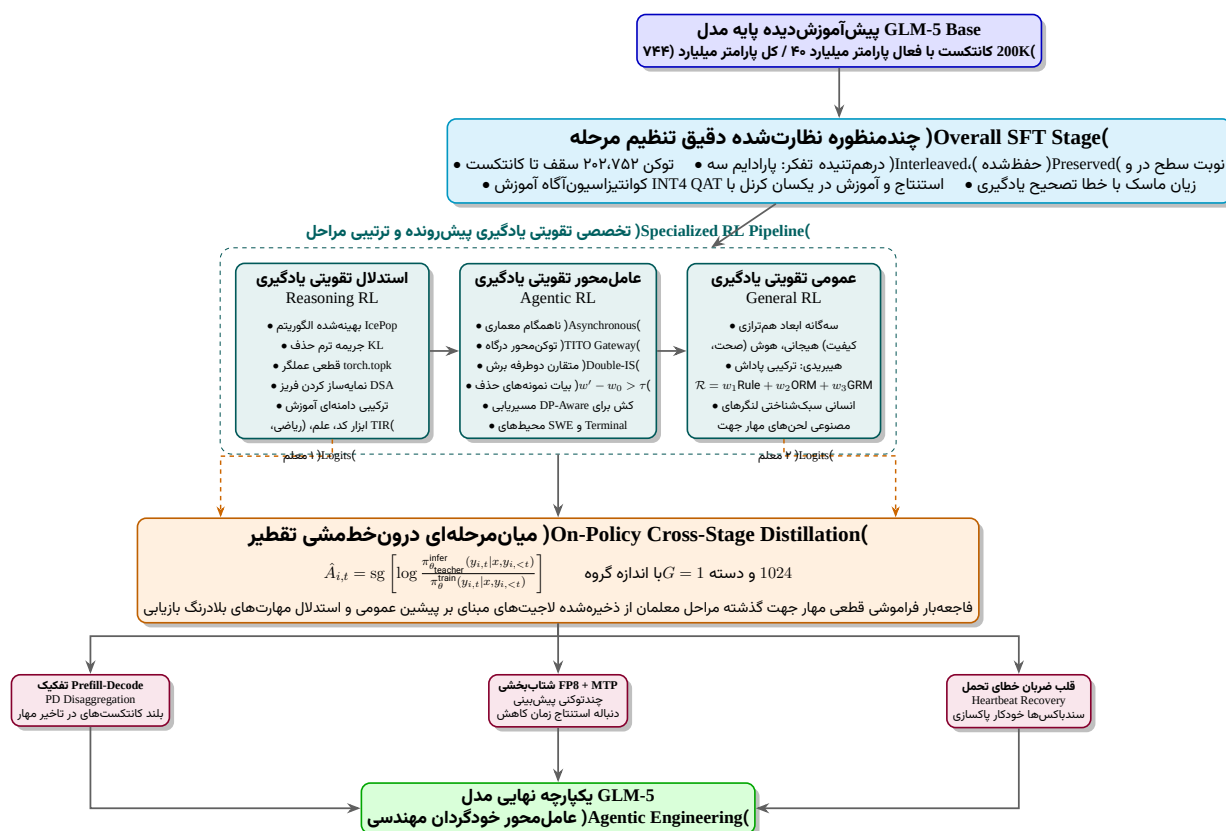
– **مقیاس‌پذیری RL برای بافت یک میلیون توکن:** داده‌های رول‌اوت به متادیتای سبک (جهت درهم‌آمیزی سراسری) و فیلدهای سنگین به ازای هر توکن تفکیک شده و فیلدهای سنگین با حافظه اشتراکی بارگذاری و بلافاصله پس از مصرف در سطح ریزدسته آزاد می‌شوند.

– **پلتفرم جعبه‌شنی DSec برای کارهای عاملی:** پلتفرم صنعتی DeepSeek Elastic Compute (DSec) با زبان راکد Rust طراحی شده و صدها هزار سندباکس هم‌زمان را روی سامانه ذخیره‌سازی توزیع‌شده 3FS [۱۹۳] مدیریت می‌کند. این بستر چهار لایه اجرایی را تحت یک واسط پایتون یکپارچه ارائه می‌دهد: فراخوانی سبک تابع (Function Call)، کانتینر ایزوله (Container) با فایل‌سیستم EROFS [۱۹۴]، ماشین‌های مجازی خرد (microVM) بر پایه Firecracker [۱۹۵] با دیسک‌های overlaybd [۱۹۶]، و ماشین‌های مجازی کامل (fullVM) بر پایه QEMU [۱۹۷]. همچنین با ثبت سراسری وقایع، امکان بازتولید قطعی ردپای عامل و بازیابی سریع وضعیت فراهم شده است.

• GLM-5

مقدمه و پارادایم نوین: گذار از کدنویسی حسی به مهندسی عامل‌محور (From Vibe Coding to Agentic Engineering) مدل GLM-5 [۱۹۸] با هدف شکستن مرزهای سنتی مدل‌های زبانی و بازتعریف مرحله پس‌آموزش (Post-Training)، گذار از «کدنویسی حسی متکی بر پرامپت انسانی» (Vibe Coding) به «مهندسی نرم‌افزار خودگردان عامل‌محور» (Agentic Engineering) را پایه‌گذاری کرده است. در حالی که در نسل‌های پیشین (نظیر GLM-4.5 و GLM-4.7) تمرکز بر ادغام قابلیت‌های استدلال و کدنویسی درون معماری متعارف MoE بود، چالش‌های بنیادینی نظیر حباب‌های محاسباتی ناشی از افق‌های زمانی بلندمدت (Long-Horizon Trajectories)، واگرایی توزیع استنتاج و آموزش، و پدیده فراموشی فاجعه‌بار (Catastrophic Forgetting) مانع از حل مستقل مسائل پیچیده مهندسی می‌گردید. در پس‌آموزش GLM-5، یک خط‌لوله پیش‌رونده و چندمرحله‌ای تعبیه شده است:

۱. **تنظیم دقیق نظارت‌شده پیشرفته (Overall SFT):** برقراری سه الگوی تفکر بنیادین (درهم‌تنیده، حفظ‌شده و در سطح نوبت)، آموزش کوانتیزاسیون آگاه INT4 QAT، و یادگیری اصلاح خطا از طریق تابع زیان پوشش‌دار (Masked Loss).
۲. **یادگیری تقویتی استدلال (Reasoning RL):** به‌کارگیری نسخه ارتقا یافته الگوریتم IcePop بدون جریمه KL جهت رفع عدم انطباق توزیع آموزش-استنتاج، تثبیت عملگرهای قطعی Top-K در بستر توجه پراکنده DSA، و آموزش چند دامنه‌ای متوازن.
۳. **یادگیری تقویتی عامل‌محور ناهمگام (Asynchronous Agentic RL):** تفکیک فیزیکی موتورهای تولید و آموزش بر بستر چارچوب slime، دروازه توکن‌محور (TITO)، و برش دوطرفه سخت با نمونه‌برداری ترجیحی مستقیم.
۴. **یادگیری تقویتی عمومی (General RL):** هم‌ترازی سه‌بعدی با سامانه‌های پاداش ترکیبی (Rule + ORM + GRM) و مهار رفتار فرمولی با لنگرهای انسانی.
۵. **تقطیر درون‌خط‌مشی میان‌مرحله‌ای (On-Policy Cross-Stage Distillation):** بازیابی و تثبیت مهارت‌های استدلال و عمومی پس از بهینه‌سازی‌های متوالی بدون افت در ظرفیت‌های عاملی.



شکل ۵: جریان کاری جامع پس‌آموزش در مدل GLM-5: تنظیم دقیق با الگوهای تفکر سه‌گانه، یادگیری تقویتی ناهمگام، پاداش ترکیبی و تقطیر درون‌خط‌مشی میان‌مرحله‌ای.

تنظیم دقیق نظارت‌شده و ساختار سه‌گانه تفکر (Supervised Fine-Tuning - SFT) در فاز نخست پس‌آموزش، مقیاس داده‌های تعامل عاملی و کدنویسی به‌طور چشمگیری گسترش یافته است. این مجموعه سه شاخه کلیدی را پوشش می‌دهد: گفتگوی عمومی، استدلال تحلیلی، و وظایف عاملی-کدنویسی مهندسی. در این مرحله، پنجره بافت به ۲۰۲,۷۵۲ توکن افزایش یافته و ساختار گفتگوی جدید مدل، سه خصیصه استدلالی نوین را پشتیبانی می‌کند:

– **تفکر درهم‌تنیده (Interleaved Thinking):** مدل پیش از تولید هر پاسخ نهایی یا فراخوانی هر ابزار بیرونی (Tool Call)، یک بلوک تحلیلی تفکر تولید می‌کند. این امر موجب پیش‌بینی اثرات فراخوانی و کاهش خطاهای صدور دستور می‌گردد [۱۹۹].

- **تفکر حفظ‌شده (Preserved Thinking):** در حل مسائل چندنوبته در محیط‌های نرم‌افزاری طولانی، تمامی بلوک‌های تفکر نوبت‌های گذشته در حافظه کانتکست نگه‌داری می‌شوند. این ساختار از تحلیل مجدد پیش‌فرض‌ها جلوگیری کرده و ثبات تصمیم‌گیری در افق‌های زمانی وسیع را تقویت می‌نماید.
- **تفکر در سطح نوبت (Turn-level Thinking):** امکان کنترل پویا بر فعال یا غیرفعال بودن پردازش استدلالی در هر نوبت به فراخور پیچیدگی وظیفه؛ غیرفعال‌سازی برای درخواست‌های عادی جهت کاهش تأخیر و فعال‌سازی برای چالش‌های پیچیده.
- **آموزش اصلاح خطا با ماسک‌گذاری تابع زیان (Masked Loss):** در مسیرهای حل مسئله که شامل گام‌های نادرست و اصلاحات متوالی هستند، توکن‌های مربوط به تصمیمات ناصحیح حذف نمی‌شوند؛ بلکه تنها در محاسبه تابع زیان بازگشت کراس‌آنتروپی ضریب صفر دریافت می‌کنند ($m_t = 0$):

$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{t=1}^{|y|} m_t \log P_{\theta}(y_t | x, y_{<t}), \quad m_t \in \{0, 1\} \quad (120)$$

این فرمولاسیون سبب می‌شود مدل رفتار خود-اصلاحی (Self-Correction) را از خطاهای گذشته بیاموزد بی آنکه اقدامات خطا تقویت شوند.

- **کوانتیزاسیون INT4 QAT در مرحله SFT:** به منظور دستیابی به حداکثر کارایی استنتاج بر روی سخت‌افزارهای داخلی و لبه، فاز SFT مجهز به کوانتیزاسیون آگاه از آموزش INT4 است. با بهره‌گیری از یک کرنل محاسباتی یکپارچه، تطابق دقیق بیتی (Bitwise-Identical) میان فرایند آموزش و استنتاج تضمین شده است.

یادگیری تقویتی استدلال (Reasoning RL) و مهار واگرایی توزیع ستون فقرات الگوریتم استدلال در GLM-5 بر مبنای «بهینه‌سازی خط‌مشی نسبی گروهی» (GRPO) [۲۴] پی‌ریزی شده است. برای مهار مسئله بنیادین عدم تطابق میان توزیع استنتاج حین نمونه‌برداری و توزیع آموزش گرادیان، نوآوری IcePop [۱۱۰] با بازطراحی ساختاری به خدمت گرفته شده است.

اشتقاق ریاضیاتی عدم تطابق آموزش-استنتاج (Training-Inference Discrepancy): در سامانه‌های استنتاج توزیع‌شده با دقت‌های پایین یا بهینه‌سازهای ناهمگام، توزیع سیاست حین نمونه‌برداری ($\pi_{\theta_{\text{old}}}^{\text{infer}}$) دقیقاً با سیاست موتور آموزش ($\pi_{\theta_{\text{old}}}^{\text{train}}$) یکسان نیست. لذا نسبت عدم تطابق آماری به صورت زیر تعریف می‌گردد:

$$\rho_{i,t} = \frac{\pi_{\theta_{\text{old}}}^{\text{train}}(y_{i,t} | x, y_{i,<t})}{\pi_{\theta_{\text{old}}}^{\text{infer}}(y_{i,t} | x, y_{i,<t})} \quad (121)$$

برای مهار نوسانات شدید آماری، عملگر سرکوب $\text{pop}(\cdot)$ به ازای کران $\beta > 1$ روی نسبت توزیع‌ها اعمال می‌شود:

$$\text{pop}(\rho_{i,t}, 1/\beta, \beta) = \begin{cases} \rho_{i,t}, & \text{if } \frac{1}{\beta} \leq \rho_{i,t} \leq \beta \\ 0, & \text{otherwise} \end{cases} \quad (122)$$

در پیاده‌سازی GLM-5، برخلاف ساختار سنتی IcePop، به منظور شتاب‌بخشی حداکثری به بهبود استدلال، ترم رگولاریزاسیون واگرایی KL حذف شده است. تابع زیان بهینه‌سازی نهایی استدلال با نسبت اهمیت $r_{i,t} = \frac{\pi_{\theta_{\text{old}}}^{\text{train}}(y_{i,t} | x, y_{i,<t})}{\pi_{\theta_{\text{old}}}^{\text{train}}(y_{i,t} | x, y_{i,<t})}$ به صورت زیر فرمول‌بندی می‌گردد:

(123)

$$\mathcal{L}_{\text{Reasoning}}(\theta) = -\mathbb{E}_{\{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}^{\text{infer}}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \text{pop} \left(\rho_{i,t}, \frac{1}{\beta}, \beta \right) \times \min \left(r_{i,t} \hat{A}_{i,t}, \text{clip}(r_{i,t}, 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}) \hat{A}_{i,t} \right) \right]$$

که در آن مزیت نرمال سازی شده گروهی پاسخ i -ام برابر است با:

$$\hat{A}_{i,t} = \frac{R_i - \text{mean}(R_1, \dots, R_G)}{\text{std}(R_1, \dots, R_G) + \epsilon} \quad (124)$$

اِبرپارامترهای بهینه سازی در این مرحله شامل $\beta = 2$ ، $\epsilon_{\text{low}} = 0.2$ ، $\epsilon_{\text{high}} = 0.28$ ، با اندازه گروه نمونه برداری $G = 32$ و اندازه دسته داده ۳۲ به صورت کاملاً برخط (On-policy) تنظیم شده اند.

پایداری در معماری توجه پراکنده DSA و مهار فروپاشی آنتروپی: مدل GLM-5 مجهز به سازوکار توجه پراکنده دیپ سیک (DeepSeek Sparse Attention - DSA) [۱۲] است که در آن نمایه ساز (Indexer) تعداد $k = 2048$ عنصر کلید-مقدار را برای بافت های طویل فراخوانی می کند. پیاده سازی های غیراقتعی (Non-deterministic) عملگر Top-K مبتنی بر کرنل های متداول، حین اجرای RL پس از گام های معدودی به افت ناگهانی و فاجعه بار آنتروپی (Entropy Collapse) و واگرایی شدید خط مشی می انجامیدند. در GLM-5 با جایگزینی عملگر قطعی torch.topk در موتور آموزش و انجماد کامل (Freeze) پارامترهای نمایه ساز در فاز RL، پایداری محاسباتی مطلق حاصل گردید.

آموزش چند دامنه ای (Mixed Domain Reasoning RL): داده های استدلال به صورت همزمان و متوازن بر روی چهار قلمرو بهینه سازی می شوند: ریاضیات، علوم، برنامه نویسی الگوریتمی، و استدلال متکی بر ابزار (Tool-Integrated Reasoning - TIR). پاداش ها به صورت دودویی ($R \in \{0, 1\}$) و با سیستم های داوری دقیق دامنه محور ارزیابی می گردند.

یادگیری تقویتی عامل محور ناهمگام (Asynchronous Agentic RL) مسیرهای طولانی در وظایف عاملی (نظیر اجرای کدهای ترمینال و مهندسی معکوس) و عدم تعادل شدید در زمان خاتمه تعاملات، اجرای همگام RL را با حباب های بیکاری گسترده مواجه می سازد. GLM-5 برای نخستین بار یک زیرساخت کاملاً ناهمگام را پیاده سازی نموده است:

- **تفکیک فیزیکی موتورهای و ارکستریاتور چندوظیفه ای:** موتور تولید مسیرها و موتور به روزرسانی گرادیان روی خوشه های GPU مجزا قرار دارند. ارکستریاتور مرکزی بیش از ۱۰۰۰ مسیر موازی همزمان را از وظایف گوناگون به صورت یکپارچه مدیریت می کند. وزن های مدل هر K گام آپدیت گرادیان به موتور استنتاج منتقل شده و وضعیت بهینه ساز پس از همگام سازی ریست می گردد.
- **درگاه توکن محور (TITO Gateway):** در پردازش سنتی متنی (Text-in-Text-out)، تبدیل مکرر متن خروجی به توکن در موتور آموزش باعث ناهماهنگی در مرز توکن ها و اختلال در تخصیص پاداش به اقدامات می گردد. درگاه Token-in-Token-out (TITO) شناسه های عددی توکن ها و فراداده ها را مستقیماً ثبت و منتقل می کند.
- **نمونه برداری ترجیحی دوطرفه مستقیم (Direct Double-Sided IS):** در شرایط ناهمگام، ثبت چک پوینت های قدیمی برای محاسبه $\pi_{\theta_{\text{old}}}$ به لحاظ حافظه ناممکن است. GLM-5 لگاریتم احتمالات ثبت شده حین تولید را مستقیماً به عنوان تقریب رفتار به کار می گیرد:

$$r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\text{rollout}}(a_t | s_t)} = \exp(\log \pi_{\theta}(a_t | s_t) - \log \pi_{\text{rollout}}(a_t | s_t)) \quad (125)$$

سپس تابع کالیبراسیون دوطرفه سخت با بازه $[1 - \epsilon_{\ell}, 1 + \epsilon_h]$ اعمال می شود:

$$f(x; \epsilon_{\ell}, \epsilon_h) = \begin{cases} x, & \text{if } 1 - \epsilon_{\ell} < x < 1 + \epsilon_h \\ 0, & \text{otherwise} \end{cases} \quad (126)$$

که تابع هدف را به صورت زیر درمی آورد:

$$\mathcal{L}_{\text{Agentic}}(\theta) = \mathbb{E}_t \left[f(r_t(\theta), \epsilon_{\ell}, \epsilon_h) \hat{A}_t \log \pi_{\theta}(a_t | s_t) \right] \quad (127)$$

اگر نسبت $r_t(\theta)$ از بازه اطمینان خارج شود، گرادیان آن توکن صفر می شود که پایداری بی نظیری را در مقابل خط مشی های بسیار کهنه پدید می آورد.

- **فیلتر مسیرهای کهنه و خطاهای زیرساختی:** مسیرهایی که با کهنه‌ترین نسخه خط‌مشی تولید شده و تاخیر آنها از آستانه مجاز فراتر رود ($w' - w_0 > \tau$) از دور آموزش حذف می‌شوند. همچنین رخدادهای ناشی از کرش کانتینرهای نرم‌افزاری ایزوله و نادیده گرفته می‌شوند.
- **مسیریابی آگاه از داده‌موازی (DP-Aware Routing):** برای حفظ لوکالیتی و استفاده حداکثری از KV-Cache در طول نوبت‌های متوالی یک عامل، تمام تعاملات یک جلسه از طریق هشینگ سازگار (Consistent Hashing) به یک رنک ثابت DP تخصیص می‌یابند.

مقیاس‌پذیری محیط‌های اعتبارسنجی عاملی (Environment Scaling) یادگیری عاملی بدون محیط‌های تعاملی تاییدپذیر بی‌اثر است. GLM-5 زیرساخت‌های محیطی زیر را بنا نهاده است:

- **محیط‌های مهندسی نرم‌افزار (RepoLaunch SWE):** بیش از ۱۰,۰۰۰ محیط اجرایی اعتبارسنجی شده در ۹ زبان برنامه‌نویسی به همراه کانتینرهای داکر مستقل و آزمون‌های F2P و P2P برای سنجش دقیق اصلاح کد [۲۰۰].
- **محیط‌های ترمینال بر پایه استاندارد Harbor:** سنتز هزاران وظیفه پوسته فرمان با عامل‌های دوقلوی ساخت و ارزیابی در قالب استاندارد هاربر [۲۰۱] با نرخ صحت ساخت فراتر از ۹۰٪.
- **مدیریت سلسله‌مراتبی کانتکست برای عامل‌های جستجو (HCM):** در ارزیابی‌های جستجوی وب نظیر BrowseComp [۲۰۲]، تراکم تاریخچه ابزارها موجب سردرگمی مدل می‌شود. با ادغام راهکار حفظ ۵ نوبت اخیر (Keep-recent-5) و بازنشانی سراسری کانتکست (Discard-all) در آستانه ۳۲ هزار توکن، امتیاز مدل به $9.75\%^{**}$ ارتقا یافته است.
- **سامانه پاداش سه‌سطحی و مهار هک پاداش در تولید اسلاید:** سیستم تولید کدهای فرانت‌اند و اسلاید به پاداش‌های سطح ۱ (نشانه‌گذاری استاتیک)، سطح ۲ (زندینگ زمان اجرا و ابعاد المان‌های DOM)، و سطح ۳ (ادراک تعادل بصری) مجهز شد تا مانع از تقلب مدل از طریق ویژگی‌هایی نظیر پنهان‌سازی محتوا با overflow:hidden گردد.

یادگیری تقویتی عمومی (General RL) و هم‌ترازی با ترجیحات انسانی فاز یادگیری عمومی به عنوان لایه متعادل‌کننده رفتار نهایی عمل می‌کند:

- **اهداف سه‌بعدی:** صحت بنیادین، هوش هیجانی در مکالمه، و غنای نگارشی.
- **سیستم پاداش هیبریدی:** تجمیع پاداش‌های قاعده‌محور، مدل‌های پاداش پیام‌محور (ORM)، و مدل‌های پاداش زایشی (GRM):

$$\mathcal{R}_{\text{Hybrid}}(x, y) = w_1 \mathcal{R}_{\text{Rule}}(y) + w_2 \mathcal{R}_{\text{ORM}}(x, y) + w_3 \mathcal{R}_{\text{GRM}}(x, y) \quad (128)$$

- **لنگرهای سبک‌شناختی انسانی (Human Style Anchors):** تزریق متون تألیف‌شده توسط متخصصان زبده انسانی به جریان گرادیان جهت پیشگیری از تولید ساختارهای کلیشه‌ای و متکلف ناشی از بهینه‌سازی صرفاً ماشینی.

تقطیر درون خط‌مشی میان‌مرحله‌ای (On-Policy Cross-Stage Distillation) بهینه‌سازی متوالی برای اهداف متعادل در مراحل پیشین، خطر زوال برخی از مهارت‌های استدلال را به همراه دارد. برای غلبه بر این پدیده، مدل‌های نهایی هر فاز به عنوان معلمان متخصص تعیین می‌شوند. با بهره‌گیری از تقطیر برخط مبتنی بر واگرایی KL معکوس [۱۸۹]، متغیر مزیت در الگوریتم بهینه‌سازی با اختلاف لاگ-احتمال خروجی‌ها جایگزین می‌شود:

$$\hat{A}_{i,t} = \text{sg} \left[\log \frac{\pi_{\theta_{\text{teacher}}}^{\text{infer}}(y_{i,t} | x, y_{i,<t})}{\pi_{\theta}^{\text{train}}(y_{i,t} | x, y_{i,<t})} \right] \quad (129)$$

در این گام نهایی، به دلیل حذف نیاز به تخمین واریانس گروهی، اندازه گروه $G = 1$ تنظیم شده و اندازه دسته داده تا ۱۰۲۴ افزایش می‌یابد که دستیابی به همگرایی سریع و بازیابی کامل مهارت‌ها بدون تداخل گرادیان را میسر می‌سازد.

زیرساخت مقیاس پذیر پس آموزش: چارچوب slime تمام فرآیندهای یادگیری تقویتی بر بستر چارچوب اختصاصی slime به اجرا درآمده اند:

– **تفکیک کامل پیش محاسبه و رمزگشایی (PD Disaggregation):** جداسازی منابع پردازشی کانتکست های پیشوند طویل (Prefill) از مراحل تولید توکن (Decode) به منظور ریشه کن کردن تداخل بار کاری و مهار تأخیر در نمونه های کند.

– **شتاب بخشی تأخیر دنباله با FP8 و MTP:** کاهش زمان استنتاج خط سیرهای طولانی با کوانتیزاسیون هشت بیتی و به کارگیری پیش بینی چندتوکنی (Multi-Token Prediction).

– **تحمل خطای مبتنی بر ضربان قلب (Heartbeat-Driven Fault Tolerance):** ارزیابی سلامت سرورهای سندباکس و هدایت پویای وظایف جهت تداوم بی وقفه آموزش.

ارزیابی تجربی پس آموزش نتایج مدل GLM-5 پس از اتمام خطلوله پس آموزش، بیانگر برتری قاطع آن در میان تمامی مدل های متن باز و رقابت شانه به شانه با پرچمداران تجاری جهان است (جدول ۵۷).

جدول ۵۷: مقایسه عملکرد GLM-5 پس از اعمال کامل خطلوله پس آموزش در برابر مدل های رقیب

GLM-5	Claude Opus 4.5	Gemini 3 Pro	Kimi-K2.5	DeepSeek-V3.2	GLM-4.7	شاخص / بنچمارک ارزیابی
۵۰	–	–	–	–	۴۲	شاخص هوشمندی (AA Intelligence Index v4.0)
۴۰.۵۰	۴۰.۴۳	۸۰.۴۵	۸۰.۵۱	۸۰.۴۰	۸۰.۴۲	آزمون نهایی بشریت (HLE w/ Tools)
۸۰.۷۷	۹۰.۸۰	۲۰.۷۶	۸۰.۷۶	۱۰.۷۳	۸۰.۷۳	مهندسی نرم افزار (SWE-bench Verified)
۳۰.۷۳	۵۰.۷۷	۰.۶۵	۰.۷۳	۲۰.۷۰	۷۰.۶۶	مهندسی چندزبانه (SWE-bench Multilingual)
۱۷.۶۰	۳۰.۵۹	۲۰.۵۴	۸۰.۵۰	۳۰.۳۹	۰.۴۱	محیط خط فرمان (Terminal-Bench 2.0)
۹۰.۷۵	۸۰.۵۷	۲۰.۵۹	۹۰.۷۴	۶۰.۶۷	۵۰.۶۷	عامل وب گردی (BrowseComp w/ HCM)
\$۴,۴۳۲	\$۴,۹۶۷	\$۵,۴۷۸	\$۱,۱۹۸	\$۱,۰۳۴	\$۲,۳۷۷	عامل کسب و کار (Vending-Bench 2 Balance)
۰.۱۰۰	۰.۹۵	–	–	–	۰.۶۵	پایداری ساخت فرانت اند (CC-Bench-V2 BSR)

• Kimi K3

مقدمه و پارادایم نوین پس آموزش (Post-Training Paradigm) مرحله پس آموزش (Post-Training) در مدل Kimi K3 [۱۳] بر پایه تعمیم مقیاس پذیری محاسبات زمان استدلال (Test-Time Computation Scaling) [۲۰۵، ۱۶۴، ۲۰۴، ۲۰۳] به طول بافت بی سابقه 1M توکن بنا نهاده شده است. بر خلاف رویکردهای متداول که یک مدل پایه منفرد را تحت یک فاز یادگیری تقویتی چندمنظوره قرار می دهند، Kimi K3 یک خطلوله منسجم، سه مرحله ای و چندمعلمه را به کار می بندد:


۱. **پیش تنظیم نظارت شده (SFT) و ایجاد خط مشی آغازین (Cold-Start):** پایه گذاری توانمندی های عاملی با خط سیرهای داده ساختاریافته در قالب نشانه گذاری زبان XTML، همراه با آموزش آگاه از کوانتیزاسیون میکرومقیاس (MXFP4/MXFP8 QAT) [۱۹۱، ۱۹۰].

۲. **یادگیری تقویتی چنددامنه ای و چندسطحی (Multi-Domain, Multi-Effort RL):** تربیت مستقل ۹ مدل متخصص دامنه ای در سطوح مختلف تلاش استدلالی با الگوریتم نمونه برداری ناهمگام رول اوت جزئی (Partial Rollout) [۲۰۵، ۱۱۴] و شبیه سازهای ایزوله AgentENV [۱۹۵].

۳. **تقطیر برخط چنداستاده (Multi-Teacher On-Policy Distillation - MOPD):** یکپارچه سازی تخصص های ۹ مدل معلم درون یک مدل دانش آموز واحد بر مبنای پاداش چگال لگاریتم نسبت چگالی توزیع حین خط مشی [۲۰۶، ۲۰۷، ۱۸۹].

قالب گفتگو: زبان نشانه گذاری بسط پذیر توکن (XTML Chat Template) به منظور برطرف سازی کاستی های ساختاری قالب های سنتی، بازنمایی خط سیرهای پیچیده عاملی در Kimi K3 بر اساس زبان نشانه گذاری اختصاصی XTML پایه گذاری شده است. این قالب بر مبنای سه اصل اساسی طراحی گردیده است:

– **بسط پذیری (Extensibility):** توسعه ویژگی های تعاملی بدون تغییر در گرامر بنیادین مدل.



شکل ۶: فرآیند پس‌آموزش مدل Kimi K3: پیش‌تنظیم SFT با قالب XTML، پرورش ۹ متخصص دامنه‌ای - تلاشی با RL، یکپارچه‌سازی با MOPD، و شتاب‌دهی استنتاج بر مبنای زبان LK.

- **مالیات هم‌ترازی اندک (Low Alignment Tax):** یادگیری سریع فرمت ساخت‌یافته توسط مدل پیش‌آموزش‌دیده با حداقل داده‌های نظارت‌شده، جهت ورود بی‌درنگ به مرحله یادگیری تقویتی.
- **سازگاری با کدگشایی ساخت‌یافته (Decoding Friendliness):** حذف ابهام نشانه‌گذاری (Tok-enization Ambiguity) در مرز برچسب‌ها با جایگزینی براکت‌های زاویه‌ای با نشانه‌های اختصاصی [open], [sep], [close] و نشانه توقف پیام [end_of_msg].

ساختار یک پیام دستیار به سه کانال محاسباتی تفکیک می‌شود:

۱. **کانال تفکر (think):** شامل ردپای استدلال درونی مدل. این کانال در حالت استدلالی همواره حفظ می‌شود (Preserved Thinking) تا ساختار پیام در نوبت‌های متوالی پایدار بماند.
۲. **کانال پاسخ (response):** متن نهایی قابل مشاهده برای کاربر.
۳. **کانال ابزارها (tools):** فراخوانی هم‌زمان ابزارها با شناسه اختصاصی (Index) و آرگومان‌های صریح نوع‌دار (Typed Arguments).

همچنین چیدمان مؤلفه‌های پرامپت در حافظه میانگیر پیشوند (Prefix KV-Cache) بهینه‌سازی شده است؛ گزینه‌های سراسری پایدار نظیر اعلان ابزارها (tool-declare) و تنظیمات درجه تلاش فکری در صدر بافت قرار می‌گیرند تا بافت پیشوند در تمام طول گفتگو معتبر بماند و گزینه‌های تک‌نوبتی (One-shot) به انتهای بافت الصاق می‌شوند.

یادگیری تقویتی مقیاس‌پذیر چنددامنه‌ای و چندتلاشی (Multi-Domain, Multi-Effort RL) فاز یادگیری تقویتی مدل Kimi K3 به سه دامنه عملیاتی کلان گسترش یافته که هر یک طیف وسیعی از زیرمسائل را پوشش می‌دهند:

- **وظایف عمومی (General Tasks):** استدلال صوری، بینایی چندوجهی با مفسر کد، اعتبارسنجی حقیقت‌پژوهی، و امور تحلیل داده‌های علمی.
- **عامل‌های عمومی (General Agents):** دستیارهای خودکار بلندمدت، پژوهش عمیق وب، و نگارش ساخت‌یافته متون طولانی.

– **عامل‌های کدنویسی (Coding Agents):** مهندسی سیستم‌های بزرگ‌مقیاس (SWE)، برنامه‌نویسی سطح کرنل‌های شتاب‌دهنده، و توسعه برنامه‌های تعاملی وب.

با تقاطع این ۳ دامنه و ۳ سطح تلاش فکری $\mathcal{E} = \{\text{low, high, max}\}$ ، مجموعاً ۹ مدل کارشناس متخصص به موازات هم آموزش داده می‌شوند:

$$\Pi_{\text{experts}} = \left\{ \pi_{\text{teacher}}^{(d,e)} \mid d \in \{\text{General, Agent, Coding}\}, e \in \{\text{low, high, max}\} \right\} \quad (130)$$

الگوریتم رول‌اوت جزئی (Partial Rollout) و مهار داده‌های آف‌پالیسی در تعاملات عاملی با بافت‌های بسیار طولانی، بروز تأخیرهای ناشی از مسیرهای کند (Execution Stragglers) بهره‌وری پردازنده‌های گرافیکی را تهدید می‌کند. برای رفع این چالش، Kimi K³ مکانیزم رول‌اوت همگام توسعه‌یافته را اتخاذ می‌کند: به ازای دسته‌ای شامل N پرامپت، تعداد K مسیر نمونه‌برداری می‌شود ($N \times K$ مسیر فعال). به محض تکمیل کسری از مسیرها نظیر $\lambda \in (0, 1)$ (تعداد λNK مسیر)، فاز تولید متوقف شده و بهینه‌سازی خط‌مشی آغاز می‌گردد. مسیرهای ناتمام در وضعیت تعلیق قرار گرفته و در تکرار بعدی با اولویت بالا از سر گرفته می‌شوند.

توقف و ازسرگیری مسیرها در طول چندین مرحله آموزش، داده‌ها را در معرض پدیده «کهنگی خط‌مشی» (Policy Staleness) قرار می‌دهد. الگوریتم بهینه‌سازی خط‌مشی با اعمال یک قید تنظیم‌گری موضعی در سطح توکن (Per-Token Regularization)، فضای تغییرات خط‌مشی را مقید می‌سازد. از منظر نظریه اطلاعات، اگر خط‌مشی قدیمی با $\pi_{\theta_{\text{old}}}$ و خط‌مشی در حال به‌روزرسانی با π_{θ} نشان داده شود، گرادیان ارتقا با مهار نسبت درست‌نمایی $\rho_t(\theta) = \frac{\pi_{\theta}(y_t|x, y_{<t})}{\pi_{\theta_{\text{old}}}(y_t|x, y_{<t})}$ در یک همسایگی مجاز به صورت زیر محاسبه می‌شود:

$$g_t(\theta) = \min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \quad (131)$$

این قید از واگرایی کولبک-لایبلر شدید میان توزیع‌های متوالی در طول تکرارهای ناهمگام ممانعت به عمل می‌آورد.

کنترل بودجه توکن و تلاش استدلالی (Reasoning Effort & Budget Control) به منظور شکل‌دهی دقیق رفتار مدل در سطوح تلاش مختلف فکری و پیشگیری از تفکر بیهوده (Overthinking)، یک مکانیزم کنترلی پویا در طول یادگیری تقویتی اعمال می‌شود [۱۱۴]. برای هر پرامپت ورودی x ، بودجه اولیه توکن $b_0(x)$ توسط مدل پایه برآورد می‌گردد. مقدار مصرف واقعی توکن خروجی y با تابع $T(y)$ سنجیده می‌شود (شامل توکن‌های تفکر برای وظایف استدلالی، و مجموع توکن‌های تفکر و آرگومان‌های فراخوانی ابزار برای وظایف عاملی).

در صورتی که طول پاسخ از آستانه ضریب بودجه $\tau \cdot b_0(x)$ تجاوز نماید، سیگنال پاداش وظیفه بازنویسی شده و مقدار جریمه قطعی -1 جایگزین آن می‌گردد:

$$\tilde{R}(x, y) = \begin{cases} R_{\text{task}}(x, y) & \text{اگر } T(y) \leq \tau \cdot b_0(x) \\ -1 & \text{اگر } T(y) > \tau \cdot b_0(x) \end{cases} \quad (132)$$

آموزش مدل‌ها از یک برنامه آموزشی مرحله‌ای (Stage-wise Curriculum) بر روی ضریب τ پیروی می‌کند: ابتدا مدل با ضریب τ بزرگ آموزش داده شده تا استدلال عمیق شکل گیرد و سپس مقدار τ بازپخت (Anneal) شده و به مقادیر کوچک‌تر برای سطوح تلاش متوسط و پایین تقلیل می‌یابد.

مدل پاداش زایشی عاملی (Agentic Generative Reward Model - GRM) در وظایف باز و کیفی که فاقد اعتبارسنج‌های صلب هستند، یک قاضی زایشی مبتنی بر مقایسه‌های دودویی تورنمنت به کار گرفته می‌شود [۱۱۴، ۱۴]. داور عاملی موظف به رعایت یک پروتکل چهارمرحله‌ای اجباری است:

۱. بررسی دقیق صورت مسئله و خروجی‌های نامزدها،

۲. تولید رابریک جامع ارزیابی (Rubric Generation)،

۳. نمره‌دهی به هر نامزد در برابر معیارهای رابریک،

۴. درج ممیزی در دفترچه امتیازات (Scorepad) و تعیین پاسخ برتر.

برای جلوگیری از پدیده «هک پاداش از طریق اطناب کلام» (Verbosity Bias)، اگر طول پاسخ نامزدی از ضریب طول مرجع پایه ($\sigma \cdot \ell_0$) فراتر رود، آن گزینه به‌طور خودکار بازنده مقایسه زوجی اعلام می‌گردد.

محیط‌های شبیه‌سازی و سنتز وظایف عاملی (Agentic Environments) یادگیری رفتارهای پایدار نیازمند بسترهای تعاملی غنی و ایزوله است (بخش ۲.۴ گزارش فنی):

– **سنتز وظایف مبتنی بر گراف دانش (DAG-Guided Task Synthesis)**: یک گراف جهت‌دار بدون دور از مفاهیم علمی، برنامه‌نویسی و استدلالی توسط عامل‌های کاوشگر وب به صورت خودکار توسعه یافته است. با نمونه‌برداری از گره‌های مفهومی در سطوح دانه‌بندی گوناگون و ره‌گیری اجداد در گراف، داده‌های آموزشی با ترکیبی غنی از مفاهیم بین‌رشته‌ای سنتز می‌شوند.

– **بهینه‌سازی کرنل‌های گرافیکی (GPU Kernel Tasks)**: مدل در محیط‌های مبتنی بر CUDA، CuTe، Triton، ThunderKittens [۱۲۳] و TileLang [۱۲۴] آموزش داده می‌شود. پاداش‌دهی مبتنی بر دو شاخص است: خطای عددی نسبت به مرجع PyTorch و میزان نزدیکی بازدهی اجرایی به مدل سقف سخت‌افزار (Roofline Model). سامانه پیشرفته ضدتقلب مانع از ترفندهایی چون کش‌کردن ورودی یا افت عمده دقت می‌گردد.

– **وظایف اجرای خودمختار (Autonomous Execution Tasks - AET)**: عامل در محیط‌های پیچیده نظیر بازسازی بلادرنگ سیستم‌ها، کشف فاکتورهای مالی و ممیزی مالیاتی بدون دسترسی به دستورالعمل‌های از پیش‌آماده عمل می‌کند. پاداش صرفاً بر مبنای بازبینی‌های مستقل روی وضعیت نهایی محیط تخصیص می‌یابد و عامل‌ها به اعتبارسنج‌های عمومی (جهت عیب‌یابی) و پنهان (جهت نمره‌دهی نهایی) متصل می‌شوند.

– **دستیارهای تعاملی ماندگار (Personal Assistant Tasks)**: پیاده‌سازی ماک نرم‌افزارهای Gmail، Notion، Slack و Canvas جهت شبیه‌سازی تعاملات درازمدت کاری در طول چندین روز مجازی با ثبت هزاران فراخوانی ابزار.

تقطیر برخط چنداستاد (Multi-Teacher On-Policy Distillation - MOPD) برای تجمیع توانمندی‌های

۹ مدل متخصص در یک مدل واحد π_θ ، روش تقطیر حین خط‌مشی چنداستاد اتخاذ می‌گردد [۱۸۹، ۲۰۶، ۲۰۷]. برای پرسش ورودی x با دامنه تخصصی d و سطح تلاش $e \in \{\text{low}, \text{high}, \text{max}\}$ ، هدایت آموزشی توسط مدل معلم متناظر $\pi_{\text{teacher}}^{(d,e)}$ صورت می‌پذیرد.

اشتقاق ریاضی پاداش MOPD بر مبنای نظریه اطلاعات در نظریه اطلاعات، واگرایی کولبک-لایبلر معکوس (Reverse KL) به صورت زیر تعریف می‌شود:

$$\mathbb{D}_{\text{KL}}(\pi_\theta \parallel \pi_{\text{teacher}}) = \sum_{y \in \mathcal{V}} \pi_\theta(y \mid x, e) \log \left(\frac{\pi_\theta(y \mid x, e)}{\pi_{\text{teacher}}^{(d,e)}(y \mid x)} \right) \quad (۱۳۳)$$

این واگرایی دارای ویژگی مدجویی (Mode-Seeking) است و مدل دانش‌آموز را ملزم می‌سازد تا در بخش‌هایی از فضا که احتمال معلم ناچیز است، احتمال خود را صفر کند. در چارچوب گرادیان خط‌مشی (Policy Gradient)، تابع هدف بهینه‌سازی امید ریاضی مجموع پاداش‌های تولیدی حین خط‌مشی است:

$$\mathcal{J}(\theta) = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(\cdot \mid x, e)} \left[\sum_{t=1}^T r(y_t \mid e, x, y_{<t}) \right] \quad (۱۳۴)$$

طبق قضیه گرادیان خطمشی، مشتق نسبت به بردار پارامترهای θ برابر است با:

$$\nabla_{\theta} \mathcal{J}(\theta) = \mathbb{E}_{y \sim \pi_{\theta}} \left[\sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(y_t | e, x, y_{<t}) \cdot Q(y_t) \right] \quad (135)$$

برای آن که این بهینه‌سازی دقیقاً معادل با کمینه‌سازی واگرایی کولبک-لایبلر باشد، تابع پاداش توکن y_t باید بر اساس لگاریتم نسبت درست‌نمایی تعریف شود:

$$r(y_t) \propto \log \left(\frac{\pi_{\text{teacher}}^{(d,e)}(y_t | x, y_{<t})}{\pi_{\theta}(y_t | e, x, y_{<t})} \right) \quad (136)$$

به منظور جلوگیری از ناپایداری‌های عددی ناشی از توکن‌های نادر که در آن‌ها نسبت احتمالات به بی‌نهایت میل می‌کند، فرمولاسیون پاداش متراکم مدل به صورت زیر تعریف می‌گردد (معادله ۱۵ گزارش مرجع):

$$r_{\text{opd}}^d(y_t | e, x, y_{<t}) = \text{clip} \left(\text{sg} \left(\log \frac{\pi_{\text{teacher}}^{(d,e)}(y_t | x, y_{<t})}{\pi_{\theta}(y_t | e, x, y_{<t})} \right), -R_{\max}, R_{\max} \right) \quad (137)$$

در این رابطه:

– $\text{sg}(\cdot)$ عملگر گرادیان-ایست (Stop-Gradient) است؛ یعنی $\text{sg}(u) = u$ ولی $\frac{\partial \text{sg}(u)}{\partial u} = 0$. این عملگر تضمین می‌کند که سیگنال پاداش صرفاً به عنوان یک مقدار تراز عددی عمل کرده و تداخل گرادیانی میان مخرج نسبت و مشتقات خطمشی ایجاد نگردد.

– عملگر $\text{clip}(\cdot, -R_{\max}, R_{\max})$ پاداش را در یک بازه متقارن معین مهار می‌کند که معادل با ایجاد کران بالا بر روی واگرایی رنی (Rényi Divergence) میان دو توزیع بوده و واریانس گرادیان را به شدت تثبیت می‌نماید.

پس‌آموزش آگاه از استقرار و مدل پیش‌نویس (Deployment-Aware Post-Training) بهینه‌سازی کارایی زمان استنتاج برای سرویس‌دهی مدل در بافت‌های یک میلیون توکنی دارای دو رکن کلیدی است:

– **آموزش آگاه از کوانتیزاسیون (MXFP4 QAT):** وزن‌های کارشناسان MoE که بخش غالب حافظه را تشکیل می‌دهند به فرمت ریزمقیاس MXFP4 [۱۹۱] نگاشته شده و اکتیویشن‌ها در فرمت MXFP8 پردازش می‌شوند. لایه‌های حساس غیرکارشناس (طرح‌ریزی‌های توجه، کارشناسان مشترک و روترها) در دقت بالاتر حفظ می‌گردند. اجرای پیوسته QAT در هر دو مرحله SFT و RL مانع از ایجاد شکاف دقت میان آموزش و استنتاج می‌شود.

– **تنظیم دقیق مدل پیش‌نویس با معماری EAGLE-3:** لایه پیش‌بینی چندتوکنی (MTP) مدل که در فاز پیش‌آموزش وجود داشته، در این مرحله به عنوان مدل پیش‌نویس برای رمزگشایی گمانه‌زن (Speculative Decoding) [۲۰۸] تنظیم می‌گردد. در طول آموزش مدل پیش‌نویس، پارامترهای مدل اصلی منجمد (Frozen) بوده و تنها لایه پیش‌نویس و ماتریس تصویرسازی ویژگی‌های آن به‌روزرسانی می‌شوند.

اتصال لایه‌های پس‌ماند توجه (AttnRes) و طرح‌ریزی W_{E^3} ورودی لایه پیش‌نویس ترکیبی از ویژگی‌های سطوح پایین، میانی و بالای مدل اصلی است که به ترتیب از خروجی بلوک‌های اول، چهارم و نهمی مکانیزم پس‌ماند توجه (Attention Residuals - AttnRes) استخراج می‌گردند. این ویژگی‌ها با هم الحاق شده و توسط ماتریس بدون بایاس W_{E^3} تصویر می‌شوند:

$$h_{\text{draft}} = W_{E^3} \begin{bmatrix} h_{\text{low}} \\ h_{\text{mid}} \\ h_{\text{high}} \end{bmatrix}, \quad W_{E^3} = \begin{bmatrix} 0 & 0 & I \end{bmatrix} \text{ با مقداردهی اولیه:} \quad (138)$$

این شیوه مقداردهی موجب می‌شود که در گام اول آموزش، بردار ویژگی منطبق بر h_{high} (ورودی اصلی فاز پیش‌آموزش MTP) باشد و سپس به مرور ویژگی‌های سطوح دیگر جذب شوند.

اشتقاق تحلیلی تابع زیان درست‌نمایی LK Loss در رمزگشایی گمانه‌زن بدون اتلاف، فرض کنید $p(x)$ توزیع مدل هدف و $q(x)$ توزیع مدل پیش‌نویس روی دایره واژگان $\mathcal{V}$ باشد. یک توکن پیشنهادی نمونه‌برداری شده از $q(x)$ با احتمال زیر پذیرفته می‌شود:

$$P(\text{accept} \mid x \sim q) = \min \left(1, \frac{p(x)}{q(x)} \right) \quad (۱۳۹)$$

امید ریاضی نرخ پذیرش تحت توزیع q برابر است با:

$$\alpha = \mathbb{E}_{x \sim q} \left[\min \left(1, \frac{p(x)}{q(x)} \right) \right] = \sum_{x \in \mathcal{V}} q(x) \min \left(1, \frac{p(x)}{q(x)} \right) = \sum_{x \in \mathcal{V}} \min(p(x), q(x)) \quad (۱۴۰)$$

از منظر نظریه اطلاعات و فاصله احتمالاتی، این نرخ با فاصله تغییر کل (Total Variation Distance) رابطه مستقیم دارد:

$$D_{\text{TV}}(p, q) = \frac{1}{2} \sum_{x \in \mathcal{V}} |p(x) - q(x)| = 1 - \sum_{x \in \mathcal{V}} \min(p(x), q(x)) = 1 - \alpha \quad (۱۴۱)$$

بنابراین، بیشینه‌سازی نرخ پذیرش توکن مستقیماً معادل کمینه‌سازی فاصله تغییر کل است:

$$\max_q \alpha \iff \min_q D_{\text{TV}}(p, q) \quad (۱۴۲)$$

رویکردهای مرسوم که واگرایی کولبک-لایبلر یا خطای آنتروپی متقاطع را بهینه‌سازی می‌کنند، همپوشانی مساحت توزیع‌ها را بیشینه نمی‌سازند. لذا **Kimi K3** تابع زیان بر مبنای درست‌نمایی LK [۲۰۹] را مستقیماً به عنوان منفی لگاریتم نرخ پذیرش بهینه‌سازی می‌کند (معادله ۱۶ گزارش مرجع):

$$\mathcal{L}_{\text{LK}} = -\log \sum_{x \in \mathcal{V}} \min(p(x), q(x)) \quad (۱۴۳)$$

برای استخراج مشتق نسبت به لاجیت‌های خروجی مدل پیش‌نویس (z_k با رابطه $q(x_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$ ، قاعده زنجیره‌ای دیفرانسیل را به کار می‌بندیم:

$$\frac{\partial \mathcal{L}_{\text{LK}}}{\partial z_k} = -\frac{1}{\sum_{x \in \mathcal{V}} \min(p(x), q(x))} \cdot \frac{\partial}{\partial z_k} \left[\sum_{x \in \mathcal{V}} \min(p(x), q(x)) \right] \quad (۱۴۴)$$

چون جمله $\min(p(x), q(x))$ برای $q(x) < p(x)$ برابر با $q(x)$ و برای $q(x) \geq p(x)$ برابر با مقدار ثابت $p(x)$ است:

$$\frac{\partial}{\partial z_k} \min(p(x), q(x)) = \begin{cases} \frac{\partial q(x)}{\partial z_k} & \text{اگر } q(x) < p(x) \\ 0 & \text{اگر } q(x) \geq p(x) \end{cases} \quad (۱۴۵)$$

با جایگذاری مشتق تابع بیشینه هموار ($\frac{\partial q(x_i)}{\partial z_k} = q(x_i)(\delta_{ik} - q(x_k))$):

$$\begin{aligned} \frac{\partial \mathcal{L}_{\text{LK}}}{\partial z_k} &= -\frac{1}{\alpha} \sum_{x_i: q(x_i) < p(x_i)} q(x_i) (\delta_{ik} - q(x_k)) \\ &= \frac{q(x_k)}{\alpha} \left(\sum_{x_i: q(x_i) < p(x_i)} q(x_i) - \mathbb{I}_{q(x_k) < p(x_k)} \right) \end{aligned} \quad (۱۴۶)$$

این گرادیان به صراحت نشان می‌دهد که در صورت عقب‌ماندن احتمال پیش‌نویس نسبت به مدل اصلی ($q(x_k) < p(x_k)$)، شیب گرادیان به سوی تقویت لاجیت z_k متمایل می‌شود تا سطح مشترک دو توزیع بیشینه گردد.

نوآوری‌های زیرساختی پس‌آموزش در بافت ۱ میلیون توکن (System Infrastructures) اجرای الگوریتم‌های پس‌آموزش روی مدلی با ابعاد 2.8T و طول بافت 1M توکن با راهکارهای زیرساختی پیشرفته میسر شده است (بخش ۳.۵ گزارش فنی):

- **استخر حافظه میانگیر خارجی (External KV-Cache Pool):** اتخاذ راهبرد نوشتن-پس‌انداز (Write-Back) برای پیشوندهای حافظه؛ بلوک‌های فعال در حافظه VRAM باقی مانده و پیشوندهای بیکار به حافظه رم پردازنده اصلی (CPU DRAM) منتقل می‌شوند. حالات بازگشتی KDA نیز همگام با گش MLA مدیریت می‌شوند. همچنین در طول فاز رول‌اوت، حالات آموزشی وزن‌ها و بهینه‌سازها به دیسک‌های NVMe تخلیه می‌شوند تا فضای رم برای بافت‌های میلیونی مهیا گردد.
- **زمان‌بند خودکار مهار ترافیک (Rollout Auto-Throttling):** پایش بی‌درنگ نرخ اشغال گش حافظه و تعداد درخواست‌های فعال به منظور تعدیل پویای تعداد پرامپت‌های ارسالی به موتور استنتاج، جهت جلوگیری از وقوع خطای سرریز حافظه یا توقف ناخواسته پردازش (Preemption).
- **بازاستفاده از بافر گرادیان (Gradient-Buffer Reuse):** اجرای مدل‌های مرجع فاقد گرادیان با استریم تکه‌به‌تکه وزن‌ها از حافظه CPU به داخل بافر گرادیان FP32 مدل در حال آموزش، که نیاز به تخصیص حافظه گرافیکی مازاد را به صفر می‌رساند.
- **زیرساخت سندباکس عاملی AgentENV:** سیستم ایزولاسیون سبک‌وزن مبتنی بر ماشین‌های مجازی خرد Firecracker [۱۹۵] با قابلیت ایجاد بیش از ۵۱ میلیون سندباکس پایدار. ویژگی‌های برجسته این بستر شامل ثبت نقطه بازرسی تفاضلی در 133ms، بازیابی در 49ms، تعلیق و ازسرگیری (Pause & Resume) جهت صفر کردن مصرف منابع در زمان انتظار پاسخ مدل، و انشعاب ایزوله (Fork) جهت قضاوت مدل پاداش است.

• Magistral

مقدمه و پارادایم پس‌آموزش استدلالی (Reasoning Post-Training Paradigm) مدل استدلالی Magistral [۲۱۰] نخستین مدل استدلال عمیق شرکت Mistral AI است که در دو نسخه Magistral Medium (بر پایه Mistral Medium 3 [۲۱۱]) و Magistral Small (بر پایه Mistral Small 3 با 24B پارامتر) معرفی شده است. این مدل اثبات می‌کند که بدون نیاز به تقطیر از مدل‌های استدلالی پیشین نظیر سری o1 [۱۲۵] یا DeepSeek-R1 [۱۰۳]، می‌توان با یادگیری تقویتی برخط خالص (Pure Online RLVR) به توان استدلال سطح بالا دست یافت.

مبانی ریاضی، اشتقاق گرادیان خط‌مشی و نظریه اطلاعات فرآیند تولید متن در مدل‌های زبانی خودهمبسته، یک فرآیند تصمیم‌گیری متوالی روی دایره واژگان گسسته است. فرض کنید به ازای پرامپت ورودی $q \sim \mathcal{P}(Q)$ ، توالی خروجی $o = (y_1, y_2, \dots, y_T)$ توسط خط‌مشی مدل با توزیع احتمالاتی زیر تولید شود:

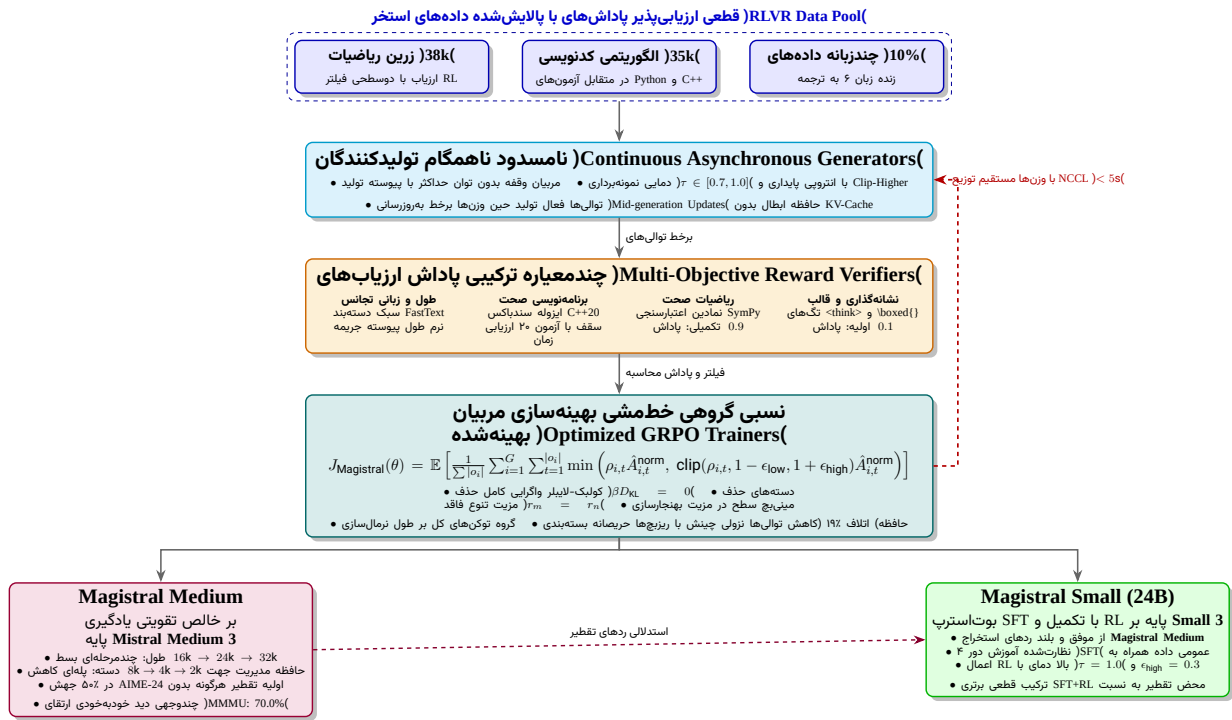
$$\pi_{\theta}(o | q) = \prod_{t=1}^T \pi_{\theta}(y_t | q, y_{<t}) \quad (147)$$

هدف در یادگیری تقویتی، بیشینه‌سازی امید ریاضی پاداش اسکالر $r(q, o) \in \mathbb{R}$ بر روی توزیع داده‌ها است:

$$J(\theta) = \mathbb{E}_{q \sim \mathcal{P}(Q), o \sim \pi_{\theta}(\cdot | q)} [r(q, o)] = \sum_q \mathcal{P}(q) \sum_o \pi_{\theta}(o | q) r(q, o) \quad (148)$$

با استفاده از اتحاد مشتق لگاریتمی (Log-derivative trick):

$$\nabla_{\theta} \pi_{\theta}(o | q) = \pi_{\theta}(o | q) \frac{\nabla_{\theta} \pi_{\theta}(o | q)}{\pi_{\theta}(o | q)} = \pi_{\theta}(o | q) \nabla_{\theta} \log \pi_{\theta}(o | q) \quad (149)$$



شکل ۷: معماری یکپارچه پس‌آموزش در **Magistral**: چرخه ناهمگام تولید و آموزش، پالایش پاداش و مقیاس‌پذیری مدل‌ها.

گرایان تابع هدف نسبت به بردار پارامترهای $\theta \in \mathbb{R}^d$ به‌دست می‌آید:

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \sum_q \mathcal{P}(q) \sum_o \nabla_{\theta} \pi_{\theta}(o | q) r(q, o) \\ &= \sum_q \mathcal{P}(q) \sum_o \pi_{\theta}(o | q) \nabla_{\theta} \log \pi_{\theta}(o | q) r(q, o) \\ &= \mathbb{E}_{q \sim \mathcal{P}(Q), o \sim \pi_{\theta}(\cdot | q)} [\nabla_{\theta} \log \pi_{\theta}(o | q) r(q, o)] \end{aligned} \quad (150)$$

برای کاهش واریانس، یک خط مبنای مستقل از عمل $b(q)$ تفریق می‌شود. از آنجا که $\sum_o \pi_{\theta}(o | q) = 1$ است:

$$\sum_o \pi_{\theta}(o | q) \nabla_{\theta} \log \pi_{\theta}(o | q) b(q) = b(q) \nabla_{\theta} \sum_o \pi_{\theta}(o | q) = b(q) \nabla_{\theta} (1) = 0 \quad (151)$$

تفريق خط مبنا، امید ریاضی گرایان را بدون تورش نگه داشته و واریانس تخمین‌گر را مهار می‌کند. مقدار $A(q, o) = r(q, o) - b(q)$ بیانگر تابع مزیت (Advantage) است.

در نظریه اطلاعات، انتروپی خطمشی به صورت $\mathcal{H}(\pi_{\theta}(\cdot | q)) = -\sum_o \pi_{\theta}(o | q) \log \pi_{\theta}(o | q)$ تعریف می‌شود. اگر خطمشی به سرعت قطعی شود، انتروپی به سمت صفر سقوط کرده و مدل دچار پدیده «فروپاشی انتروپی» (Entropy Collapse) می‌گردد که مانع از جستجوی استدلال‌های جدید می‌شود.

الگوریتم GRPO بهینه‌شده در Magistral الگوریتم بهینه‌سازی خطمشی گروهی نسبی (GRPO) [۲۴] مدل نقاد را حذف کرده و به ازای هر پرسش q ، یک گروه G تایی از پاسخ‌ها $\{o_1, o_2, \dots, o_G\}$ توسط خطمشی پیشین $\pi_{\theta_{\text{old}}}$ تولید می‌کند:

$$\mu = \frac{1}{G} \sum_{i=1}^G r_i, \quad \sigma = \sqrt{\frac{1}{G} \sum_{i=1}^G (r_i - \mu)^2} \quad (152)$$

در مدل **Magistral** پنج اصلاح اساسی بر این ساختار اعمال شده است:

۱. **حذف کامل واگرایی کولبک-لایبلر** ($\beta D_{KL} = 0$): حضور مدل مرجع و جریمه KL مانع از شکل‌گیری استدلال‌های عمیق می‌شد و بار حافظه گرافیکی را به شدت افزایش می‌داد؛ لذا این ترم به‌طور کامل حذف گردید.

۲. **نرمال‌سازی اتلاف بر مبنای کل توکن‌های گروه**: اتلاف تمام توکن‌های تمامی توالی‌ها با هم جمع شده و بر مجموع طول کل توکن‌های حاضر در گروه ($\sum_{i=1}^G |o_i|$) تقسیم می‌شود تا از سوگیری به سمت پاسخ‌های کوتاه جلوگیری شود.

۳. **نرمال‌سازی مزیت در سطح مینی‌بچ**: پس از محاسبه اختلاف مزیت خام $\hat{A}_i = r_i - \mu$ ، مقادیر مزیت بر مبنای میانگین و انحراف معیار کل نمونه‌های مینی‌بچ بر مبنای [۲۱۲] باز-مقیاس‌گذاری می‌شوند:

$$\hat{A}_{i,t}^{\text{norm}} = \frac{\hat{A}_i - \hat{A}_{\text{mean}}}{\hat{A}_{\text{std}} + \epsilon} \quad (153)$$

۴. **گسترش نامتقارن کران بالای ناحیه اعتماد (Clip-Higher)**: بر اساس راهبرد [۲۱۳]، کران بالا تا ϵ_{high} توسعه داده شد (0.26 تا 0.28 در مدل Medium و 0.3 در مدل Small) تا از افت انتروپی جلوگیری شود:

$$\text{بازه برش} = [1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}] \quad (154)$$

۵. **حذف گروه‌های فاقد تنوع مزیت**: دسته‌هایی که پاسخ‌های آن‌ها همگی صحیح یا همگی غلط باشند فاقد سیگنال یادگیری هستند و پیش از تشکیل مینی‌بچ حذف می‌شوند.

با تلفیق این موارد، تابع هدف نهایی بهینه‌سازی به فرم چندخطی و دقیق زیر تعریف می‌شود:

$$J_{\text{Magistral}}(\theta) = \mathbb{E}_{q \sim \mathcal{P}(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(\rho_{i,t}(\theta) \hat{A}_{i,t}^{\text{norm}}, \right. \right. \\ \left. \left. \text{clip}(\rho_{i,t}(\theta), 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}) \hat{A}_{i,t}^{\text{norm}} \right) \right] \quad (155)$$

مشروط بر اینکه شرط تنوع درون‌گروهی برقرار باشد:

$$\exists 1 \leq m < n \leq G \quad \text{s.t.} \quad r_m \neq r_n \quad (156)$$

که در آن نسبت درست‌نمایی توکنی برابر است با:

$$\rho_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})} \quad (157)$$

مهندسی پاداش چندمعیاره (Reward Shaping) تابع پاداش نهایی از ترکیب چهار مؤلفه تشکیل می‌شود:

– **پاداش قالب (R_{format})**: پاسخ باید حتماً دارای یک جفت تگ `<think>` و `</think>` باشد. در ریاضیات باید عبارت نهایی در `\boxed{...}` و در کدنویسی بلوک کد Markdown درج گردد. نقض این ساختار موجب صفر شدن پاداش کل ($R = 0$) می‌شود و در صورت تطابق، پاداش اولیه 0.1 اعطا می‌گردد.

– **پاداش صحت علمی (R_{correct})**: در ریاضیات از ارزیاب نمادین SymPy جهت تایید هم‌ارزی جبری استفاده شده و در صورت صحت، پاداش 0.9 اضافه می‌شود. در کدنویسی، برنامه تحت استاندارد C++20 کامپایل شده و روی ۲۰ آزمون تصادفی با مهلت ۴ ثانیه و سقف حافظه 300MB ارزیابی می‌گردد؛ قبولی در همه آزمون‌ها پاداش 0.9 به همراه دارد.

- **جریمه طول نرم (Soft Length Penalty):** برای هشدار به مدل در نزدیکی سقف حافظه بدون بریدگی تند گرادیان، جریمه زیر اعمال می‌شود:

$$R_{\text{length}}(y) = \begin{cases} 0, & |y| \leq l_{\text{max}} - l_{\text{cache}} \\ -0.1 \times \left(\frac{|y| - (l_{\text{max}} - l_{\text{cache}})}{l_{\text{cache}}} \right), & l_{\text{max}} - l_{\text{cache}} < |y| \leq l_{\text{max}} \\ -0.1, & |y| > l_{\text{max}} \end{cases} \quad (158)$$

- **پاداش تجانس زبانی (R_{lang}):** متن مسئله، زنجیره تفکر و پاسخ نهایی توسط دسته‌بند سریع FastText [۲۱] ارزیابی شده و در صورت همخوانی با زبان کاربر، پاداش تشویقی 0.1 اعطا می‌شود.

پرامپت سیستمی و هدایت انترویی پرامپت سیستمی مدل برای هدایت ساختار و سطح انترویی به صورت زیر در محیط اختصاصی لاتین تعریف شده است:

Magistral System Prompt:

"A user will ask you to solve a task. You should first draft your thinking process (inner monologue) until you have derived the final answer. Afterwards, write a self-contained summary of your thoughts... Write both your thoughts and summary in the same language as the task posed by the user.

Your thinking process must follow the template below:

<think>

Your thoughts or/and draft, like working through an exercise on scratch paper. Be as casual and as long as you want until you are confident to generate a correct answer.

</think>

Here, provide a concise summary that reflects your reasoning and presents a clear final answer to the user."

استفاده از عبارت "Be as long as and casual as you want" انترویی اولیه مدل را افزایش داده و ظرفیت اکتشاف را تقویت می‌نماید.

زیرساخت توزیع‌شده ناهمگام (Asynchronous Infrastructure) برای مهار ناهماهنگی زمانی ناشی از اختلاف طول توالی‌ها:

- واحدهای تولیدکننده (Generators) به‌صورت کاملاً ناهمگام و مداوم خروجی تولید می‌کنند.
- انتقال وزن‌ها پس از هر گام گرادیان با کتابخانه ارتباطی NCCL مستقیماً میان حافظه کارت‌های گرافیک در کمتر از ۵ ثانیه انجام می‌شود.
- **به‌روزرسانی در میانه تولید (Mid-generation Updates):** توالی‌های در حال تولید، وزن‌های جدید را بلافاصله دریافت می‌کنند بدون آنکه حافظه کش KV بازنشانی شود.
- **مهار انحراف از خط‌مشی:** پایداری آموزش با قید $\frac{n_{\text{async}}}{n_{\text{batch}}} \leq 2$ و برابری $n_{\text{batch}} = n_{\text{minibatch}}$ تضمین گردید.
- **بسته‌بندی حریصانه ریزبج‌ها:** توالی‌ها بر مبنای طول مرتب شده و به شکل حریصانه در ریزبج‌ها قرار گرفتند که اتلاف حافظه (Padding) را ۱۹٪ کاهش داد.

تحلیل هندسه وزن‌ها با الگوریتم لانچوز-آرنولدی (Lanczos-Arnoldi PCA) با تشکیل ماتریس وزن‌های چک‌پوینت‌ها در طول زمان ($X \in \mathbb{R}^{T \times W}$) و محاسبه دو بردار ویژه اول ماتریس کوواریانس $X^T X$ توسط روش تکراری لانچوز-آرنولدی [۲۱۴]، ابرصفحه تغییرات با بردارهای یک‌ه c_1, c_2 بر طبق [۲۱۵] به‌دست آمد:

$$w(\alpha_1, \alpha_2) = w^* + \alpha_1 c_1 + \alpha_2 c_2 \quad (159)$$

این تحلیل نشان داد که مسیر بهینه‌سازی مدل دقیقاً در امتداد جهت افزایش طول زنجیره تفکر حرکت می‌کند و پاداش با لگاریتم طول توالی رابطه خطی مستقیم دارد ($R_{\text{raw}} \propto a \cdot \log(\text{Length}) + b$).

پدیده نوظهور استدلال دیداری چندوجهی (Multimodal Free Lunch) با وجود آنکه در طول مرحله RL حتی یک داده تصویری استفاده نشد، توانایی استدلال مرحله به مرحله به انکودر بینایی مدل سرایت کرد. مدل در بنچمارک MMMU [۱۳۰] به دقت ۰.۷۰٪ (ارتقای ۵٪) و در بنچمارک دشوار MMMU-Pro (Vision) [۱۳۱] به دقت ۱۲.۵۲٪ (جهش ۱۲٪) دست یافت.

رویکردهای ناموفق (Unsuccessful Approaches) نویسندگان نشان دادند که:

- **پاداش جزئی در کدنویسی:** پاداش‌دهی بر مبنای کسری از آزمون‌های موفق موجب افت ۲ درصدی در LiveCodeBench شد؛ چرا که سیگنال‌های مثبت کاذب به راه‌حل‌های غلط اما با انطباق تصادفی تزریق می‌کرد.
- **ترم پاداش انتروپی سنتی:** اضافه کردن ضریب انتروپی به تابع اتلاف موجب ناپایداری و انفجار انتروپی گردید.
- **جریمه KL با میانگین متحرک:** استفاده از هر شکلی از جریمه واگرایی KL مانع از تغییر رفتار مدل به سمت تفکر عمیق شد.

ارزیابی‌های تجربی و نتایج نتایج مدل‌های خانواده Magistral در مقایسه با سایر مدل‌ها در جدول ۵۸ ارائه شده است.

جدول ۵۸: ارزیابی جامع عملکرد مدل‌های خانواده Magistral در بنچمارک‌های استدلالی

مدل	رویکرد آموزش	AIME ۲۴'	AIME ۲۵'	MATH-۵۰۰	GPQA	LiveCodeBench
Mistral Medium 3	پایه دستوری	۸.۲۶٪	۲.۲۱٪	۰.۹۱٪	۶.۵۹٪	۱.۲۹٪
Magistral Medium	RL خالص	۶.۷۳٪	۹.۶۴٪	۳.۹۴٪	۸.۷۰٪	۴.۵۹٪
DeepSeek-R1-Zero	RL خالص	۰.۷۱٪	-	۹.۹۵٪	۳.۷۳٪	۰.۵۰٪
DeepSeek-R1	SFT استدلالی + RL	۸.۷۹٪	۰.۷۰٪	۳.۹۷٪	۵.۷۱٪	۹.۶۵٪
Mistral Small 24B	تقطیر SFT	۴.۶۵٪	۶.۵۵٪	۲.۹۳٪	۴.۶۳٪	۲.۵۲٪
Mistral Small 24B	RL خالص	۸.۶۵٪	۹.۵۱٪	۴.۹۵٪	۸.۶۸٪	۴.۴۶٪
Magistral Small (24B)	ترکیب SFT+RL	۷.۷۰٪	۸.۶۲٪	۹.۹۵٪	۲.۶۸٪	۸.۵۵٪

• MiniMax-M2


مقدمه و فلسفه طراحی پس‌آموزش (Post-Training Philosophy) سری مدل‌های MiniMax-M2 (شامل نسخه‌های M2.5، M2 و M2.7) بر پایه پارادایم نوین «فعال‌سازی حداقلی برای دستیابی به حداکثر هوشمندی جهان واقعی» (Mini Activations Unleashing Max Real-World Intelligence) بنا نهاده شده‌اند [۲۵]. مدل پرچمدار این خانواده با ساختار ترکیبی از متخصصان (MoE) دارای 229.9B پارامتر کل است که در هر توکن تنها 9.8B پارامتر (حدود ۱۰ میلیارد پارامتر) از میان ۲۵۶ متخصص ریزدانه (Fine-Grained Experts) با دروازه‌بانی مستقل سیگموئید (Sigmoid Gating) فعال می‌گردند [۲۸، ۲۱۶، ۱۳۲].

در حالی که فاز پیش‌آموزش بر روی 29.2T توکن، دانش پایه‌ای مدل را شکل می‌دهد، جهش اصلی قابلیت‌های عاملی در افق‌های زمانی بلندمدت (Long-Horizon Agentic Workflows) از طریق یک خط‌لوله پس‌آموزش (Post-Training) چندمرحله‌ای حاصل شده است. این سیستم بر چهار پایه استوار است:

۱. **خط‌لوله‌های داده عاملی و محیط‌های اجرایی (Agent-Driven Data Pipelines):** تولید داده‌های ساختاریافته در حوزه‌های کدنویسی، همکاری اداری و استدلال، مقید به محیط‌های سندباکس داکر و پاداش‌های مبتنی بر آزمون‌های اجرایی.
۲. **تنظیم دقیق نظارت‌شده با تفکر درهم‌تنیده (Interleaved Thinking SFT):** درهم‌آمیختن استدلال پیوسته، اقدامات و مشاهدات محیطی، همراه با حفظ کامل حافظه وضعیت استدلال (Reasoning State Persistence).

۳. **یادگیری تقویتی عامل محور با بهینه ساز CISPO:** فرمولاسیون فرایند تصمیم گیری مارکوف (MDP) برای کنشگری ابزارها، طراحی پاداش ترکیبی سه گانه و مهار واریانس بهینه سازی از طریق برش نامتقارن نسبت اهمیت.

۴. **زیرساخت مقیاس پذیر Forge و تکامل خودکار (Self-Evolution):** معماری توزیع شده برای آموزش همزمان عامل های جعبه سفید و جعبه سیاه، زمان بندی پنجره های FIFO، ادغام درخت پیشوند با اتلاف صفر، و توانمندسازی مدل در دیباگ مستقل کدهای آموزشی خود.



شکل ۸: جریان کاری جامع و ساختار پس آموزش در سری MiniMax-M2: از خطوط داده عامل محور و تفکر درهم تنیده تا بهینه سازی CISPO در بستر Forge و تکامل خودکار مدل.

خطوله های داده های پس آموزش عامل محور (Agent-Driven Data Pipelines) برای تضمین پایایی مدل در تعاملات پیچیده، داده های پس آموزش حول محور محیط های عملیاتی و بازخوردهای عینی مهندسی شده اند:

– **خطوله مقیاس بندی مهندسی نرم افزار (SWE-Scaling):** با واکنشی درخواست های ادغام شده (Merged PRs) از گیت هاب با مجوزهای آزاد، مسائل کدنویسی استخراج می شوند. برای رفع چالش های کامپایل در زبان های غیر پایتونی نظیر Rust، Java و C++، Go، از یک عامل خودکار برای تولید چرخه ای و بهینه سازی اسکریپت های Dockerfile استفاده شده است. وظایف بر اساس

پاداش‌های آزمون محور تفکیک می‌شوند: آزمون‌های ناموفق-به-موفق (F2P) و موفق-به-موفق (P2P) برای باگ‌زدایی، آزمون‌های قابلیت جدید، و آزمون‌های سنجش کارایی برای بهینه‌سازی کد. همچنین تکنیک‌های تزریق باگ (Bug Injection) و تبدیل وظیفه به نوشتن آزمون معکوس (SWE-Test) جهت غنی‌سازی توزیع داده اعمال گردیده‌اند [۱۳۴].

– **توسعه اپلیکیشن با عامل ارزیاب (AppDev via Agent-as-a-Verifier - AaaV):** به منظور سنتز برنامه‌های کامل از ابتدا (From Scratch)، متخصصان انسانی متاکوئری‌هایی متناسب با فناوری‌های نوین (نظیر React + Zustand + Tailwind) تدوین می‌کنند. پس از تنوع‌بخشی و رفع تکرار با الگوریتم MinHash، برنامه‌های تولیدشده در سندباکس اجرا شده و توسط چارچوب AaaV در سه سطح ارزیابی می‌شوند: لایه اجرا (Execution) به عنوان گیت سخت‌گیرانه، لایه تعامل کاربر (Interaction) از طریق سناریوهای خودکار فریم‌ورک Playwright، و لایه زیبایی‌شناسی بصری (Visual Aesthetics). همچنین با تکنیک «تقطیر پرامپت» (Prompt Distillation)، بخش‌های تفصیلی راهنمای سیستم حین آموزش تدریجاً حذف می‌شوند تا مدل رفتار استاندارد را درونی‌سازی کند.

– **محیط خودکار خط فرمان (Terminal-Gym):** با پالایش و تبدیل داده‌های سایت Stack Overflow [۲۱۷]، مسائل تعاملی سیستم‌عامل لینوکس در قالب سناریوهای مشخص بازنویسی می‌شوند. فرایند تبدیل طی سه گام تولید محیط و اسکرپت آزمون، انتزاع سرنخ‌ها (Query Evolution) و کالیبراسیون سختی انجام می‌پذیرد تا وظایفی استاندارد و قابل ارزیابی پدید آید.

– **همکاری سازمانی و پژوهش وب (Agentic Cowork):** وظایف این بخش در چهار شاخه عملیاتی می‌شوند: پژوهش عمیق وب (Deep Search) با استراتژی بازنویسی و پنهان‌سازی نهادهای جهت الزام مدل به بازایی مستند شواهد [۱۳۹]؛ وظایف اداری بر پایه بنچمارک GDPval [۱۳۷] با معیارهای چندبعدی راستی‌آزمایی؛ تحلیل و مدل‌سازی مالی بر مبنای سنتز معکوس شواهد [۱۳۸] همراه با بازسنجی قطعی فرمول‌ها و سلول‌های اکسل؛ و تولید و اصلاح ساختاری اسلایدها با رندرسازی و نمره‌دهی توسط مدل‌های بینایی.

– **پایداری هویت و نقش‌آفرینی (Role-Play Persona):** فضای گفتگو به صورت حاصل ضرب دکارتی $\{Worlds\} \times \{Stories\}$ شرطی‌شده بر ترجیحات کاربر مدل‌سازی شده است [۲۱۸]. ارزیابی با معیار Role-Play Bench جهت جریمه شکست نقش یا تناقض منطقی صورت گرفته و بهینه‌سازی نهایی با پالایش آماری داده‌های ترجیحی و پایش آنروپی انجام می‌شود.

تنظیم دقیق نظارت‌شده با تفکر درهم‌تنیده (Interleaved Thinking SFT) در وظایف عاملی طولانی‌مدت، رویکردهای سنتی زنجیره تفکر مقدماتی (Front-loaded CoT) که پیش از هر اقدامی کل استدلال را تولید می‌کنند، توانایی انطباق با بازخوردهای ابزار را ندارند؛ همچنین رویکردهای تفکر بدون حالت (Stateless CoT) که در هر مرحله تفکرات دوره‌های قبل را حذف می‌کنند، به رانش پیوسته وضعیت منجر می‌گردند.

در **MiniMax-M2**، مفهوم تفکر درهم‌تنیده (Interleaved Thinking) پیاده‌سازی شده است که در آن مسیر اجرایی عامل τ به صورت دنباله‌ای متناوب از توکن‌های استدلال a_t ، توکن‌های اقدام o_t و مشاهدات محیطی o_t تعریف می‌شود:

$$\tau = (r_1, a_1, o_1, r_2, a_2, o_2, \dots, r_T, a_T, o_T) \quad (۱۶۰)$$

هر بخش استدلال r_t بر کل تاریخچه پیشین شرطی می‌گردد:

$$P(r_t \mid r_1, a_1, o_1, \dots, r_{t-1}, a_{t-1}, o_{t-1}) \quad (۱۶۱)$$

نوآوری کلیدی معماری، حفظ دائمی وضعیت استدلال (Reasoning State Persistence) در طول تاریخچه مکالمه $\mathcal{H}$ است:

$$\mathcal{H}_{t+1} = \mathcal{H}_t \oplus [\text{assistant}(r_t, a_t)] \oplus [\text{tool}(o_t)] \quad (۱۶۲)$$

در صورت حذف وضعیت تفکر، بافت مکالمه به $\mathcal{H}_{t+1}^{(\text{drop})} = \mathcal{H}_t \oplus [\text{assistant}(a_t)] \oplus [\text{tool}(o_t)]$ تقلیل می‌یابد که مدل را ناچار می‌سازد فرضیات و قیود را مکرراً از ابتدا بازتولید کند. پایایی وضعیت تفکر، حلقه شناختی سه‌گانه «طرح‌ریزی، اقدام و تأمل» (Plan-Act-Reflect Loop) را ممکن ساخته و بازدهی نمونه‌برداری و خوداصلاحی را به میزان چشمگیری ارتقا می‌دهد.

فرمولاسیون تصمیم‌گیری مارکوف برای عامل‌ها (Agent MDP Formulation) فرایند تعامل عامل با محیط به صورت یک فرایند تصمیم‌گیری مارکوف $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R}, \gamma)$ مدل‌سازی می‌شود:

- **وضعیت** ($s_t \in \mathcal{S}$): شامل کلیه محتویات پنجره کانتکست در گام t (دستور مسئله، سوابق قبلی، پیام‌های سیستمی و خروجی ابزارها).
- **اقدام** ($a_t \in \mathcal{A}$): یک گام کامل تولید متن مدل زبانی شامل استدلال متنی، فراخوانی ساختاریافته توابع، یا دستورات مدیریتی.
- **انتقال وضعیت** (f_{trans}): محیط پس از اجرای اقدام، مشاهده o_t را بازگردانده و وضعیت بعدی با تابع دلخواه زیر رقم می‌خورد:

$$s_{t+1} = f_{\text{trans}}(s_t, a_t, o_t) \quad (163)$$

مرز میان سیاست π_θ و محیط دقیقاً در لایه درگاه خروجی مدل قرار دارد. بدین ترتیب مدل نیازی به درک سازوکار داخلی بازنویسی بافت متنی ندارد؛ سیاست بر جفت‌های منفرد (s_t, a_t) بهینه‌سازی شده، در حالی که تخمین مزیت و بازگشت پاداش در سطح کل اپیزود τ ارزیابی می‌گردد.

اشتقاق کامل ریاضی و تحلیل اطلاعاتی الگوریتم CISPO برای بهینه‌سازی سیاست عامل در مقیاس‌های بزرگ، الگوریتم بهینه‌سازی سیاست با نمونه‌برداری بااهمیت بریده‌شده (Clipped Importance Sampling - CISPO) [۲۱۹] به کار گرفته شده است. در ادامه، استخراج تحلیلی این بهینه‌ساز از اصول پایه‌ای حسابان، آمار و تئوری اطلاعات ارائه می‌گردد.

۱. **قضیه گرادیان خط‌مشی و ترفند نسبت درست‌نمایی (Score Function Trick):** هدف یادگیری تقویتی بیشینه‌سازی پاداش مورد انتظار تحت توزیع مسیرهای ناشی از خط‌مشی π_θ است:

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [R(\tau)] = \int P(\tau; \theta) R(\tau) d\tau \quad (164)$$

که در آن احتمال یک مسیر با طول T برابر است با:

$$P(\tau; \theta) = \rho(s_0) \prod_{t=0}^T \pi_\theta(a_t | s_t) P(s_{t+1} | s_t, a_t) \quad (165)$$

با مشتق‌گیری دیفرانسیلی نسبت به بردار پارامترها $\theta \in \mathbb{R}^d$ و استفاده از هویت مشتق لگاریتمی $\nabla_\theta P(\tau; \theta) = P(\tau; \theta) \nabla_\theta \log P(\tau; \theta)$:

$$\begin{aligned} \nabla_\theta J(\theta) &= \int \nabla_\theta P(\tau; \theta) R(\tau) d\tau \\ &= \int P(\tau; \theta) \nabla_\theta \log P(\tau; \theta) R(\tau) d\tau \\ &= \mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau; \theta) R(\tau)] \end{aligned} \quad (166)$$

با توجه به استقلال توابع انتقال محیط از پارامترهای مدل ($\nabla_\theta P(s_{t+1} | s_t, a_t) = 0$)، مشتق زنجیره‌ای چگالی مسیر به جمع گرادیان لاگ-احتمالات اقدامات تبدیل شده و با جایگزینی پاداش کل با تابع مزیت $\hat{A}(s_t, a_t)$ برای کاهش واریانس، گرادیان استاندارد خط‌مشی حاصل می‌شود:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t | s_t) \hat{A}(s_t, a_t) \right] \quad (167)$$

۲. نمونه برداری با اهمیت (Importance Sampling) و تحلیل تئوری اطلاعات: هنگام آموزش ناهمگام (Off-Policy) که در آن داده‌ها توسط خطمشی پیشین $\pi_{\theta_{old}}$ تولید شده‌اند، امید ریاضی تحت توزیع جدید با استفاده از وزن اهمیت بازنویسی می‌شود. به ازای توکن t از پاسخ o_i برای پرامپت q :

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t} | q, o_{i,<t})} \quad (۱۶۸)$$

از منظر تئوری اطلاعات، فاصله میان دو خطمشی با واگرایی کولبک-لایبیلر (KL Divergence) سنجیده می‌شود:

$$\mathbb{D}_{KL}(\pi_{\theta_{old}} || \pi_{\theta}) = -\mathbb{E}_{\pi_{\theta_{old}}} [\log r_{i,t}(\theta)] \quad (۱۶۹)$$

واریانس تخمین‌گر نمونه‌برداری با اهمیت به ممان دوم نسبت احتمال وابسته است:

$$\text{Var}_{\pi_{\theta_{old}}} [r_{i,t}(\theta) f(x)] = \mathbb{E}_{\pi_{\theta_{old}}} [(r_{i,t}(\theta))^2 f^2(x)] - (\mathbb{E}_{\pi_{\theta}} [f(x)])^2 \quad (۱۷۰)$$

هنگامی که خطمشی جدید π_{θ} دچار انحراف شود، نسبت $r_{i,t}(\theta)$ می‌تواند بی‌نهایت بزرگ شده و به انفجار واریانس گرادیان و فروپاشی آموزش در مدل‌های زبانی عظیم منتهی گردد.

۳. برش نامتقارن (Asymmetric Clipping) و عملگر توقف گرادیان (Stop-Gradient): برای برطرف کردن این ناپایداری، الگوریتم CISPO نسبت اهمیت را به صورت نامتقارن برش می‌زند:

$$\hat{r}_{i,t}(\theta) = \text{clip} \left(\frac{\pi_{\theta}(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t} | q, o_{i,<t})}, 0, 1 + \epsilon_{\text{high}}^{\text{IS}} \right) \quad (۱۷۱)$$

کران بالای $1 + \epsilon_{\text{high}}^{\text{IS}}$ از جهش‌های بزرگ خطمشی ممانعت می‌کند؛ در حالی که کران پایین صفر (برخلاف رویکرد متقارن PPO [۲۲۰]) که کران پایین را روی $1 - \epsilon$ می‌بندد) اجازه می‌دهد توکن‌ها و رفتارهایی که در خطمشی جدید رد شده‌اند، با شدت زیاد تضعیف و سرکوب شوند.

همچنین با اعمال عملگر توقف گرادیان $\text{sg}(\cdot)$ بر روی وزن اهمیت، از تشکیل مشتقات مرتبه دوم ناشی از خود نسبت وزنی جلوگیری شده و فرمول نهایی تابع هدف CISPO به دست می‌آید:

$$J_{\text{CISPO}}(\theta) = \mathbb{E}_{\substack{(q,a) \sim \mathcal{D} \\ \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(\cdot|q)}} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \text{sg}(\hat{r}_{i,t}(\theta)) \hat{A}_{i,t} \log \pi_{\theta}(o_{i,t} | q, o_{i,<t}) \right] \quad (۱۷۲)$$

که در آن G تعداد رول‌اوت‌ها به ازای هر پرسش و $|o_i|$ طول توالی است. ضریب نرمال‌سازی $\frac{1}{\sum |o_i|}$ موجب وزن‌دهی یکنواخت به ازای هر توکن و حذف سوگیری به نفع مسیرهای طولانی‌تر می‌گردد.

تخمین مزیت $\hat{A}_{i,t}$ نیز از طریق جمع پاداش تا انتها (Reward-to-Go) منهای خط پایه کاهش واریانس محاسبه می‌شود:

$$\hat{A}_{i,t} = \sum_{p=t}^T r_p - B_i, \quad G_t = \sum_{\tau=t}^T \gamma^{\tau-t} r_{\tau} \quad (۱۷۳)$$

طراحی پاداش ترکیبی و آموزش چنددامنه‌ای (Composite Reward & Mixed-Domain RL) در مسیرهای طولانی تا 192K توکن، سیگنال‌های تنک انتهای مسیر کفایت نمی‌کنند. پاداش در هر گام به صورت ترکیبی از سه مولفه تعیین می‌شود:

$$r_t = \alpha \cdot r_t^{\text{process}} + \beta \cdot r_t^{\text{speed}} + r_t^{\text{perf}} \quad (۱۷۴)$$

– **پاداش متراکم فرایند (r_t^{process}):** تشویق ساختار منظم استدلال و اعمال جریمه بر خطاهای سینتکسی در فراخوانی ابزارها یا اختلاط نامطلوب زبان‌ها.

– **پاداش سرعت اجرای وظیفه (r_t^{speed}):** تشویق مدل به موازی‌سازی اجرای ابزارها و کاهش زمان واقعی انتظار (Wall-clock Time):

$$r_t^{\text{speed}} = h\left(\frac{T_{\text{completion}}}{T_{\text{baseline}}}\right) \quad (175)$$

که در آن $h(\cdot)$ تابعی اکیداً نزولی، $T_{\text{completion}}$ زمان سپری‌شده در مسیر و T_{baseline} زمان مرجع است.

– **پاداش عملکرد (r_t^{perf}):** سیگنال عینی موفقیت در تست‌ها یا تطابق مقادیر با داده‌های مرجع.

برای جلوگیری از پدیده فراموشی فاجعه‌بار و انتقال منفی (Negative Transfer)، آموزش RL به صورت هم‌زمان بر روی چهار دامنه استدلال، کد، کارهای عاملی و گفتگو پیش می‌رود. در طول مراحل، سه بعد اصلی به صورت برنامه‌ریزی‌شده (Curriculum) تنظیم می‌شوند: نسبت آمیختگی دامنه‌ها (تمرکز نخستین بر مهارت‌های استدلالی و سپس گسترش وظایف عاملی)، افزایش تدریجی طول کانتکست، و ارتقای توزیع دشواری مسائل.

زیرساخت مقیاس‌پذیر Forge و حل مثلث ناممکن (Forge RL Infrastructure) آموزش سیستم‌های عاملی با یک چالش سه‌گانه بنیادین (Impossible Triangle) شامل **بیشینه‌سازی توان عملیاتی (Throughput)**، **پایداری بهینه‌سازی ($\mathbb{E}[\text{Var}(\nabla_{\theta} J)] < \delta$)**، و **پشتیبانی از ساختارهای دلخواه عامل ($\mathcal{A} \in \Omega_{\text{agent}}$)** مواجهه است. زیرساخت Forge با نوآوری‌های زیر این تنش‌ها را برطرف ساخته است:

– **معماری تفکیک‌شده سه‌لایه:** تفکیک لایه عامل (Agent Side) به عنوان تولیدکننده صرف مسیر، لایه میان‌افزار (Gateway Server و Data Pool) برای مسیریابی مستقل و ذخیره توزیع‌شده داده‌ها، و لایه موتورهای محاسباتی (Rollout Engine و Train Engine) جهت همگام‌سازی ناهمگام وزن‌ها.

– **پشتیبانی از عامل‌های جعبه‌سفید و جعبه‌سیاه:** عامل‌های جعبه‌سفید امکان بازسازی دقیق کانتکست و پس‌انتشار در تحولات حافظه را فراهم می‌سازند؛ در حالی که عامل‌های جعبه‌سیاه با تکیه صرف بر جریان درخواست‌های بیرونی (s_t, a_t, o_t)، بدون نیاز به دستکاری کدهای درونی، داربست‌های چندعاملی و حلقه‌های استدلال عمیق را آموزش می‌دهند.

– **زمان‌بندی پنجره‌ای (Windowed FIFO Scheduling):** زمان اجرای وظایف عاملی تنوع شدیدی دارد (از چند ثانیه تا چندین ساعت). صف‌بندی سنتی FIFO موجب انسداد صف توسط تسک‌های کند (Head-of-Line / HoL Blocking) می‌شود؛ در مقابل، صف‌بندی حریصانه منجر به هجوم نمونه‌های کوتاه و ایجاد رانش شدید توزیع داده می‌گردد. الگوریتم Windowed FIFO واکنشی داده‌ها را به یک پنجره لغزان $[T_i, T_{i+W-1}]$ با اندازه متناسب ($W = 0.3N$) محدود می‌سازد؛ درون پنجره واکنشی آزاد است (مهار HoL)، اما پیشروی پنجره منوط به مصرف کهنه‌ترین تسک‌ها در ابتدای صف است که ثبات توزیع آماری را تضمین می‌کند.

اثبات ریاضی عدم اتلاف در ادغام درخت پیشوند (Prefix Tree Merging) در تعاملات چندمرحله‌ای، نمونه‌های یک گروه دارای پیشوندهای متنی مشترک طولانی هستند. در رویکرد معمول، این بخش‌های مشترک به ازای هر نمونه مکرراً پردازش می‌شوند. سیستم Forge این ساختار را به یک درخت پیشوند تبدیل کرده و بخش مشترک را تنها یک بار در گذر پیشرو (Forward Pass) محاسبه می‌نماید.

اثبات برابری و خطای تقریب صفر بر مبنای جبر خطی: در لایه خودتوجهی چندسر (Multi-Head Attention)، برای دنباله‌ای به طول L ، ماتریس توجه با ماسک علی $M \in \mathbb{R}^{L \times L}$ محاسبه می‌شود:

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V \quad (176)$$

ماسک علی ساختار ماتریس مثلثی پایینی دارد:

$$M_{ij} = \begin{cases} 0 & j \leq i \\ -\infty & j > i \end{cases} \quad (177)$$

به دلیل این ساختار، بازنمایی فعال‌سازی پنهان برای هر موقعیت توکن k در پیشوند مشترک ($k \leq L_{\text{prefix}}$) منحصراً تابعی از بردارهای پیشین است:

$$h_k = f_{\text{attn}}(h_{\leq k}, W_Q, W_K, W_V) \quad (178)$$

این بردار h_k نسبت به توکن‌هایی که در آینده در شاخه‌های گوناگون منشعب خواهند شد، به صورت اکید مستقل است. در نتیجه:

$$\|h_{\text{tree}} - h_{\text{independent}}\| = 0 \quad (179)$$

پس از پایان گذر پیشرو، فعال‌سازی‌ها بر اساس فراداده‌های شاخه‌ها تفکیک شده و گرادیان تابع اتلاف به صورت مستقل محاسبه می‌شود. این نوآوری تا ۴۰ برابر سرعت آموزش را در بافت‌های طولانی افزایش داده و حافظه مصرفی را به حداقل می‌رساند.

بهینه‌سازی‌های شتاب‌دهی استنتاج (Inference Acceleration) به منظور تسریع فرآیند رول‌اوت در حین یادگیری تقویتی:

- **آموزش همگام ماژول‌های MTP:** ماژول‌های پیش‌بینی چندتوکنی (Multi-Token Prediction) (MTP) [۲۷] با کپی کردن وزن‌های مدل اصلی مقداردهی شده و در حین RL با اتلاف واگرایی کولبک-لایبلر (Top-K KL Loss) آموزش می‌بینند تا نرخ پذیرش توکن‌های حدسی در رمزگشایی گمانه‌زن (Speculative Decoding) [۲۶] در شرایط تغییر توزیع مدل حفظ شود.
- **جداسازی محاسباتی فازهای Prefill و Decode:** پردازش کانتکست (Prefill) و تولید توکن (Decode) به نودهای سخت‌افزاری مجزا با استراتژی‌های موازی‌سازی بهینه‌شده تفکیک شده‌اند تا تداخل زمان‌بندی در معماری MoE حذف گردد.
- **استخر سراسری L3 KV Cache:** یک کش توزیع‌شده با ساختار پیمایش عمقی (DFS-backed) که با مسیریابی آگاه از هزینه، نرخ برخورد (Cache Hit) کانتکست‌های تکراری را در طول مکالمات چندمرحله‌ای بهینه می‌سازد.

سامانه خودتکاملی و داربست‌های بازگشتی (Self-Evolution & MLE-Bench) در نسخه MiniMax M2.7، مدل وارد مرحله عملیاتی **خودتکاملی (Self-Evolution)** شده است؛ بدین معنا که مدل به صورت خودمختار در هدایت چرخه توسعه، رفع عیوب و بازآرایی زیرساخت‌های خود نقش ایفا می‌کند:

- **سامانه تکرار مدل (Model Iteration System):** این چارچوب بر اصل «انسان هدایت می‌کند، مدل می‌سازد» بنا شده است. محیط کاری عامل (Agent Harness) شامل مهارت‌های تعاملی، حافظه پایدار، گاردریل‌ها و بسترهای تست، تماماً توسط نسخه داخلی M2.7 و بدون حتی یک خط کدنویسی انسان تولید شده است.
- **چرخه کاری دوگانه تیم RL:** عامل به طور خودکار به پایش لاگ‌های آموزش، پروفایلینگ اجرای مدل و ریشه‌یابی ناهنجاری‌های یادگیری تقویتی پرداخته و با دیباگ کد و تنظیم ابرپارامترها، ۳۰٪ تا ۵۰٪ از بار کاری روزمره مهندسان RL را جذب کرده است.
- **بهینه‌سازی بازگشتی داربست‌ها:** مدل در یک آزمایش بهینه‌سازی ۱۰۰ دوره‌ای خودمختار، با تحلیل خطاها و افزودن قابلیت‌هایی نظیر تشخیص حلقه بی‌نهایت (Loop Detection) به کدهای ابزار خود، توانست کارایی داربست داخلی کدنویسی را ۳۰٪ افزایش دهد.
- **مطالعه موردی در مهندسی یادگیری ماشین (MLE-Bench Lite):** در ارزیابی جامع روی ۲۲ مسابقه واقعی یادگیری ماشین در بنچمارک MLE-Bench Lite [۲۸]، مدل تحت پنجره ۲۴ ساعته با نقد مداوم خود (Self-reflection) و ذخیره آموخته‌ها در حافظه کوتاه، توانست به **نرخ مدال ۶۶.۶۶٪** (شامل ۹ مدال طلا، ۵ نقره و ۱ برنز) دست یافته و با مدل اختصاصی Gemini 3.1 Pro برابری نماید.

نتایج ارزیابی‌های جامع و مقایسه با مدل‌های مرزی همان‌گونه که در جدول ۵۹ نشان داده شده است، مدل MiniMax-M2.7 با وجود ردپای محاسباتی کوچک (تنها ~۱۰ میلیارد پارامتر فعال در هر توکن)، در سطحی هم‌تراز با بزرگ‌ترین مدل‌های وزن‌بسته تجاری جهان رقابت می‌کند.

جدول ۵۹: عملکرد MiniMax-M2.7 در مقایسه با مدل‌های تجاری مطرح بر روی بنچمارک‌های عامل‌محور، اداری و استدلال

شاخه ارزیابی / بنچمارک	M2.7	M2.5	Opus 4.6	Sonnet 4.6	GPT 5.4	Gemini 3.1 Pro
کدنویسی و مهندسی نرم‌افزار (Coding & SWE Agents)						
SWE-bench Pro	۲.۵۶	۴.۵۵	۳.۵۷	۲.۵۷	۷.۵۷	۲.۵۴
SWE-bench Multilingual	۵.۷۶	۱.۷۴	۸.۷۷	۹.۷۵	۵.۷۰	—
Multi-SWE-bench	۷.۵۲	۳.۵۱	۳.۵۰	۰.۵۱	۰.۴۹	—
Terminal-Bench 2.0	۰.۵۷	۷.۵۱	۴.۶۵	۱.۵۹	۱.۷۵	۵.۶۸
MLE Bench Lite (Medal %)	۶.۶۶	۵.۵۱	۷.۷۵	۷.۷۲	۲.۷۱	۶.۶۶
توسعه اپلیکیشن (Application Development)						
VIBE-Pro	۶.۵۵	۲.۵۴	۶.۵۵	۱.۵۶	—	۰.۴۱
HyperTask	۶.۶۷	۴.۵۹	۷.۷۵	۱.۷۴	—	۹.۵۰
همکاری اداری و وب (Agentic Cowork & Search)						
BrowseComp	۸.۷۷	۳.۷۶	۰.۸۴	۷.۷۴	۷.۸۲	۹.۸۵
GDPval-AA	۰.۵۰	۰.۳۵	۰.۵۵	۰.۵۷	۰.۵۸	۰.۴۱
Toolathlon	۳.۴۶	۳.۳۸	۲.۴۷	۸.۴۴	۶.۵۴	۸.۴۸
MM Claw	۷.۶۲	۶.۵۷	۴.۷۵	۲.۶۴	۶.۷۳	۸.۶۱
استدلال ریاضی و دانش تخصصی (Reasoning & Knowledge)						
AIME 2026	۲.۹۴	۲.۸۷	۵.۹۲	۷.۹۲	۰.۹۷	۷.۸۸
GPQA-Diamond	۸.۸۹	۲.۸۵	۶.۸۹	۵.۸۷	۰.۹۲	۱.۹۴
IFBench	۰.۷۶	۰.۷۲	۱.۵۳	۶.۵۶	۹.۷۳	۱.۷۷

MobileLLM-Pro •

مقدمه و پارادایم پس‌آموزش (Post-Training Paradigm) مدل MobileLLM-Pro [۴۰] یک مدل زبانی بنیادی در مقیاس ۱ میلیارد پارامتر (1.08B) است که به طور خاص برای استقرار و اجرای بلادرنگ بر روی دستگاه‌های با منابع محدود محاسباتی نظیر تلفن‌های همراه و گجت‌های پوشیدنی بهینه‌سازی شده است. در مدل‌های کوچک مقیاس، مرحله پس‌آموزش (Post-Training) یا تنظیم دقیق دستورالعمل‌محور (Instruction Fine-Tuning - IFT) چالش‌های منحصربه‌فردی به همراه دارد؛ زیرا گنجایش فرضیاتی مدل (Hypothesis Space) در مقایسه با مدل‌های عظیم محدودتر بوده و تداخل گرادیان‌ها یا عدم تعادل در توزیع داده‌ها به سرعت به پدیده فراموشی فاجعه‌بار (Catastrophic Forgetting) و افت قابلیت‌های شناختی منجر می‌گردد.

مدل پایه‌ای که وارد مرحله پس‌آموزش می‌شود (MobileLLM-Pro-base)، واجد مشخصات ساختاری زیر است:

– **پیکربندی ترانسفورمر: ۳۰ لایه**، بعد پنهان $d_{\text{model}} = 1280$ ، لایه پیش‌خوران (FFN) با ضریب گسترش $4.8\times$ (بعد پنهان ۶۱۴۴)، ۲۰ سر توجه پرسمان و ۴ سر کلید-مقدار بر مبنای سازوکار توجه تجمیعی (GQA) [۳۵].

– **اشتراک‌گذاری تعبیه‌سازی‌ها (Tied Embeddings):** با هدف صرفه‌جویی در ۲۶۰ میلیون پارامتر، ماتریس تعبیه ورودی و سر پیش‌بینی خروجی با دایره واژگان کامل ۲۰۲،۰۴۸ توکنی به اشتراک گذاشته شده است [۲۲۲، ۲۲۳].

– سازوکار پنجره زمینه طولانی (128k Long-Context): پشتیبانی از پنجره ۱۲۸,۰۰۰ توکنی با مکانیزم توجه متناوب محلی-سراسری (Local-Global Attention) با نسبت ۳ به ۱، که در آن لایه‌های محلی دارای پنجره لغزان ۵۱۲ توکنی بوده و لایه‌های ابتدا (۰) و انتها (۲۹) سراسری هستند [۳۴].

در فاز پس‌آموزش، تابع زیان از تقطیر نرم توزیع لاجیت‌های مدل معلم (Forward KL Distillation) به سمت کمینه‌سازی انتروپی متقاطع تفکیکی بر روی توکن‌های پاسخ و در ادامه بهینه‌سازی مستقیم ترجیحات (DPO) با حفظ کامل پنجره ۱۲۸ هزار توکنی تغییر می‌یابد.



شکل ۹: جریان کاری سه مرحله‌ای پس‌آموزش در MobileLLM-Pro: پایه‌ریزی تنوع‌محور، هدایت با ارزیابی حذفی (LOO) و ترازسازی با DPO.

مبانی تئوری اطلاعات و فرمول‌بندی ریاضی فرآیند پس‌آموزش در درک تحلیلی آموزش مدل‌های زبانی، انتروپی متقاطع (Cross-Entropy) مستقیماً از تئوری اطلاعات شانون و واگرایی کولبک-لایبلر (KL) مشتق می‌شود. اگر توزیع احتمال تجربی توکن‌های زبان طبیعی هدف برابر با $P(y)$ و توزیع پیش‌بینی‌شده توسط مدل پارامتری θ برابر با $P_\theta(y)$ روی فضای گسسته $\mathcal{V}$ باشد، واگرایی KL میان دو توزیع به صورت زیر تعریف می‌گردد:

$$\mathbb{D}_{\text{KL}}(P \parallel P_\theta) = \sum_{y \in \mathcal{V}} P(y) \ln \left(\frac{P(y)}{P_\theta(y)} \right) = \sum_{y \in \mathcal{V}} P(y) \ln P(y) - \sum_{y \in \mathcal{V}} P(y) \ln P_\theta(y) \quad (180)$$

با توجه به اینکه انتروپی شانون توزیع هدف برابر با $H(P) = -\sum_{y \in \mathcal{V}} P(y) \ln P(y)$ است، تابع زیان انتروپی متقاطع به فرم زیر بازنویسی می‌شود:

$$\mathcal{L}_{\text{CE}}(\theta) = H(P) + \mathbb{D}_{\text{KL}}(P \parallel P_\theta) = -\sum_{y \in \mathcal{V}} P(y) \ln P_\theta(y) \quad (181)$$

در فازهای اول و دوم تنظیم دقیق تحت نظارت (SFT)، دنباله ورودی به دو بخش پرامپت $\mathbf{x} = (x_1, \dots, x_N)$ و پاسخ دستیار $\mathbf{y} = (y_1, \dots, y_M)$ تفکیک می‌شود. احتمال شرطی کل پاسخ طبق قاعده زنجیره‌ای احتمال برابر است با:

$$P_\theta(\mathbf{y} \mid \mathbf{x}) = \prod_{m=1}^M P_\theta(y_m \mid \mathbf{x}, y_{<m}) \quad (182)$$

زیان بهینه‌سازی صرفاً بر روی توکن‌های پاسخ دستیار محاسبه شده و توکن‌های پرامپت کاربر ماسک می‌شوند:

$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{m=1}^M \ln P_{\theta}(y_m | \mathbf{x}, y_{<m}) \quad (183)$$

فرض کنید بردار ویژگی لایه آخر برای توکن m -ام برابر با $\mathbf{h}_m \in \mathbb{R}^{d_{\text{model}}}$ و ماتریس وزن لایه واژگان برابر با $\mathbf{W} \in \mathbb{R}^{V \times d_{\text{model}}}$ باشد. لاجیت مولفه k -ام به صورت $z_{m,k} = \mathbf{w}_k^T \mathbf{h}_m$ و احتمال حاصل از تبدیل بیشینه هموار (Softmax) به صورت زیر محاسبه می‌شود:

$$P_{\theta}(y_m = k | \mathbf{x}, y_{<m}) = \frac{\exp(z_{m,k})}{\sum_{j=1}^V \exp(z_{m,j})} \quad (184)$$

مشتق جزئی تابع زیان تک‌توکن $\ell_m = -\ln P_{\theta}(y_m = t)$ نسبت به لاجیت دلخواه $z_{m,k}$ با اعمال قاعده زنجیره‌ای دیفرانسیل به فرم زیر استخراج می‌گردد:

$$\frac{\partial \ell_m}{\partial z_{m,k}} = P_{\theta}(y_m = k) - \mathbb{I}(k = t) \implies \frac{\partial \ell_m}{\partial \mathbf{z}_m} = \mathbf{P}_{\theta,m} - \mathbf{e}_{y_m} \quad (185)$$

که در آن $\mathbf{e}_{y_m}$ بردار پایه یکانی در موقعیت برچسب واقعی است. این رابطه نشان می‌دهد گرادیان بازگشتی خطایی معادل با اختلاف میان احتمال پیش‌بینی‌شده مدل و توزیع قطعی واقعی است.

استخراج تحلیلی الگوریتم بهینه‌سازی مستقیم ترجیحات (DPO) در فاز سوم، برای هم‌ترازی ایمنی و رفتار هویتی مدل، از الگوریتم DPO [۲۲۴] استفاده شده است. بر خلاف روش‌های سنتی RLHF مبتنی بر الگوریتم‌های بازیگر-نقاد نظیر PPO که به آموزش یک مدل پاداش مجزا و ناپایداری‌های عددی بالا وابسته‌اند، DPO مدل پاداش پنهان را مستقیماً درون خط‌مشی زبانی ادغام می‌کند. مسئله هم‌ترازی با قید تحدید واگرایی KL نسبت به مدل پایه اولیه π_{ref} به صورت تابعی زیر فرمول‌بندی می‌شود:

$$\max_{\pi} \mathbb{E}_{x \sim \mathcal{D}} [\mathbb{E}_{y \sim \pi(\cdot|x)} [r(x, y)] - \beta \mathbb{D}_{\text{KL}}(\pi(y | x) \parallel \pi_{\text{ref}}(y | x))] \quad (186)$$

به ازای هر پرامپت ثابت x ، لاگرانژین بهینه‌سازی با قید پایداری احتمالات ($\sum_y \pi(y | x) = 1$) به فرم زیر درمی‌آید:

$$\mathcal{J}(\pi) = \sum_y \pi(y | x) r(x, y) - \beta \sum_y \pi(y | x) \ln \left(\frac{\pi(y | x)}{\pi_{\text{ref}}(y | x)} \right) + \lambda \left(1 - \sum_y \pi(y | x) \right) \quad (187)$$

با مشتق‌گیری جزئی بر اساس روش حساب تغییرات نسبت به $\pi(y | x)$ و برابر قرار دادن با صفر:

$$\frac{\partial \mathcal{J}}{\partial \pi(y | x)} = r(x, y) - \beta (\ln \pi(y | x) - \ln \pi_{\text{ref}}(y | x) + 1) - \lambda = 0 \quad (188)$$

$$\ln \left(\frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} \right) = \frac{1}{\beta} r(x, y) - \frac{\beta + \lambda}{\beta} \implies \pi^*(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp \left(\frac{1}{\beta} r(x, y) \right) \quad (189)$$

که در آن $Z(x) = \sum_y \pi_{\text{ref}}(y | x) \exp \left(\frac{1}{\beta} r(x, y) \right)$ تابع تقسیم و ضریب نرمال‌سازی است.

با اعمال لگاریتم بر دو طرف رابطه و بازآرایی آن بر حسب تابع پاداش $r(x, y)$:

$$r(x, y) = \beta \ln \left(\frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} \right) + \beta \ln Z(x) \quad (190)$$

بر اساس مدل روان‌سنجی ترجیحات زوجی بردلی-تری (Bradley-Terry):

$$P(y_w \succ y_l | x) = \sigma(r(x, y_w) - r(x, y_l)) = \frac{1}{1 + \exp(-(r(x, y_w) - r(x, y_l)))} \quad (191)$$

با جای‌گذاری رابطه پاداش، جمله نامعین و پرهزینه $\beta \ln Z(x)$ به دلیل تفاضل کاملاً حذف می‌گردد:

$$r(x, y_w) - r(x, y_l) = \beta \ln \left(\frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} \right) - \beta \ln \left(\frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) = \beta \ln \left(\frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} \cdot \frac{\pi_{\text{ref}}(y_l | x)}{\pi_\theta(y_l | x)} \right) \quad (192)$$

در نتیجه، تابع هدف کمینه‌سازی DPO بر روی توزیع داده‌های ترجیحی $\mathcal{D}_{\text{pref}} = \{(x, y_w, y_l)\}$ به فرم بسته زیر حاصل می‌شود:

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}_{\text{pref}}} \left[\ln \sigma \left(\beta \ln \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \ln \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right] \quad (193)$$

با محاسبه گرادیان این زیان نسبت به پارامترهای مدل θ :

$$\nabla_\theta \mathcal{L}_{\text{DPO}}(\theta) = -\beta \mathbb{E}_{(x, y_w, y_l)} [\sigma(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w)) \cdot (\nabla_\theta \ln \pi_\theta(y_w | x) - \nabla_\theta \ln \pi_\theta(y_l | x))] \quad (194)$$

که در آن $\hat{r}_\theta(x, y) = \beta \ln \frac{\pi_\theta(y | x)}{\pi_{\text{ref}}(y | x)}$ نشان‌دهنده پاداش ضمنی مدل است. ضریب $\sigma(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w))$ به عنوان وزن تصحیح گرادیان عمل می‌کند؛ هر چه مدل پاسخ نامطلوب y_l را مطلوب‌تر بداند، گرادیان بزرگ‌تری برای افزایش درست‌نمایی y_w و کاهش درست‌نمایی y_l اعمال می‌نماید.

فاز اول: تنظیم دقیق تنوع‌محور (Diversity-First Instruction Tuning) در گام اول، تمرکز بر روی تنوع زبانی داده‌ها قرار داده شد. جدول ۶۰ آمار مجموعه داده‌های استفاده‌شده در این فاز با حجم مجموع ۶۴.۷ میلیون نمونه را نشان می‌دهد.

جدول ۶۰: آمار مجموعه داده‌های مورد استفاده در فاز اول تنظیم دقیق دستورالعمل‌ها (IFT)

نام مجموعه داده (Dataset)	تعداد نمونه‌ها (میلیون)	درصد سهم از کل (%)
[۱۴۳] Flan (2021)	۸۰.۲	۶۵.۳۶
[۲۲۵] Nemotron Math (2025)	۷۰.۲	۳۴.۳۵
[۱۶۳] Tulu 3 (2024)	۹۴.۰	۳۰.۱۲
[۲۲۵] Nemotron Code (2025)	۶۵.۰	۵۱.۸
[۲۲۵] Nemotron Science (2025)	۴۸.۰	۲۸.۶
[۲۲۵] Nemotron Chat (2025)	۰۴.۰	۵۲.۰
[۲۲۵] Nemotron Safety (2025)	۰۳.۰	۳۹.۰
مجموع کل	۶۴.۷	۱۰۰

یافته کلیدی تجربی: بیش از ۷۰٪ از حجم نمونه‌ها متعلق به دو مجموعه Flan و Nemotron Math است. آزمایش‌های نویسندگان نشان داد که تلاش برای بیش‌نمونه‌برداری (Oversampling) مصنوعی حوزه‌های کوچک‌تر (مانند Chat و Safety) در این فاز آغازین، اثرات نامطلوبی بر همگرایی مدل و قدرت تعمیم عمومی آن می‌گذارد؛ بنابراین پیروی از توزیع طبیعی منابع بهترین نتیجه را ارائه داد.

فاز دوم: تنظیم ادامه‌دار بر پایه ارزیابی حذفی (Leave-One-Out Continued Tuning) در فاز دوم، جهت تطبیق ترکیب داده‌ها با نقاط ضعف مدل، یک ارزیابی حذفی نوبتی (Leave-One-Out - LOO) روی ۷ مجموعه داده اجرا شد. مدل به ازای حذف هر حوزه (Domain) در ۷ مهارت اساسی شامل

فراخوانی ابزار (Function Calling)، پیروی از دستورات (Instruction Following)، دانش (Knowledge)، بازنویسی (Rewriting)، خلاصه‌سازی (Summarization)، استدلال منطقی (Reasoning) و ریاضیات (Math) سنجیده شد. نتایج نشان داد که حذف Tulu 3 و Nemotron Science شدیدترین پسرقت‌ها را در عملکرد چندگانه مدل به وجود می‌آورد. بر اساس این یافته، ضرایب ترکیب داده‌ها در فاز دوم مجدداً تنظیم شد تا این نواقص رفتاری به طور موثر پوشش داده شوند.

فاز سوم: ترازسازی ایمنی و هویت دستیار (Safety & Self-ID Alignment) در این فاز نهایی، ترکیبی از تنظیم دقیق نظارت‌شده (SFT) و بهینه‌سازی مستقیم ترجیحات (DPO) بر روی داده‌های ساختگی ترجیحی اعمال شد تا مدل رفتارهای ایمن، رد درخواست‌های خطرناک و پایبندی به هویت خود را فراگیرد. نویسندگان تصریح می‌کنند که برقراری دقیق این ویژگی‌ها مستلزم پرداخت «مالیات ترازسازی» (Alignment Tax) و چشم‌پوشی جزئی از صعود بر روی برخی بنچ‌مارک‌های خام آکادمیک بوده است تا مدلی امن برای عرضه واقعی حاصل شود.

تحلیل ابلیشن ترکیب داده‌ها با شبیه‌سازی آفلاین (SDM Ablation) در بخش ۱.۱۲ مقاله، اثر استراتژی اختلاط خودکار داده‌ها با رویکرد Scalable Data Mixer (SDM) [۴۳] در مقایسه با ترکیب یکنواخت داده‌ها (Uniform) در فاز تنظیم دقیق دستورات عمل‌ها ارزیابی شده است (جدول ۶۱).

جدول ۶۱: مقایسه عملکرد فاز Instruction Tuning بر مبنای ترکیب یکنواخت و ترکیب هدایت‌شده با SDM

مرحله آموزش	بودجه توکن	روش ترکیب داده‌ها	میانگین امتیاز عملکردی (%)
تنظیم دقیق دستورات عمل‌ها (IFT)	80B	یکنواخت (Uniform)	۹۴.۱۷
تنظیم دقیق دستورات عمل‌ها (IFT)	80B	بهینه‌سازی‌شده با SDM	۲۳.۴۵

این آزمایش نشان می‌دهد که بهره‌گیری از داده‌آرایی هدایت‌شده با شبیه‌سازی سودمندی در SDM، منجر به یک جهش خیره‌کننده 29.27^{**} درصدی مطلق** (ارتقای امتیاز از 94.17% به 23.45%) در عملکرد میانگین بنچ‌مارک‌های پس‌آموزش شده است.

نتایج ارزیابی بر روی بنچ‌مارک‌های استاندارد چت (Benchmark Results) عملکرد مدل دستورپذیر MobileLLM-Pro در برابر رقبای مطرح رده ۱ میلیارد پارامتر یعنی Gemma 3-1B [۱۴۶] و Llama 3.2-1B [۱۴۷] در جدول ۶۲ خلاصه شده است.

جدول ۶۲: مقایسه عملکرد مدل‌های دستورپذیر در مقیاس ۱ میلیارد پارامتر بر روی بنچ‌مارک‌های استاندارد

بنچ‌مارک (Benchmark)	شاخص متریک	MobileLLM-Pro	Gemma 3-1B	Llama 3.2-1B
MMLU (2021)	macro_avg/acc	۸.۴۴	۹.۲۹	۳.۴۹
IFEval (2023) [۲۲۶]	acc*	۰.۶۲	۲.۸۰	۵.۵۹
MBPP (2021)	pass@1	۸.۴۶	۲.۳۵	۶.۳۹
HumanEval (2021)	pass@1	۸.۵۹	۵.۴۱	۸.۳۷
ARC-Challenge (2018)	acc	۷.۶۲	—	۴.۵۹
HellaSwag (2019)	acc	۴.۵۸	—	۲.۴۱
BFCL v2 (2024) [۲۲۷]	acc	۴.۲۹	—	۷.۲۵
Open Rewrite (2023)	micro_avg/rougeL	۰.۵۱	—	۶.۴۱
TLDR9+ (2021)	rougeL	۸.۱۶	—	۸.۱۶

تحلیل نتایج: مدل MobileLLM-Pro در ۷ بنچ‌مارک از ۹ بنچ‌مارک استاندارد رتبه اول را تصاحب کرده است. برتری چشمگیر در آزمون‌های کدنویسی (HumanEval با نمره 8.59% در مقایسه با 5.41% و 8.37% رقبا) و ارتقای قاطع در فراخوانی ابزار (BFCL v2) و بازنویسی (Open Rewrite)، کارآمدی خط‌لوله طراحی‌شده پس‌آموزش را اثبات می‌نماید.

ارزیابی‌های انسانی و داوری مدل بزرگ‌تر (Human Evaluation & LLM-as-a-Judge) برای راستی‌آزمایی دقیق و مهار خطاهای ناشی از آلودگی آزمون‌ها، ارزیابی‌های کورسوی مقایسه‌ای بر روی ۱۰۰ پرامپت در چهار حوزه دستکاری انجام شد (جدول ۶۳ و ۶۴). برای وظیفه ساختاریافته فراخوانی ابزار، از مدل Llama 3-70B به عنوان داور معتبر استفاده شده است.

جدول ۶۳: ارزیابی مقایسه‌ای MobileLLM-Pro در برابر Gemma 3-1B (۱۰۰ نمونه در هر دسته)

وظیفه / دسته	برد MobileLLM-Pro	برد Gemma 3-1B	تساوی (Tie)
خلاصه‌سازی (Summarization)	۴۷	۵۱	۲
بازنویسی متون (Rewrite)	۴۵	۴۹	۶
بازیابی اطلاعات (Recall)	۴۷	۳۰	۲۳
فراخوانی ابزار (Tool Calling*)	۵۳	۲۴	۲۳

جدول ۶۴: ارزیابی مقایسه‌ای MobileLLM-Pro در برابر Llama 3.2-1B (۱۰۰ نمونه در هر دسته)

وظیفه / دسته	برد MobileLLM-Pro	برد Llama 3.2-1B	تساوی (Tie)
خلاصه‌سازی (Summarization)	۴۲	۳۰	۲۸
بازنویسی متون (Rewrite)	۵۳	۳۰	۱۶
بازیابی اطلاعات (Recall)	۵۶	۸	۳۷
فراخوانی ابزار (Tool Calling*)	۴۰	۳۵	۲۵

ارزیابی‌ها نشان‌دهنده برتری مطلق در برابر Llama 3.2-1B در تمامی زمینه‌ها (به‌ویژه برتری چشمگیر ۵۶ به ۸ در بازیابی اطلاعات) و برتری آشکار در قابلیت‌های کلیدی عاملی و دستکاری نظیر ابزارمحوری (۵۳ به ۲۴) و بازیابی نسبت به Gemma 3-1B است.

استقرار کوانتیزه‌شده بر روی سخت‌افزارهای لبه (Edge Deployment Efficiency) برای آنکه مدل حاصل از فاز پس‌آموزش بر روی دستگاه‌های تلفن همراه به صورت عملیاتی مستقر شود، از الگوریتم کوانتیزاسیون آگاه از آموزش (QAT) با بازه‌های یادگیرنده دامنه مقیاس (Learnable Quant Ranges) بر روی بستر ExecuTorch استفاده شده است. مشخصات کارایی این مدل روی پردازنده Galaxy S25 CPU و شتاب‌دهنده تنسور Galaxy S24 HTP در جدول ۶۵ گزارش شده است.

جدول ۶۵: تاخیر پیش‌پردازش (Prefill)، سرعت تولید (Decode) و حجم حافظه KV Cache در طول زمینه‌های گوناگون

شاخص کارایی (Benchmark Metric)	واحد	زمینه 2k	زمینه 4k	زمینه 8k
تاخیر پیش‌پردازش پردازنده (CPU Prefill Latency)	ثانیه	۹.۸	۸.۲۴	۵.۶۳
تاخیر پیش‌پردازش شتاب‌دهنده (HTP Prefill Latency)	ثانیه	۰.۲	۴.۳	۸.۹
سرعت رمزگشایی پردازنده (CPU Decode Speed)	توکن بر ثانیه	۶.۳۳	۸.۲۴	۷.۱۹
سرعت رمزگشایی شتاب‌دهنده (HTP Decode Speed)	توکن بر ثانیه	۶.۳۱	۰.۲۹	۸.۲۲
فضای اشغال‌شده KV Cache	مگابایت	۰.۱۴	۰.۲۳	۰.۴۰

این نتایج تجربی نشان می‌دهند که وزن‌های حاصل از متدولوژی پس‌آموزش MobileLLM-Pro نه تنها در فرمت دقیق، بلکه پس از فشردگی شدید ۴ بیتی (با افت کیفی ناچیز ۷۳٪.۰ در پردازنده و ۳٪.۱ در شتاب‌دهنده) توانمندی‌های منطقی، طول زمینه 128k و هوشمندی عامل‌محور خود را حفظ کرده و تجربه‌ای سریع و بدون وقفه را در پردازش محلی رقم می‌زنند.

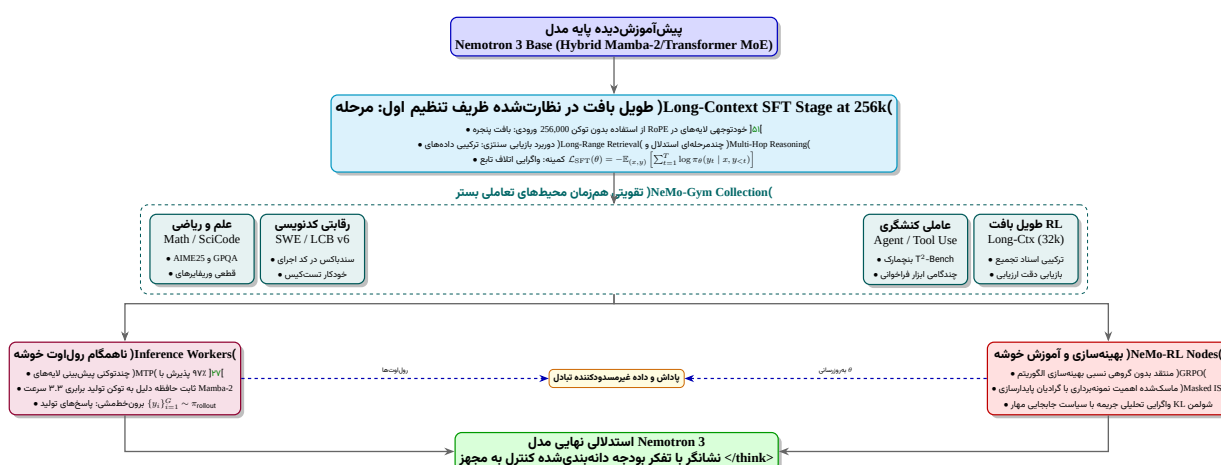
• NVIDIA Nemotron 3

مقدمه و پارادایم پس‌آموزش عاملی (Agentic Post-Training Paradigm) فاز پس‌آموزش (Post-Training) در خانواده مدل‌های NVIDIA Nemotron 3 (شامل مدل‌های Nano، Super و Ultra) بر پایه

پارادایم آموزش همزمان چندمحیطی (Simultaneous Multi-Environment RL) و بهینه‌سازی دقیق بودجه استدلال در زمان استنتاج پی‌ریزی شده است [۱۸۶]. در مدل‌های نسل پیشین نظیر Nemotron 2 [۹] یا کارهای مشابه نظیر [۱۲]، به‌کارگیری رویکردهای مرحله‌ای (Staged RL) جهت ارتقای گام‌به‌گام توانمندی‌ها، به پدیده‌های مخربی همچون فراموشی فاجعه‌بار (Catastrophic Degradation)، تداخل گرادیان‌ها و فریب پاداش (Reward Hacking) منجر می‌گردید.

در Nemotron 3، کل خط‌لوله پس‌آموزش در چهار گام منسجم یکپارچه شده است:

۱. **تنظیم دقیق نظارت‌شده برای بافت‌های کلان (Long-Context SFT):** هم‌ترازسازی مدل در پنجره بافت 256k توکن با تکیه بر داده‌های ترکیبی چندمرحله‌ای بدون نیاز به نشانگرهای موقعیتی روتاری (RoPE).
۲. **یادگیری تقویتی چندمحیطی همزمان (Simultaneous Multi-Environment RL):** بهینه‌سازی هم‌گام و موازی قابلیت‌های استدلال ریاضی، المپادی، برنامه‌نویسی، کنشگری ابزارها و درک بافت طویل در چارچوب NeMo-Gym.
۳. **بهینه‌سازی خط‌مشی گروهی با نمونه‌برداری اهمیت ماسک‌شده (Asynchronous GRPO with Masked IS):** حذف کامل شبکه نقاد (Critic) و تثبیت گرادیان‌های آف‌پالیسی در معماری نامتقارن تولید رول‌اوت.
۴. **کنترل دانه‌بندی‌شده بودجه استدلال در زمان استنتاج (Granular Reasoning Budget Control):** مدیریت پویا و بلادرنگ طول افکار مدل با تزریق نشانه توقف </think>.



شکل ۱۰: پایپ‌لاین جامع پس‌آموزش در Nemotron 3: ترکیب SFT بافت طولانی، یادگیری تقویتی چندمحیطی ناهمگام و کنترل بودجه استنتاج.

تنظیم ظریف نظارت‌شده در پنجره بافت کلان (Long-Context SFT) پیش از ورود به بهینه‌سازی تقویتی، مدل پایه تحت آموزش نظارت‌شده در طول توالی 256k توکن قرار می‌گیرد. به دلیل آنکه لایه‌های ساختاریافته Mamba-2 اطلاعات موقعیتی توکن‌ها را به‌طور ضمنی درون ماتریس حالت پنهان خود مدل‌سازی می‌کنند [۵۰]، نیازی به سیستم الحاق موقعیت دوار (RoPE) در لایه‌های توجه وجود ندارد. این امر مدل را در برابر خطاهای تعمیم طول و خروج از توزیع فرکانسی کاملاً ایمن می‌سازد [۵۱].

داده‌های آموزشی این مرحله تماماً مصنوعی و شامل سه سناریوی محوری هستند: بازیابی متون پراکنده دوربرد (Long-Range Retrieval)، استدلال چندمرحله‌ای (Multi-Hop Reasoning) و خلاصه‌سازی اسناد چندگانه.

از منظر تئوری اطلاعات، تابع هدف نظارت‌شده کمینه‌سازی واگرایی کولبک-لایبلر میان توزیع داده تجربی P_{data} و خط‌مشی پارامتریک π_{θ} است:

$$D_{KL}(P_{data} \parallel \pi_{\theta}) = \sum_{y \in \mathcal{Y}} P_{data}(y \mid x) \log \left(\frac{P_{data}(y \mid x)}{\pi_{\theta}(y \mid x)} \right) \quad (195)$$

با بسط جبری لگاریتم داریم:

$$D_{\text{KL}}(P_{\text{data}} \parallel \pi_{\theta}) = -\mathcal{H}(P_{\text{data}}) - \sum_{y \in \mathcal{Y}} P_{\text{data}}(y \mid x) \log \pi_{\theta}(y \mid x) \quad (196)$$

از آنجا که آنتروپی شانون داده‌ها ($\mathcal{H}(P_{\text{data}})$) نسبت به وزن‌های مدل θ نامتغیر است ($\nabla_{\theta} \mathcal{H} = 0$)، کمینه‌سازی واگرایی به حداکثرسازی درست‌نمایی لگاریتمی (MLE) در طول توالی منتهی می‌شود:

$$\mathcal{L}_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y) \sim \mathcal{D}_{\text{SFT}}} \left[\sum_{t=1}^T \log \pi_{\theta}(y_t \mid x, y_{<t}) \right] \quad (197)$$

یادگیری تقویتی چندمحیطی همزمان (Simultaneous Multi-Environment RL) بر خلاف رویه‌های سنتی که آموزش را به فازهای متوالی (ریاضی، سپس کدنویسی و سپس ابزارها) تقسیم می‌کردند، در Nemotron 3 تمامی محیط‌ها به صورت همزمان در قالب بسته متن‌باز NeMo-Gym آموزش داده می‌شوند. این رویکرد به مهارت‌های گرادیان‌ها و جلوگیری از پدیده فریب پاداش منجر شده و بهینه‌سازی همگن تمامی توانمندی‌ها را تضمین می‌کند.

تابع هدف چندوظیفه‌ای بر روی K محیط تعاملی به فرم زیر پیشنهاد می‌گردد:

$$\max_{\theta} \mathcal{J}_{\text{Multi-Env}}(\theta) = \sum_{k=1}^K \omega_k \mathbb{E}_{x \sim \mathcal{D}_k} [\mathbb{E}_{y \sim \pi_{\theta}(\cdot \mid x)} [R_k(x, y)]] \quad (198)$$

که در آن پاداش‌های $R_k(x, y)$ توسط بازبین‌های قطعی و محیط‌های واقعی برنامه‌نویسی و استدلال ارزیابی می‌شوند.

اثبات ریاضی قضیه گرادیان سیاست و برآوردگر مزیت گروهی (GRPO) برای اشتقاق گرادیان تابع هدف خط‌مشی $J(\theta) = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}} [R(x, y)]$ از اصول اولیه دیفرانسیل و انتگرال، ابتدا فرم انتگرالی را تشکیل می‌دهیم:

$$J(\theta) = \int_{\mathcal{X}} \mathcal{D}(x) \left(\sum_{y \in \mathcal{Y}} \pi_{\theta}(y \mid x) R(x, y) \right) dx \quad (199)$$

با اعمال عملگر مشتق در زیر نماد انتگرال بر اساس قاعده لایبنیتس:

$$\nabla_{\theta} J(\theta) = \int_{\mathcal{X}} \mathcal{D}(x) \sum_{y \in \mathcal{Y}} \nabla_{\theta} \pi_{\theta}(y \mid x) R(x, y) dx \quad (200)$$

با استفاده از شگرد مشتق لگاریتمی (Log-Derivative Trick):

$$\nabla_{\theta} \pi_{\theta}(y \mid x) = \pi_{\theta}(y \mid x) \frac{\nabla_{\theta} \pi_{\theta}(y \mid x)}{\pi_{\theta}(y \mid x)} = \pi_{\theta}(y \mid x) \nabla_{\theta} \log \pi_{\theta}(y \mid x) \quad (201)$$

لذا گرادیان به صورت امید ریاضی بازنویسی می‌شود:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(y \mid x) R(x, y)] \quad (202)$$

با تفریق یک خط مبنای مستقل از کنش $b(x)$ ، ناریب بودن گرادیان حفظ می‌شود؛ زیرا:

(203)

$$\mathbb{E}_{y \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(y \mid x) b(x)] = b(x) \sum_{y \in \mathcal{Y}} \nabla_{\theta} \pi_{\theta}(y \mid x) = b(x) \nabla_{\theta} \left(\sum_{y \in \mathcal{Y}} \pi_{\theta}(y \mid x) \right) = b(x) \nabla_{\theta}(1) = 0$$

در الگوریتم GRPO [۲۴]، جهت پرهیز از تخصیص حافظه برای شبکه سنگین نقاد (Critic)، خط مبنا از طریق میانگین‌گیری گروهی از G پاسخ نمونه‌برداری‌شده $\{y_1, \dots, y_G\}$ برای هر مسئله محاسبه می‌شود:

$$\mu_G = \frac{1}{G} \sum_{i=1}^G R(x, y_i), \quad \sigma_G = \sqrt{\frac{1}{G} \sum_{i=1}^G (R(x, y_i) - \mu_G)^2 + \epsilon} \quad (۲۰۴)$$

مقدار مزیت به‌نکارشده درون‌گروهی برای پاسخ i -ام به‌صورت زیر تعیین می‌شود:

$$\hat{A}_i = \frac{R(x, y_i) - \mu_G}{\sigma_G} \quad (۲۰۵)$$

تحلیل نظریه اطلاعات جریمه KL شولمن برای جلوگیری از فروپاشی خط‌مشی، واگرایی نسبت به مدل مرجع منجمد (π_{ref}) کنترل می‌گردد. برآوردگر ناریب شولمن [۲۲۸] برای هر توکن به‌صورت زیر تعریف می‌شود:

$$\mathbb{D}_t^{\text{KL}}(\theta) = \frac{\pi_{\text{ref}}(y_t \mid x, y_{<t})}{\pi_{\theta}(y_t \mid x, y_{<t})} - \log \left(\frac{\pi_{\text{ref}}(y_t \mid x, y_{<t})}{\pi_{\theta}(y_t \mid x, y_{<t})} \right) - 1 \quad (۲۰۶)$$

اگر نسبت دو توزیع را با متغیر اسکالر $u = \frac{\pi_{\text{ref}}}{\pi_{\theta}} > 0$ نشان دهیم، تابع تلفات $h(u) = u - \log u - 1$ دارای مشتقات زیر است:

$$h'(u) = 1 - \frac{1}{u}, \quad h''(u) = \frac{1}{u^2} > 0 \quad (۲۰۷)$$

از آنجا که مشتق دوم در سراسر دامنه اکیداً مثبت است، تابع اکیداً محدب بوده و تنها کمینه سراسری آن در $u = 1$ (انطباق کامل دو مدل) با مقدار صفر حاصل می‌شود.

نمونه‌برداری اهمیت ماسک‌شده در RL ناهمگام (Masked Importance Sampling) به‌منظور بهره‌وری حداکثری از توان پردازشی، سامانه تولید رول‌اوت از گره‌های بهینه‌سازی گرادین تفکیک شده است. در نتیجه داده‌ها با خط‌مشی با تأخیر π_{rollout} تولید می‌شوند. در فضاهای با بعد بالا، وزن اهمیت توالی کامل با انفجار واریانس روبرو می‌شود:

$$w(y) = \prod_{t=1}^T \frac{\pi_{\theta}(y_t \mid x, y_{<t})}{\pi_{\text{rollout}}(y_t \mid x, y_{<t})} \implies \lim_{T \rightarrow \infty} \text{Var}_{\pi_{\text{rollout}}}[w(y)] \rightarrow \infty \quad (۲۰۸)$$

برای مهار این ناپایداری، نسبت وزن‌ها در سطح هر توکن محاسبه شده:

$$\rho_{i,t}(\theta) = \frac{\pi_{\theta}(y_{i,t} \mid x, y_{i,<t})}{\pi_{\text{rollout}}(y_{i,t} \mid x, y_{i,<t})} \quad (۲۰۹)$$

و یک ماسک پویای باینری بر مبنای مرزهای تغییرات مجاز اعمال می‌گردد:

$$\mathcal{M}_{i,t} = \mathbb{I}(1 - \delta_{\text{low}} \leq \rho_{i,t}(\theta) \leq 1 + \delta_{\text{high}}) \quad (۲۱۰)$$

بدین ترتیب، تابع اتلاف نهایی بهینه‌سازی در چارچوب NeMo-RL به‌صورت فرم بسته زیر حاصل می‌شود:

$$\mathcal{L}_{\text{GRPO-Masked}}(\theta) = -\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \left[\mathcal{M}_{i,t} \cdot \min \left(\rho_{i,t}(\theta) \hat{A}_i, \text{clip}(\rho_{i,t}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i \right) - \beta \mathbb{D}_t^{\text{KL}}(\theta) \right] \quad (۲۱۱)$$

شتاب‌دهی رول‌اوت با معماری هیبریدی و لایه‌های MTP سرعت بالای تولید رول‌اوت‌ها در پس‌آموزش Nemotron 3 متکی بر دو نوآوری است:

- **حافظه ثابت لایه‌های Mamba-2:** برخلاف لایه‌های توجه ترنسفورمر که به نگهداری حافظه پنهان KV Cache با رشد خطی $O(T)$ نیاز دارند، لایه‌های ساختاریافته Mamba-2 از بردار وضعیت با حافظه ثابت $O(1)$ در استنتاج بهره می‌برند که سرعت تولید را تا ۳.۳ برابر مدل‌های هم‌اندازه ارتقا می‌دهد [۱۸۶].
- **لایه‌های پیش‌بینی چندتوکنی (MTP):** با پیش‌بینی موازی توکن‌های آتی در طول آموزش [۲۷]، نرخ پذیرش توکن‌های حدسی در رمزگشایی گمانه‌زن (Speculative Decoding) به ۹۷٪ می‌رسد [۲۶].

کنترل دانه‌بندی‌شده بودجه استدلال در زمان استنتاج (Budget Control) مدل‌های خانواده Nemotron 3 امکان تخصیص بودجه محاسباتی دلخواه در زمان آزمون را فراهم می‌سازند. با تنظیم سقف تعداد توکن‌های تفکر، به محض رسیدن شمارنده به سقف معین، نشانه پایانی </think> به رشته الصاق شده و خط‌مشی مدل فوراً اقدام به استخراج پاسخ نهایی بر اساس ردپای استدلال تولیدشده تا آن لحظه می‌نماید (جدول ۶۶).

جدول ۶۶: تحلیل اثر بودجه توکن تفکر بر دقت وظایف استدلالی در مدل Nemotron-3-Nano

بودجه توکن (Budget)	دقت ریاضی (AIME25)	دقت علمی (GPQA)	کدنویسی (LCB v6)	دانش عمومی (MMLU-Pro)
۲ هزار توکن (2k)	18.4%	51.2%	50.1%	69.5%
۴ هزار توکن (4k)	42.6%	58.4%	58.3%	75.8%
۸ هزار توکن (8k)	68.9%	64.5%	64.2%	78.2%
۱۶ هزار توکن (16k)	84.0%	71.0%	68.2%	78.9%
۳۲ هزار توکن (32k)	89.1% (+tools: 99.2%)	74.5%	68.5%	79.1%

زیرساخت نرم‌افزاری متن‌باز (Open-Source Ecosystem) انویدیا کل معماری پس‌آموزش این مدل را تحت پروانه آپاچی ۲.۰ (Apache 2.0) منتشر نموده است:

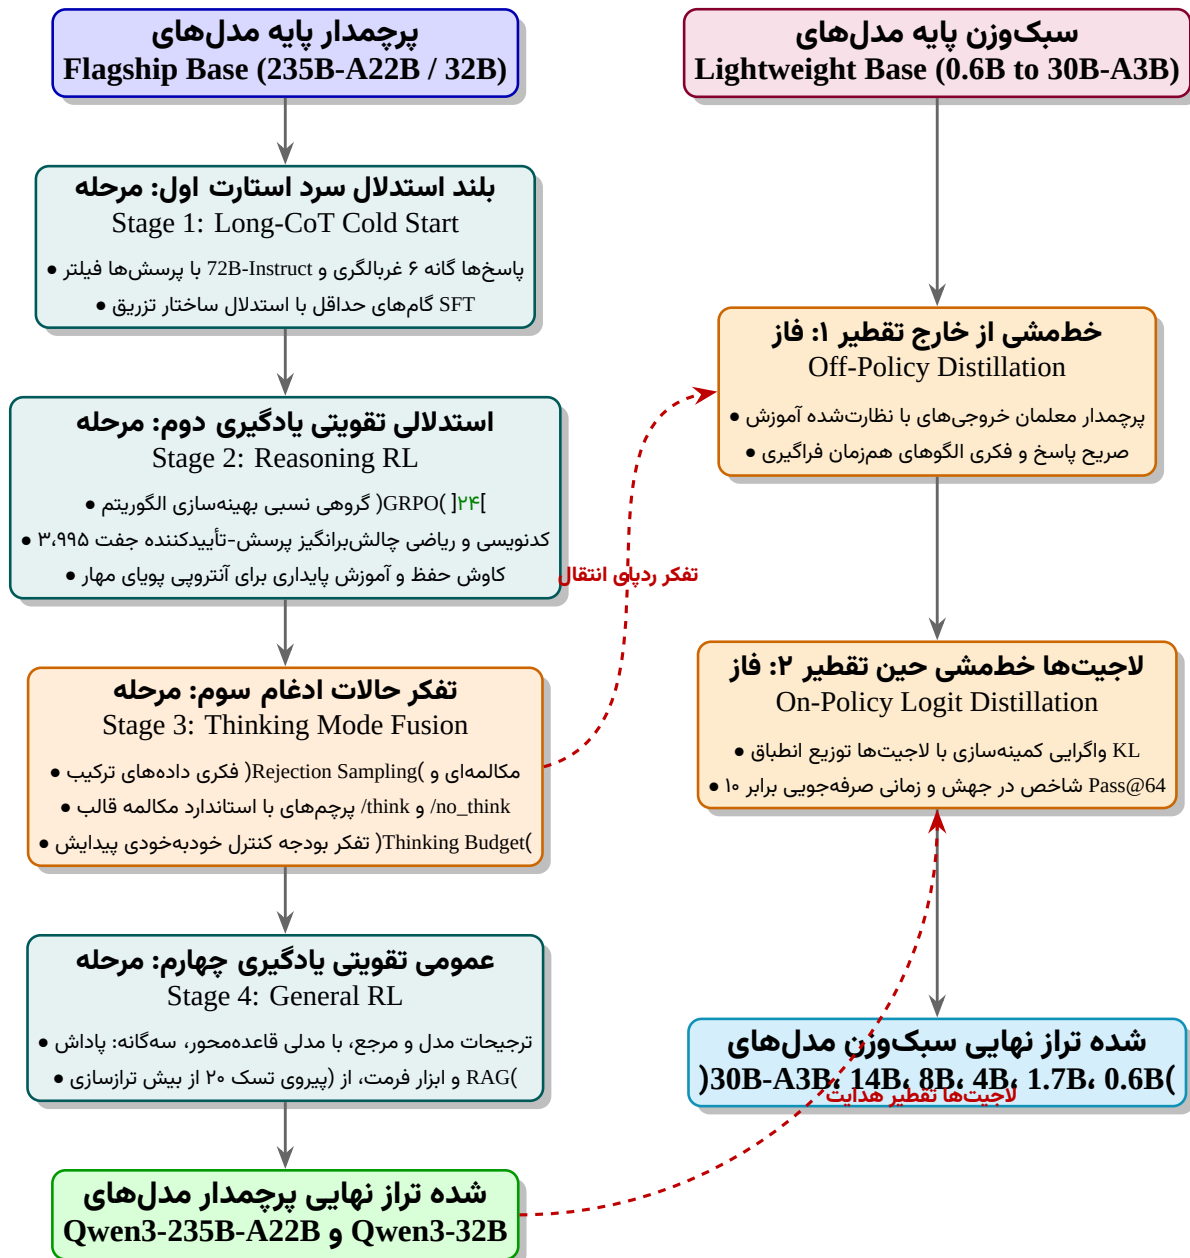
- **NeMo-RL:** چارچوب مقیاس‌پذیر بهینه‌سازی خط‌مشی با پشتیبانی بومی از فرمت‌های محاسباتی نوین NVFP4 و MXFP8 و الگوریتم‌های GRPO [۱۸۶].
- **NeMo-Gym:** جعبه‌ابزار استاندارد شامل صدها محیط تعاملی و وریفایرهای قطعی برای سنجش بلادرنگ برنامه‌ها و معادلات ریاضی [۱۸۶].

• Qwen3

مقدمه و پارادایم یکپارچه پس‌آموزش (Post-Training Paradigm) فرآیند پس‌آموزش (Post-Training) در خانواده مدل‌های Qwen3 [۲۲۹] بر پایه یک معماری تحول‌آفرین با دو هدف راهبردی بنیادین بازطراحی شده است:

۱. **کنترل یکپارچه تفکر (Thinking Control):** ادغام کامل «حالت تفکر» (Thinking Mode) برای استدلال‌های عمیق چندمرحله‌ای و «حالت عدم تفکر» (Non-thinking Mode) برای پاسخ‌های سریع و محاوره‌ای (درون یک مدل واحد، بدون نیاز به سوئیچ میان مدل‌های مجزا (نظیر جابجایی میان Qwen2.5 و QwQ [۲۳۰]).
۲. **تقطیر بهینه قوی‌به‌ضعیف (Strong-to-Weak Distillation):** ارتقای عملکرد مدل‌های سبک‌وزن با انتقال دانش توزیع لاجیت‌ها از مدل‌های پرچمدار، که ضمن کاهش ده برابری هزینه‌های محاسباتی نسبت به یادگیری تقویتی مستقیم، فضای کاوش (Exploration Space) مدل‌های کوچک‌تر را به طرز چشمگیری گسترش می‌دهد.

مدل‌های پرچمدار (Qwen3-32B و Qwen3-235B-A22B) یک فرآیند جامع چهار مرحله‌ای را طی می‌کنند، در حالی که مدل‌های سبک‌وزن (Qwen3-30B-A3B و مدل‌های چگال از 0.6B تا 14B) از طریق خط‌لوله تقطیر دانش دومرحله‌ای آموزش می‌بینند.



شکل ۱۱: جریان کاری جامع پس‌آموزش در خانواده Qwen3: تمایز راهبردی مسیر چهار مرحله‌ای مدل‌های پرچمدار و تقطیر قوی به‌ضعیف دومرحله‌ای برای مدل‌های سبک‌وزن.

مرحله اول: استارت سرد استدلال زنجیره‌ای بلند (Long-CoT Cold Start) هدف این مرحله، تزریق الگوهای تعمق و استدلال گام‌به‌گام (Chain-of-Thought - CoT) بدون محدود ساختن ظرفیت کاوش آزادانه مدل در مراحل پسین است. مجموعه داده این مرحله دامنه‌های ریاضیات، کدنویسی و مسائل علمی (STEM) را در بر می‌گیرد که دارای پاسخ نهایی قطعی هستند. پالایش داده‌ها در دو فاز انجام می‌شود:

– **فاز نخست؛ پالایش پرسش‌ها (Query Filtering):** با کمک مدل Qwen2.5-72B-Instruct پرسش‌های بدون شیوه ارزیابی خودکار، پرسش‌های چندبخشی و همچنین مسائلی که بدون نیاز به تفکر گام‌به‌گام به درستی حل می‌شوند، حذف می‌گردند تا از شکل‌گیری حدس‌های سطحی در مدل ممانعت به عمل آید.

– **فاز دوم؛ پالایش پاسخ‌ها (Response Filtering):** به ازای هر پرسش باقیمانده، تعداد N پاسخ کاندید توسط مدل QwQ-32B [۲۳] تولید می‌شود. پاسخ‌های موفق تحت غربالگری شش‌گانه سخت‌گیرانه‌ای قرار می‌گیرند تا موارد دارای جواب اشتباه، تکرار بیهوده، حدس نامعتبر، عدم تطابق میان محتوای تفکر و پاسخ نهایی، ناهماهنگی زبانی و شباهت به آزمون‌ها حذف شوند.

تعداد نمونه‌ها و گام‌های به‌روزرسانی در این مرحله در حداقل مقدار ممکن نگه داشته می‌شود تا مدل در فاز یادگیری تقویتی انعطاف کافی برای کشف مسیرهای نو را داشته باشد.

مرحله دوم: یادگیری تقویتی متمرکز بر استدلال (Reasoning RL) در این مرحله، پارامترهای مدل با تکیه بر ۳،۹۹۵ جفت «پرسش-تأییدکننده» (Query-Verifier Pairs) ارتقا می‌یابند. این جفت‌ها بر مبنای چهار معیار انتخاب شده‌اند: در فاز استارت سرد استفاده نشده باشند، برای مدل قابل یادگیری باشند، بیشترین چالش و دشواری را داشته باشند، و زیرشاخه‌های موضوعی متنوع را پوشش دهند. بهینه‌سازی پارامترها با استفاده از الگوریتم «بهینه‌سازی خط‌مشی نسبی گروهی» (Group Relative Policy Optimization - GRPO) [۲۴] صورت می‌گیرد که نیاز به مدل نقاد (Value Network) را منتفی می‌سازد.

اشتقاق کامل ریاضی و دیفرانسیلی گرادین خط‌مشی و GRPO یک توالی خروجی به صورت مسیر (q, o) در نظر گرفته می‌شود که احتمال وقوع آن تحت مدل با پارامترهای θ برابر است با:

$$P_{\theta}(o | q) = \prod_{t=1}^T \pi_{\theta}(o_t | q, o_{<t}) \quad (۲۱۲)$$

تابع هدف کلی یادگیری تقویتی مبتنی بر بهینه‌سازی امید ریاضی پاداش است:

$$J(\theta) = \mathbb{E}_{q \sim \mathcal{D}, o \sim \pi_{\theta}(\cdot | q)} [R(q, o)] = \int_{\mathcal{Q}} \mathcal{D}(q) \left[\int_{\mathcal{O}} P_{\theta}(o | q) R(q, o) do \right] dq \quad (۲۱۳)$$

با به کار بستن قاعده مشتق لگاریتمی (Log-Derivative Trick):

$$\nabla_{\theta} P_{\theta}(o | q) = P_{\theta}(o | q) \nabla_{\theta} \log P_{\theta}(o | q) \quad (۲۱۴)$$

گرادین تابع هدف به صورت زیر مشتق می‌شود:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{q, o} \left[\sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(o_t | q, o_{<t}) R(q, o) \right] \quad (۲۱۵)$$

به منظور کاهش واریانس، یک تابع خط پایه $b(q)$ تفریق می‌گردد. اثبات عدم اریب بودن این تفریق بر مبنای حساب دیفرانسیل و انتگرال به صورت زیر است:

$$\begin{aligned} \mathbb{E}_{o \sim \pi_{\theta}} [\nabla_{\theta} \log P_{\theta}(o | q) b(q)] &= \int_{\mathcal{O}} P_{\theta}(o | q) \frac{\nabla_{\theta} P_{\theta}(o | q)}{P_{\theta}(o | q)} b(q) do \\ &= b(q) \nabla_{\theta} \left(\int_{\mathcal{O}} P_{\theta}(o | q) do \right) = b(q) \nabla_{\theta}(1) = 0 \end{aligned} \quad (۲۱۶)$$

در الگوریتم GRPO، برای هر پرامپت $q \sim \mathcal{D}$ ، خط‌مشی پیشین $\pi_{\theta_{\text{old}}}$ تعداد G پاسخ کاندید $\{o_1, \dots, o_G\}$ تولید می‌کند. پاداش هر پاسخ با تابع تأییدکننده قاعده‌محور ارزیابی شده و مزیت نسبی محاسبه می‌شود:

$$\mu_q = \frac{1}{G} \sum_{i=1}^G r_i, \quad \sigma_q = \sqrt{\frac{1}{G} \sum_{i=1}^G (r_i - \mu_q)^2 + \epsilon_{\text{eps}}} \quad (۲۱۷)$$

$$\hat{A}_i = \frac{r_i - \mu_q}{\sigma_q} \quad (218)$$

با تعریف نسبت وزن‌های اهمیت توکنی به صورت $\rho_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, o_{i,<t})}$ تابع هدف نهایی بهینه‌سازی به صورت زیر درمی‌آید:

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{\substack{q \sim \mathcal{D} \\ \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \min \left(\rho_{i,t}(\theta) \hat{A}_i, \text{clip}(\rho_{i,t}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i \right) - \beta \mathbb{D}_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}}) \right] \quad (219)$$

جریمه واگرایی کولبک-لایبلر نسبت به مدل اولیه استارت سرد (π_{ref}) با تقریب ناریب شولمن [۲۳۱] محاسبه می‌شود:

$$\mathbb{D}_{\text{KL}}^{\text{approx}}(\pi_\theta \parallel \pi_{\text{ref}}) = \frac{\pi_{\text{ref}}(o_{i,t} | s)}{\pi_\theta(o_{i,t} | s)} - \log \left(\frac{\pi_{\text{ref}}(o_{i,t} | s)}{\pi_\theta(o_{i,t} | s)} \right) - 1 \quad (220)$$

تحلیل تئوری اطلاعات و مهار پویای آنتروپی شانون برای پیشگیری از فروریزش خط‌مشی (Policy Collapse)، آنتروپی شانون توزیع خروجی‌ها پایش می‌گردد:

$$H(\pi_\theta(\cdot | s_t)) = - \sum_{w \in \mathcal{V}} \pi_\theta(w | s_t) \log \pi_\theta(w | s_t) \quad (221)$$

مشتق آنتروپی نسبت به لاجیت پیش از سافت‌مکس z_k (با توجه به $\frac{\partial \pi(w_i)}{\partial z_k} = \pi(w_i)(\delta_{ik} - \pi(w_k))$) برابر است با:

$$\begin{aligned} \frac{\partial H}{\partial z_k} &= - \sum_{i \in \mathcal{V}} \left[\frac{\partial \pi(w_i)}{\partial z_k} \log \pi(w_i) + \pi(w_i) \frac{1}{\pi(w_i)} \frac{\partial \pi(w_i)}{\partial z_k} \right] \\ &= - \sum_{i \in \mathcal{V}} \pi(w_i)(\delta_{ik} - \pi(w_k)) \log \pi(w_i) - 0 \\ &= -\pi(w_k) [\log \pi(w_k) + H(\pi)] \end{aligned} \quad (222)$$

در آموزش مرحله دوم Qwen3، استراتژی به‌روزرسانی به‌گونه‌ای کنترل شد که آنتروپی خط‌مشی ثابت مانده یا صعود ملایم داشته باشد. این امر موجب شد تا امتیاز مدل پرچمدار Qwen3-235B-A22B در بنچمارک المپیادی AIME'24 در طول ۱۷۰ گام از ۱.۷۰** به ۱.۸۵** صعود کند.

مرحله سوم: ادغام حالات تفکر (Thinking Mode Fusion) در این مرحله، قابلیت‌های پاسخ سریع به مدل استدلال‌گر پیوند داده می‌شود. این فرآیند بر دو اصل استوار است:

– **تلفیق داده‌های آموزشی (SFT Data):** داده‌های تفکری از طریق نمونه‌برداری دفعی (Rejection Sampling) توسط مدل مرحله دوم تولید می‌گردند تا توانمندی استدلال دچار افت نشود. داده‌های غیرتفکری نیز گستره وسیعی از کدنویسی، خلاقیت، مکالمات و ترجمه را پوشش می‌دهند.

– **طراحی قالب مکالمه (Chat Template Design):** برای مدیریت حالات تفکر، قالب تعاملی استاندارد با پرچم‌های صریح طراحی شده است (جدول ۶۷).

رفتار پیش‌فرض مدل حالت تفکر است و در صورت عدم استفاده از پرچم /think نیز استدلال عمیق فراخوانی می‌شود. قرار دادن پرچم /no_think بلوک تفکر خالی (<think>\n</think>) تولید کرده و بلافاصله پاسخ صادر می‌گردد. در مکالمات چندنوبته با ورودی‌های گوناگون، مدل همواره بر اساس آخرین پرچم دیده‌شده عمل می‌کند.

جدول ۶۷: قالب تبادل پیام در فاز ادغام حالات تفکر Qwen3

حالت تفکر (Thinking Mode)	حالت عدم تفکر (Non-Thinking Mode)
< im_start >user	< im_start >user
{query} /think< im_end >	{query} /no_think< im_end >
< im_start >assistant	< im_start >assistant
<think>	<think>
{thinking_content}	</think>
</think>	{response}< im_end >
{response}< im_end >	

کنترل بودجه استنتاج (Thinking Budget Control) به عنوان یک توانمندی نوظهور، مدل یاد می‌گیرد بر مبنای تفکر ناتمام پاسخ معتبر تولید کند. با تعیین سقف بودجه توکن، سیستم فرآیند تفکر را متوقف ساخته و رشته پرامپت زیر را تزریق می‌کند:

Stop-Thinking Prompt Injection:

"Considering the limited time by the user, I have to give the solution based on the thinking directly now.\n</think>.\n\n"

سپس مدل فرآیند تولید را بر اساس پیش‌نویس استدلال انباشته‌شده تا همان نقطه پی می‌گیرد.

مرحله چهارم: یادگیری تقویتی عمومی (General RL) مرحله پایانی خطوله مدل‌های پرچمدار، ترازسازی رفتار بر روی بیش از ۲۰ تسک عملیاتی است:

- **پیروی از دستورات و فرمت (Instruction & Format Following):** رعایت طول پاسخ، ارائه ساختارهای JSON و تفکیک دقیق تگ‌های تفکر.
- **تراز ترجیحات (Preference Alignment):** صیقل دادن لحن، طبیعی‌سازی گفتگو و حذف ادبیات ماشینی.
- **کنشگری عاملی (Agent Ability):** آموزش استفاده پایدار از ابزارها (Tool Calling) در محیط تعاملی چندنوبته.
- **سناریوهای تخصصی (RAG):** کاهش خطا و توهم بر مبنای اسناد مرجع.

سیستم پاداش سه‌گانه (Tri-Reward Architecture) سیگنال‌های پاداش از سه منبع استخراج می‌شوند:

۱. **پاداش مبتنی بر قاعده (Rule-based):** ارزیابی قطعی فرمت و صحت پاسخ‌های ریاضی و کد در سندباکس.
۲. **پاداش مدلی با مرجع (Model-based with Ref):** داوری کیفی توسط Qwen2.5-72B-Instruct جهت جلوگیری از منفی کاذب.
۳. **پاداش مدلی ترجیحی (Preference RM):** مبتنی بر مدل‌سازی ترجیحات مقایسه‌ای طبق رابطه بردلی-تری [۲۳۲]:

$$P_{\psi}(y_w \succ y_l | x) = \sigma(r_{\psi}(x, y_w) - r_{\psi}(x, y_l)) = \frac{1}{1 + e^{-(r_{\psi}(x, y_w) - r_{\psi}(x, y_l))}} \quad (223)$$

$$\mathcal{L}_{RM}(\psi) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}_{pref}} [\log \sigma(r_{\psi}(x, y_w) - r_{\psi}(x, y_l))] \quad (224)$$

تقطیر قوی به ضعیف برای مدل‌های سبک‌وزن (Strong-to-Weak Distillation) مدل‌های سبک‌وزن (30B-A3B) و مدل‌های چگال از 0.6B تا 14B) از طریق خطلوله تقطیر دانش دومرحله‌ای آموزش می‌بینند:

– **تقطیر خارج از خط‌مشی (Off-Policy Distillation):** آموزش نظارت‌شده دانش‌آموز بر پایگاه داده خروجی‌های معلمان پرچمدار در هر دو حالت تفکر و عدم تفکر.

– **تقطیر حین خط‌مشی (On-Policy Logit Distillation):** دانش‌آموز در یکی از دو حالت نمونه‌برداری کرده و توزیع لاجیت‌های آن با کمینه‌سازی واگرایی کولبک-لایبیلر مستقیم (Forward KL) نسبت به معلمان پرچمدار (Qwen3-32B یا Qwen3-235B-A22B) هم‌تراز می‌گردد.

اشتقاق دیفرانسیلی گرادیان تقطیر لاجیت‌ها با در نظر گرفتن لاجیت‌های معلم با نماد z_i^T ، لاجیت‌های دانش‌آموز با z_i^S و دمای نرم‌سازی $\mathcal{T}$:

$$P_i^T = \frac{\exp(z_i^T/\mathcal{T})}{\sum_{k \in \mathcal{V}} \exp(z_k^T/\mathcal{T})}, \quad Q_i^T = \frac{\exp(z_i^S/\mathcal{T})}{\sum_{k \in \mathcal{V}} \exp(z_k^S/\mathcal{T})} \quad (225)$$

تابع اتلاف تقطیر لاجیت‌ها به صورت زیر تعریف می‌شود:

$$\mathcal{L}_{\text{distill}} = \mathcal{T}^2 \cdot \mathbb{D}_{\text{KL}}(P^T \parallel Q^T) = \mathcal{T}^2 \sum_{j \in \mathcal{V}} P_j^T (\log P_j^T - \log Q_j^T) \quad (226)$$

مشتق نسبت به لاجیت دانش‌آموز z_i^S با استفاده از قاعده زنجیره‌ای به فرم زیر مشتق می‌گردد:

$$\begin{aligned} \frac{\partial \mathcal{L}_{\text{distill}}}{\partial z_i^S} &= \sum_{j \in \mathcal{V}} \frac{\partial \mathcal{L}_{\text{distill}}}{\partial Q_j^T} \frac{\partial Q_j^T}{\partial z_i^S} = \sum_{j \in \mathcal{V}} \left(-\mathcal{T}^2 \frac{P_j^T}{Q_j^T} \right) \left[\frac{1}{\mathcal{T}} Q_j^T (\delta_{ji} - Q_i^T) \right] \\ &= \mathcal{T} \sum_{j \in \mathcal{V}} P_j^T (Q_i^T - \delta_{ji}) = \mathcal{T} (Q_i^T - P_i^T) \end{aligned} \quad (227)$$

گرادیان حاصله مستقیماً متناسب با تفاضل چگالی احتمالات میان معلم و دانش‌آموز است.

تحلیل تجربی بازدهی تقطیر و شاخص $\text{Pass}@k$ برای سنجش ظرفیت حل مسئله، از تخمین‌گر ناریب چن و همکاران [۲۳۳] استفاده شده است:

$$\text{Pass}@k = \mathbb{E} \left[1 - \frac{\binom{n-c}{k}}{\binom{n}{k}} \right] = 1 - \prod_{j=0}^{k-1} \frac{n-c-j}{n-j} \quad (228)$$

نتایج ارزیابی تقطیر در برابر یادگیری تقویتی مستقیم بر روی مدل Qwen3-8B در جدول ۶۸ ارائه شده است.

جدول ۶۸: مقایسه عملکرد و هزینه محاسباتی تقطیر حین خط‌مشی با یادگیری تقویتی روی مدل Qwen3-8B (اعداد داخل پرانتز نشان‌دهنده شاخص $\text{Pass}@64$ هستند)

متدولوژی	AIME'24	AIME'25	MATH500	LCB v5	MMLU-Redux	GPQA-Diam.	هزینه محاسباتی (GPUh)
تقطیر خارج از خط‌مشی	55.0 (90.0)	42.8 (83.3)	92.4	42.0	86.4	55.6	–
+ یادگیری تقویتی مستقیم	67.6 (90.0)	55.5 (83.3)	94.8	52.9	86.9	61.3	17,920
+ تقطیر حین خط‌مشی لاجیت‌ها	74.4 (93.3)	65.5 (86.7)	97.0	60.3	88.3	63.3	1,800

تقطیر حین خط‌مشی لاجیت‌ها با صرف تنها ۱/۱۰** زمان محاسباتی**، افزون بر ارتقای $\text{Pass}@1$ ، سقف کاوش مدل ($\text{Pass}@64$) را در AIME'24 به ۳.۹۳** و در AIME'25 به ۷.۸۶** رسانده است، در حالی که RL مستقیم در این زمینه هیچ بهبودی ایجاد نکرده بود.

جدول ۶۹: ارزیابی گام به گام مدل Qwen3-32B در مراحل مختلف پس آموزش (علامت * نشان دهنده آزمون های داخلی است)

حوزه ارزیابی	نام بنچمارک	مرحله ۲ (Reasoning RL)		مرحله ۳ (Mode Fusion)		مرحله ۴ (General RL)	
		حالت تفکر		بدون تفکر	حالت تفکر	بدون تفکر	حالت تفکر
وظایف عمومی	LiveBench 2024	68.6	70.9	57.1	74.9	59.8	74.9
	Arena-Hard	86.8	89.4	88.5	93.8	92.8	93.8
	CounterFactQA*	50.4	61.3	64.3	68.1	66.4	68.1
دستورات و فرمت	IFEval strict	73.0	78.4	78.4	85.0	83.2	85.0
	LengthCtrl*	62.6	70.6	84.9	73.5	87.3	73.5
	ThinkFollow*	—	88.7	—	98.9	—	98.9
عاملیت	BFCL v3	69.0	68.4	61.5	70.3	63.0	70.3
	ToolUse*	63.3	70.4	73.2	85.5	86.5	85.5
ریاضی و کد	AIME'24	83.8	81.9	28.5	81.4	31.0	81.4
	LiveCodeBench v5	68.4	67.2	31.1	65.7	31.3	65.7

سیر تکاملی مدل Qwen3-32B و مالیات ترازسازی (Alignment Tax) تکامل گام به گام مدل ۳۲ میلیاردی (جدول ۶۹) نشان دهنده ارتقای قابلیت های کنشگری در کنار یک مصالحه عملکردی است. این ارزیابی ها دو نکته اساسی را تبیین می کنند:

۱. امتیاز آزمون ThinkFollow در مرحله چهارم به 9.98^{**} ارتقا یافته که نشانگر پایداری قطعی به سوی بیچ حالات تفکر است. همچنین شاخص استفاده از ابزار (ToolUse) از 3.63 به 5.86^{**} جهش پیدا کرده است.

۲. در وظایف محاسباتی نظیر AIME'24، امتیاز حالت تفکر پس از مراحل ۳ و ۴ با افتی معادل ۴.۲ نمره روبرو شده است. این افت به عنوان مالیات ترازسازی (Alignment Tax) برای دستیابی به یک مدل همه منظوره و منعطف پذیرفته شده است.

• sda

۲ ساختار (Architecture)

۱.۲ کدگذاری موقعیت (Positional Encoding)

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

• sda

۲.۲ بردارکننده (Tokenizer)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۳.۲ شبکه عصبی (MLP)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۴.۲ تابع فعالساز (Activation Function)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۵.۲ نرمالسازی (Normalization)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۶.۲ مکانیزم توجه (Attention)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۷.۲ ساختار ترنسفورمر (Transformer)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۳ بهینه سازی (Optimization)

۱.۳ الگوریتم (Algorithm)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۲.۳ تابع هزینه (Loss Function)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۴ تنظیم هایپرپارامتر (Hyperparameter Tuning)

- sda
- sda
- sda
- sda
- sda
- sda
- sda
- sda

۵ قوانین مقیاس پذیری (Scaling Laws)

۱.۵ مقدمه

قوانین مقیاس‌پذیری (Scaling Laws) به عنوان یکی از ارکان اصلی در توسعه و درک مدل‌های زبانی بزرگ (LLMs) شناخته می‌شوند. این قوانین که در ابتدا توسط محققانی چون Kaplan و Hoffmann (قانون Chinchilla) مطرح شدند، نشان می‌دهند که عملکرد مدل‌ها با افزایش پارامترها، حجم داده‌ها و بودجه محاسباتی به صورت قابل پیش‌بینی بهبود می‌یابد. با این حال، تحقیقات اخیر نشان داده‌اند که قوانین کلاسیک دارای محدودیت‌هایی هستند؛ از جمله نادیده گرفتن هزینه‌های استنتاج (Inference)، تاثیر شکل معماری (Architecture Shape)، کیفیت داده‌ها و ساختارهای نوینی مانند «ترکیبی از خبرگان» (Mixture-of-Experts یا MoE). این بخش، با ترکیب و تحلیل ۱۹ مقاله علمی جدید، به بررسی ابعاد پنهان و توسعه‌یافته‌ی قوانین مقیاس‌پذیری می‌پردازد.

۲.۵ اصلاح و توسعه قوانین مقیاس‌پذیری کلاسیک

قوانین اولیه مانند Chinchilla فرض می‌کردند که نسبت بهینه داده به پارامتر (D/N) یک مقدار ثابت (حدود ۲۰) است. اما لی و همکاران [۲۳۴] با معرفی قانون Farseeer نشان می‌دهند که این نسبت ثابت نیست و با افزایش بودجه محاسباتی، نسبت بهینه D/N نیز افزایش می‌یابد. روش Farseeer با استفاده از برازش قطعه‌ای دیفرانسیلی (Differential Piecewise Fitting)، خطای برون‌یابی (Extrapolation Error) را نسبت به قانون Chinchilla تا ۴۳۳ درصد کاهش می‌دهد.

از سوی دیگر، چن و همکاران [۲۳۵] پدیده Sub-scaling (کاهش نرخ بهبود عملکرد) را بررسی می‌کنند. این پدیده زمانی رخ می‌دهد که مدل‌ها بیش از حد آموزش می‌بینند (Over-training) یا چگالی داده‌ها (افزونگی اطلاعات) بسیار بالا است. این مقاله یک قانون مقیاس‌پذیری زیر-بهینه (Sub-optimal) ارائه می‌دهد که نشان می‌دهد داده‌های با چگالی بالا منجر به رشد توانی (کاهش بازدهی نهایی) و داده‌های با چگالی پایین منجر به رشد خطی در عملکرد می‌شوند.

همچنین، مک‌لیش و همکاران [۲۳۶] با معرفی مجموعه Gemstones (شامل بیش از ۴۰۰۰ چک‌پوینت)، شکنندگی قوانین مقیاس‌پذیری نسبت به انتخاب‌های ابرپارامتری (مانند نرخ یادگیری و شکل مدل) را برجسته می‌کنند. آن‌ها روش Convex Hull را برای برازش قوانین پیشنهاد می‌دهند که نسبت به روش‌های پیشین بسیار مقاوم‌تر است.

۳.۵ تاثیر معماری و شکل مدل (Model Shape & Architecture)

یکی از مهم‌ترین نقایص قوانین گذشته، نادیده گرفتن تاثیر شکل مدل (نسبت عمق به عرض) و هزینه‌های استنتاج است.

- عرض در برابر عمق:** بیان و همکاران [۲۳۷] نشان می‌دهند که معماری مدل مستقیماً بر تاخیر استنتاج (Inference Latency) تاثیر می‌گذارد. مدل‌های عریض‌تر و کم‌عمق‌تر (Wider and Shallower) با بودجه پارامتری یکسان، توان عملیاتی (Throughput) بسیار بالاتری در استنتاج دارند. در همین راستا، لیو و همکاران [۲۳۸] پدیده Inverse Depth Scaling را معرفی می‌کنند؛ جایی که خطا با نسبت معکوس عمق ($1/\ell$) کاهش می‌یابد. آن‌ها دلیل این امر را میانگین‌گیری گروهی (Ensemble Averaging) لایه‌ها می‌دانند، به این معنا که لایه‌های متعدد در LLM‌ها کارهای مشابهی انجام می‌دهند و صرفاً با میانگین‌گیری، خطا را کاهش می‌دهند که نشان‌دهنده استفاده ناکارآمد از عمق است.

- تعامل عصبی (Neural Interaction):** سان و همکاران [۲۳۹] با استفاده از مفهوم Average Gradient Outer Product (AGOP)، قانون «تعامل عصبی» را مطرح می‌کنند. آن‌ها نشان می‌دهند که تعمیم‌پذیری خوب نیازمند برهم‌نهی خوش‌خیم (Benign Superposition) است؛ جایی که مدل با انرژی تعاملی پایین، سهم بالایی از حساسیت تعاملی را به دست می‌آورد. نسبت عمق به عرض ($R_{D/W}$) ابزاری برای قرار دادن مدل در این بازه بهینه است.

- **قوانین مقیاس‌پذیری طیفی (Spectral Scaling Laws):** جها و ریگن [۲۴۰] نشان می‌دهند که افزایش عرض شبکه‌های پیش‌خور (FFN) عمدتاً ظرفیت‌های کم‌انرژی (دم طیف) را گسترش می‌دهد، در حالی که زیرفضاهای غالب به سرعت اشباع می‌شوند. این قانون مقیاس‌پذیری طیفی نامتقارن نشان می‌دهد که انتخاب عرض FFN یک مبادله بین ظرفیت دم و ظرفیت حالت غالب است.
- **معماری‌های جایگزین (xLSTM و Mamba):** بک و همکاران [۲۴۱] قوانین مقیاس‌پذیری معماری xLSTM (با پیچیدگی زمانی خطی) را با ترانسفورمرها مقایسه می‌کنند. نتایج نشان می‌دهد که xLSTM در مبادله محاسبات-خطا (Compute-Loss Trade-off) بر ترانسفورمرها برتری پارتو (Pareto-dominate) دارد. همچنین، در مقاله‌ای دیگر [۲۴۲] با رویکرد تفسیرپذیری مکانیسمی، نشان داده شده است که معماری Mamba بازیابی اطلاعات (Associative Recall) را از طریق یادگیری ضمنی توابع هش خطی انجام می‌دهد و کران‌های بالایی برای اندازه واژگان و ابعاد حالت بر اساس لم Johnson-Lindenstrauss ارائه می‌دهد.

۴.۵ قوانین مقیاس‌پذیری برای مدل‌های ترکیبی از خبرگان (MoE)

مدل‌های MoE به دلیل جداسازی تعداد کل پارامترها از هزینه محاسباتی (FLOPs)، نیازمند قوانین مقیاس‌پذیری مختص به خود هستند.

- **اهرم کارایی (Efficiency Leverage):** تیان و همکاران [۲۴۳] معیار EL را برای سنجش برتری محاسباتی MoE نسبت به مدل‌های متراکم (Dense) معرفی می‌کنند. آن‌ها نشان می‌دهند که نسبت فعال‌سازی (Activation Ratio) محرک اصلی کارایی است و دانه‌بندی خبرگان (Expert Granularity) به عنوان یک تعدیل‌کننده غیرخطی عمل می‌کند.
- **مبادله پارامتر و FLOPs:** آبنار و همکاران [۲۴۴] نشان می‌دهند که برای یک بودجه محاسباتی ثابت، افزایش سطح پراکندگی (Sparsity) – یعنی داشتن پارامترهای کل بیشتر اما پارامترهای فعال کمتر – منجر به کاهش خطای آموزش می‌شود.
- **کارایی حافظه:** برخلاف تصور رایج، لودزجوسکی و همکاران [۲۴۵] ثابت می‌کنند که مدل‌های MoE می‌توانند از نظر حافظه نیز کارآمدتر از مدل‌های متراکم باشند، به شرطی که روی توکن‌های بیشتری آموزش ببینند.
- **بازیافت مدل‌ها (Upcycling):** لیو و همکاران [۲۴۶] به بررسی تبدیل مدل‌های متراکم از پیش‌آموزش‌دیده به MoE می‌پردازند. آن‌ها یک قانون مقیاس‌پذیری مشترک کشف کردند که نشان می‌دهد Upcycling تنها زمانی کارآمدتر از آموزش از صفر (From-scratch) است که هزینه اولیه (Sunk Cost - توکن‌های آموزش مدل متراکم) و اندازه مدل نسبتاً کوچک باشند.

۵.۵ نقش داده‌ها: کیفیت، ترکیب و چگالی

داده‌ها سوخت اصلی قوانین مقیاس‌پذیری هستند و کیفیت آن‌ها به اندازه کمیتشان اهمیت دارد.

- **کیفیت داده‌ها:** سوبرامانیام و همکاران [۲۴۷] یک پارامتر بدون بعد کیفیت به نام $Q \in (0, 1]$ را معرفی کرده و قانون Chinchilla را برای در نظر گرفتن کیفیت داده‌ها بسط می‌دهند. آن‌ها نشان می‌دهند که داده‌های با کیفیت بالا می‌توانند نیاز به اندازه مدل و محاسبات را به شدت کاهش دهند و اندازه موثر نمونه به صورت $D_{eff} = D \cdot Q^\gamma$ مقیاس می‌یابد.
- **ترکیب بهینه داده‌ها (Data Mixtures):** انتخاب نسبت ترکیب دامنه‌های مختلف داده معمولاً با آزمون و خطا انجام می‌شود. شوکور و همکاران [۲۴۸] روشی سیستماتیک ارائه می‌دهند که با استفاده از برازش قوانین مقیاس‌پذیری روی اجراهای مقیاس کوچک، می‌توان وزن‌های بهینه دامنه را برای آموزش مدل‌های بسیار بزرگ پیش‌بینی کرد.

- **ساختار سلسله‌مراتبی داده‌ها:** کاگنتا و همکاران [۲۴۹] با استفاده از مدل سلسله‌مراتب تصادفی (RHM)، نشان می‌دهند که شبکه‌های عصبی پیچیدگی‌های داده را لایه به لایه یاد می‌گیرند. آن‌ها ثابت می‌کنند که شبکه‌های پیچشی (CNNs) به دلیل اشتراک وزن و اتصال محلی، در یادگیری داده‌های سلسله‌مراتبی سریع‌تر از ترانسفورمرها مقیاس می‌یابند.

۶.۵ فراتر از خطای مطلق: معیارهای نوین ارزیابی

ارزیابی مدل‌ها صرفاً بر اساس خطای آنتروپی متقاطع (Cross-Entropy) تصویر کاملی از توانایی‌های مدل ارائه نمی‌دهد.

- **قوانین مقیاس‌پذیری نسبی (Relative Scaling Laws):** هلد و همکاران [۲۵۰] استدلال می‌کنند که ارزیابی‌های تجمیعی، تفاوت عملکرد در زیرگروه‌ها را پنهان می‌کند. آن‌ها قوانین نسبی را معرفی می‌کنند تا نشان دهند چگونه شکاف عملکرد بین توزیع‌ها با افزایش مقیاس تغییر می‌کند. نتایج نشان می‌دهد که مقیاس‌پذیری یک تساوی‌بخش جهانی نیست؛ در حالی که دامنه‌های علمی در MMLU به همگرایی می‌رسند، خطرات هوش مصنوعی (مانند توانایی فریکاری) با افزایش مقیاس واگرا شده و افزایش می‌یابند.

- **احتمال مبتنی بر رتبه (Relative-Based Probability):** یو و همکاران [۲۵۱] معیار RBP را معرفی می‌کنند که احتمال قرار گرفتن توکن صحیح در میان k پیش‌بینی برتر را می‌سنجد. آن‌ها نشان می‌دهند که $-\log(RBP_k)$ نیز از یک قانون توانی پیروی می‌کند. این دیدگاه پدیده ظهور توانایی‌ها (Emergence) را نه به عنوان یک جهش ناگهانی، بلکه به عنوان یک اثر ماکروسکوپی قابل پیش‌بینی از مقیاس‌پذیری میکروسکوپی هموار توضیح می‌دهد.

- **قانون چگال‌سازی (Densing Law):** در نهایت، شیائو و همکاران [۲۵۲] برای ارزیابی روند پیشرفت کارایی LLM‌ها در طول زمان، مفهوم چگالی قابلیت (Capability Density) را معرفی می‌کنند. مشاهدات تجربی آن‌ها نشان می‌دهد که حداکثر چگالی قابلیت مدل‌های متن‌باز تقریباً هر ۵.۳ ماه دو برابر می‌شود که نشان‌دهنده کاهش نمایی هزینه‌های استنتاج و نیازهای پارامتری برای رسیدن به یک سطح عملکرد ثابت است.

۷.۵ نتیجه‌گیری

بررسی جامع این مقالات نشان‌دهنده یک تغییر پارادایم در درک ما از قوانین مقیاس‌پذیری است. ما از دوران «بزرگتر بودن همیشه بهتر است» (صرفاً با افزایش پارامتر و داده) عبور کرده‌ایم. قوانین مقیاس‌پذیری نوین اکنون چندوجهی شده‌اند و باید هزینه‌های استنتاج، شکل معماری (عمق/عرض)، کیفیت و چگالی داده‌ها، ساختارهای پراکنده (MoE) و معیارهای ارزیابی نسبی را در بر بگیرند. این بینش‌های جدید به محققان و مهندسان اجازه می‌دهد تا مدل‌های زبانی آینده را نه تنها قدرتمندتر، بلکه از نظر محاسباتی، حافظه و استنتاج به مراتب کارآمدتر و هدفمندتر طراحی کنند.

۶ ارزیابی (Evaluation)

sda •

sda •

sda •

sda •

sda •

- sda •
- sda •
- sda •

۷ یادگیری تقویتی (Reinforcement Learning)

• مبانی و تئوری الگوریتم‌های مبتنی بر خط‌مشی (Policy-Based RL) (Theory)

مقدمه و انگیزه‌های بنیادین


روش‌های یادگیری تقویتی سنتی مبتنی بر ارزش (Value-Based)، نظیر Q-Learning، خط‌مشی را از طریق بیشینه‌سازی مقادیر عمل ($a = \operatorname{argmax}_a Q(s, a)$) استخراج می‌کنند. این رویکردها با چالش‌های نظری و محاسباتی متعددی روبه‌رو هستند [۲۵۳]:

– **انقطاع در خط‌مشی (Discontinuity):** تغییرات بسیار کوچک در مقادیر تقریب‌زده‌شده $Q(s, a)$ می‌تواند منجر به تغییرات ناگهانی و ناپیوسته در خط‌مشی انتخابی شود که مانع از همگرایی پایدار در فضاهای پارامتری پیوسته می‌گردد [۲۵۴].

– **فضاهای عمل پیوسته (Continuous Action Spaces):** حل مسئله بیشینه‌سازی پیوسته $\max_{a \in \mathcal{A}} Q(s, a)$ در هر گام محاسباتی، به‌ویژه با تقریب‌زننده‌های عصبی، بسیار پرهزینه است.

– **خط‌مشی‌های تصادفی بهینه (Stochastic Policies):** در محیط‌های با مشاهدات جزئی (POMDPs) و در شرایط تقریب تابع، خط‌مشی بهینه ممکن است ماهیتاً تصادفی باشد (مانند بازی‌های با اطلاعات ناقص یا راهروی کوتاه با اعمال معکوس [۲۵۳]).

الگوریتم‌های مبتنی بر خط‌مشی (Policy-Based) با پارامترسازی مستقیم خط‌مشی $\pi_\theta(a|s)$ توسط بردار پارامتر $\theta \in \mathbb{R}^d$ ، تابع هدف عملکردی $J(\theta)$ را به صورت هموار و مستقیم بهینه‌سازی می‌کنند.



قضیه گرادیان خط‌مشی (Policy Gradient Theorem)

فرآیند تصمیم‌گیری مارکوف را با توزیع اولیه ρ_0 ، پاداش کران‌دار $r(s, a)$ و ضریب تنزیل $\gamma \in [0, 1]$ در نظر می‌گیریم. تابع ارزش حالت $V^\pi(s)$ و ارزش حالت-عمل $Q^\pi(s, a)$ به صورت زیر تعریف می‌شوند:

$$V^\pi(s) \triangleq \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s \right], \quad (۲۲۹)$$

$$Q^\pi(s, a) \triangleq r(s, a) + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}(s'|s, a) V^\pi(s'). \quad (۲۳۰)$$

همچنین تابع مزیت (Advantage Function) برابر است با $A^\pi(s, a) \triangleq Q^\pi(s, a) - V^\pi(s)$. معیار عملکرد هدف برای حالت اپیزودیک برابر با $J(\theta) \triangleq V^{\pi_\theta}(s_0)$ است.

اثبات تحلیلی در حالت اپیزودیک: با مشتق‌گیری مستقیم نسبت به θ (برای سادگی نماد، $\pi \equiv \pi_\theta$):

$$\begin{aligned} \nabla V^\pi(s) &= \nabla \left[\sum_{a \in \mathcal{A}} \pi(a|s) Q^\pi(s, a) \right] \\ &= \sum_{a \in \mathcal{A}} [\nabla \pi(a|s) Q^\pi(s, a) + \pi(a|s) \nabla Q^\pi(s, a)]. \end{aligned} \quad (۲۳۱)$$

با توجه به اینکه پاداش و ماتریس انتقال محیط مستقل از θ هستند:

$$\nabla Q^\pi(s, a) = \nabla \left[r(s, a) + \gamma \sum_{s'} \mathcal{P}(s'|s, a) V^\pi(s') \right] = \gamma \sum_{s'} \mathcal{P}(s'|s, a) \nabla V^\pi(s'). \quad (۲۳۲)$$

با جایگذاری در رابطه قبل و گشودن رابطه به صورت بازگشتی روی زمان (Unrolling):

$$\begin{aligned} \nabla V^\pi(s) &= \sum_a \nabla \pi(a|s) Q^\pi(s, a) + \gamma \sum_{s'} \mathcal{P}_\pi(s'|s) \nabla V^\pi(s') \\ &= \sum_{x \in \mathcal{S}} \sum_{t=0}^{\infty} \gamma^t \Pr(s \rightarrow x, t, \pi) \sum_a \nabla \pi(a|x) Q^\pi(x, a). \end{aligned} \quad (۲۳۳)$$

با تعریف توزیع اشغال حالات تنزیل‌شده $\rho_\pi(s) \triangleq \sum_{t=0}^{\infty} \gamma^t \Pr(s_0 \rightarrow s, t, \pi)$ ، گرادیان عملکرد به دست می‌آید [۲۵۵]:

$$\nabla J(\theta) = \sum_{s \in \mathcal{S}} \rho_\pi(s) \sum_{a \in \mathcal{A}} \nabla \pi_\theta(a|s) Q^\pi(s, a) = \mathbb{E}_{s \sim \rho_\pi, a \sim \pi_\theta} [\nabla_\theta \ln \pi_\theta(a|s) Q^\pi(s, a)]. \quad (۲۳۴)$$

حالت نامتناهی با پاداش میانگین (Continuing / Average-Reward Case): برای مسائل پیوسته، عملکرد با نرخ پاداش میانگین $r(\pi) \triangleq \lim_{h \rightarrow \infty} \frac{1}{h} \sum_{t=1}^h \mathbb{E}[R_t]$ تعریف می‌شود. با تعریف تابع ارزش دیفرانسیلی $V^\pi(s) = \sum_a \pi(a|s) [r(s, a) - r(\pi) + \sum_{s'} \mathcal{P}(s'|s, a) V^\pi(s')]$ و ضرب در توزیع ایستا $\mu(s)$ ، رابطه زیر با خنثی شدن تغییرات ارزش حاصل می‌شود [۲۵۳]:

$$\nabla J(\theta) = \nabla r(\pi) = \sum_{s \in \mathcal{S}} \mu(s) \sum_{a \in \mathcal{A}} \nabla \pi_\theta(a|s) Q^\pi(s, a). \quad (۲۳۵)$$

الگوریتم REINFORCE و خط مبنا (Baseline)

الگوریتم REINFORCE [۲۵۶] از بازگشت تجربی مسیر $G_t = \sum_{k=t+1}^T \gamma^{k-t-1} R_k$ به عنوان برآوردگر ناریب $Q^\pi(S_t, A_t)$ استفاده می‌کند:

$$\theta_{t+1} = \theta_t + \alpha \gamma^t G_t \nabla_{\theta} \ln \pi_{\theta}(A_t | S_t). \quad (۲۳۶)$$

برای کاهش واریانس، یک تابع خط مبنا $b(s)$ مستقل از عمل تفریق می‌گردد. از آنجا که:

$$\sum_{a \in \mathcal{A}} \nabla \pi_{\theta}(a|s) b(s) = b(s) \nabla \sum_{a \in \mathcal{A}} \pi_{\theta}(a|s) = b(s) \nabla (1) = 0, \quad (۲۳۷)$$

تفریق خط مبنا هیچ اریبی در تخمین گرادیان ایجاد نکرده و واریانس را به شدت کاهش می‌دهد. انتخاب $b(s) = V(s)$ ضریب گرادیان را به مزیت $A(s, a)$ تبدیل می‌کند [۲۵۳].

هندسه اطلاعات و گرادیان خطمشی هموردا (Covariant Policy Search)

گرادیان استاندارد اقلیدسی به شدت وابسته به نحوه پارامترسازی است (Non-Covariant). برای تحقق استقلال از پارامترسازی، بگنل و اشنایدر [۲۵۷] منیفلد آماری توزیع کل مسیره (Path Space) را تعریف کردند:

$$P(\xi; \theta) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t | s_t) \mathcal{P}(s_{t+1} | s_t, a_t). \quad (۲۳۸)$$

طبق قضیه چنتسوف (Chentsov's Theorem)، تنها متریک ریمانی که نسبت به تبدیل‌های آماری و تعویض متغیرها ناوردا است، متریک فیشر-رائو (Fisher-Rao Metric) است [۲۵۷، ۲۵۸]:

$$G(\theta) = \mathbb{E}_{\xi \sim P(\cdot; \theta)} [\nabla_{\theta} \ln P(\xi; \theta) \nabla_{\theta} \ln P(\xi; \theta)^{\top}] = \mathbb{E}_{s \sim d_{\rho_0, \pi}} \left[\sum_{a \in \mathcal{A}} \pi_{\theta}(a|s) \nabla_{\theta} \ln \pi_{\theta}(a|s) \nabla_{\theta} \ln \pi_{\theta}(a|s)^{\top} \right].$$

جهت صعود بیشترین شیب هموردا (Natural Policy Gradient) به صورت زیر حاصل می‌شود:

$$\tilde{\nabla} J(\theta) = G(\theta)^{-1} \nabla J(\theta). \quad (۲۴۰)$$

کاکاده [۲۵۸] نشان داد که اگر تابع ارزش با تقریب‌زننده خطی سازگار (Compatible Function Approximation) $f_w(s, a) = w^{\top} \nabla_{\theta} \ln \pi_{\theta}(a|s)$ تقریب زده شود، وزن‌های بهینه کمترین مربعات دقیقاً منطبق بر گرادیان طبیعی هستند: $w^* = \tilde{\nabla} J(\theta)$.

تکرار خطمشی محافظه‌کارانه (CPI) و کران‌های بهبود

کاکاده و لنگفورد [۲۵۴] اتحاد تفاوت عملکرد (Performance Difference Lemma) را برای هر دو خطمشی دلخواه π و $\tilde{\pi}$ اثبات کردند:

$$\eta(\tilde{\pi}) - \eta(\pi) = \sum_{s \in \mathcal{S}} \rho_{\tilde{\pi}}(s) \sum_{a \in \mathcal{A}} \tilde{\pi}(a|s) A^{\pi}(s, a). \quad (۲۴۱)$$

با تقریب توزیع حالات توسط خطمشی فعلی، تقریب محلی زیر تعریف می‌شود:

$$L_{\pi}(\tilde{\pi}) \triangleq \eta(\pi) + \sum_{s \in \mathcal{S}} \rho_{\pi}(s) \sum_{a \in \mathcal{A}} \tilde{\pi}(a|s) A^{\pi}(s, a). \quad (۲۴۲)$$

در الگوریتم CPI، به‌روزرسانی خطمشی به صورت ترکیب تصادفی $\pi_{\text{new}} = (1 - \alpha)\pi + \alpha\pi'$ با سیاست حریصانه π' صورت می‌گیرد. با استفاده از نظریه جفت‌شدگی متغیرهای تصادفی (α -Coupling)، کران بهبود زیر اثبات می‌شود [۲۵۴]:

$$\eta(\pi_{\text{new}}) \geq L_{\pi}(\pi_{\text{new}}) - \frac{2\gamma\epsilon}{(1 - \gamma)^2} \alpha^2, \quad \text{where } \epsilon = \max_s |\mathbb{E}_{a \sim \pi'} [A^{\pi}(s, a)]|. \quad (۲۴۳)$$

بهینه‌سازی در ناحیه اعتماد (TRPO)

شولمن و همکاران [۲۵۹] کران بهبود CPI را با استفاده از تئوری اختلال اپراتوری به تمامی فضاهای خط‌مشی تصادفی بر حسب واگرایی تغییرات کل (D_{TV}) و واگرایی کولبک-لایبلر (D_{KL}) تعمیم دادند:

$$\eta(\pi_{\text{new}}) \geq L_{\pi_{\text{old}}}(\pi_{\text{new}}) - \frac{4\epsilon\gamma}{(1-\gamma)^2} \max_s D_{TV}(\pi_{\text{old}}(\cdot|s) \parallel \pi_{\text{new}}(\cdot|s))^2. \quad (۲۴۴)$$

با استفاده از نامساوی پینسکر ($D_{TV}^2 \leq \frac{1}{2} D_{KL}$)، مسئله بهینه‌سازی در ناحیه اعتماد (Trust Region) به فرم زیر حاصل می‌شود:

$$\max_{\theta} L_{\theta_{\text{old}}}(\theta) \quad \text{to subject} \quad \bar{D}_{KL}^{\theta_{\text{old}}}(\theta_{\text{old}}, \theta) \leq \delta. \quad (۲۴۵)$$

حل تقریبی این مسئله درجه دوم مقید توسط روش گرادیان مزدوج (Conjugate Gradient) و ضرب ماتریس فیشر-برداری (Fisher-Vector Product) به فرم زیر اجرا می‌گردد [۲۵۹]:

$$\theta_{\text{new}} = \theta_{\text{old}} + \sqrt{\frac{2\delta}{g^{\top} A^{-1} g}} A^{-1} g, \quad g = \nabla_{\theta} L_{\theta_{\text{old}}}(\theta), \quad A = \nabla_{\theta}^2 \bar{D}_{KL}. \quad (۲۴۶)$$

Algorithm 1 Trust Region Policy Optimization (TRPO)

Require: Initial policy parameters θ_0 , KL step size limit δ , line search backtrack coefficient $\zeta \in (0, 1)$

- 1: **for** $k = 0, 1, 2, \dots$ **do**
- 2: Collect trajectory rollouts $\mathcal{D}_k = \{\tau_i\}$ using policy π_{θ_k} .
- 3: Estimate advantages $\hat{A}^{\pi_{\theta_k}}(s_t, a_t)$ using GAE or state-value baseline.
- 4: Compute objective gradient: $g_k = \nabla_{\theta} L_{\theta_k}(\theta)|_{\theta=\theta_k}$.
- 5: Compute Fisher Information Matrix-vector product function $v \mapsto A_k v = \nabla_{\theta} ((\nabla_{\theta} \bar{D}_{KL})^{\top} v)$.
- 6: Solve $A_k x_k \approx g_k$ using the Conjugate Gradient algorithm.
- 7: Compute maximal step length: $\beta_k = \sqrt{2\delta / (x_k^{\top} A_k x_k)}$.
- 8: Update direction: $\Delta\theta_k = \beta_k x_k$.
- 9: Perform backtracking line search: find smallest integer $j \geq 0$ such that:
- 10: $L_{\theta_k}(\theta_k + \zeta^j \Delta\theta_k) > 0$ and $\bar{D}_{KL}(\theta_k, \theta_k + \zeta^j \Delta\theta_k) \leq \delta$.
- 11: Update parameter: $\theta_{k+1} = \theta_k + \zeta^j \Delta\theta_k$.
- 12: **end for**

تئوری فرآیندهای مارکوف منظم‌شده (Regularized MDPs)

گایست، شرر و پیتکین [۲۶۰] با معرفی عملگرهای بلمن منظم‌شده از طریق تبدیل لژاندر-فنجل (Legendre-Fenchel Conjugate)، تئوری یکپارچه‌ای برای منظم‌سازی آنتروپی و واگرایی برگمن ارائه دادند:

$$T_{\pi, \Omega} V \triangleq T_{\pi} V - \Omega(\pi) = r_{\pi} - \Omega(\pi) + \gamma P_{\pi} V, \quad (۲۴۷)$$

$$T_{*, \Omega} V \triangleq \max_{\pi \in \Delta(\mathcal{A})} T_{\pi, \Omega} V = \Omega^*(q), \quad \text{where} \quad q(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} [V(s')]. \quad (۲۴۸)$$

عملگرهای $T_{*, \Omega}$ و $T_{\pi, \Omega}$ هر دو γ -انقباض در نرم بی‌نهایت هستند. در الگوریتم فرود آینه‌ای تکرار خط‌مشی اصلاح‌شده (MD-MPI)، با جایگزینی $\Omega(\pi)$ با واگرایی برگمن $D_{\Omega}(\pi \parallel \pi_k)$ نسبت به خط‌مشی مرحله قبل:

$$\pi_{k+1} = \operatorname{argmax}_{\pi} (\langle q_k, \pi \rangle - D_{\Omega}(\pi \parallel \pi_k)). \quad (۲۴۹)$$


با استفاده از اتحاد سه‌نقطه‌ای برگمن (Three-Point Identity)، نرخ همگرایی میانگین حسرت (Regret) به فرم زیر اثبات می‌شود [۲۶۰]:

$$\frac{1}{K} \sum_{k=1}^K \|V^* - V^{\pi_k}\|_{\infty} \leq \frac{1 - \gamma^K}{(1 - \gamma)^2} \left[\frac{2\gamma \|V^* - V_0\|_{\infty} + \max_{\pi} \|D_{\Omega}(\pi \parallel \pi_0)\|_{\infty}}{K} \right] = \mathcal{O}\left(\frac{1}{K}\right). \quad (۲۵۰)$$

مقایسه ساختاریافته الگوریتم‌های تکرار خطمشی تقریبی

شرر [۲۶۱] چهار خانواده الگوریتم‌های تکرار خطمشی تقریبی را از منظر ضرایب تمرکزپذیری (Concen- trability Coefficients) مقایسه کرده است:

- $C_{\pi^*} \triangleq \left\| \frac{d_{\mu, \pi^*}}{\nu} \right\|_{\infty}$ (تنها توزیع خطمشی بهینه π^* را می‌سنجد و بهترین ضریب است).
- $C^{(1,0)} \triangleq (1 - \gamma) \sum_{i=0}^{\infty} \gamma^i \sup_{\pi_1, \dots, \pi_i} \left\| \frac{\mu P_{\pi_1} \dots P_{\pi_i}}{\nu} \right\|_{\infty}$.
- $C^{(2,1,0)}$ بدترین ضریب است که خطاهای تمام خطمشی‌ها را در بدترین حالت ترکیب می‌کند.



جدول ۷۰: مقایسه مشخصه‌های نظری الگوریتم‌های تکرار خطمشی تقریبی [۲۶۱]

الگوریتم	کران خطای عملکرد $(\mu(V^* - V^{\pi_k}))$	تعداد تکرارها	پیچیدگی حافظه	نوع خطمشی
API	$\frac{C^{(2,1,0)}}{(1-\gamma)^2} \epsilon$	$\mathcal{O}\left(\frac{1}{1-\gamma} \ln \frac{1}{\epsilon}\right)$	$\mathcal{O}(1)$	ایستا و قطعی
CPI	$\frac{C_{\pi^*}}{(1-\gamma)^2} \epsilon$	$\mathcal{O}\left(\frac{1}{\epsilon^2}\right)$	$\mathcal{O}\left(\frac{1}{\epsilon^2}\right)$	ایستا و تصادفی (مخلوط)
PSDP $_{\infty}$	$\frac{C_{\pi^*}}{(1-\gamma)^2} \epsilon \ln \frac{1}{\epsilon}$	$\mathcal{O}\left(\frac{1}{1-\gamma} \ln \frac{1}{\epsilon}\right)$	$\mathcal{O}\left(\frac{1}{1-\gamma} \ln \frac{1}{\epsilon}\right)$	غیرایستا (حلقه‌ای)
NSPI(m)	$\left(C_{\pi^*} + \frac{\gamma^m C^{(2,m,0)}}{m(1-\gamma^m)}\right) \frac{\epsilon \ln(1/\epsilon)}{(1-\gamma)^2}$	$\mathcal{O}\left(\frac{1}{1-\gamma} \ln \frac{1}{\epsilon}\right)$	$\mathcal{O}(m)$	m -دوره‌ای غیرایستا

همان‌طور که در جدول مشاهده می‌شود، الگوریتم PSDP $_{\infty}$ بهترین ویژگی‌های هر دو روش API (همگرایی سریع لگاریتمی) و CPI (ضریب تمرکزپذیری بهینه C_{π^*}) را ترکیب می‌کند. الگوریتم NSPI(m) نیز با معرفی حافظه با اندازه ثابت m ، خطای ناشی از تقریب را با ضریب هندسی کاهشی γ^m کنترل کرده و تعادل کاملی میان مصرف حافظه و کیفیت عملکرد برقرار می‌سازد [۲۶۱، ۲۶۲].

۱.۷ الگوریتم بهینه‌سازی تقریبی خطمشی (Proximal Policy Optimization - PPO)

الگوریتم PPO که توسط جان شولمن (John Schulman) و همکارانش در سال ۲۰۱۷ در OpenAI معرفی شد [۲۶۳]، یکی از برجسته‌ترین، پایدارترین و پرکاربردترین الگوریتم‌های حوزه یادگیری تقویتی عمیق (Deep Reinforcement Learning) به شمار می‌رود. این الگوریتم با حل چالش‌های بنیادین بهینه‌سازی در روش‌های پیشین، تعادلی بهینه میان سادگی پیاده‌سازی، کارایی محاسباتی، بهره‌وری نمونه (Sample Efficiency) و پایداری همگرایی برقرار ساخته است.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

پیش از ابداع PPO، روش‌های یادگیری تقویتی عمیق به سه دسته عمده با محدودیت‌های ساختاری تقسیم می‌شدند:

– **روش‌های مبتنی بر ارزش (Value-Based Methods):** شاخص‌ترین الگوریتم این دسته، DQN [۲۶۴] است. این روش‌ها گرچه در فضاهای عمل گسسته و محیط بازی‌های آتاری [۲۶۵] موفق ظاهر شدند، اما امکان تعمیم کارآمد به فضاهای عمل پیوسته (Continuous Action Spaces) با ابعاد بالا در رباتیک [۲۶۶، ۲۶۷] را نداشتند، چرا که یافتن $\arg \max_a Q(s, a)$ در هر گام نیازمند بهینه‌سازی غیرخطی زمان‌بر است. همچنین این روش‌ها از ناپایداری‌های ناشی از تقریب تابع و یادگیری خارج از خط‌مشی رنج می‌برند.

– **روش‌های گرادیان خط‌مشی استاندارد (Vanilla Policy Gradient):** روش‌هایی نظیر REINFORCE [۲۵۶] و A2C/A3C [۲۶۸] مستقیماً پارامترهای خط‌مشی را بهینه‌سازی می‌کنند. با این حال، به دلیل وابستگی گرادیان به توزیع داده‌های جمع‌آوری‌شده، مجاز به اجرای تنها یک گام گرادیان به ازای هر نمونه داده بودند. انجام چندین گام بهینه‌سازی (Multiple Epochs) روی داده‌های یکسان، منجر به جابجایی شدید خط‌مشی جدید نسبت به خط‌مشی قدیم و در نتیجه سقوط فاجعه‌بار کارایی (Catastrophic Policy Collapse) می‌شد؛ امری که باعث ناکارآمدی شدید در تعداد نمونه‌ها (Sample Inefficiency) بود.

– **روش‌های بهینه‌سازی در ناحیه اطمینان (Trust Region Methods):** کاکاده و لنگفورد [۲۵۴] و سپس شولمن و همکاران با معرفی الگوریتم TRPO [۲۵۹] نشان دادند که با مقید ساختن تغییرات خط‌مشی از طریق واگرایی کولبک-لایبلر (KL-Divergence)، می‌توان بهبود یکنواخت کارایی (Monotonic Improvement) را تضمین کرد. با این وجود، TRPO به محاسبات مرتبه دوم ماتریس اطلاعات فیشر (Fisher Information Matrix)، ماتریس هسین و حل با الگوریتم گرادیان مزدوج (Conjugate Gradient) نیازمند بود. این امر نه تنها پیچیدگی محاسباتی بالایی ایجاد می‌کرد، بلکه با معماری‌های دارای لایه‌های مشترک میان خط‌مشی و ارزش و تکنیک‌های نویزدار مانند Dropout ناسازگار بود.

هدف بنیادین PPO، دستیابی به ثبات، قابلیت اطمینان و نرخ همگرایی بالای TRPO، صرفاً با تکیه بر بهینه‌سازهای مشتق اول (First-Order Optimizers) نظیر بهینه‌ساز Adam [۲۶۹] و با سادگی پیاده‌سازی بالا است.

مبانی نظری و اشتقاق‌های کامل ریاضی

یک فرآیند تصمیم‌گیری مارکوف (MDP) با چندتایی متناهی یا نامتناهی $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, r, \gamma, \rho_0)$ مدل‌سازی می‌شود که در آن $\mathcal{S}$ فضای حالات، $\mathcal{A}$ فضای اعمال، $\mathcal{P}(s'|s, a)$ تابع احتمال انتقال، $r(s, a)$ تابع پاداش، $\gamma \in [0, 1]$ ضریب تخفیف پاداش و $\rho_0(s_0)$ توزیع حالت اولیه است.

توزیع یک مسیر (Trajectory) $\tau = (s_0, a_0, s_1, a_1, \dots, s_T)$ تحت خط‌مشی تصادفی پارامتریزه شده $\pi_\theta(a|s)$ برابر است با:

$$P(\tau; \theta) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t|s_t) \mathcal{P}(s_{t+1}|s_t, a_t) \quad (۲۵۱)$$

هدف بهینه‌سازی، بیشینه‌سازی امید ریاضی بازده کل است:

$$J(\theta) = \mathbb{E}_{\tau \sim P(\cdot; \theta)}[R(\tau)] = \int_{\tau} P(\tau; \theta) R(\tau) d\tau \quad (۲۵۲)$$

که در آن $R(\tau) = \sum_{t=0}^T \gamma^t r(s_t, a_t)$ است. با اعمال عملگر گرادیان و استفاده از قاعده مشتق لگاریتمی $(\nabla_{\theta} P = P \nabla_{\theta} \log P)$:

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \nabla_{\theta} \int P(\tau; \theta) R(\tau) d\tau = \int \nabla_{\theta} P(\tau; \theta) R(\tau) d\tau \\ &= \int P(\tau; \theta) \nabla_{\theta} \log P(\tau; \theta) R(\tau) d\tau = \mathbb{E}_{\tau \sim \pi_{\theta}} [\nabla_{\theta} \log P(\tau; \theta) R(\tau)] \end{aligned} \quad (۲۵۳)$$

از آنجا که جملات انتقال وضعیت محیط $\mathcal{P}$ به پارامتر θ وابسته نیستند، داریم $\nabla_{\theta} \log P(\tau; \theta) = \sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$. با بهره‌گیری از اصل علیت و کسر خط مبنای مستقل از عمل $b(s_t) = V(s_t)$ جهت کاهش واریانس، قضیه گرادیان خطمشی حاصل می‌شود:

$$\hat{g} = \hat{\mathbb{E}}_t [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \hat{A}_t] \quad (۲۵۴)$$

که در آن $\hat{A}_t = Q(s_t, a_t) - V(s_t)$ برآوردگر تابع مزیت (Advantage Function) است. با استفاده از مفهوم نمونه‌برداری ترجیحی (Importance Sampling)، هدف خطمشی برای داده‌های جمع‌آوری‌شده توسط $\pi_{\theta_{\text{old}}}$ به صورت تابع هدف جایگزین تکرار خطمشی محافظه‌کارانه (CPI) [۲۵۴] تعریف می‌شود:

$$L^{CPI}(\theta) = \hat{\mathbb{E}}_t \left[\frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)} \hat{A}_t \right] = \hat{\mathbb{E}}_t [r_t(\theta) \hat{A}_t] \quad (۲۵۵)$$

که در آن نسبت احتمالات $r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}$ بوده و $r_t(\theta_{\text{old}}) = 1$ است.

توابع هدف در الگوریتم PPO

الگوریتم PPO دو فرمول‌بندی برای محدود ساختن تغییرات گام خطمشی ارائه می‌دهد:

۱. **تابع هدف با برش جایگزین (Clipped Surrogate Objective):** رویکرد اصلی و پیشنهادی مقاله، استفاده از تابع هدف زیر است:

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (۲۵۶)$$

که در آن ϵ یک ابرپارامتر (معمولاً 0.2) است. این تابع هدف یک کران پایین بدبینانه (Pessimistic Lower Bound) را تشکیل می‌دهد:

– **در شرایط مزیت مثبت ($\hat{A}_t > 0$):** اگر عمل انجام‌شده بهتر از حد انتظار باشد، افزایش احتمال آن مفید است؛ اما به محض اینکه نسبت احتمال از $1 + \epsilon$ فراتر رود، گرادیان صفر شده و از تغییرات مفرط جلوگیری می‌کند.

– **در شرایط مزیت منفی ($\hat{A}_t < 0$):** اگر عمل بدتر از حد انتظار باشد، احتمال آن باید کاهش یابد؛ اگر نسبت احتمال از $1 - \epsilon$ کمتر شود، مقدار بریده شده و گرادیان صفر می‌شود. اما اگر خطمشی اشتباهاً احتمال این عمل بد را افزایش دهد ($r_t \gg 1$)، مقدار بدون برش انتخاب شده و جریمه کامل به خطمشی اعمال می‌شود.

۲. **تابع هدف با ضریب جریمه تطبیقی (Adaptive KL Penalty):** به عنوان رویکرد جایگزین، جریمه واگرایی KL مستقیماً در تابع هدف لحاظ شده و ضریب β به صورت دینامیک به‌روزرسانی می‌شود:

$$L^{\text{KL PEN}}(\theta) = \hat{\mathbb{E}}_t \left[r_t(\theta) \hat{A}_t - \beta D_{\text{KL}}(\pi_{\theta_{\text{old}}}(\cdot | s_t) \parallel \pi_{\theta}(\cdot | s_t)) \right] \quad (۲۵۷)$$

در هر تکرار، پس از محاسبه $d = \hat{\mathbb{E}}_t [D_{\text{KL}}(\pi_{\theta_{\text{old}}} \parallel \pi_{\theta})]$ ، ضریب جریمه به این صورت تطبیق می‌یابد:

$$\beta \leftarrow \begin{cases} \beta/2 & \text{if } d < d_{\text{targ}}/1.5 \\ \beta \times 2 & \text{if } d > d_{\text{targ}} \times 1.5 \end{cases} \quad (۲۵۸)$$

برآوردگر مزیت تعمیم‌یافته (GAE) و تابع هزینه یکپارچه

برای کاهش واریانس، از برآوردگر مزیت تعمیم‌یافته (GAE) منقطع [۲۷۰] استفاده می‌شود:

$$\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}^V \quad \text{where} \quad \delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t) \quad (259)$$

برای شبکه‌های دارای پارامترهای مشترک میان خط‌مشی و تابع ارزش، تابع هزینه سراسری بهینه‌سازی زیر پیشنهاد می‌گردد:

$$L_t^{\text{CLIP+VF+S}}(\theta) = \mathbb{E}_t \left[L_t^{\text{CLIP}}(\theta) - c_1 \left(V_\theta(s_t) - V_t^{\text{targ}} \right)^2 + c_2 S[\pi_\theta](s_t) \right] \quad (260)$$

که در آن $S[\pi_\theta]$ آنتروپی شانون برای تشویق به اکتشاف (Exploration) و c_1, c_2 ضرایب وزنی هستند.

تحلیل‌های تئوری اطلاعات و آمار

بر اساس بسط تیلور مرتبه دوم واگرایی KL حول نقطه θ_{old} داریم:

$$D_{\text{KL}}(\pi_{\theta_{\text{old}}} \parallel \pi_\theta) \approx \frac{1}{2}(\theta - \theta_{\text{old}})^T F(\theta - \theta_{\text{old}}) \quad (261)$$


که در آن $F = \mathbb{E}[\nabla_\theta \log \pi_\theta \nabla_\theta \log \pi_\theta^T]$ ماتریس اطلاعات فیشر است. تابع برش در PPO تضمین می‌کند که فاصله روی منیفلد ریمانی توزیع‌ها بدون نیاز به تشکیل و معکوس کردن صریح ماتریس F در محدوده‌ای امن محبوس بماند. همچنین با محدود کردن $r_t(\theta) \in [1 - \epsilon, 1 + \epsilon]$ واریانس بازوزن‌دهی نمونه‌برداری ترجیحی ($\text{Var}_Q[P/Q \cdot f]$) کنترل شده و از انفجار واریانس در بهینه‌سازی چند دوره‌ای جلوگیری می‌شود.

دیگرام معماری و جریان داده‌های الگوریتم

شکل ۱۲، ساختار تعامل با محیط، محاسبه مزیت، تشکیل توابع هدف و چرخه به‌روزرسانی چند دوره‌ای در الگوریتم PPO را نشان می‌دهد.

شبکه‌کد الگوریتم PPO

شبکه‌کد استاندارد ساختار Actor-Critic الگوریتم PPO در الگوریتم ۲ آورده شده است:



شکل ۱۲: دیاگرام جامع جریان داده‌ها، محاسبه مزیت و بهینه‌سازی چند دوره‌ای در الگوریتم PPO.

Algorithm 2 Proximal Policy Optimization (PPO), Actor-Critic Style

```

1: Input: Initial policy parameters  $\theta_0$ , initial value function parameters  $\phi_0$ , clipping threshold  $\epsilon$ ,
   GAE parameters  $\gamma, \lambda$ , epoch count  $K$ , minibatch size  $M$ , coefficients  $c_1, c_2$ .
2: for iteration = 1, 2, ... do
3:   for actor = 1, ...,  $N$  do
4:     Run policy  $\pi_{\theta_{\text{old}}}$  in environment for  $T$  timesteps.
5:     Compute predictions  $V_\phi(s_t)$  and log-probabilities  $\log \pi_{\theta_{\text{old}}}(a_t|s_t)$ .
6:     Compute TD residuals:  $\delta_t^V = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$ .
7:     Compute GAE estimates:  $\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}^V$ .
8:     Compute state-value targets:  $V_t^{\text{targ}} = \hat{A}_t + V_\phi(s_t)$ .
9:   end for
10:  Collect all  $NT$  transitions:  $\mathcal{D} = \{(s_t, a_t, r_t, \log \pi_{\theta_{\text{old}}}(a_t|s_t), \hat{A}_t, V_t^{\text{targ}})\}$ .
11:  Normalize advantage values:  $\hat{A}_t \leftarrow \frac{\hat{A}_t - \mu(\hat{A})}{\sigma(\hat{A}) + 10^{-8}}$ .
12:  for epoch = 1, ...,  $K$  do
13:    Shuffle dataset  $\mathcal{D}$  and partition into minibatches of size  $M$ .
14:    for each minibatch  $\mathcal{B} \subset \mathcal{D}$  do
15:      Compute probability ratio:  $r_t(\theta) = \exp(\log \pi_\theta(a_t|s_t) - \log \pi_{\theta_{\text{old}}}(a_t|s_t))$ .
16:      Compute policy surrogate loss:
17:       $L^{\text{CLIP}}(\theta) = \frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} \min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)$ .
18:      Compute value function squared error loss:
19:       $L^{\text{VF}}(\phi) = \frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} (V_\phi(s_t) - V_t^{\text{targ}})^2$ .
20:      Compute entropy bonus:  $S[\pi_\theta] = \frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} \mathbb{H}(\pi_\theta(\cdot|s_t))$ .
21:      Maximize total objective using Adam:
22:       $\theta, \phi \leftarrow \text{Adam}(\nabla_{\theta, \phi} [L^{\text{CLIP}}(\theta) - c_1 L^{\text{VF}}(\phi) + c_2 S[\pi_\theta]])$ .
23:    end for
24:  end for
25:   $\theta_{\text{old}} \leftarrow \theta$ 
26: end for

```

نتایج تجربی و ارزیابی بنچمارک‌ها

کارایی PPO در مقایسه با انواع روش‌های بهینه‌سازی در جدول ۷۱ و روی بازی‌های آتاری در جدول ۷۲ خلاصه شده است:

ابزارهای استاندارد گزارش‌شده در مقاله

جداول ۷۳ و ۷۴ مقادیر دقیق ابزارهای بهینه‌شده برای محیط‌های مختلف را نمایش می‌دهند:

جمع‌بندی

الگوریتم PPO به واسطه تابع برش بدبینانه L^{CLIP} ، بدون نیاز به محاسبات سنگین ماتریس فیشر و با استفاده مستقیم از گرادینت مرتبه اول Adam، رفتار ناحیه اطمینان را شبیه‌سازی کرده و امروزه به عنوان پایه‌ای‌ترین و مطمئن‌ترین الگوریتم یادگیری تقویتی در زمینه‌های مختلف از کنترل حرکت ربات‌های سه‌بعدی [۲۷۱] تا هم‌ترازسازی مدل‌های زبانی بزرگ از طریق بازخورد انسانی (RLHF) شناخته می‌شود.

جدول ۷۱: مقایسه عملکرد انواع توابع هدف جایگزین در ۷ محیط پیوسته MuJoCo (برگرفته از مقاله مرجع [۲۶۳]).

فرمول بندی الگوریتم / تابع هدف	میانگین امتیاز نرمال شده
بدون برش و بدون جریمه (No clipping or penalty)	۳۹.۰-
برش با $\epsilon = 0.1$ (Clipping)	۷۶.۰
برش با $\epsilon = 0.2$ (Clipping)	۸۲.۰
برش با $\epsilon = 0.3$ (Clipping)	۷۰.۰
جریمه تطبیقی با $d_{\text{targ}} = 0.003$ (Adaptive KL)	۶۸.۰
جریمه تطبیقی با $d_{\text{targ}} = 0.01$ (Adaptive KL)	۷۴.۰
جریمه تطبیقی با $d_{\text{targ}} = 0.03$ (Adaptive KL)	۷۱.۰
جریمه ثابت با $\beta = 0.3$ (Fixed KL)	۶۲.۰
جریمه ثابت با $\beta = 1.0$ (Fixed KL)	۷۱.۰
جریمه ثابت با $\beta = 3.0$ (Fixed KL)	۷۲.۰
جریمه ثابت با $\beta = 10.0$ (Fixed KL)	۶۹.۰

جدول ۷۲: تعداد بازی های برده شده توسط هر الگوریتم در بنچمارک ۴۹ تایی آتاری (ALE) [۲۶۳].

معیار ارزیابی	A2C	ACER	PPO	تساوی
(۱) میانگین پاداش در کل طول آموزش	۱	۱۸	۳۰	۰
(۲) میانگین پاداش در ۱۰۰ اپیزود پایانی	۱	۲۸	۱۹	۱

جدول ۷۳: ابرپارامترهای PPO در بنچمارک رباتیک پیوسته MuJoCo (۱ میلیون گام).

مقدار	ابروپارامتر
۲۰۴۸	افق زمانی داده برداری (T)
3×10^{-4}	نرخ یادگیری بهینه ساز Adam
۱۰	تعداد دور بهینه سازی در هر آپدیت (K)
۶۴	اندازه دسته کوچک (M)
۹۹.۰	ضریب تخفیف پاداش (γ)
۹۵.۰	پارامتر برآوردگر مزیت (λ)

جدول ۷۴: ابرپارامترهای PPO در بنچمارک بازی های آتاری (Atari).

مقدار	ابروپارامتر
۱۲۸	افق زمانی داده برداری (T)
$2.5 \times 10^{-4} \times \alpha$	نرخ یادگیری Adam
۸	تعداد عامل های موازی (N)
۳	تعداد دورها (K)
$32 \times 8 = 256$	اندازه دسته کوچک (M)
۹۹.۰	ضریب تخفیف پاداش (γ)
۹۵.۰	پارامتر λ در GAE
$0.1 \times \alpha$	آستانه برش (ϵ)
۰.۱	ضریب خطای تابع ارزش (c_1)
۰.۱۰	ضریب پاداش آنتروپی (c_2)

۲.۷ الگوریتم بهینه‌سازی نسبی خط‌مشی گروهی (Group Relative Policy Optimization - GRPO)

الگوریتم GRPO که توسط تیم DeepSeek-AI در سال ۲۰۲۴ معرفی شد [۲۴]، یکی از پیشرفته‌ترین و کارآمدترین الگوریتم‌های یادگیری تقویتی در حوزه هم‌ترازسازی مدل‌های زبانی بزرگ (LLMs) برای مسائل استدلالی پیچیده و ریاضیات به شمار می‌رود. این الگوریتم با بازتعریف شیوه محاسبه مزیت و حذف کامل مدل منتقد (Critic Model)، بار حافظه و محاسبات الگوریتم‌های سنتی نظیر PPO را به طور چشمگیری کاهش داده و همگرایی پایدارتری را به نمایش می‌گذارد.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

الگوریتم بهینه‌سازی تقریبی خط‌مشی (PPO) [۲۶۳] به عنوان استاندارد اصلی در مرحله یادگیری تقویتی از بازخورد انسانی (RLHF) [۲۷۲] شناخته می‌شود. با این حال، استفاده از ساختار کنشگر-منتقد (Actor-Critic) در مدل‌های زبانی با موانع اساسی زیر همراه است:

- **بار سنگین حافظه و محاسبات (Memory and Compute Footprint):** در PPO استاندارد، مدل منتقد (V_{ψ}) از نظر ابعاد پارامتری هم‌اندازه مدل خط‌مشی (π_{θ}) است. بارگذاری، محاسبه گرادیان و نگهداری متغیرهای بهینه‌ساز برای هر دو مدل، حجم عظیمی از حافظه پردازشی (VRAM) را اشغال می‌کند.
- **پاداش‌های تنک و عدم انطباق با تقریب ارزش توکنی (Sparse Reward Mismatch):** در استدلال‌های ریاضی، پاداش‌ها معمولاً در انتهای توالی (Outcome) یا در انتهای هر گام استدلال (Process) صادر می‌شوند. آموزش یک تابع ارزش برای پیش‌بینی ارزش تک‌تک توکن‌ها در طول یک متن طولانی، دارای واریانس بسیار بالا و خطای تقریب شدید است.
- **طبیعت مقایسه‌ای مدل‌های پاداش (Comparative Nature of Reward Models):** مدل‌های پاداش ذاتاً بر اساس مقایسه نسبی بین گزینه‌ها آموزش می‌بینند. تلاش مدل منتقد برای یادگیری ارزش مطلق به صورت نقطه‌ای، همخوانی کاملی با ماهیت نسبی سیگنال‌های پاداش ندارد.

الگوریتم GRPO با حذف کامل مدل ارزش و جایگزینی آن با خط مبنای آماری حاصل از گروهی از پاسخ‌های تولیدشده برای یک پرسش یکسان، این چالش‌ها را به طور بنیادین برطرف می‌سازد.

مبانی نظری و اشتقاق‌های کامل ریاضی

فرض کنید q یک پرسش از توزیع داده‌های آموزشی باشد. الگوریتم GRPO به ازای هر پرسش q ، گروهی متشکل از G خروجی $\{o_1, o_2, \dots, o_G\}$ را از خط‌مشی پیشین $\pi_{\theta_{old}}$ نمونه‌برداری می‌کند.

۱. **تابع هدف بهینه‌سازی GRPO:** تابع هدف سراسری این الگوریتم به صورت زیر فرمول‌بندی می‌شود:

$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}_{\substack{q \sim P(Q) \\ \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)}} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(\frac{\pi_{\theta}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t}|q, o_{i,<t})} \hat{A}_{i,t}, \right. \right. \right. \\ \left. \left. \left. \text{clip} \left(\frac{\pi_{\theta}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t}|q, o_{i,<t})}, 1 - \varepsilon, 1 + \varepsilon \right) \hat{A}_{i,t} \right) - \beta \mathbb{D}_{KL}(\pi_{\theta} \parallel \pi_{ref}) \right] \quad (262)$$

که در آن ε آستانه برش برای جلوگیری از به‌روزرسانی‌های مخرب، β ضریب جریمه واگرایی کولبک-لایبلر و $\hat{A}_{i,t}$ مزیت نرمال‌شده در سطح گروه است.

۲. اثبات نارایی و نامنفی بودن تخمین گر واگرایی KL: در این الگوریتم، به جای تزریق جریمه واگرایی به عنوان پاداش به ازای هر توکن، از تخمین گر ناریب شولمن [۲۲۸] به صورت مستقیم در تابع زیان استفاده می‌شود:

$$\mathbb{D}_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) = \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - 1 \quad (۲۶۳)$$

اثبات نامنفی بودن: فرض کنید $r = \frac{\pi_{\text{ref}}}{\pi_{\theta}} > 0$ باشد. تابع $f(r) = r - \log r - 1$ را در نظر می‌گیریم. مشتقات اول و دوم این تابع عبارتند از:

$$f'(r) = 1 - \frac{1}{r}, \quad f''(r) = \frac{1}{r^2} > 0 \quad (\forall r > 0) \quad (۲۶۴)$$

از آنجا که مشتق دوم همواره مثبت است، تابع اکیداً محدب بوده و نقطه بحرانی آن در $f'(r) = 0 \implies r = 1$ یک کمینه مطلق است:

$$f(1) = 1 - \log(1) - 1 = 0 \implies f(r) \geq 0 \quad (\forall r > 0) \quad (۲۶۵)$$

اثبات نارایی: امید ریاضی این تخمین گر تحت توزیع کنونی خطمشی π_{θ} برابر است با:

$$\begin{aligned} \mathbb{E}_{x \sim \pi_{\theta}} \left[\frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - \log \frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - 1 \right] &= \sum_x \pi_{\theta}(x) \left(\frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - \log \frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - 1 \right) \\ &= \sum_x \pi_{\text{ref}}(x) - \sum_x \pi_{\theta}(x) \log \frac{\pi_{\text{ref}}(x)}{\pi_{\theta}(x)} - \sum_x \pi_{\theta}(x) \\ &= 1 + \sum_x \pi_{\theta}(x) \log \frac{\pi_{\theta}(x)}{\pi_{\text{ref}}(x)} - 1 = D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \quad (۲۶۶) \end{aligned}$$

۳. اشتقاق گرادیان و ضریب گرادیان (Gradient Coefficient): با در نظر گرفتن شرایط خطمشی در گام نخست ($\pi_{\theta_{\text{old}}} \approx \pi_{\theta}$)، مشتق تابع هدف را نسبت به پارامترهای θ به دست می‌آوریم:

$$\nabla_{\theta} \mathcal{L}_{i,t}(\theta) = \nabla_{\theta} \left[\frac{\pi_{\theta}(o_{i,t})}{\pi_{\theta_{\text{old}}}(o_{i,t})} \hat{A}_{i,t} \right] - \beta \nabla_{\theta} \left[\frac{\pi_{\text{ref}}(o_{i,t})}{\pi_{\theta}(o_{i,t})} - \log \frac{\pi_{\text{ref}}(o_{i,t})}{\pi_{\theta}(o_{i,t})} - 1 \right] \quad (۲۶۷)$$

با استفاده از تساوی $\nabla_{\theta} \pi_{\theta} = \pi_{\theta} \nabla_{\theta} \log \pi_{\theta}$:

$$\nabla_{\theta} \left[\frac{\pi_{\theta}}{\pi_{\theta_{\text{old}}}} \hat{A}_{i,t} \right] = \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(o_{i,t}) \quad (۲۶۸)$$

$$\nabla_{\theta} \left[\frac{\pi_{\text{ref}}}{\pi_{\theta}} - \log \pi_{\text{ref}} + \log \pi_{\theta} - 1 \right] = -\frac{\pi_{\text{ref}}}{\pi_{\theta}^2} \nabla_{\theta} \pi_{\theta} + \frac{1}{\pi_{\theta}} \nabla_{\theta} \pi_{\theta} = \left(1 - \frac{\pi_{\text{ref}}}{\pi_{\theta}} \right) \nabla_{\theta} \log \pi_{\theta}(o_{i,t}) \quad (۲۶۹)$$

با تجميع دو عبارت فوق، گرادیان کامل به صورت زیر حاصل می‌شود:

$$\nabla_{\theta} \mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\hat{A}_{i,t} + \beta \left(\frac{\pi_{\text{ref}}(o_{i,t})}{\pi_{\theta}(o_{i,t})} - 1 \right) \right) \nabla_{\theta} \log \pi_{\theta}(o_{i,t}|q, o_{i,<t}) \right] \quad (۲۷۰)$$

بنابراین ضریب گرادیان (Gradient Coefficient - GC) در این روش برابر است با:

$$GC_{\text{GRPO}}(q, o, t, \pi_{\theta_{\text{rm}}}) = \hat{A}_{i,t} + \beta \left(\frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - 1 \right) \quad (۲۷۱)$$

رویکردهای نظارت و محاسبه مزیت در GRPO

الگوریتم GRPO امکان بهره‌گیری از دو نوع ناظر را برای تعیین پاداش فراهم می‌سازد:

۱. **نظارت بر خروجی (Outcome Supervision RL with GRPO):** مدل پاداش به ازای هر پاسخ کامل o_i یک امتیاز r_i تولید می‌کند. بردار پاداش گروهی $\mathbf{r} = \{r_1, r_2, \dots, r_G\}$ به شکل زیر نرمال‌سازی می‌شود:

$$\hat{A}_{i,t} = \tilde{r}_i = \frac{r_i - \text{mean}(\mathbf{r})}{\text{std}(\mathbf{r}) + 10^{-8}}, \quad \forall t \in \{1, \dots, |o_i|\} \quad (272)$$

۲. **نظارت بر فرآیند (Process Supervision RL with GRPO):** مدل پاداش فرایندی (PRM) [۲۷۳]، [۲۷۴] به انتهای هر گام استدلال j پاداش $r_i^{\text{index}(j)}$ اختصاص می‌دهد. با نرمال‌سازی کل پاداش‌های مرحله‌ای درون گروه:

$$\tilde{r}_i^{\text{index}(j)} = \frac{r_i^{\text{index}(j)} - \text{mean}(\mathbf{R})}{\text{std}(\mathbf{R}) + 10^{-8}} \quad (273)$$

سپس مزیت هر توکن در موقعیت t از مجموع پاداش‌های گام‌های پسین محاسبه می‌شود:

$$\hat{A}_{i,t} = \sum_{\substack{j=1 \\ \text{index}(j) \geq t}}^{K_i} \tilde{r}_i^{\text{index}(j)} \quad (274)$$

چارچوب یکپارچه روش‌های هم‌ترازسازی

مقاله یک صورت‌بندی فراگیر ارائه می‌دهد که تمامی روش‌های تنظیم دقیق و یادگیری تقویتی را تحت معادله گرادیان زیر متحد می‌سازد:

$$\nabla_{\theta} \mathcal{J}_{\mathcal{A}}(\theta) = \mathbb{E}_{(q,o) \sim \mathcal{D}} \left[\frac{1}{|o|} \sum_{t=1}^{|o|} GC_{\mathcal{A}}(q, o, t, \pi_{\text{ref}}) \nabla_{\theta} \log \pi_{\theta}(o_t | q, o_{<t}) \right] \quad (275)$$

جدول ۷۵ مقایسه ساختاری این روش‌ها را نشان می‌دهد:

جدول ۷۵: تحلیل ساختار روش‌های هم‌ترازسازی در چارچوب یکپارچه گرادیان [۲۴].

روش (Method)	منبع داده ($\mathcal{D}$)	تابع پاداش (π_{ref})	ضریب گرادیان (GC)	نوع نمونه‌برداری
SFT	$q, o \sim P_{\text{sft}}(Q, O)$	انتخاب انسانی	1	آفلاین ایستا
[۲۷۵] RFT	$q \sim P_{\text{sft}}(Q), o \sim \pi_{\text{sft}}(O q)$	قاعده قطعی (Rule)	$\mathbb{I}(o \text{ correct is})$	آفلاین تصادفی
[۲۷۶] DPO	$q \sim P_{\text{sft}}(Q), o^+, o^- \sim \pi_{\text{sft}}(O q)$	ترجیح / قاعده	$\sigma \left(\beta \log \frac{\pi_{\theta}(o^-)}{\pi_{\text{ref}}(o^-)} - \beta \log \frac{\pi_{\theta}(o^+)}{\pi_{\text{ref}}(o^+)} \right)$	آفلاین زوجی
Online RFT	$q \sim P_{\text{sft}}(Q), o \sim \pi_{\theta}(O q)$	قاعده قطعی (Rule)	$\mathbb{I}(o \text{ correct is})$	آنلاین تصادفی
[۲۶۳] PPO	$q \sim P_{\text{sft}}(Q), o \sim \pi_{\theta}(O q)$	مدل پاداش	$A_t = \text{GAE}(\{r_{\geq t}\}, V_{\psi})$	آنلاین پیوسته
GRPO	$q \sim P_{\text{sft}}(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta}(O q)$	مدل پاداش / فرآیند	$\hat{A}_{i,t} + \beta \left(\frac{\pi_{\text{ref}}(o_{i,t})}{\pi_{\theta}(o_{i,t})} - 1 \right)$	آنلاین گروهی

تحلیل‌های تئوری اطلاعات، آمار و چرایی موفقیت الگوریتم

– **کاهش واریانس بدون منتقد:** میانگین پاداش درون‌گروهی r_i $b(q) = \frac{1}{G} \sum_{i=1}^G r_i$ به عنوان خط مبنای نارایب عمل کرده و واریانس تخمین‌گر به میزان $\mathcal{O}(1/G)$ کاهش می‌یابد بدون آنکه نیازی به خطای تخمین مدل منتقد ($\epsilon_{\text{critic}} = V^*(s) - V_{\psi}(s)$) باشد.

– **تحلیل معیارهای Pass@K در برابر Maj@K:** ارزیابی‌های تجربی روی بنچمارک‌های GSM8K و MATH نشان می‌دهند که یادگیری تقویتی توان بالقوه خام (Pass@K) مدل را نسبت به مرحله SFT تغییر چشمگیری نمی‌دهد؛ بلکه توزیع احتمالاتی پاسخ‌ها را کالبره کرده و با متمرکز ساختن چگالی احتمال حول پاسخ‌های صحیح، دقت رأی‌گیری اکثریت (Maj@K) و پاسخ برتر (Top-1) را به شدت ارتقا می‌بخشد.

دیگرام معماری و جریان داده‌های الگوریتم

شکل ۱۳ ساختار داده‌برداری گروهی، نرمال‌سازی آماری، محاسبه ضریب گرادیان و چرخه به‌روزرسانی بدون منتقد را در الگوریتم GRPO نمایش می‌دهد.

شبه‌کد الگوریتم GRPO

شبه‌کد کامل فرایند بهینه‌سازی سیاست نسبی گروهی تکرارشونده در الگوریتم ۳ تشریح شده است:

Algorithm 3 Iterative Group Relative Policy Optimization (GRPO)

```

1: Input: Initial policy  $\pi_{\theta_{\text{init}}}$ , reward model  $r_{\varphi}$ , prompt dataset  $\mathcal{D}$ , hyperparameters  $\varepsilon, \beta, \mu, G$ , iterations  $I$ , steps  $M$ .
2: Initialize policy  $\pi_{\theta} \leftarrow \pi_{\theta_{\text{init}}}$ 
3: for iteration = 1, ...,  $I$  do
4:   Set reference policy  $\pi_{\text{ref}} \leftarrow \pi_{\theta}$ 
5:   for step = 1, ...,  $M$  do
6:     Sample batch of prompts  $\mathcal{D}_b \sim \mathcal{D}$ 
7:     Update old policy  $\pi_{\theta_{\text{old}}} \leftarrow \pi_{\theta}$ 
8:     Sample  $G$  candidate outputs  $\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)$  for each prompt  $q \in \mathcal{D}_b$ 
9:     Compute rewards  $\{r_i\}_{i=1}^G$  using reward model  $r_{\varphi}$ 
10:    Compute group mean and standard deviation:
11:    
$$\mu_{\mathbf{r}} = \frac{1}{G} \sum_{i=1}^G r_i, \quad \sigma_{\mathbf{r}} = \sqrt{\frac{1}{G} \sum_{i=1}^G (r_i - \mu_{\mathbf{r}})^2 + 10^{-8}}$$

12:    Compute group relative advantages:  $\hat{A}_{i,t} = \frac{r_i - \mu_{\mathbf{r}}}{\sigma_{\mathbf{r}}}$ 
13:    for GRPO iteration = 1, ...,  $\mu$  do
14:      Compute ratio:  $\rho_{i,t} = \frac{\pi_{\theta}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, o_{i,<t})}$ 
15:      Compute clipped advantage objective:
16:      
$$\mathcal{L}_{i,t}^{\text{CLIP}} = \min \left( \rho_{i,t} \hat{A}_{i,t}, \text{clip}(\rho_{i,t}, 1 - \varepsilon, 1 + \varepsilon) \hat{A}_{i,t} \right)$$

17:      Compute token-level Schulman KL penalty:
18:      
$$\mathbb{D}_{\text{KL},i,t} = \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta}(o_{i,t}|q, o_{i,<t})} - 1$$


19:      Maximize GRPO loss with AdamW:
20:      
$$\theta \leftarrow \theta + \alpha \nabla_{\theta} \left[ \frac{1}{G|\mathcal{D}_b|} \sum_{q \in \mathcal{D}_b} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} (\mathcal{L}_{i,t}^{\text{CLIP}} - \beta \mathbb{D}_{\text{KL},i,t}) \right]$$

21:    end for
22:    Update reward model  $r_{\varphi}$  through replay mechanism with 10% historical samples.
23:  end for
24: end for
25: Output: Optimized Policy  $\pi_{\theta}$ 

```

نتایج تجربی و ارزیابی بنچمارک‌ها

نتایج حاصل از اعمال الگوریتم GRPO بر روی مدل پایه DeepSeekMath-Instruct 7B در مقایسه با سایر مدل‌های باز و بسته در جدول ۷۶ ارائه شده است:



شکل ۱۳: دیاگرام جامع جریان داده‌ها، ارزیابی آماری گروهی و به‌روزرسانی بدون منتقد در الگوریتم GRPO.

جدول ۷۶: مقایسه عملکرد (GRPO) DeepSeekMath-RL با مدل‌های پیشرو در بنچمارک‌های استدلال ریاضی [۲۴].

مدل (Model)	تعداد پارامتر	GSM8K (CoT)	MATH (CoT)	MGSM-zh	CMATH
مدل‌های تجاری و بسته (Closed-Source Models)					
Gemini Ultra	-	۴۰.۹۴	۲۰.۵۳	-	-
GPT-4	-	۵۰.۹۲	۹۰.۵۲	-	۵۰.۸۶
Inflection-2	-	۴۰.۸۱	۸۰.۳۴	-	-
GLM-4	-	۶۰.۸۷	۹۰.۴۷	-	-
مدل‌های منبع باز (Open-Source Models)					
InternLM2-Math	۲۰B	۶۰.۸۲	۷۰.۳۷	-	-
Qwen	۷۲B	۹۰.۷۸	۲۰.۳۵	-	-
WizardMath-v1.1	۷B	۲۰.۸۳	۵۰.۳۳	-	-
DeepSeekMath-Instruct	۷B	۹۰.۸۲	۸۰.۴۶	۲۰.۷۳	۶۰.۸۴
DeepSeekMath-RL (GRPO)	۷B	۲۰.۸۸	۷۰.۵۱	۶۰.۷۹	۸۰.۸۸

ابریارمترهای استاندارد گزارش شده در مقاله

جدول ۷۷ پیکربندی ابریارمترهای بهینه پیاده‌سازی GRPO را نشان می‌دهد:

جدول ۷۷: ابریارمترهای آموزش یادگیری تقویتی با GRPO در مدل DeepSeekMath 7B.

مقدار	ابریارمتر (Hyperparameter)
1×10^{-6}	نرخ یادگیری مدل خط‌مشی (α)
2×10^{-5}	نرخ یادگیری مدل پاداش اولیه
۶۴	تعداد نمونه‌های خروجی در هر گروه (G)
۰.۴۰	ضریب جریمه واگرایی کولبک-لایبلر (β)
۲.۰	آستانه برش پروگزیمال (ϵ)
۱۰۲۴	اندازه دسته بهینه‌سازی (Batch Size)
۱۰۲۴	حداکثر طول توالی خروجی (Max Length)
۷.۰	دمای نمونه‌برداری اکتشافی (Sampling Temperature)

جمع‌بندی

الگوریتم GRPO با حذف کامل سربار محاسباتی و حافظه مدل منتقد و جایگزینی آن با نرمال‌سازی آماری در سطح گروه‌های هم‌ارز، مسیر نوینی را در یادگیری تقویتی مدل‌های زبانی گشوده است. این نوآوری به مدل DeepSeekMath 7B اجازه داد تا با صرفه‌جویی شدید در منابع سخت‌افزاری، به دقت فراتر از ۵۱٪ در بنچمارک معتبر MATH دست یافته و استانداردهای جدیدی در زمینه استدلال هوش مصنوعی پایه‌گذاری کند.

۳.۷ الگوریتم بهینه‌سازی توالی گروهی خط‌مشی (Group Sequence Policy Optimization - GSPO)

الگوریتم GSPO که در سال ۲۰۲۵ توسط تیم کوئن (Qwen Team) در شرکت علی‌بابا (Alibaba Inc.) معرفی شد [۲۷۷]، یک چارچوب نوین، فوق‌العاده پایدار و کارآمد در زمینه یادگیری تقویتی (Reinforcement Learning) برای مدل‌های زبانی بزرگ (LLMs) به شمار می‌رود. این الگوریتم با بازنگری در

شیوه اعمال «نمونه‌برداری اهمیت» (Importance Sampling) و اصلاح خطاهای ساختاری الگوریتم‌های پیشین نظیر GRPO [۲۴]، کلیه فرآیندهای وزن‌دهی نسبت درستی‌نمایی، برش‌گرادیان (Clipping) و بهینه‌سازی را از سطح «توکن» (Token-level) به سطح «توالی کامل» (Sequence-level) منتقل کرده است. این رویکرد به عنوان ستون فقرات یادگیری تقویتی در آموزش مدل‌های استدلالی پیشرفته خانواده Qwen3 [۲۷۸، ۱۵۱] به کار گرفته شده است.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

با گسترش مدل‌های زبانی استدلالی نظیر OpenAI o1 [۲۷۹] و DeepSeek-R1 [۱۰۳]، نقش یادگیری تقویتی در مقیاس‌پذیری زمان تفکر (Test-Time Compute) و تولید زنجیره‌های طولانی استدلال (Long Chain-of-Thought) برای حل مسائل ریاضی و برنامه‌نویسی رقابتی اثبات گردید.

پیش از ابداع GSPO، روند توسعه الگوریتم‌های یادگیری تقویتی در مدل‌های زبانی با چالش‌های اساسی روبرو بود:

- **محدودیت‌های PPO [۲۶۳]:** الگوریتم PPO نیازمند یک مدل منتقد یا ارزش (Value/Critic Model) مجزا برای برآورد مزیت در هر توکن است. این مدل علاوه بر تحمیل بار حافظه و محاسباتی هم‌اندازه با مدل خط‌مشی اصلی، در پاسخ‌های طولانی استدلالی (چندین هزار توکن) به دلیل انباشت خطای پیش‌بینی، به شدت ناپایدار و غیرقابل اعتماد می‌گردد.
- **ظهور و معضلات الگوریتم GRPO [۲۴]:** الگوریتم GRPO با حذف مدل منتقد و جایگزینی آن با برآورد مزیت نسبی در یک گروه از پاسخ‌ها (Group Relative Advantage)، نیاز به حافظه اضافی را رفع کرد. با این حال، GRPO در آموزش مدل‌های بسیار بزرگ و در استدلال‌های طولانی، مکرراً با پدیده «فروپاشی فاجعه‌بار و غیرقابل بازگشت مدل» (Irreversible Model Collapse) مواجه می‌شود [۲۷۸، ۲۱۹]. در صورت وقوع این فروپاشی، هیچ‌گونه دستکاری در ابرپارامترها یا بارگذاری مجدد چک‌پوینت‌ها کمکی به همگرایی مجدد نخواهد کرد.

نویسندگان مقاله GSPO ریشه این ناپایداری در GRPO را در دو نقص تئوریک شناسایی کردند:

۱. **نقض مبانی ریاضی نمونه‌برداری اهمیت (Importance Sampling):** اصل نمونه‌برداری اهمیت برای تخمین امید ریاضی یک تابع $f(z)$ تحت توزیع هدف π_{tar} با استفاده از توزیع رفتاری π_{beh} به صورت زیر بیان می‌شود:

$$\mathbb{E}_{z \sim \pi_{tar}}[f(z)] = \mathbb{E}_{z \sim \pi_{beh}} \left[\frac{\pi_{tar}(z)}{\pi_{beh}(z)} f(z) \right] \approx \frac{1}{N} \sum_{k=1}^N \frac{\pi_{tar}(z^{(k)})}{\pi_{beh}(z^{(k)})} f(z^{(k)}) \quad (۲۷۶)$$

این رابطه ریاضی از نظر آماری تنها در صورتی معتبر و بدون انحراف است که میانگین‌گیری روی تعداد زیادی نمونه ($N \gg 1$) از توزیع رفتاری صورت پذیرد. در حالی که GRPO نسبت اهمیت $\frac{\pi_{\theta}(y_{i,t}|x,y_{i,<t})}{\pi_{\theta_{old}}(y_{i,t}|x,y_{i,<t})}$ را برای هر تک‌توکن t و با تنها یک نمونه تکی ($N = 1$) اعمال می‌کند. این کار به جای تصحیح انحراف توزیع، نویز ضرب‌شونده با واریانس بسیار بالا را وارد گرادیان کرده که با طولانی‌تر شدن زنجیره استدلال انباشته شده و مدل را نابود می‌سازد.

۲. **عدم انطباق واحد بهینه‌سازی و واحد پاداش (Mismatch Principle):** پاداش ارزیاب $r(x, y)$ به کل توالی پاسخ اعطا می‌شود نه به تک‌تک توکن‌ها. بنابراین، اعمال تصحیح خارج از خط‌مشی (Off-Policy Correction) و عملگر برش در سطح توکن‌های مجزا، فرمول‌بندی نادرست و ناسازگاری ایجاد می‌کند.

مبانی نظری و اشتقاق‌های کامل ریاضی GSPO

در یک مدل زبانی خودبازگشتی، درستی‌نمایی (Likelihood) یک پاسخ $y = (y_1, y_2, \dots, y_{|y|})$ به ازای پرسش ورودی x تحت خط‌مشی π_θ برابر است با:

$$\pi_\theta(y|x) = \prod_{t=1}^{|y|} \pi_\theta(y_t|x, y_{<t}) \quad (۲۷۷)$$

الگوریتم GSPO، تابع هدف بهینه‌سازی را مستقیماً در سطح توالی فرمول‌بندی می‌کند:

$$\mathcal{J}_{\text{GSPO}}(\theta) = \mathbb{E}_{x \sim \mathcal{D}, \{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|x)} \left[\frac{1}{G} \sum_{i=1}^G \min \left(s_i(\theta) \hat{A}_i, \text{clip}(s_i(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_i \right) \right] \quad (۲۷۸)$$

که در آن G اندازه گروه پاسخ‌های هم‌زمان به ازای هر پرسش بوده و مزیت گروهی $\hat{A}_i$ بر اساس امتیاز پاداش تاییدکننده $r(x, y_i) \in [0, 1]$ به صورت زیر نرمال‌سازی می‌شود:

$$\hat{A}_i = \frac{r(x, y_i) - \text{mean}(\{r(x, y_i)\}_{i=1}^G)}{\text{std}(\{r(x, y_i)\}_{i=1}^G)} \quad (۲۷۹)$$

نسبت اهمیت توالی $s_i(\theta)$ بر اساس مفهوم درستی‌نمایی توالی با نرمال‌سازی طولی (Length-Normalized Sequence Likelihood) [۲۸۰] تعریف می‌شود:

$$s_i(\theta) \triangleq \left(\frac{\pi_\theta(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)} \right)^{\frac{1}{|y_i|}} = \exp \left(\frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \log \frac{\pi_\theta(y_{i,t}|x, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})} \right) \quad (۲۸۰)$$

اثبات گام‌به‌گام اشتقاق گرادیان GSPO: با صرف‌نظر از عملگر غیرخطی برش جهت بررسی گرادیان بدون مرز، گرادیان تابع هدف نسبت به پارامترهای θ به صورت زیر محاسبه می‌شود:

$$\begin{aligned} \nabla_\theta \mathcal{J}_{\text{GSPO}}(\theta) &= \nabla_\theta \mathbb{E}_{x, \{y_i\}_{i=1}^G} \left[\frac{1}{G} \sum_{i=1}^G s_i(\theta) \hat{A}_i \right] \\ &= \mathbb{E}_{x, \{y_i\}_{i=1}^G} \left[\frac{1}{G} \sum_{i=1}^G \hat{A}_i \nabla_\theta s_i(\theta) \right] \end{aligned} \quad (۲۸۱)$$

با توجه به اینکه برای هر تابع مثبت $f(\theta)$ داریم $\nabla_\theta \log f(\theta) = \frac{\nabla_\theta f(\theta)}{f(\theta)}$ ، مشتق نسبت اهمیت توالی برابر است با:

$$\nabla_\theta s_i(\theta) = s_i(\theta) \nabla_\theta \log s_i(\theta) \quad (۲۸۲)$$

با اعمال لگاریتم بر طرفین معادله (۲۸۰):

$$\log s_i(\theta) = \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} [\log \pi_\theta(y_{i,t}|x, y_{i,<t}) - \log \pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})] \quad (۲۸۳)$$

از آنجا که جمله مربوط به θ_{old} مستقل از θ است، مشتق آن صفر می‌شود:

$$\nabla_\theta \log s_i(\theta) = \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \nabla_\theta \log \pi_\theta(y_{i,t}|x, y_{i,<t}) \quad (۲۸۴)$$

بنابراین، فرمول بسته نهایی گرادیان GSPO حاصل می‌شود:

$$\nabla_{\theta} \mathcal{J}_{\text{GSPO}}(\theta) = \mathbb{E}_{x, \{y_i\}_{i=1}^G} \left[\frac{1}{G} \sum_{i=1}^G \left(\frac{\pi_{\theta}(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)} \right)^{\frac{1}{|y_i|}} \hat{A}_i \cdot \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \nabla_{\theta} \log \pi_{\theta}(y_{i,t}|x, y_{i,<t}) \right] \quad (285)$$

در مقام مقایسه، گرادیان الگوریتم GRPO به صورت زیر است:

$$\nabla_{\theta} \mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{x, \{y_i\}_{i=1}^G} \left[\frac{1}{G} \sum_{i=1}^G \hat{A}_i \cdot \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \left(\frac{\pi_{\theta}(y_{i,t}|x, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})} \right) \nabla_{\theta} \log \pi_{\theta}(y_{i,t}|x, y_{i,<t}) \right] \quad (286)$$

تحلیل مقایسه‌ای دو گرادیان: در GRPO (معادله (286))، گرادیان هر توکن با یک وزن نابرابر و تصادفی $\frac{\pi_{\theta}(y_{i,t})}{\pi_{\theta_{\text{old}}}(y_{i,t})}$ مقیاس‌بندی می‌شود که این نوسانات نامتعادل در طول هزاران گام به فروپاشی مدل می‌انجامد. اما در GSPO (معادله (285))، تمامی توکن‌های درون یک پاسخ با یک ضریب کاملاً همگن و یکنواخت $(s_i(\theta) \frac{\hat{A}_i}{|y_i|})$ وزن‌دهی می‌شوند که عامل اصلی ثبات بی‌نظیر این الگوریتم است.

گونه تعمیم‌یافته برای توکن‌ها (GSPO-token Variant)

برای سناریوهایی نظیر یادگیری تقویتی چندنوبته (Multi-turn RL) یا استفاده از مدل‌های پاداش فرآیندی (PRM) که نیازمند مزیت‌های متفاوت برای هر گام یا توکن $(\hat{A}_{i,t})$ هستیم، گونه GSPO-token با بهره‌گیری از عملگر سد گرادیان (Stop-Gradient یا $\text{sg}[\cdot]$) معرفی شده است:

$$\mathcal{J}_{\text{GSPO-token}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \min \left(s_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(s_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_{i,t} \right) \right] \quad (287)$$

که در آن نسبت توکن با ساختار زیر تعریف می‌شود:

$$s_{i,t}(\theta) \triangleq \text{sg}[s_i(\theta)] \cdot \frac{\pi_{\theta}(y_{i,t}|x, y_{i,<t})}{\text{sg}[\pi_{\theta}(y_{i,t}|x, y_{i,<t})]} \quad (288)$$

از آنجا که عبارت کسری از نظر مقداری دقیقاً برابر با 1 است، مقدار عددی $s_{i,t}(\theta) = s_i(\theta)$ بوده و شرط برش در سطح کل توالی حفظ می‌شود. در زمان مشتق‌گیری، گرادیان مستقیماً روی توکن t اثر می‌گذارد:

$$\nabla_{\theta} \mathcal{J}_{\text{GSPO-token}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \left(\frac{\pi_{\theta}(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)} \right)^{\frac{1}{|y_i|}} \cdot \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(y_{i,t}|x, y_{i,<t}) \right] \quad (289)$$

در حالتی که مزیت تمام توکن‌ها یکسان باشد ($\hat{A}_{i,t} = \hat{A}_i$)، این گرادیان دقیقاً و به صورت تحلیلی با گرادیان GSPO اصلی هم‌ارز می‌گردد.

تحلیل‌های تئوری اطلاعات، آمار و دینامیک مدل‌های MoE

۱. **کنترل واریانس و واگرایی KL:** بر اساس تئوری اطلاعات، نسبت درستی‌نمایی ضرب‌شونده بدون نرمال‌سازی طولی دارای واریانس متناسب با طول پاسخ است ($\text{Var} \propto \mathcal{O}(|y|)$). با اعمال میانگین هندسی در توان $\frac{1}{|y|}$ ، واریانس نسبت اهمیت به صورت $\mathcal{O}(1/|y|)$ میرا شده و کران واگرایی اطلاعاتی میان سیاست جدید و قدیم کنترل می‌شود.

۲. **تثبیت دینامیک آموزش در معماری‌های ترکیبی از متخصصان (MoE):** در مدل‌های MoE نظیر Qwen3-30B-A3B با ۴۸ لایه، پس از هر به‌روزرسانی گرادیان، تخصیص حدود ۱۰٪ از روترهای متخصصان تغییر می‌کند (Expert-Activation Volatility). این پدیده باعث نوسان شدید در درستی‌نمایی محلی توکن‌ها شده و آموزش GRPO را به شکست قطعی می‌کشاند، مگر آنکه از روش پرهزینه «بازپخش مسیریابی» (Routing Replay) برای اجبار به استفاده از مسیرهای قدیمی استفاده شود. GSPO به دلیل تمرکز بر درستی‌نمایی کل توالی و عدم حساسیت به تغییرات جابجایی روترهای محلی، نیاز به Routing Replay را کاملاً منسوخ کرده و ظرفیت کامل مدل را بدون افت سرعت آزاد می‌سازد.

۳. **بهینه‌سازی زیرساخت آموزش (Infrastructure):** تفاوت‌های دقت ممیز شناور میان موتورهای استنتاج (vLLM / SGLang) و موتورهای آموزش (Megatron-LM) در سطح تک‌توکن‌ها خطاساز است. GSPO به دلیل پایداری در سطح توالی، به مدل اجازه می‌دهد تا مستقیماً لاگ‌احتمالات خروجی از موتور استنتاج را بدون نیاز به محاسبه مجدد (Recomputation) در موتور آموزش استفاده کند.

دیاگرام معماری و جریان داده‌های الگوریتم

شکل ۱۴ ساختار جامع خط لوله آموزش، محاسبات نسبت توالی و تفاوت بنیادین جریان داده در الگوریتم GSPO در مقایسه با روش‌های پیشین را نمایش می‌دهد.

شبه‌کد الگوریتم GSPO


شبه‌کد رسمی و استاندارد پیاده‌سازی مقیاس‌پذیر الگوریتم GSPO در الگوریتم ۴ ارائه شده است:

Algorithm 4 Group Sequence Policy Optimization (GSPO)

```

1: Input: Initial actor policy parameters  $\theta_0$ , verifier reward function  $r(x, y)$ , group size  $G$ , clipping threshold  $\varepsilon$ , learning rate  $\eta$ , number of mini-batches  $K$ .
2: for iteration = 1, 2, ... do
3:   Sample a batch of queries  $\{x_j\}_{j=1}^B \sim \mathcal{D}$ .
4:   Set behavior policy  $\theta_{\text{old}} \leftarrow \theta$ .
5:   Initialize rollout buffer  $\mathcal{B} \leftarrow \emptyset$ .
6:   for each query  $x \in \{x_j\}_{j=1}^B$  do
7:     Generate  $G$  responses  $\{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|x)$  using inference engine.
8:     Compute scalar rewards  $r_i = r(x, y_i)$  for  $i \in \{1, \dots, G\}$ .
9:     Compute group advantage:  $\hat{A}_i = \frac{r_i - \text{mean}(\{r_k\})}{\text{std}(\{r_k\}) + 10^{-8}}$ .
10:    for  $i = 1, \dots, G$  do
11:      Store rollout record  $(x, y_i, \hat{A}_i, \{\log \pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})\}_{t=1}^{|y_i|})$  in  $\mathcal{B}$ .
12:    end for
13:  end for
14:  Partition buffer  $\mathcal{B}$  into  $K$  mini-batches  $\{\mathcal{B}_m\}_{m=1}^K$ .
15:  for each mini-batch  $\mathcal{B}_m$  do
16:    Forward current policy  $\pi_\theta$  to get current log-probabilities  $\log \pi_\theta(y_{i,t}|x, y_{i,<t})$ .
17:    Compute length-normalized sequence importance ratio for each sample:
18:     $s_i(\theta) = \exp\left(\frac{1}{|y_i|} \sum_{t=1}^{|y_i|} (\log \pi_\theta(y_{i,t}|x, y_{i,<t}) - \log \pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t}))\right)$ .
19:    Compute sequence clipped surrogate loss:
20:     $\mathcal{L}(\theta) = -\frac{1}{|\mathcal{B}_m|} \sum_{i \in \mathcal{B}_m} \min\left(s_i(\theta)\hat{A}_i, \text{clip}(s_i(\theta), 1 - \varepsilon, 1 + \varepsilon)\hat{A}_i\right)$ .
21:    Perform backward pass and parameter update:
22:     $\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}(\theta)$ .
23:  end for
24: end for

```



شکل ۱۴: دیاگرام جامع معماری خط لوله آموزش، محاسبه نسبت اهمیت توالی با نرمال‌سازی طولی و به‌روزرسانی گرادین همگن در الگوریتم GSPO.

نتایج تجربی و ارزیابی بنچمارک‌ها

ارزیابی تجربی GSPO بر روی مدل پایه Qwen3-30B-A3B-Base در مقایسه با GRPO در بنچمارک‌های استاندارد استدلالی، برنامه‌نویسی و ریاضی در جدول ۷۸ آورده شده است.

جدول ۷۸: مقایسه عملکرد و پایداری الگوریتم‌های GRPO و GSPO بر روی مدل Qwen3-30B-A3B (برگرفته از [۲۷۷]).

الگوریتم یادگیری تقویتی	AIME ۲۴' (Pass@1)	LiveCodeBench (Pass@1)	CodeForces (Elo)	پایداری در آموزش MoE
GRPO (بدون Replay)	ناموفق (فروپاشی)	ناموفق (فروپاشی)	ناموفق (فروپاشی)	کاملاً ناپایدار
GRPO (با Replay)	۲٪.۷۷	۴٪.۶۳	۱۹۲۰	نیازمند سربرار حافظه
GSPO (رویکرد پیشنهادی)	۶٪.۸۲	۱٪.۶۸	۲۰۶۵	پایداری کامل و ذاتی

پارادوکس کسر توکن‌های برش‌خورده (Clipping Fraction Paradox): جدول ۷۹ مقایسه جالب میانگین توکن‌های برش‌خورده را نشان می‌دهد. با وجود اینکه GSPO حدود دو مرتبه بزرگی توکن‌های بیشتری را برش می‌زند (۱۵٪ در برابر ۱۳٪.۰)، راندمان نمونه‌ای بسیار بالاتری ارائه می‌دهد؛ امری که نشان می‌دهد گرادیان‌های توکنی GRPO سراسر نویز مخرب بوده‌اند.

جدول ۷۹: مقایسه کسر توکن‌های برش‌خورده در طول آموزش [۲۷۷].

شاخص مقایسه‌ای	الگوریتم GRPO	الگوریتم GSPO
کسر توکن‌های برش‌خورده (Clipping Fraction)	۱۳٪.۰	۱۵۰۰.۰ (۱۵٪.۰)
نحوه اعمال برش	سطح تک‌توکن	سطح کل توالی
راندمان بهره‌وری نمونه (Sample Efficiency)	پایین (آنباشت نویز)	بسیار بالا

ابریارمترهای استاندارد گزارش‌شده در مقاله

جدول ۸۰ ابریارمترهای بهینه‌سازی آموزش GSPO را در مقایسه با GRPO نشان می‌دهد:

جدول ۸۰: ابریارمترهای استاندارد آموزش RL برای مدل Qwen3-30B-A3B.

مقدار در الگوریتم GSPO	ابریارمتر
3×10^{-4} , 4×10^{-4}	محدوده برش چپ و راست (ϵ_{left} , ϵ_{right})
0.20, 0.27	محدوده برش در الگوریتم پایه GRPO
۸	اندازه گروه پاسخ‌ها به ازای پرسش (G)
۴	تعداد مینی‌بچ‌ها به ازای هر دسته داده‌برداری (K)
$s_i(\theta) \hat{A}_i / y_i $	نوع توزیع وزن گرادیان درون توالی
خیر (حذف کامل)	نیاز به استراتژی Routing Replay

جمع‌بندی

الگوریتم GSPO با حل ناسازگاری ریاضی نمونه‌برداری اهمیت و اعمال وزن‌دهی و برش همگن در سطح کل توالی، معضل فروپاشی فاجعه‌بار آموزش را برای همیشه برطرف ساخته است. این الگوریتم با حذف نیاز به Routing Replay در مدل‌های تنک MoE و افزایش چشمگیر راندمان محاسباتی در زیرساخت‌های توزیع‌شده، به عنوان استاندارد نوین مقیاس‌پذیری یادگیری تقویتی در مدل‌های زبانی استدلالی شناخته می‌شود.

۴.۷ الگوریتم بهینه‌سازی خط‌مشی با برش مجزا و نمونه‌برداری پویا Decoupled Clip and Dynamic Sampling Policy Optimization - DAPO

الگوریتم DAPO که در سال ۲۰۲۵ توسط محققان آزمایشگاه ByteDance Seed و دانشگاه تسینگ‌هاوا (Tsinghua AIR) معرفی شد [۱۲۹]، یک سامانه پیشرفته، مقیاس‌پذیر و کاملاً متن‌باز برای یادگیری تقویتی در مدل‌های زبانی استدلال‌گر بزرگ (Reasoning LLMs) به شمار می‌رود. این الگوریتم با برطرف کردن موانع اساسی در سناریوهای استدلال با زنجیره تفکر طولانی (Long Chain-of-Thought - Long-CoT)، موفق شد بر پایه مدل پایه Qwen2.5-32B [۵۵] به دقت ۵۰٪ در بنچمارک المپیاد ریاضی AIME 2024 دست یابد و با مصرف تنها ۵۰٪ از گام‌های آموزشی، از مدل پیشروی DeepSeek-R1-Zero- پیشی بگیرد. [۲۸۱] Qwen-32B

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

با ظهور پارادایم افزایش محاسبات در زمان استنتاج (Test-Time Compute Scaling) توسط مدل‌هایی همچون OpenAI o1 [۲۷۹] و DeepSeek-R1 [۲۸۱]، استدلال مبتنی بر زنجیره تفکر طولانی به ابزار اصلی حل مسائل ریاضیات پیشرفته و برنامه‌نویسی مبدل گشت. با این وجود، به دلیل پنهان نگه‌داشتن جزئیات فنی و ترفندهای حیاتی پایدارسازی آموزش در گزارش‌های فنی این مدل‌ها، تلاش‌های مستقل جامعه متن‌باز برای بازتولید این نتایج با الگوریتم‌های رایج نظیر GRPO [۲۴] و PPO [۲۶۳] با ناکامی مواجه شد (دستیابی به تنها ۳۰٪ در AIME).

تحلیل‌های عمیق نشان داد که الگوریتم‌های سنتی در سناریوی استدلال‌های طولانی از چهار چالش بحرانی رنج می‌برند:

- **فروپاشی آنترופی (Entropy Collapse):** محدودیت بازه برش استاندارد، مانع ارتقای احتمال توکن‌های نادر اما حیاتی برای اکتشاف شده و مدل را به سرعت دچار دترمینیسم زودهنگام و پاسخ‌های یکنواخت می‌کرد.
- **افت سیگنال گرادینان (Vanishing Gradient in Extreme Samples):** در پرامپت‌هایی که تمام خروجی‌های گروه درست یا همگی غلط بودند، واریانس پاداش صفر شده و گرادینان آموزشی ناپدید می‌گشت که به کاهش اندازه موثر دسته و افت شدید نسبت سیگنال به نویز (SNR) می‌انجامید.
- **ناهمگونی وزن توکن‌ها (Sample vs. Token Level Imbalance):** میانگین‌گیری در سطح نمونه در روش‌های پیشین باعث می‌شد که توکن‌های مفید در پاسخ‌های طولانی سهم گرادینان اندکی دریافت کنند و الگوهای تکراری مخرب و هذیان‌های طویل (Repetitive Gibberish) به اندازه کافی جریمه نشوند.
- **نویز ناشی از برش سخت پاسخ‌ها (Truncation Reward Noise):** جریمه کردن پاسخ‌های درستی که صرفاً به سقف طول مجاز برخورد کرده بودند، سیگنال‌های گمراه‌کننده‌ای به مدل القا می‌کرد.

الگوریتم DAPO برای حل جامع این معضلات، چهار نوآوری اساسی را در قالب یک چارچوب بهینه‌سازی مقیاس‌پذیر ارائه داد.

مبانی نظری و اشتقاق‌های کامل ریاضی

فرض کنید یک توالی کامل تولیدشده به صورت $\tau = (q, o_1, o_2, \dots, o_T)$ نمایش داده شود که در آن q پرسش و o_t توکن‌های خروجی تحت خط‌مشی پارامتریزه π_θ هستند. هدف بهینه‌سازی بیشینه‌سازی

امید ریاضی پاداش است:

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [R(\tau)] = \int P(\tau; \theta) R(\tau) d\tau \quad (۲۹۰)$$

با مشتق‌گیری نسبت به بردار پارامترها θ طبق قاعده لاینیتس و اعمال اتحاد لگاریتمی تابع امتیاز $(\nabla_\theta P = P \nabla_\theta \log P)$:

(۲۹۱)

$$\nabla_\theta J(\theta) = \int \nabla_\theta P(\tau; \theta) R(\tau) d\tau = \int P(\tau; \theta) \nabla_\theta \log P(\tau; \theta) R(\tau) d\tau = \mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau; \theta) R(\tau)]$$

با توجه به ساختار خودبازگشتی مدل‌های زبانی $(P(\tau; \theta) = P(q) \prod_{t=1}^{|o|} \pi_\theta(o_t | q, o_{<t}))$ و کسر خط مبنای مستقل از عمل جهت کاهش واریانس، گرادینت بر حسب تابع مزیت $\hat{A}_t$ استخراج می‌شود:

$$\nabla_\theta J(\theta) = \mathbb{E}_{q \sim \mathcal{D}, o \sim \pi_\theta(\cdot | q)} \left[\sum_{t=1}^{|o|} \nabla_\theta \log \pi_\theta(o_t | q, o_{<t}) \hat{A}_t \right] \quad (۲۹۲)$$

با استفاده از نمونه‌برداری ترجیحی (Importance Sampling) برای استفاده مجدد از داده‌های جمع‌آوری‌شده توسط خط‌مشی قدیمی $\pi_{\theta_{\text{old}}}$ ، نسبت احتمالاتی برای توکن t به صورت زیر تعریف می‌شود:

$$r_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})} \quad (۲۹۳)$$

در الگوریتم **GRPO** [۲۴]، برای هر پرسش q یک گروه شامل G پاسخ $\{o_i\}_{i=1}^G$ تولید شده و مزیت هر نمونه به صورت نرمال‌سازی درون‌گروهی بدون شبکه منتقد محاسبه می‌شود:

$$\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G) + \epsilon_{\text{var}}} \quad (۲۹۴)$$

حذف جریمه واگرایی KL: برخلاف روش‌های رایج RLHF که عبارت جریمه $-\beta D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}})$ را برای جلوگیری از انحراف مدل تحمیل می‌کنند، در استدلال‌های طولانی، توزیع مدل برای یادگیری راهبردهای جدید باید بتواند به طور چشمگیری از مدل پایه اولیه فاصله بگیرد؛ لذا در **DAPO** ترم واگرایی KL به طور کامل حذف شده است ($\beta = 0$).

فرمولاسیون ریاضی و چهار نوآوری بنیادین DAPO

تابع هدف سراسری الگوریتم **DAPO** به صورت زیر تعریف می‌شود:

(۲۹۵)

$$J_{\text{DAPO}}(\theta) = \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}) \hat{A}_{i,t} \right) \right]$$

$$\text{s.t. } 0 < \sum_{i=1}^G \mathbb{I}(\text{is_equivalent}(a, o_i)) < G \quad (۲۹۶)$$

چهار رکن اساسی این فرمولاسیون عبارتند از:

۱. **برش نامتقارن به سمت بالا (Clip-Higher):** در برش متقارن کلاسیک ($\epsilon = 0.2$)، بیشینه نسبت احتمالاتی مجاز برای توکن‌های با مزیت مثبت برابر با $1 + \epsilon = 1.2$ است. برای توکن‌های استثنای

با احتمال اولیه بالا (مثلاً $\pi_{old} = 0.9$) بیشینه احتمال مجاز 1.08 بوده که اجازه رشد تا نزدیکی ۱ را می‌دهد. اما برای توکن‌های اکتشافی نادر (مثلاً $\pi_{old} = 0.01$)، سقف رشد مجاز تنها 0.012 است ($\Delta p = +0.002$). الگوریتم DAPO با تفکیک آستانه‌ها و قرار دادن $\varepsilon_{high} = 0.28$ و $\varepsilon_{low} = 0.20$ ، فضای کافی برای ارتقای توکن‌های اکتشافی فراهم می‌سازد و مانع فروپاشی آنتروپی می‌شود.

۲. نمونه‌برداری پویا (Dynamic Sampling): اگر تمامی نمونه‌های گروه برای یک پرامپت درست یا همگی غلط باشند، $\hat{A}_{i,t} = 0$ شده و گرادیان آموزشی آن پرامپت صفر می‌شود. DAPO با اعمال شرط قید در حین گردآوری داده، نمونه‌برداری را تا پر شدن کامل بافر با دسته‌های دارای گرادیان موثر ($0 < \text{Correct} < G$) ادامه می‌دهد که این امر نسبت سیگنال به نویز گرادیان را در بالاترین سطح نگه می‌دارد.

۳. تابع اتلاف در سطح توکن (Token-Level Policy Gradient Loss): بر خلاف GRPO که ابتدا اتلاف را بر طول هر نمونه $|o_i|$ تقسیم می‌کرد، DAPO نرمال‌سازی را بر مجموع کل توکن‌های گروه ($\sum_{i=1}^G |o_i|$) انجام می‌دهد. این امر موجب می‌شود توکن‌های الگوهای استدلالی بلندمرتبه ارزش‌گذاری عادلانه شده و توکن‌های هذیان‌گونه در پاسخ‌های معیوب به شدت تنبیه شوند.

۴. شکل‌دهی نرم پاداش طول پاسخ (Soft Overlong Punishment): برای جلوگیری از شوک گرادینانی ناشی از برش سخت پاسخ‌ها در طول L_{max} ، یک بازه حفاظتی L_{cache} تعریف شده و جریمه خطی پیوسته‌ای به پاداش درستی اضافه می‌گردد:

$$R_{\text{length}}(y) = \begin{cases} 0 & |y| \leq L_{max} - L_{cache} \\ \frac{(L_{max} - L_{cache}) - |y|}{L_{cache}} & L_{max} - L_{cache} < |y| \leq L_{max} \\ -1 & |y| > L_{max} \end{cases} \quad (۲۹۷)$$

تحلیل‌های تئوری اطلاعات و آمار ریاضی

آنتروپی شانون خط‌مشی به صورت $\mathcal{H}(\pi_{\theta}(\cdot|s)) = -\sum_{v \in \mathcal{V}} \pi_{\theta}(v|s) \log \pi_{\theta}(v|s)$ تعریف می‌شود. در الگوریتم‌های استاندارد، به دلیل محدودیت شدید رشد احتمالات کوچک، $\mathcal{H} \rightarrow 0$ میل کرده و توزیع احتمالاتی بر روی چند توکن محدود تیز می‌شود. راهبرد Clip-Higher باعث حفظ یک شیب ملایم مثبت در آنتروپی تولیدی در طول آموزش شده و از افت به سمت حالت دترمینستیک جلوگیری می‌نماید. همچنین نسبت سیگنال به نویز گرادیان که با $\text{SNR} = \frac{\|\mathbb{E}[g]\|_2}{\sqrt{\text{Tr}(\text{Cov}(g))}}$ تعریف می‌شود، در حضور نمونه‌برداری پویا به دلیل حذف گرادیان‌های تهی همواره در حالت ماکسیمم باقی می‌ماند.

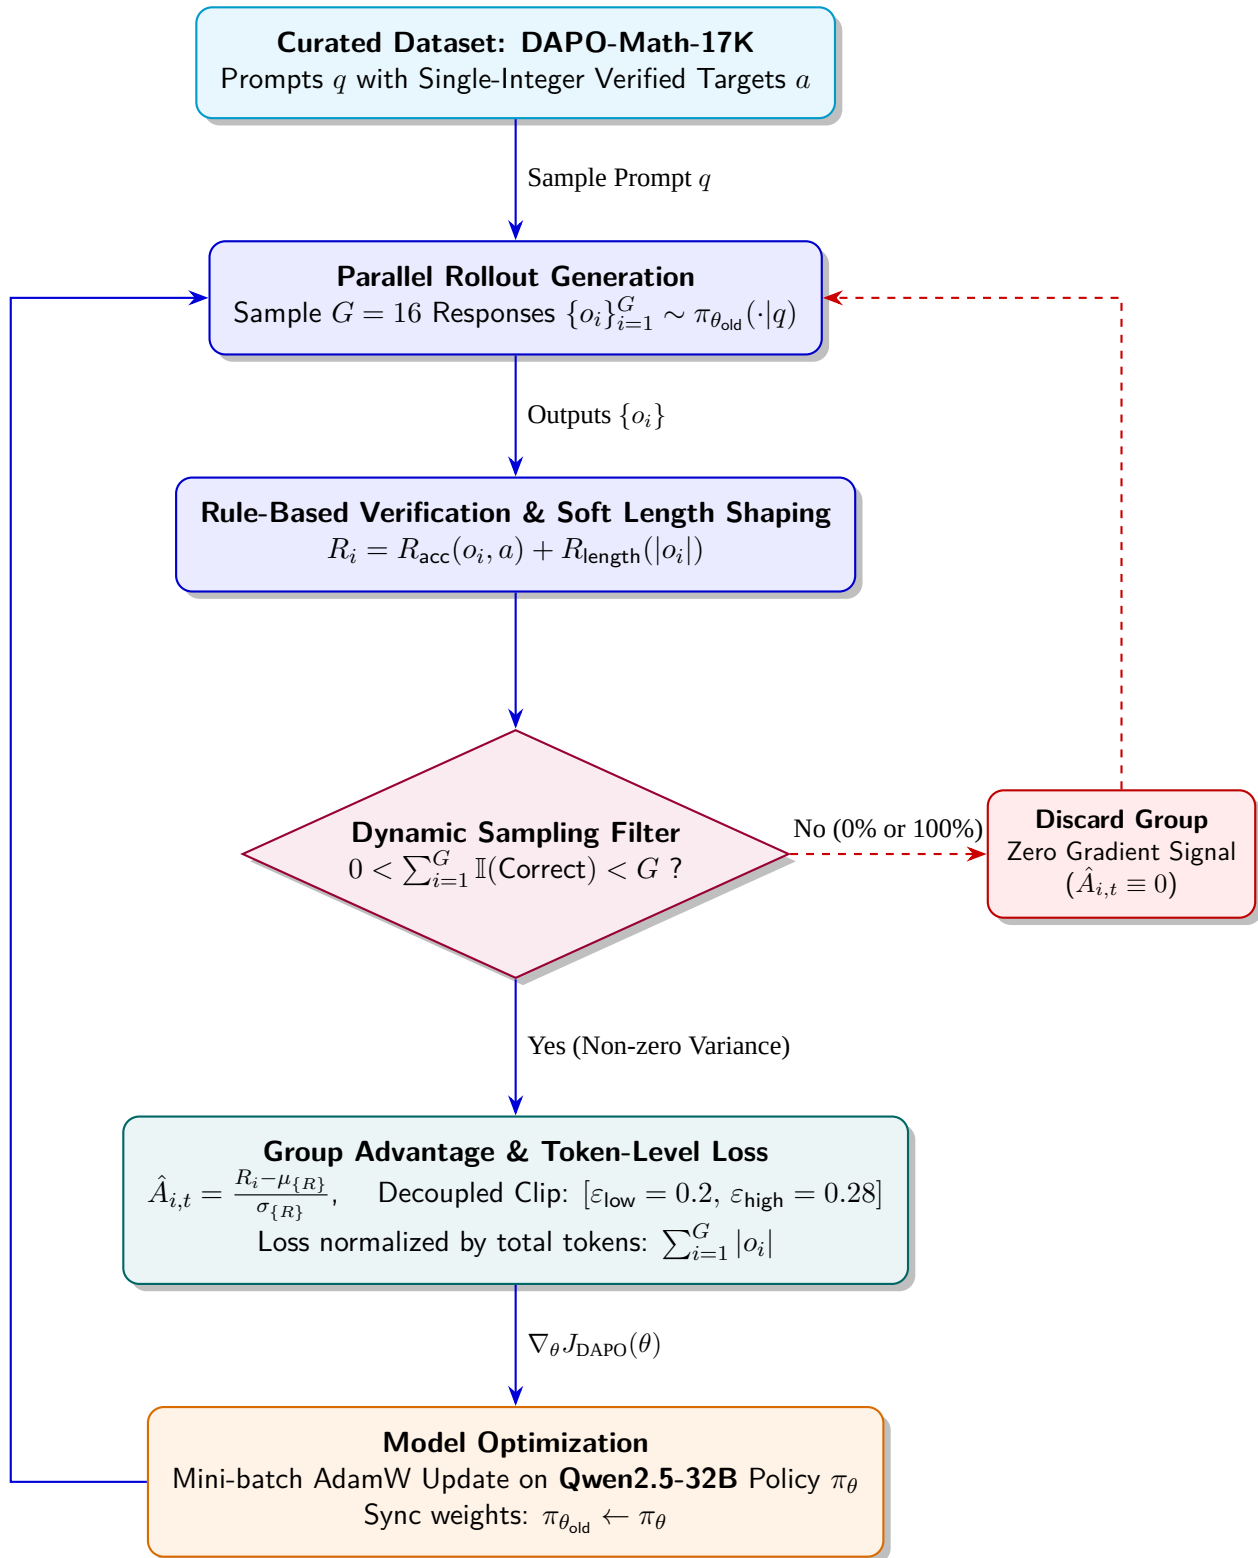
مهندسی داده و تبدیل مجموعه داده (DAPO-Math-17K)

برای بهره‌گیری از پاداش‌های قطعی مبتنی بر قاعده و حذف خطاهای ناشی از مفسرهای فرمول‌های ریاضی (Math Parsers)، مجموعه داده DAPO-Math-17K شامل ۱۷ هزار مسئله بازنویسی‌شده ایجاد شده است. در این فرآیند، با استفاده از مدل‌های زبانی و زنجیره تفکر، صورت مسائل به گونه‌ای بازنویسی شده‌اند که خروجی نهایی آن‌ها بدون استثنا یک **عدد صحیح منفرد** باشد؛ امری که ارزیابی پاداش را بر اساس تابع قطعی زیر مقدور می‌سازد:

$$R(\hat{y}, y) = \begin{cases} +1 & \text{is_equivalent}(\hat{y}, y) \\ -1 & \text{otherwise} \end{cases} \quad (۲۹۸)$$

دیگرام معماری و جریان داده‌های الگوریتم

شکل ۱۵، ساختار کلی جریان داده، فیلتر نمونه‌برداری پویا، شکل‌دهی پاداش و به‌روزرسانی خط‌مشی را در الگوریتم DAPO نشان می‌دهد.



شکل ۱۵: دیاگرام جامع جریان داده، نمونه‌برداری پویا، شکل‌دهی طول و بهینه‌سازی توکن‌محور در الگوریتم DAPO.

شبه‌کد الگوریتم DAPO

شبه‌کد کامل مراحل اجرایی الگوریتم DAPO در الگوریتم ۵ ارائه شده است:

Algorithm 5 Decoupled Clip and Dynamic Sampling Policy Optimization (DAPO)

```

1: Input: Initial policy  $\pi_\theta$ , verifiable reward function  $R$ , dataset  $\mathcal{D}$ , thresholds  $\varepsilon_{\text{low}}, \varepsilon_{\text{high}}$ , group size  $G$ , batch capacity  $N$ , update iterations  $\mu$ .
2: for step = 1, ...,  $M$  do
3:   Synchronize behavior policy:  $\pi_{\theta_{\text{old}}} \leftarrow \pi_\theta$ 
4:   Initialize dynamic buffer  $\mathcal{B}_{\text{dyn}} \leftarrow \emptyset$ 
5:   while  $|\mathcal{B}_{\text{dyn}}| < N$  do
6:     Sample a prompt batch  $\mathcal{D}_b \sim \mathcal{D}$ 
7:     for each question-answer pair  $(q, a) \in \mathcal{D}_b$  do
8:       Sample  $G$  independent rollouts  $\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)$ 
9:       Evaluate correctness count:  $C_q = \sum_{i=1}^G \mathbb{I}(\text{is\_equivalent}(a, o_i))$ 
10:      if  $C_q == 0$  or  $C_q == G$  then
11:        continue  $\triangleright$  Dynamic Sampling: Filter out degenerate zero-variance prompts
12:      end if
13:      for each response  $o_i$  do
14:        Compute length punishment  $R_{\text{length}}(|o_i|)$  via soft linear caching.
15:        Compute total reward  $R_i = R(o_i, a) + R_{\text{length}}(|o_i|)$ .
16:      end for
17:      Compute group statistics:  $\mu_R = \text{mean}(\{R_i\}_{i=1}^G)$ ,  $\sigma_R = \text{std}(\{R_i\}_{i=1}^G)$ .
18:      for each response  $o_i$  do
19:        Compute advantage:  $\hat{A}_{i,t} = (R_i - \mu_R) / (\sigma_R + 10^{-8})$ .
20:        Add tuple  $(q, o_i, \hat{A}_{i,t})$  to  $\mathcal{B}_{\text{dyn}}$ .
21:      end for
22:    end for
23:  end while
24:  for iter = 1, ...,  $\mu$  do
25:    Compute total token count:  $T_{\text{total}} = \sum_{o_i \in \mathcal{B}_{\text{dyn}}} |o_i|$ .
26:    Compute importance ratio:  $r_{i,t}(\theta) = \frac{\pi_\theta(o_{i,t}|q, o_{i,t})}{\pi_{\theta_{\text{old}}}(o_{i,t}|q, o_{i,t})}$ .
27:    Compute Token-Level Clipped Surrogate Loss:
28:     $J_{\text{DAPO}}(\theta) = \frac{1}{T_{\text{total}}} \sum_{i=1}^{|\mathcal{B}_{\text{dyn}}|} \sum_{t=1}^{|o_i|} \min \left( r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left( r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}} \right) \hat{A}_{i,t} \right)$ .
29:    Update policy parameters via AdamW:  $\theta \leftarrow \theta + \alpha \nabla_\theta J_{\text{DAPO}}(\theta)$ .
30:  end for
31: end for
32: Output: Optimized Reasoning Policy  $\pi_\theta$ .

```

نتایج تجربی، تحلیل پویایی آموزش و مطالعات موردی

اثربخشی گام‌به‌گام هر یک از تکنیک‌های پیشنهادی در جدول ۸۱ بر روی بنچمارک AIME 2024 خلاصه شده است:

پدیدار شدن رفتار خوداصلاحی (Emergence of Self-Correction): در طول آموزش با DAPO، رفتارهای بازبینی و خوداصلاحی عمیق بدون داده نظارت‌شده پدیدار گشت. به عنوان مثال در حل یک مسئله ترکیبیاتی، مدل پس از محاسبه مقدار کسری اشتباه $a_4 = 54.75$ برای تعداد افراد، تفکر خود را قطع کرده و بیان می‌کند:

جدول ۸۱: تحلیل ابلیشن و سهم پیشرونده تکنیک‌های DAPO روی مدل Qwen2.5-32B در بنچمارک AIME 2024 [۱۲۹].

مدل و راهبرد بهینه‌سازی	دقت AIME 2024 (avg@۳۲)
DeepSeek-R1-Zero-Qwen-32B (مرجع پیشین) [۲۸۱]	۰.۴۷٪
Naive GRPO (خط مبنای استاندارد)	۰.۳۰٪
+ فیلتر کردن پاسخ‌های قطع‌شده (Overlong Filtering)	۰.۳۶٪
+ برش نامتقارن به سمت بالا (Clip-Higher)	۰.۳۸٪
+ جریمه نرم طول پاسخ (Soft Overlong Punishment)	۰.۴۱٪
+ اتلاف در سطح توکن (Token-Level Loss)	۰.۴۲٪
+ نمونه‌برداری پویا (DAPO کامل)	۰.۵۰٪

”Since a_4 , the number of people owning all four items, must be a whole number, our current approach needs to be reconsidered...”

و سپس با بازتعریف متغیرها به پاسخ صحیح عدد صحیح دست می‌یابد.

ابریارمترهای استاندارد گزارش‌شده در مقاله

جدول ۸۲ مقادیر دقیق ابریارمترهای بهینه‌شده برای آموزش DAPO را نمایش می‌دهد:

مقدار	ابریارمتر
Qwen2.5-32B-Base	مدل پایه پیش‌آموزش‌دیده
[۲۸۲] verl (HybridFlow)	فریم‌ورک محاسباتی
[۲۸۳] AdamW	بهینه‌ساز
1×10^{-6} (ثابت با ۲۰ گام گرم‌کردن خطی)	نرخ یادگیری (Learning Rate)
۵۱۲	اندازه دسته پرامپت در Rollout
۱۶	تعداد نمونه به ازای هر پرامپت (G)
۵۱۲ (۱۶ گام به‌روزرسانی گرادیان به ازای هر Rollout)	اندازه مینی‌دسته آموزشی
۱۶،۳۸۴ توکن	سقف طول مجاز استدلال (L_{max})
۴،۰۹۶ توکن	بازه حافظه جریمه نرم (L_{cache})
۲۰،۴۸۰ توکن	حداکثر سقف مطلق طول تولید
۲۰.۰	حد آستانه برش پایین (ϵ_{low})
۲۸.۰	حد آستانه برش بالا (ϵ_{high})
دما $T = 1.0$ و $Top-p = 0.7$ روی ۳۲ بار ارزیابی	پارامترهای ارزیابی استنتاج

جمع‌بندی

الگوریتم DAPO با ترکیب چهار مولفه کلیدی Clip-Higher، Dynamic Sampling، Token-Level Loss و Soft Overlong Punishment نشان داد که چالش‌های بازتولید یادگیری تقویتی در استدلال‌های طولانی ناشی از کاستی‌های ظریف در فرمول‌بندی و پویایی‌های بهینه‌سازی است. انتشار متن‌باز کدها، معماری و پایگاه داده تبدیل‌شده DAPO-Math-17K، زیرساختی پایدار و تکرارپذیر را برای پژوهش‌های آینده در زمینه توسعه مدل‌های هوش مصنوعی استدلال‌گر در مقیاس بزرگ فراهم آورده است.

۵.۷ الگوریتم بهینه‌سازی خطمشی تطبیقی نرم (Soft Adaptive Pol-icy Optimization - SAPO)

الگوریتم SAPO که در اواخر سال ۲۰۲۵ توسط تیم Qwen در شرکت علی‌بابا (Alibaba Inc.) معرفی شد [۲۸۴]، یکی از پیشرفته‌ترین و پایدارترین روش‌های بهینه‌سازی خطمشی در مقیاس بزرگ برای مدل‌های زبانی استدلال‌گر (Reasoning LLMs) و مدل‌های چندوجهی (Vision-Language Models) به شمار می‌رود. این الگوریتم با بازنگری بنیادین در مکانیزم برش سخت (Hard Clipping) در روش‌های پیشین گروهی نظیر GRPO [۲۴] و GSPO [۲۸۵]، یک دروازه‌بندی نرم کنترل‌شده با دما (Temperature-Controlled Soft Gate) به همراه طراحی دمای نامتقارن برای گرادیان‌های مثبت و منفی معرفی می‌کند که مانع از فروپاشی زود هنگام آموزش (Early Training Collapse) شده و بهره‌وری نمونه‌ها را به حداکثر می‌رساند.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

با گسترش آموزش یادگیری تقویتی در مدل‌های زبانی بزرگ برای انجام استدلال‌های طولانی ریاضی، برنامه‌نویسی و منطقی [۲۷۹، ۲۸۶، ۲۸۷]، روش‌های مبتنی بر بهینه‌سازی گروهی (Group-based Policy Optimization) به عنوان استاندارد کارآمد جایگزین روش‌های کلاسیک نظیر PPO شدند:

- **معضل روش‌های برش سخت در سطح توکن (GRPO):** الگوریتم GRPO [۲۴] با حذف مدل نقاد (Critic) و نرمال‌سازی پاداش‌ها در یک گروه از پاسخ‌ها، هزینه محاسباتی را به شدت کاهش داد. با این حال، استفاده از تابع برش ناپیوسته در سطح توکن باعث ایجاد رفتار «همه یا هیچ» شد؛ به طوری که توکن‌هایی با نسبت اهمیت خارج از بازه $[1 - \epsilon, 1 + \epsilon]$ گرادیان صفر دریافت کرده و سیگنال‌های یادگیری ارزشمند از بین می‌رفتند.
- **معضل روش‌های برش در سطح توالی (GSPO):** الگوریتم GSPO [۲۸۵] برش را به میانگین هندسی نسبت‌های کل توالی اعمال کرد تا واریانس انباشته در توالی‌های طولانی را مهار کند. اما نقطه ضعف اساسی آن شکنندگی در برابر توکن‌های پرت (Outlier Tokens) بود؛ اگر تنها چند توکن ناهمگون در یک توالی وجود داشت، کل توالی بریده شده و گرادیان تمامی توکن‌های مفید درون آن توالی مسدود می‌شد.
- **ناپایداری در مدل‌های ترکیبی از متخصصان (MoE):** در معماری‌های MoE نظیر Qwen3-30B-A3B، به دلیل ناهمگونی مسیریابی توکن‌ها (Routing Heterogeneity) به متخصصان مختلف، واریانس نسبت‌های اهمیت $r_{i,t}$ فوق‌العاده افزایش می‌یابد که این پدیده به ناپایداری‌های شدید و سقوط آموزش در الگوریتم‌های سنتی می‌انجامد.

الگوریتم SAPO برای حل این چالش‌ها، یک ناحیه اطمینان پیوسته، نرم و دیفرانسیل‌پذیر معرفی می‌کند که در شرایط عادی انسجام سطح توالی را حفظ کرده و در صورت وجود توکن‌های پرت، به صورت تطبیقی تنها توکن‌های مخرب را مهار می‌نماید.

مبانی نظری و اشتقاق‌های کامل ریاضی الگوریتم SAPO

یک مدل زبانی خودبازگشت به عنوان خطمشی تصادفی π_θ بر روی توالی توکن‌های پاسخ $y = (y_1, y_2, \dots, y_{|y|})$ به ازای پرامپت ورودی $q \sim \mathcal{D}$ به صورت حاصل ضرب احتمال‌های شرطی تجزیه می‌شود:

$$\pi_\theta(y | q) = \prod_{t=1}^{|y|} \pi_\theta(y_t | q, y_{<t}) \quad (۲۹۹)$$

برای هر پرامپت q ، گروهی متشکل از G پاسخ مستقل $\{y_1, \dots, y_G\}$ از خطمشی رفتار $\pi_{\theta_{old}}$ نمونه‌برداری شده و پاداش‌های عددی $\{R_1, \dots, R_G\}$ محاسبه می‌شوند. مقدار مزیت نرمال‌شده گروهی $(\hat{A}_i)$ برای

پاسخ i -ام برابر است با:

$$\hat{A}_{i,t} = \hat{A}_i = \frac{R_i - \text{mean}(\{R_j\}_{j=1}^G)}{\text{std}(\{R_j\}_{j=1}^G) + 10^{-8}} \quad (300)$$

نسبت اهمیت در سطح توکن به صورت زیر تعریف می‌شود:

$$r_{i,t}(\theta) \triangleq \frac{\pi_{\theta}(y_{i,t} \mid q, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t} \mid q, y_{i,<t})} \quad (301)$$

تابع هدف بهینه‌سازی در الگوریتم SAPO:

$$J_{\text{SAPO}}(\theta) = \mathbb{E}_{q \sim \mathcal{D}, \{y_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot \mid q)} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} f_{i,t}(r_{i,t}(\theta)) \hat{A}_{i,t} \right] \quad (302)$$

که در آن تابع دروازه‌بندی نرم کنترل‌شده با دما $f_{i,t}(x)$ به صورت زیر تعریف می‌گردد:

$$f_{i,t}(x) = \sigma(\tau_{i,t}(x - 1)) \cdot \frac{4}{\tau_{i,t}}, \quad \tau_{i,t} = \begin{cases} \tau_{\text{pos}} & \text{if } \hat{A}_{i,t} > 0 \\ \tau_{\text{neg}} & \text{if } \hat{A}_{i,t} \leq 0 \end{cases} \quad (303)$$

در این رابطه، $\sigma(u) = \frac{1}{1+e^{-u}}$ تابع سیگموئید استاندارد است.

محاسبه تحلیلی گرادیان خط‌مشی در SAPO: با اعمال عملگر گرادیان ∇_{θ} به رابطه (302) و استفاده از قاعده زنجیره‌ای:

$$\nabla_{\theta} [f_{i,t}(r_{i,t}(\theta)) \hat{A}_{i,t}] = f'_{i,t}(r_{i,t}(\theta)) \cdot \nabla_{\theta} r_{i,t}(\theta) \cdot \hat{A}_{i,t} \quad (304)$$

مشتق نسبت اهمیت $\nabla_{\theta} r_{i,t}(\theta)$ بر اساس قاعده مشتق لگاریتمی برابر است با:

$$\nabla_{\theta} r_{i,t}(\theta) = \frac{\nabla_{\theta} \pi_{\theta}(y_{i,t} \mid q, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t} \mid q, y_{i,<t})} = r_{i,t}(\theta) \nabla_{\theta} \log \pi_{\theta}(y_{i,t} \mid q, y_{i,<t}) \quad (305)$$

مشتق اول تابع دروازه‌بندی $f'_{i,t}(x)$ نسبت به x :

$$f'_{i,t}(x) = \frac{4}{\tau_{i,t}} \cdot \frac{d}{dx} [\sigma(\tau_{i,t}(x - 1))] = \frac{4}{\tau_{i,t}} \cdot \tau_{i,t} \cdot \sigma'(\tau_{i,t}(x - 1)) = 4\sigma'(\tau_{i,t}(x - 1)) \quad (306)$$

با توجه به اتحاد مشتق تابع سیگموئید $\sigma'(u) = \sigma(u)(1 - \sigma(u))$ ، اگر $p_{i,t}(\theta) \triangleq \sigma(\tau_{i,t}(r_{i,t}(\theta) - 1))$ تعریف شود:

$$w_{i,t}(\theta) \triangleq f'_{i,t}(r_{i,t}(\theta)) = 4p_{i,t}(\theta)(1 - p_{i,t}(\theta)) \quad (307)$$

با استفاده از تعاریف توابع هذلولوی و رابطه $\frac{1}{4 \cosh^2(u/2)} = \frac{1}{4} \text{sech}^2(u/2)$ ، وزن گرادیان برابر می‌شود با:

$$w_{i,t}(\theta) = 4 \cdot \frac{1}{4} \text{sech}^2\left(\frac{\tau_{i,t}}{2}(r_{i,t}(\theta) - 1)\right) = \text{sech}^2\left(\frac{\tau_{i,t}}{2}(r_{i,t}(\theta) - 1)\right) \quad (308)$$

بنابراین، فرم نهایی گرادیان خط‌مشی به دست می‌آید:

$$\nabla_{\theta} J_{\text{SAPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} w_{i,t}(\theta) r_{i,t}(\theta) \nabla_{\theta} \log \pi_{\theta}(y_{i,t} \mid q, y_{i,<t}) \hat{A}_{i,t} \right] \quad (309)$$

اثبات حفظ رفتار روی خطمشی (On-Policy Consistency): در نقطه روی خطمشی که $r_{i,t}(\theta) = 1$ است:

$$p_{i,t} = \sigma(0) = \frac{1}{2} \implies w_{i,t} = 4 \left(\frac{1}{2} \right) \left(\frac{1}{2} \right) = 1 \quad (310)$$

این نتیجه اثبات می‌کند که در نقطه تعادل، گرادیان نرم SAPO دقیقاً برابر با گرادیان خطمشی بدون برش $r_{i,t} \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}$ است و ضریب $\frac{4}{\tau_{i,t}}$ در تعریف اولیه تابع $f_{i,t}$ دقیقاً جهت تضمین این شرط مقیاس‌گذاری شده است.

تحلیل گرادیان لاجیت‌ها و اثبات ضرورت دمای نامتقارن ($\tau_{\text{neg}} > \tau_{\text{pos}}$)

برای درک علت برتری دمای نامتقارن، انتشار گرادیان در لایه خروجی لاجیت‌ها $\mathbf{z} = [z_1, \dots, z_{|V|}]^T \in \mathbb{R}^{|V|}$ (با اندازه دایره واژگان $|V|$) را تحلیل می‌کنیم. توزیع احتمال توکن‌ها با تابع بیشینه هموار (Softmax) محاسبه می‌شود: $\pi_{\theta}(v) = \frac{e^{z_v}}{\sum_k e^{z_k}}$.

مشتق جزئی تابع اتلاف نسبت به لاجیت دلخواه z_v برابر است با:

$$\frac{\partial [\log \pi_{\theta}(y_{i,t}) \hat{A}_{i,t}]}{\partial z_v} = \frac{\hat{A}_{i,t}}{\pi_{\theta}(y_{i,t})} \cdot \frac{\partial \pi_{\theta}(y_{i,t})}{\partial z_v} \quad (311)$$

بر اساس ماتریس ژاکوبی تابع Softmax:

$$\text{توکن نمونه‌برداری شده: } v = y_{i,t} \quad \frac{\partial \pi_{\theta}(y_{i,t})}{\partial z_{y_{i,t}}} = \pi_{\theta}(y_{i,t}) (1 - \pi_{\theta}(y_{i,t})) \quad (312)$$

$$\text{سایر توکن‌ها: } v \neq y_{i,t} \quad \frac{\partial \pi_{\theta}(y_{i,t})}{\partial z_v} = -\pi_{\theta}(y_{i,t}) \pi_{\theta}(v) \quad (313)$$

با جایگذاری روابط فوق در رابطه (311)، گرادیان لاجیت‌ها حاصل می‌شود:

$$\frac{\partial \mathcal{L}_{i,t}}{\partial z_v} = \begin{cases} (1 - \pi_{\theta}(y_{i,t})) \hat{A}_{i,t} & \text{if } v = y_{i,t} \quad (\text{Sampled Token}) \\ -\pi_{\theta}(v) \hat{A}_{i,t} & \text{if } v \neq y_{i,t} \quad (\text{Unsampled Tokens}) \end{cases} \quad (314)$$

تحلیل تئوریک رفتار نامتقارن:

- **در شرایط مزیت مثبت ($\hat{A}_{i,t} > 0$):** لاجیت توکن نمونه‌برداری شده افزایش یافته و لاجیت تمامی توکن‌های دیگر با ضریب $-\pi_{\theta}(v) \hat{A}_{i,t} < 0$ به آرامی کاهش می‌یابد. این فرآیند ذاتاً همگرا و متمرکز است.

- **در شرایط مزیت منفی ($\hat{A}_{i,t} < 0$):** لاجیت توکن نمونه‌برداری شده کاهش می‌یابد؛ اما برای تمامی $|V| - 1$ توکن دیگر، مقدار $-\pi_{\theta}(v) \hat{A}_{i,t} > 0$ مثبت می‌شود! یعنی لاجیت صدها هزار توکن نامربوط به طور همزمان افزایش می‌یابد. این پدیده باعث پخش نویز گرادییانی شدید در دایره واژگان بزرگ شده و عامل اصلی ناپایداری آموزش است.

SAPO با تنظیم $\tau_{\text{neg}} > \tau_{\text{pos}}$ ، نرخ تضعیف گرادیان برای نمونه‌های با مزیت منفی را سریع‌تر می‌کند و بدین ترتیب نویز مخرب ناشی از انتشار مزیت منفی را مهار می‌نماید.

چارچوب یکپارچه سوروگیت و اثبات همگرایی به دروازه توالی (SAPO-GSPO اتصال)

فرض‌های تحلیلی:

- فرض A1 (گام‌های کوچک و نزدیکی به خط‌مشی): $r_{i,t}(\theta) \approx 1 \implies \log r_{i,t}(\theta) \approx r_{i,t}(\theta) - 1$
- فرض A2 (پراکندگی پایین درون توالی): با تعریف $z_{i,t} \triangleq \log r_{i,t}(\theta)$ و میانگین $\mu_i \triangleq \frac{1}{|y_i|} \sum_t z_{i,t}$ ، واریانس درون توالی $\text{Var}_i(\theta) \triangleq \frac{1}{|y_i|} \sum_t (z_{i,t} - \mu_i)^2$ برای اکثر توالی‌ها مقداری بسیار کوچک است.

تحت فرض A1 داریم $f'_{i,t}(r_{i,t}) = \text{sech}^2\left(\frac{\tau_i}{2}(r_{i,t} - 1)\right) \approx \text{sech}^2\left(\frac{\tau_i}{2} \log r_{i,t}\right) = g_{\tau_i}(z_{i,t})$ که در آن $g_{\tau}(z) \triangleq \text{sech}^2\left(\frac{\tau}{2}z\right)$ است.

با نوشتن بسط تیلور مرتبه دوم تابع $g_{\tau_i}(z_{i,t})$ حول نقطه میانگین $\mu_i = \log s_i(\theta)$:

$$g_{\tau_i}(z_{i,t}) = g_{\tau_i}(\mu_i) + g'_{\tau_i}(\mu_i)(z_{i,t} - \mu_i) + \frac{1}{2}g''_{\tau_i}(\xi_{i,t})(z_{i,t} - \mu_i)^2 \quad (315)$$

با میانگین‌گیری روی تمام توکن‌های توالی، جمله خطی اول دقیقاً صفر می‌شود:

$$\frac{1}{|y_i|} \sum_{t=1}^{|y_i|} g_{\tau_i}(z_{i,t}) = g_{\tau_i}(\mu_i) + \frac{1}{2|y_i|} \sum_{t=1}^{|y_i|} g''_{\tau_i}(\xi_{i,t})(z_{i,t} - \mu_i)^2 \quad (316)$$

با محاسبه مشتق دوم $g_{\tau}(z) = \text{sech}^2(\alpha z)$ با $\alpha = \frac{\tau}{2}$:

$$g''_{\tau}(z) = \alpha^2(4\text{sech}^2(\alpha z) - 6\text{sech}^4(\alpha z)) \implies \sup_z |g''_{\tau}(z)| = 2\alpha^2 = \frac{\tau^2}{2} \quad (317)$$

بنابراین، کران یکنواخت اختلاف میانگین دروازه توکن‌ها و دروازه توالی $D_i(\theta)$ حاصل می‌شود:

$$D_i(\theta) \triangleq \left| \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} g_{\tau_i}(z_{i,t}) - g_{\tau_i}(\log s_i(\theta)) \right| \leq \frac{1}{2} \sup_z |g''_{\tau_i}(z)| \text{Var}_i(\theta) = \frac{\tau_i^2}{4} \text{Var}_i(\theta) \quad (318)$$

از آنجا که $D_i(\theta) \approx 0$ است، گرادیان SAPO به فرم سطح توالی تقلیل می‌یابد:

$$\nabla_{\theta} J_{\text{SAPO}}(\theta) \approx \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \text{sech}^2\left(\frac{\tau_i}{2} \log s_i(\theta)\right) \nabla_{\theta} \log s_i(\theta) \hat{A}_i \right] \quad (319)$$

این اثبات نشان می‌دهد که SAPO در حالت عادی رفتاری کاملاً منسجم و هموار در سطح توالی (مشابه GSPO) دارد، اما در برخورد با توکن‌های پرت، به جای قطع کل گرادیان توالی، تنها توکن خطاکار را تضعیف می‌کند.

تحلیل‌های تئوری اطلاعات، آمار و دینامیک‌های ناحیه اطمینان

بر اساس بسط تیلور مرتبه دوم واگرایی کولبک-لایبیلر موضعی در سطح توکن:


$$D_{\text{KL}}(\pi_{\theta_{\text{old}}} \parallel \pi_{\theta}) \approx \frac{1}{2} \mathbb{E} [(\log r_{i,t}(\theta))^2] \quad (320)$$

در روش‌های برش سخت (GRPO و GSPO)، تابع جریمه در مرزهای برش دارای ناپیوستگی در مشتق اول است که شوک‌های بهینه‌سازی ایجاد می‌کند. در مقابل، تابع دروازه‌بندی SAPO از رده توابع بی‌نهایت بار مشتق‌پذیر (C^{∞}) بوده و یک ناحیه اطمینان پیوسته را شکل می‌دهد.

بررسی‌های تجربی روی بیش از 10^5 توالی و 10^9 توکن نشان می‌دهد که توزیع واریانس درون توالی $\text{Var}_i(\theta)$ در مدل‌های متراکم (Dense) نظیر Qwen3-4B کمتر از 0.005 و در مدل‌های ترکیبی از متخصصان (MoE) نظیر Qwen3-30B-A3B کمتر از 0.020 است. در هر دو حالت کران خطا $D_i(\theta) \leq \frac{\tau_i^2}{4} \text{Var}_i(\theta)$ زیر 0.005 باقی مانده و تقلیل تئوریک را به طور کامل در عمل پشتیبانی می‌کند.

دیاگرام معماری و جریان داده‌های الگوریتم

شکل ۱۶ ساختار پردازش داده، ارزیابی گروهی، اعمال دمای نامتقارن، دروازه‌بندی نرم و بهروزرسانی پارامترها در الگوریتم SAPO را نمایش می‌دهد.



شکل ۱۶: دیاگرام جامع جریان داده، انتخاب دمای نامتقارن، دروازه‌بندی نرم و بهینه‌سازی خطمشی در الگوریتم SAPO.

شبکه الگوریتم SAPO

شبکه استاندارد پیاده‌سازی بهینه‌سازی خطمشی تطبیقی نرم در الگوریتم ۶ ارائه شده است.

Algorithm 6 Soft Adaptive Policy Optimization (SAPO)

```

1: Input: Policy parameters  $\theta_0$ , behavior policy checkpoint  $\theta_{\text{old}} = \theta_0$ , prompt dataset  $\mathcal{D}$ , group size  $G$ , learning rate  $\eta$ , positive temperature  $\tau_{\text{pos}}$ , negative temperature  $\tau_{\text{neg}}$ , number of mini-batches  $M$ , epochs  $K$ .
2: for iteration = 1, 2, ...,  $N_{\text{iters}}$  do
3:   Sample a batch of queries  $\{q_1, q_2, \dots, q_B\} \sim \mathcal{D}$ .
4:   Initialize rollout storage buffer  $\mathcal{B}_{\text{rollout}} \leftarrow \emptyset$ .
5:   for each query  $q \in \{q_1, \dots, q_B\}$  do
6:     Sample  $G$  responses  $\{y_1, \dots, y_G\} \sim \pi_{\theta_{\text{old}}}(\cdot | q)$ .
7:     Compute rewards  $\{R_1, \dots, R_G\}$  via task-specific environment/verifier.
8:     Compute mean  $\mu_R = \frac{1}{G} \sum_{j=1}^G R_j$  and std  $\sigma_R = \sqrt{\frac{1}{G} \sum_{j=1}^G (R_j - \mu_R)^2} + 10^{-8}$ .
9:     for  $i = 1, \dots, G$  do
10:      Compute group-normalized advantage:  $\hat{A}_i = (R_i - \mu_R) / \sigma_R$ .
11:      Store cached old log-probabilities  $\{\log \pi_{\theta_{\text{old}}}(y_{i,t} | q, y_{i,<t})\}_{t=1}^{|y_i|}$ .
12:      Append tuple  $(q, y_i, \hat{A}_i, \{\log \pi_{\theta_{\text{old}}}(y_{i,t})\}_{t=1}^{|y_i|})$  to  $\mathcal{B}_{\text{rollout}}$ .
13:    end for
14:  end for
15:  Partition  $\mathcal{B}_{\text{rollout}}$  into  $M$  disjoint mini-batches  $\{\mathcal{M}_1, \dots, \mathcal{M}_M\}$ .
16:  for epoch = 1, ...,  $K$  do
17:    for each mini-batch  $\mathcal{M}_b$  do
18:      Initialize mini-batch loss:  $\mathcal{L}_{\text{mini}}(\theta) \leftarrow 0$ .
19:      for each sample  $(q, y_i, \hat{A}_i, \text{log-probs}) \in \mathcal{M}_b$  do
20:        Select asymmetric temperature:  $\tau_i \leftarrow \tau_{\text{pos}}$  if  $\hat{A}_i > 0$  else  $\tau_{\text{neg}}$ .
21:        Compute current log-probabilities  $\{\log \pi_{\theta}(y_{i,t} | q, y_{i,<t})\}_{t=1}^{|y_i|}$ .
22:        Initialize sequence objective:  $\mathcal{L}_{\text{seq}} \leftarrow 0$ .
23:        for  $t = 1, \dots, |y_i|$  do
24:          Compute token ratio:  $r_{i,t}(\theta) = \exp(\log \pi_{\theta}(y_{i,t}) - \log \pi_{\theta_{\text{old}}}(y_{i,t}))$ .
25:          Compute soft gate:  $f_{i,t}(r_{i,t}) = \frac{4}{\tau_i} \cdot \sigma(\tau_i(r_{i,t}(\theta) - 1))$ .
26:           $\mathcal{L}_{\text{seq}} \leftarrow \mathcal{L}_{\text{seq}} + f_{i,t}(r_{i,t}(\theta)) \cdot \hat{A}_i$ .
27:        end for
28:         $\mathcal{L}_{\text{mini}}(\theta) \leftarrow \mathcal{L}_{\text{mini}}(\theta) - \frac{1}{|y_i|} \mathcal{L}_{\text{seq}}$ .
29:      end for
30:      Update parameters:  $\theta \leftarrow \theta - \eta \cdot \nabla_{\theta} \left( \frac{1}{|\mathcal{M}_b|} \mathcal{L}_{\text{mini}}(\theta) \right)$ .
31:    end for
32:  end for
33:  Synchronize behavior policy checkpoint:  $\theta_{\text{old}} \leftarrow \theta$ .
34: end for

```

نتایج تجربی و ارزیابی بنچمارک‌ها

عملکرد الگوریتم SAPO در مقایسه با GRPO-R2 و GSPO روی مدل استدلال گر Qwen3-30B-A3B-Base در جدول ۸۳ خلاصه شده است.

تحلیل ابلیشن دمای نامتقارن (τ_{neg} در برابر τ_{pos}): جدول ۸۴ تأثیر تنظیم دماهای مختلف را نشان می‌دهد. بر اساس این نتایج، تعیین دمای بالاتر برای توکن‌های با مزیت منفی ($\tau_{\text{neg}} > \tau_{\text{pos}}$) نقش حیاتی در جلوگیری از انحرافات گرادینانی و تثبیت آموزش ایفا می‌کند.

آموزش مدل‌های چندوجهی (Qwen3-VL): در ارزیابی‌های مقیاس بزرگ روی سری مدل‌های چندوجهی Qwen3-VL-30B-A3B در چهار بنچمارک چندوجهی و متنی شامل AIME25 (با ۳۲ نمونه)، Live-

جدول ۸۳: مقایسه عملکرد نهایی و پایداری در بنچمارک‌های استدلال ریاضی (Pass@1 روی ۱۶ نمونه) [۲۸۴].

الگوریتم	AIME 2025	HMMT 2025	BeyondAIME	وضعیت پایداری آموزش
GRPO-R2 [۲۸۵، ۲۴]	۵٪.۷۶	۰٪.۵۷	۵٪.۵۱	سقوط در گام ۷۵۰ (Collapse)
GSPO [۲۸۵]	۰٪.۷۹	۰٪.۶۱	۰٪.۵۴	سقوط در گام ۱۲۵۰ (Collapse)
SAPO (پیشنهادی)	۲٪.۸۲	۵٪.۶۴	۸٪.۵۸	کاملاً پایدار (۱۷۵۰ > گام)

جدول ۸۴: تحلیل ابلیشن تنظیمات دما در الگوریتم SAPO روی مدل Qwen3-30B-A3B [۲۸۴].

پیکربندی دما	مقادیر	دقت در AIME25	دینامیک آموزش
$\tau_{neg} < \tau_{pos}$	$\tau_{neg} = 0.95, \tau_{pos} = 1.00$	۰٪.۷۱	ناپایداری بسیار شدید و سقوط زودهنگام
$\tau_{neg} = \tau_{pos}$	$\tau_{neg} = 1.00, \tau_{pos} = 1.00$	۵٪.۷۸	پایداری متوسط با افت‌های مقطعی
$\tau_{neg} > \tau_{pos}$ (اصلی)	$\tau_{neg} = 1.05, \tau_{pos} = 1.00$	۲٪.۸۲	بالاترین پایداری و رشد پیوسته

CodeBench v6 [۲۸۸] (با ۸ نمونه)، ZebraLogic [۲۸۹] و MathVision [۲۹۰]، الگوریتم SAPO تحت بودجه محاسباتی یکسان موفق شد به امتیاز اعتبارسنجی تجمعی ۷۶.۰ دست یابد و با اختلاف معنادار از GSPO (با امتیاز ۷۴۵.۰) و GRPO-R2 (با امتیاز ۷۳۸.۰) پیشی بگیرد.

جمع‌بندی

الگوریتم SAPO با جایگزین کردن برش سخت ناپیوسته با یک ناحیه اطمینان نرم (sech^2) و اعمال مکانیزم تنظیم دمای نامتقارن برای مهار نویز گرادیان‌های منفی، پایداری بهینه‌سازی خط‌مشی را متحول ساخته است. این الگوریتم بدون نیاز به سازوکارهای پرهزینه نظیر بازپخش مسیریابی (Routing Replay) در مدل‌های MoE، بالاترین دقت و بهره‌وری داده را به نمایش گذاشته و به عنوان چارچوبی استاندارد برای آموزش مدل‌های پیشرفته نسل جدید زبانی و چندوجهی شناخته می‌شود.

۶.۷ الگوریتم بهینه‌سازی خط‌مشی با ضریب اهمیت برش‌خورده (Clipped) (IS-weight Policy Optimization - CISPO)

الگوریتم CISPO یک الگوریتم پیشرفته در حوزه یادگیری تقویتی برون‌پویا (Off-Policy Reinforcement Learning) است که توسط آزمایشگاه MiniMax در سال ۲۰۲۵ و در جریان توسعه مدل استدلال‌گر بزرگ MiniMax-M1 معرفی شد [۲۱۹]. این الگوریتم با حذف کامل قید سنتی ناحیه اطمینان (Trust Region) روی گرادیان توکن‌ها و در عوض اعمال برش (Clipping) صرفاً بر روی وزن‌های نمونه‌برداری اهمیت (Importance Sampling Weights)، انقلابی در مقیاس‌پذیری پایدار و کارآمد فرآیند تفکر طولانی‌مدت (Long Chain-of-Thought) پدید آورده است.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

با پیدایش مدل‌های استدلال‌گر نظیر OpenAI o1 و DeepSeek-R1 [۱۰۳]، مقیاس‌پذیری محاسبات زمان آزمون (Test-Time Compute Scaling) به یکی از ارکان اصلی پیشرفت مدل‌های زبانی بدل شد. در این پارادایم، طول استدلال مدل به ده‌ها هزار توکن افزایش می‌یابد تا راه‌حل مسائل پیچیده المپیادی، ریاضیات و مهندسی نرم‌افزار کشف شود [۲۹۱].

با این حال، الگوریتم‌های استاندارد یادگیری تقویتی مانند PPO [۲۶۳] و GRPO [۲۴] در این زمینه با یک نقیصه ساختاری بنیادین تحت عنوان «پاتولوژی برش توکن» (The Pathology of Token Clipping) مواجه می‌شوند:

– نقش حیاتی توکن‌های بازتابی (Reflective Tokens): رفتارهای کلیدی در استدلال زنجیره‌ای طولانی مانند تفکر انتقادی و تصحیح مسیر، به توکن‌های کلیدی و اتصال‌دهنده‌ای نظیر «However»، «Wait»، «Recheck» و «Aha» وابسته‌اند. این توکن‌ها نقش دوشاخه‌شدن (Forks) در گراف مسیرهای استدلال را ایفا می‌کنند.

– احتمال پایه پایین و جهش نسبت اهمیت: این توکن‌ها در مدل پایه دارای احتمال اولیه اندکی هستند ($\pi_{\theta_{old}} \ll 1$). هنگامی که مدل پاداش مثبت دریافت می‌کند، در اولین به‌روزرسانی‌ها احتمال این توکن‌ها افزایش سریعی پیدا کرده و در نتیجه نسبت اهمیت $r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t})}{\pi_{\theta_{old}}(o_{i,t})}$ به سرعت از حد مجاز ($1 + \epsilon$) فراتر می‌رود.

– صفر شدن گرادیان در PPO و GRPO: در الگوریتم‌های سنتی، به محض عبور نسبت اهمیت از سقف $1 + \epsilon$ ، گرادیان مربوط به آن توکن صفر می‌شود. در سناریوهای بهینه‌سازی برون‌پویا که شامل چندین دور به‌روزرسانی ریزدسته (مثلاً ۱۶ دور در هر بچ داده) هستند، این توکن‌های حیاتی پس از اولین دور کاملاً از فرآیند یادگیری کنار گذاشته می‌شوند.

– تخریب پویایی آنتروپی و مهار CoT: حذف گرادیان توکن‌های بازتابی باعث سقوط آنتروپی [۲۹۲]، [۲۹۳]، ناپایداری بهینه‌سازی و مهار رفتارهای استدلالی بلندمدت می‌شود.

اگرچه الگوریتم DAPO [۱۲۹] تلاش نمود با بالا بردن سقف برش بالایی این چالش را کاهش دهد، اما این راهکار در چرخه‌های آف‌پالیسی طولانی ناکافی بوده و با کندی همگرایی همراه است. CISPO با بازطراحی ساختار تابع هدف، این مشکل را به‌صورت پایه‌ای مرتفع می‌سازد.

مبانی نظری و اشتقاق‌های کامل ریاضی از اصول اولیه

مسئله تصمیم‌گیری زبانی را در قالب یک فرآیند تصمیم‌گیری مارکوف با توزیع پرسش‌های $q \sim \mathcal{D}$ و توالی پاسخ $o = (o_1, o_2, \dots, o_{|o|})$ مدل‌سازی می‌کنیم. توزیع احتمال خودمبسته تولید پاسخ تحت خطمشی پارامتری π_{θ} عبارت است از:

$$P(o | q; \theta) = \prod_{t=1}^{|o|} \pi_{\theta}(o_t | q, o_{<t}) \quad (۳۲۱)$$

تابع هدف امید ریاضی پاداش در خطمشی به صورت زیر تعریف می‌شود:

$$J(\theta) = \mathbb{E}_{q \sim \mathcal{D}, o \sim \pi_{\theta}} [R(q, o)] = \sum_q P(q) \int_{\Omega_o} P(o | q; \theta) R(q, o) do \quad (۳۲۲)$$

با مشتق‌گیری نسبت به بردار پارامترهای $\theta \in \mathbb{R}^d$ و بهره‌گیری از اتحاد لگاریتمی ($\nabla_{\theta} P = P \nabla_{\theta} \log P$):

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \sum_q P(q) \int_{\Omega_o} \nabla_{\theta} P(o | q; \theta) R(q, o) do \\ &= \sum_q P(q) \int_{\Omega_o} P(o | q; \theta) \nabla_{\theta} \log P(o | q; \theta) R(q, o) do \\ &= \mathbb{E}_{q \sim \mathcal{D}, o \sim \pi_{\theta}} [\nabla_{\theta} \log P(o | q; \theta) R(q, o)] \end{aligned} \quad (۳۲۳)$$

با اعمال قاعده زنجیره‌ای بر لگاریتم احتمال زنجیره توکن‌ها:

$$\nabla_{\theta} \log P(o | q; \theta) = \sum_{t=1}^{|o|} \nabla_{\theta} \log \pi_{\theta}(o_t | q, o_{<t}) \quad (۳۲۴)$$

در بهینه‌سازی برون‌پویا (Off-Policy) که نمونه‌ها از خط‌مشی جمع‌آوری‌کننده قدیمی $\pi_{\theta_{old}}$ نمونه‌برداری می‌شوند، با استفاده از قضیه نمونه‌برداری اهمیت (Importance Sampling Theorem) داریم:

$$\mathbb{E}_{x \sim p}[f(x)] = \int p(x)f(x) dx = \int q(x)\frac{p(x)}{q(x)}f(x) dx = \mathbb{E}_{x \sim q}\left[\frac{p(x)}{q(x)}f(x)\right] \quad (۳۲۵)$$

نسبت وزن اهمیت توکنی برای توکن t -ام از پاسخ i -ام به صورت زیر تعریف می‌گردد:

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t} \mid q, o_{i,<t})} \quad (۳۲۶)$$

در فرمولاسیون GRPO [۲۴]، برای هر پرسش q تعداد G خروجی $\{o_i\}_{i=1}^G$ تولید شده و مزیت درون‌گروهی نرمال‌شده بدون نیاز به مدل نقاد (Critic-Free) محاسبه می‌شود:

$$\hat{A}_{i,t} = \hat{A}_i = \frac{R_i - \text{mean}(\{R_j\}_{j=1}^G)}{\text{std}(\{R_j\}_{j=1}^G) + \delta} \quad (۳۲۷)$$

تابع هدف REINFORCE با تصحیح توزیع برای به‌روزرسانی‌های آفلاین با بهره‌گیری از عملگر توقف مشتق (Stop-Gradient) $\text{sg}(\cdot)$ به صورت زیر بیان می‌شود:

$$\mathcal{J}_{\text{REINFORCE}}(\theta) = \mathbb{E}_{(q,a) \sim \mathcal{D}, o_i \sim \pi_{\theta_{old}}} \left[\frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \text{sg}(r_{i,t}(\theta)) \hat{A}_{i,t} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) \right] \quad (۳۲۸)$$

فرمولاسیون اختصاصی و مشتق گرادیان CISPO

به جای اعمال برش بر روی کل تابع هدف به‌روزرسانی که موجب قطع گرادیان می‌شود، الگوریتم CISPO برش را مستقیماً بر روی ضریب اهمیت اعمال کرده و آن را در داخل عملگر توقف مشتق قرار می‌دهد:

$$\hat{r}_{i,t}(\theta) = \text{clip}(r_{i,t}(\theta), 1 - \epsilon_{\text{low}}^{IS}, 1 + \epsilon_{\text{high}}^{IS}) \quad (۳۲۹)$$

تابع هدف نهایی الگوریتم CISPO با تلفات در سطح توکن (Token-Level Loss) عبارت است از: (۳۳۰)

$$\mathcal{J}_{\text{CISPO}}(\theta) = \mathbb{E}_{q \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \text{sg}(\hat{r}_{i,t}(\theta)) \hat{A}_{i,t} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) \right]$$

با محاسبه صریح گرادیان نسبت به پارامترهای θ :

$$\nabla_{\theta} \mathcal{J}_{\text{CISPO}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \hat{r}_{i,t}(\theta) \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) \right] \quad (۳۳۱)$$

تمایز بنیادین گرادیان: در معادله فوق، از آنجا که $\hat{r}_{i,t}(\theta) \geq 1 - \epsilon_{\text{low}}^{IS} > 0$ همواره مقداری اکیداً مثبت است، مقدار مشتق $\nabla_{\theta} \log \pi_{\theta}$ هرگز صفر نمی‌شود. در نتیجه تمامی توکن‌ها با ضریب مقیاس متناسب و کران‌دار در هدایت گرادیان شبکه مشارکت خواهند داشت. در کاربرد عملی، کران پایین حذف شده ($\epsilon_{\text{low}}^{IS} \rightarrow \infty$) و تنها $\epsilon_{\text{high}}^{IS}$ تنظیم می‌شود.

فرمولاسیون تعمیم‌یافته و مقایسه‌ای (A Unified Formulation)

برای مقایسه روش‌های برش، می‌توان یک فرمولاسیون جامع با معرفی ماسک توکنی $M_{i,t}$ تعریف نمود:

$$\mathcal{J}_{\text{unify}}(\theta) = \mathbb{E} \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \text{sg}(\hat{r}_{i,t}(\theta)) \hat{A}_{i,t} \log \pi_{\theta}(o_{i,t} \mid q, o_{i,<t}) M_{i,t} \right] \quad (332)$$

که در آن ماسک ناحیه اطمینان برابر است با:

$$M_{i,t} = \begin{cases} 0 & \text{if } \hat{A}_{i,t} > 0 \text{ and } r_{i,t}(\theta) > 1 + \epsilon_{\text{high}} \\ 0 & \text{if } \hat{A}_{i,t} < 0 \text{ and } r_{i,t}(\theta) < 1 - \epsilon_{\text{low}} \\ 1 & \text{otherwise} \end{cases} \quad (333)$$

جدول ۸۵ تفاوت ساختاری این الگوریتم‌ها را به تصویر می‌کشد.

جدول ۸۵: مقایسه ساختاری الگوریتم‌های یادگیری تقویتی برون‌پویا بر پایه فرمولاسیون یکپارچه.

الگوریتم	تعریف وزن اهمیت $\hat{r}_{i,t}$	وضعیت ماسک $M_{i,t}$	حفظ گرادینان توکن‌های نادر	نیاز به مدل نقاد (Critic)
PPO [۲۶۳]	$r_{i,t}(\theta)$	شرطی (حذف گرادینان در خروج از مرز)	خیر	بله
GRPO [۲۴]	$r_{i,t}(\theta)$	شرطی (حذف گرادینان در خروج از مرز)	خیر	خیر
DAPO [۱۲۹]	$r_{i,t}(\theta)$	شرطی با ϵ_{high} بسیار بزرگتر	تا حدی	خیر
CISPO [۲۱۹]	$\text{clip}(r_{i,t}, 1 - \epsilon_{\text{low}}^{IS}, 1 + \epsilon_{\text{high}}^{IS})$	همواره فعال ($M_{i,t} = 1$)	کامل (۱۰۰٪ توکن‌ها)	خیر

تحلیل‌های تئوری اطلاعات، آمار و پویایی آنتروپی

– **توازن بایاس و واریانس (Bias-Variance Tradeoff):** واریانس برآوردگر نمونه‌برداری اهمیت متناسب با واگرایی رنی مرتبه دوم $d_2(\pi_{\theta} \parallel \pi_{\theta_{\text{old}}})$ رشد می‌کند. اعمال برش مستقیم بر وزن $\hat{r}_{i,t} \leq 1 + \epsilon_{\text{high}}^{IS}$ کران بالای واریانس گرادینان را محبوس می‌سازد:

$$\text{Var} [\nabla_{\theta} \mathcal{J}_{\text{CISPO}}] \leq (1 + \epsilon_{\text{high}}^{IS})^2 \cdot \text{Var} [\hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}] \quad (334)$$

این رویکرد مقداری بایاس اندک وارد می‌کند اما مانع از واگرایی واریانس در دنباله‌های طولانی ($L \geq 40K$) می‌شود.

– **تثبیت آنتروپی شانون و عدم نیاز به جریمه KL:** آنتروپی در سطح توکن به صورت $\mathcal{H}(\pi_{\theta}) = - \sum_v \pi_{\theta}(v) \log \pi_{\theta}(v)$ محاسبه می‌شود. از آنجا که گرادینان توکن‌های اقلیت با آنتروپی بالا حذف نمی‌شود، توزیع مدل دچار فروپاشی نابهنگام (Premature Collapse) نشده و نیاز به افزودن جریمه مستقیم واگرایی کولبک-لایبیلر (D_{KL}) منتفی می‌گردد [۲۹۳].

چالش‌های مقیاس‌پذیری در معماری‌های هیبرید و راهکارهای مهندسی


مدل **MiniMax-M1** از ساختار ترکیبی متشکل از ۷ بلوک Transormer با مکانیزم توجه خطی صاعقه‌ای (Lightning Attention) [۲۹۴] به ازای هر ۱ بلوک توجه استاندارد Softmax بهره می‌برد. آموزش یادگیری تقویتی در مقیاس ۴۵۶ میلیارد پارامتر با این معماری نیازمند راهکارهای مهندسی زیر بود:

۱. **رفع عدم تطابق دقت محاسباتی (Precision Mismatch):** تفاوت جزئی در خروجی هسته‌های محاسباتی آموزش و استنتاج مانع رشد پاداش می‌شد. با ارتقای دقت لایه خروجی سرپیش‌بینی کلمات (LM Output Head) به FP32، همبستگی پیرسون احتمالات از ۹۸.۰ به بالای ۹۹۷.۰ افزایش یافت.

۲. **پیکربندی بهینه‌ساز AdamW:** با توجه به بازه گسترده بزرگی گرادیان‌ها (10^{-18} تا 10^{-5})، پارامترهای بهینه‌ساز به صورت $\beta_1 = 0.9$ ، $\beta_2 = 0.95$ و $\epsilon = 10^{-15}$ تنظیم شدند [۲۹۵].
۳. **توقف زودهنگام مبتنی بر تشخیص تکرار (Repetition Early Truncation):** در صورت مشاهده ۳۰۰۰ توکن متوالی با احتمال بالای ۹۹.۰، تولید متوقف می‌شود تا از مصرف بیهوده کانتکست و تزریق گرادیان‌های ناپایدار جلوگیری شود.
۴. **راهبرد توسعه مرحله‌ای پنجره کانتکست (Staged Window Expansion):** طول تولید از ۴۰K آغاز و به ترتیب به ۴۸K، ۵۶K، ۶۴K، ۷۲K و نهایتاً ۸۰K ارتقا یافت.

دیاگرام جامع جریان داده، عملیات و انتشار گرادیان

شکل ۱۷ معماری کامل چرخه داده، ارزیابی، برش ضرایب و پس‌انتشار گرادیان را در الگوریتم CISPO نشان می‌دهد.



شکل ۱۷: دیاگرام جامع جریان داده، محاسبه مزیت درون‌گروهی، برش ضرایب اهمیت و به‌روزرسانی در الگوریتم CISPO.

شبه‌کد استاندارد الگوریتم CISPO

الگوریتم ۷، روند اجرایی یادگیری تقویتی مدل با الگوریتم CISPO را شرح می‌دهد:

Algorithm 7 Clipped IS-weight Policy Optimization (CISPO)

```

1: Input: Policy parameters  $\theta$ , base reference/sampling model  $\pi_{\theta_{\text{old}}}$ , group size  $G$ , upper IS clip threshold  $\epsilon_{\text{high}}^{\text{IS}}$ , learning rate schedule  $\eta$ , number of off-policy epochs  $K$ , repetition early stopping threshold  $L_{\text{rep}} = 3000$ .
2: for iteration = 1, 2, ... do
3:   Sample a batch of queries  $\{q_m\}_{m=1}^B \sim \mathcal{D}$ .
4:   Set trajectories buffer  $\mathcal{B} \leftarrow \emptyset$ .
5:   for each query  $q_m$  do
6:     Sample  $G$  independent responses  $\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot | q_m)$  using rollout engine.
7:     Apply repetition detection: Halt generation if  $L_{\text{rep}}$  consecutive tokens have  $P(o_t) > 0.99$ .
8:     Compute rewards  $R_i = \mathcal{R}(q_m, o_i)$  via rule checkers or Generative Reward Model (GenRM).
9:     Compute group mean  $\mu_R = \frac{1}{G} \sum_{j=1}^G R_j$  and std  $\sigma_R = \sqrt{\frac{1}{G} \sum_{j=1}^G (R_j - \mu_R)^2} + 10^{-8}$ .
10:    Compute advantage for each response:  $\hat{A}_i = (R_i - \mu_R) / \sigma_R$ .
11:    Store  $(q_m, o_i, \log \pi_{\theta_{\text{old}}}(o_i | q_m), \hat{A}_i)$  in buffer  $\mathcal{B}$ .
12:  end for
13:  for epoch = 1, ...,  $K$  do
14:    Clear gradients:  $\nabla_{\theta} \mathcal{J} \leftarrow 0$ .
15:    Total batch tokens:  $N_{\text{total}} = \sum_{(q,o) \in \mathcal{B}} |o|$ .
16:    for each  $(q, o_i, \log \pi_{\theta_{\text{old}}}(o_i | q), \hat{A}_i) \in \mathcal{B}$  do
17:      Compute current token log-probabilities  $\log \pi_{\theta}(o_{i,t} | q, o_{i,<t})$  with FP32 LM head.
18:      Compute token-level importance ratio:  $r_{i,t}(\theta) = \exp(\log \pi_{\theta}(o_{i,t}) - \log \pi_{\theta_{\text{old}}}(o_{i,t}))$ .
19:      Clip importance weight:  $\hat{r}_{i,t}(\theta) = \min(r_{i,t}(\theta), 1 + \epsilon_{\text{high}}^{\text{IS}})$ .
20:      Compute loss component:
21:       $\mathcal{L}_i(\theta) = -\frac{1}{N_{\text{total}}} \sum_{t=1}^{|o_i|} \text{sg}(\hat{r}_{i,t}(\theta)) \hat{A}_i \log \pi_{\theta}(o_{i,t} | q, o_{i,<t})$ .
22:      Accumulate gradients:  $\nabla_{\theta} \mathcal{J} \leftarrow \nabla_{\theta} \mathcal{J} + \nabla_{\theta} \mathcal{L}_i(\theta)$ .
23:    end for
24:    Clip global gradient norm:  $g \leftarrow \text{clip\_norm}(\nabla_{\theta} \mathcal{J}, \text{max\_norm} = 1.0)$ .
25:    Update policy parameters using AdamW ( $\beta_1 = 0.9, \beta_2 = 0.95, \epsilon = 10^{-15}$ ):
26:     $\theta \leftarrow \theta - \eta \cdot \text{AdamW}(g)$ .
27:  end for
28:  Synchronize rollout policy:  $\theta_{\text{old}} \leftarrow \theta$ .
29: end for

```

ارزیابی‌های تجربی و تحلیل نتایج بنچمارک‌ها

بر اساس ارزیابی‌های تجربی ارائه‌شده در گزارش فنی MiniMax-M1 [۲۱۹]، نتایج به شرح زیر حاصل شده است:

- **شتاب آموزش ۲ برابری نسبت به DAPO:** در آزمون کنترل‌شده روی مدل Qwen2.5-32B در بنچمارک ریاضی AIME 2024، الگوریتم CISPO با مصرف تنها ۵۰٪ از گام‌های آموزشی به عملکردی برابر با DAPO دست یافته و هر دو الگوریتم GRPO و DAPO را پشت سر گذاشت.
- **کاهش چشمگیر هزینه آموزش:** ترکیب توجه هیبرید با الگوریتم CISPO آموزش کامل مدل ۴۵۶ میلیارد پارامتری را روی ۵۱۲ پردازنده H800 در مدت تنها ۳ هفته و با هزینه تقریبی ۵۳۴،۷۰۰ دلار تکمیل نمود.

جدول ۸۶ نتایج جامع مدل‌های آموزش‌دیده با CISPO را در مقایسه با پیشرفته‌ترین مدل‌های متن‌باز و تجاری جهان نشان می‌دهد.

جدول ۸۶: ارزیابی مقایسه‌ای مدل‌های MiniMax-M1 آموزش‌دیده با الگوریتم CISPO در بنچمارک‌های استاندارد بین‌المللی [۲۱۹].

وظیفه / بنچمارک	OpenAI o3	Gemini 2.5 Pro	Claude 4 Opus	DeepSeek-R1	Qwen3-235B	M1-40k	M1-80k
سقف طول تفکر	۱۰۰K	۶۴K	۶۴K	۶۴K	۳۲K	۴۰K	۸۰K
استدلال ریاضی (Mathematics)							
۲۰۲۴ AIME	۶.۹۱	۰.۹۲	۰.۷۶	۴.۹۱	۷.۸۵	۳.۸۳	۰.۸۶
۲۰۲۵ AIME	۹.۸۸	۰.۸۸	۰.۷۵	۵.۸۷	۵.۸۱	۶.۷۴	۹.۷۶
MATH-۵۰۰	۱.۹۸	۸.۹۸	۲.۹۸	۰.۹۸	۲.۹۶	۰.۹۶	۸.۹۶
کدنویسی و مهندسی نرم‌افزار (Coding & Software Engineering)							
LiveCodeBench	۸.۷۵	۱.۷۷	۶.۵۶	۱.۷۳	۹.۶۵	۳.۶۲	۰.۶۵
Verified SWE-bench	۱.۶۹	۲.۶۷	۵.۷۲	۶.۵۷	۴.۳۴	۶.۵۵	۰.۵۶
بافت فوق طولانی (Long Context Understanding)							
(۱۲۸k) OpenAI-MRCR	۵.۵۶	۸.۷۶	۹.۴۸	۵.۵۱	۷.۲۷	۱.۷۶	۴.۷۳
(۱M) OpenAI-MRCR	—	۸.۵۸	—	—	—	۶.۵۸	۲.۵۶
LongBench-v۲	۸.۵۸	۰.۶۵	۶.۵۵	۱.۵۲	۱.۵۰	۰.۶۱	۵.۶۱
استفاده از ابزار و عامل هوشمند (Agentic Tool Use)							
(Airline) TAU-bench	۰.۵۲	۰.۵۰	۶.۵۹	۵.۵۳	۷.۳۴	۰.۶۰	۰.۶۲
(Retail) TAU-bench	۹.۷۳	۰.۶۷	۴.۸۱	۹.۶۳	۶.۵۸	۸.۶۷	۵.۶۳

جمع‌بندی

الگوریتم CISPO با تشخیص آسیب‌شناسی پنهان در توابع هدف رایج و ارائه راه‌حل مبتنی بر برش وزن اهمیت (IS-Weight Clipping)، موفق شده است ضمن حفظ کامل سیگنال‌های گرادیان در تمام مسیرهای بازتابی و استدلالی، واریانس آموزش برون‌پویا را به طور کامل مهار نماید. این الگوریتم اکنون به عنوان یکی از پایدارترین و اقتصادی‌ترین استانداردهای آموزش یادگیری تقویتی برای ساخت مدل‌های استدلال‌گر بزرگ در مقیاس‌های کانتکست میلیونی شناخته می‌شود.

۷.۷ الگوریتم یادگیری تقویتی با پاداش‌های اعتبارسنجی‌پذیر (Re-enforcement Learning with Verifiable Rewards - RLVR)

الگوریتم RLVR به عنوان مرحله نهایی خط‌لوله پس‌آموزش در مدل‌های Tulu 3 توسط لمبرت (Nathan Lambert) و همکاران در موسسه هوش مصنوعی آلن (Ai2) معرفی شد [۱۶۳]. این الگوریتم با جایگزین ساختن مدل‌های پاداش آماری و تقریبی با توابع اعتبارسنجی قطعی، عملکرد مدل‌های زبانی را در وظایف منطقی، محاسباتی و پیروی دقیق از دستورات به طور چشمگیری ارتقا می‌دهد.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

در خطوط لوله متداول هم‌ترازسازی زبانی بر پایه RLHF [۲۹۶، ۲۹۷، ۲۷۲]، بهینه‌سازی سیاست توسط یک مدل پاداش (Reward Model - RM) آموزش‌دیده بر ترجیحات انسانی یا بازخورد هوش مصنوعی (RLAIF) هدایت می‌شود. با این حال، استفاده از مدل پاداش با دو چالش اساسی روبرو است:

– **بهینه‌سازی مغرط و هک پاداش (Reward Hacking / Goodhart's Law):** همان‌طور که گائو و همکاران [۲۹۸] و سینگهال و همکاران [۲۹۹] نشان داده‌اند، در گام‌های بالای بهینه‌سازی، خط‌مشی یادگیرنده نقاط کور و سوگیری‌های آماری مدل پاداش (مانند گرایش به پاسخ‌های طولانی یا لحن متملقانه) را به عنوان میان‌بر بهره‌برداری کرده و بدون افزایش کیفیت حقیقی پاسخ، امتیاز پاداش بالایی کسب می‌کند.

– **عدم قطعیت در مسائل با درستی قطعی (Deterministic Verifiability):** در حوزه‌هایی نظیر حل مسائل ریاضیات [۳۰۰، ۷۲]، اجرای کدهای برنامه‌نویسی و آزمون‌های ساختاریافته دست‌پزیری [۳۰۱]، درستی پاسخ متکی به ترجیحات حسی انسان نبوده بلکه یک گزاره منطقی دودویی (درست یا غلط) است که مدل‌های پاداش استاندارد توان ارزیابی بی‌نقص آن را ندارند.

پیش از این، روش‌هایی مانند STaR [۳۰۲]، Quiet-STaR [۳۰۳]، TRICE [۳۰۴]، بازخورد محیطی در کدنویسی [۳۰۵] و VinePPO [۳۰۶] تلاش کردند از سیگنال درستی پاسخ استفاده کنند. الگوریتم RLVR این دیدگاه را تکامل بخشیده و چارچوبی آنلاین و عمومی بر بستر PPO ارائه می‌دهد که بدون نیاز به برچسب‌گذاری تقریب‌گرایانه، مستقیماً پاداش‌های دودویی قطعی را به عنوان سیگنال تقویت زنجیره تفکر مدل زبانی به کار می‌گیرد.

مبانی نظری و اشتقاق‌های کامل ریاضی

فرض کنید یک فرآیند تصمیم‌گیری مارکوف در سطح تولید توکن برای مدل زبانی تعریف شده است. حالت $s_t = (x, y_{<t})$ شامل پرامپت ورودی $x \sim \mathcal{D}$ و توکن‌های پیشین تولیدشده $y_{<t} = (y_1, \dots, y_{t-1})$ است و عمل $a_t = y_t \in \mathcal{V}$ انتخاب توکن بعدی از واژگان $\mathcal{V}$ است.

تابع هدف پیشینه‌سازی در الگوریتم RLVR به صورت زیر تعریف می‌شود:

$$\max_{\pi_{\theta}} \mathcal{J}(\theta) = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot|x)} [R_{\text{RLVR}}(x, y)] \quad (۳۳۵)$$

که در آن پاداش کل با تنظیم‌سازی واگرایی کولبک-لایبلر (KL-Divergence) به فرم زیر تعریف می‌گردد:

$$R_{\text{RLVR}}(x, y) = v(x, y) - \beta D_{\text{KL}}(\pi_{\theta}(y|x) \parallel \pi_{\text{ref}}(y|x)) \quad (۳۳۶)$$

۱. تابع اعتبارسنجی قطعی (Deterministic Verifier Function):

تابع اعتبارسنجی $v(x, y)$ یک مپینگ قطعی روی زوج ورودی-پاسخ است:

$$v(x, y) = \begin{cases} \alpha & \text{اگر استخراج پاسخ با پاسخ صحیح برابر باشد (Verify}(x, y) = 1) \\ 0 & \text{در غیر این صورت} \end{cases} \quad (۳۳۷)$$

در پیاده‌سازی رسمی [۱۶۳]، ضریب پاداش $\alpha = 10.0$ تنظیم شده است. همچنین به ازای پاسخ‌هایی که تا انتهای سقف توکن به توکن پایانی EOS نرسند، جریمه $r_{\text{penalty}} = -10.0$ اعمال می‌شود.

۲. تفکیک پاداش در سطح توکن و واگرایی KL:

واگرایی KL توالی کامل $y = (y_1, \dots, y_T)$ بر حسب ضرب احتمالات شرطی توکن‌ها برابر است با:

$$D_{\text{KL}}(\pi_{\theta}(y|x) \parallel \pi_{\text{ref}}(y|x)) = \sum_{t=1}^T \log \left(\frac{\pi_{\theta}(y_t | x, y_{<t})}{\pi_{\text{ref}}(y_t | x, y_{<t})} \right) \quad (۳۳۸)$$

از این رو پاداش اختصاص‌یافته به هر توکن در لحظه t به شکل زیر فرمول‌بندی می‌شود:

$$r_t(x, y) = \begin{cases} -\beta \log \left(\frac{\pi_{\theta}(y_t | x, y_{<t})}{\pi_{\text{ref}}(y_t | x, y_{<t})} \right) & \text{for } 1 \leq t < T \\ v(x, y) - \beta \log \left(\frac{\pi_{\theta}(y_T | x, y_{<T})}{\pi_{\text{ref}}(y_T | x, y_{<T})} \right) & \text{for } t = T \end{cases} \quad (۳۳۹)$$

۳. محاسبه مزیت با GAE و بهینه‌سازی PPO:

خطای تفاضل زمانی (Temporal Difference Error) برای تابع ارزش V_{ϕ} با ضریب تخفیف $\gamma = 1.0$ به صورت زیر است:

$$\delta_t^V = r_t + \gamma V_{\phi}(s_{t+1}) - V_{\phi}(s_t) \quad (۳۴۰)$$

تابع مزیت تعمیم‌یافته (GAE) با ضریب تعادل $\lambda = 0.95$ محاسبه می‌شود:

$$\hat{A}_t^{\text{GAE}} = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}^V \quad (341)$$

مقادیر مزیت در سطح هر دسته به منظور کنترل واریانس نرمال‌سازی می‌شوند:

$$\hat{A}_t^{\text{norm}} = \frac{\hat{A}_t^{\text{GAE}} - \mu(\hat{A}^{\text{GAE}})}{\sigma(\hat{A}^{\text{GAE}}) + 10^{-8}} \quad (342)$$

تابع هدف برش‌خورده سیاست (Clipped Surrogate Policy Loss) در RLVR به صورت زیر تعریف می‌شود:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta) \hat{A}_t^{\text{norm}}, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t^{\text{norm}} \right) \right] \quad (343)$$

که در آن $\rho_t(\theta) = \frac{\pi_\theta(y_t|s_t)}{\pi_{\theta_{\text{old}}}(y_t|s_t)}$ نسبت احتمالات سیاست و $\epsilon = 0.2$ است. تابع هزینه کل شامل خطای پیش‌بینی ارزش $L^{\text{VF}}(\phi) = (V_\phi(s_t) - V_t^{\text{targ}})^2$ به فرم زیر است:

$$\mathcal{L}_{\text{total}}(\theta, \phi) = -L^{\text{CLIP}}(\theta) + c_1 L^{\text{VF}}(\phi) \quad (344)$$

که در آن $c_1 = 0.1$ ضریب تلفات تابع ارزش است.

تحلیل‌های تئوری اطلاعات و آمار

سیگنال پاداش $v(x, y)$ در RLVR به شدت تنک (Sparse) و ناپیوسته است. بهینه‌سازی مستقیم چنین پاداشی بدون جریمه واگرایی، منجر به فروریزش توزیع احتمالات بر روی الگوهای غیرطبیعی و از دست رفتن روانی زبان می‌گردد. از منظر تئوری اطلاعات، قید واگرایی $D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}})$ سطح آنتروپی زبانی مدل را پایدار نگاه داشته و شعاع جستجوی سیاست را در نزدیکی منیفولد توزیع اولیه حفظ می‌کند. بررسی‌های تجربی [۱۶۳] نشان می‌دهد کاهش بیش از حد ضریب β (مانند $\beta = 0.01$) باعث پدیده بهینه‌سازی مفرط و هک قواعد ساختاری می‌شود؛ برای نمونه در آزمون‌های قیود متنی (IFEval)، مدل برای برآورده کردن شرط تکرار کلمه، اقدام به تکرار طوطی‌وار و بی‌معنای همان کلمه می‌کند (شکل ۲۸ در مقاله مرجع). از این رو تنظیم دقیق $\beta \in [0.05, 0.1]$ برای ایجاد تعادل میان درستی منطقی و حفظ گرامر ساختاری الزامی است.

جزئیات زیرساخت محاسباتی و توزیع داده‌ها

۱. **مجموعه داده‌های اعتبارسنجی‌پذیر:** ترکیب نهایی شامل ۲۹,۹۴۶ پرامپت در سه حوزه اصلی است:
 - **مجموعه GSM8K:** شامل ۷,۴۷۳ مسئله ریاضی مقطع ابتدایی با پرامپت هشت‌نمونه‌ای CoT و اعتبارسنجی با استخراج قطعی عدد پایانی.
 - **مجموعه MATH:** شامل ۷,۵۰۰ مسئله ریاضی پیشرفته با پرامپت چهارنمونه‌ای و استخراج منعطف به همراه اعتبارسنجی نمادین با بسته SymPy.
 - **مجموعه IFEval:** شامل ۱۴,۹۷۳ نمونه ترکیبی همراه با توابع بررسی قاعده دستوری بر پایه عبارات منظم (Regex).

۲. معماری ناهمگام (Asynchronous RL Infrastructure):


برای غلبه بر گلوگاه محاسباتی فاز تولید، موتور استنتاج vLLM [۳۰۷] با مکانیزم PagedAttention بر روی گره‌های اختصاصی تفکیک شده و مدل‌های یادگیرنده (Learners) با استفاده از فناوری DeepSpeed ZeRO-3 [۳۰۸] گرادیان‌ها را به طور همزمان محاسبه می‌کنند [۳۰۹]. وزن‌های جدید پس از هر دور آپدیت با استفاده از بروتوکست NCCL به موتورهای استنتاج ارسال می‌شوند.

۳. نکات پیاده‌سازی کلیدی:

- **مقداردهی اولیه مدل ارزش:** مدل ارزش V_ϕ مستقیماً از یک مدل پاداش عمومی آموزش دیده روی UltraFeedback مقداردهی می شود که پایداری همگرایی را نسبت به مقداردهی تصادفی به طور معناداری ارتقا می دهد.
- **صفر کردن نرخ دراپ اوت (Zero Dropout):** در طول آموزش، Dropout کاملاً غیرفعال است تا محاسبه لاگ-احتمالات در دو فاز نمونه برداری و یادگیری کاملاً قطعی و بدون انحراف باقی بماند [۳۱۰].

دیاگرام جامع جریان محاسباتی الگوریتم RLVR

شکل ۱۸ جریان داده ها، موتور اعتبارسنجی قطعی، نحوه کسر جریمه واگرایی KL و چرخه به روزرسانی ناهمگام در الگوریتم RLVR را نشان می دهد.



شکل ۱۸: جریان داده ها و معماری محاسباتی ناهمگام الگوریتم RLVR در چارچوب Tulu 3.

شبکه الگوریتم RLVR

شبکه اجرای کامل الگوریتم RLVR در الگوریتم ۸ به تصویر کشیده شده است:

Algorithm 8 Reinforcement Learning with Verifiable Rewards (RLVR)

```

1: Input: Policy parameters  $\theta_0$  (from DPO checkpoint), reference policy  $\pi_{\text{ref}}$ , value model parameters  $\phi_0$  (initialized from RM), verifiable dataset  $\mathcal{D}$ , reward weight  $\alpha = 10.0$ , KL penalty  $\beta$ , PPO clip ratio  $\epsilon = 0.2$ , GAE parameters  $\gamma = 1.0, \lambda = 0.95$ .
2: for iteration = 1, 2, ...,  $N_{\text{steps}}$  do
3:   Sample a batch of prompts with ground truth:  $\{(x^{(i)}, y_{\text{gold}}^{(i)})\}_{i=1}^B \sim \mathcal{D}$ .
4:   // Step 1: Parallel Rollout Generation via vLLM Engine
5:   for each prompt  $x^{(i)}$  in batch do
6:     Sample completion  $y^{(i)} = (y_1^{(i)}, \dots, y_T^{(i)}) \sim \pi_{\theta_{\text{old}}}(\cdot | x^{(i)})$ .
7:     Compute rollout log-probs:  $\log \pi_{\theta_{\text{old}}}(y_t^{(i)} | x^{(i)}, y_{<t}^{(i)})$ .
8:     Compute reference log-probs:  $\log \pi_{\text{ref}}(y_t^{(i)} | x^{(i)}, y_{<t}^{(i)})$ .
9:     Compute estimated state values:  $V_{\phi}(s_t^{(i)})$ .
10:    Evaluate deterministic correctness:  $c^{(i)} \leftarrow \text{Verify}(x^{(i)}, y^{(i)}, y_{\text{gold}}^{(i)}) \in \{0, 1\}$ .
11:    Set final verifiable reward:  $v(x^{(i)}, y^{(i)}) \leftarrow \alpha \cdot c^{(i)} - 10.0 \cdot \mathbb{I}_{[y_T^{(i)} \neq \text{EOS}]}$ .
12:  end for
13:  // Step 2: Token-Level Reward Assignment and GAE Computation
14:  for each token step  $t = 1, \dots, T$  and sequence  $i = 1, \dots, B$  do
15:    Compute token reward:
16:     $r_t^{(i)} \leftarrow -\beta \left( \log \pi_{\theta_{\text{old}}}(y_t^{(i)} | s_t^{(i)}) - \log \pi_{\text{ref}}(y_t^{(i)} | s_t^{(i)}) \right) + \mathbb{I}_{[t=T]} \cdot v(x^{(i)}, y^{(i)})$ .
17:    Compute TD residual:  $\delta_t^{V,(i)} \leftarrow r_t^{(i)} + \gamma V_{\phi}(s_{t+1}^{(i)}) - V_{\phi}(s_t^{(i)})$ .
18:  end for
19:  Compute advantage estimates:  $\hat{A}_t^{(i)} \leftarrow \sum_{l=0}^{T-t-1} (\gamma \lambda)^l \delta_{t+l}^{V,(i)}$  and target values  $V_t^{\text{target},(i)} \leftarrow \hat{A}_t^{(i)} + V_{\phi}(s_t^{(i)})$ .
20:  Standardize advantages across batch:  $\hat{A}_t^{\text{norm},(i)} \leftarrow \frac{\hat{A}_t^{(i)} - \mu(\hat{A})}{\sigma(\hat{A}) + 10^{-8}}$ .
21:  // Step 3: Asynchronous Multi-Epoch Learner Optimization
22:  for epoch = 1, ...,  $K_{\text{epochs}}$  do
23:    for each minibatch  $\mathcal{B}$  do
24:      Compute current log-probabilities:  $\log \pi_{\theta}(y_t | s_t)$ .
25:      Compute probability ratio:  $\rho_t(\theta) \leftarrow \exp(\log \pi_{\theta}(y_t | s_t) - \log \pi_{\theta_{\text{old}}}(y_t | s_t))$ .
26:      Compute policy loss:
27:       $L^{\text{CLIP}}(\theta) \leftarrow \frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} \min \left( \rho_t(\theta) \hat{A}_t^{\text{norm}}, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t^{\text{norm}} \right)$ .
28:      Compute value function loss:
29:       $L^{\text{VF}}(\phi) \leftarrow \frac{1}{|\mathcal{B}|} \sum_{t \in \mathcal{B}} (V_{\phi}(s_t) - V_t^{\text{target}})^2$ .
30:      Update parameters via Adam:  $\theta, \phi \leftarrow \text{OptimizerStep}(\nabla_{\theta, \phi} [-L^{\text{CLIP}}(\theta) + c_1 L^{\text{VF}}(\phi)])$ .
31:    end for
32:  end for
33:  Synchronize updated weights:  $\theta_{\text{old}} \leftarrow \theta$  via NCCL broadcast to inference nodes.
34: end for

```

نتایج تجربی و تحلیل‌های مقایسه‌ای

تأثیر اعمال مرحله RLVR پس از بهینه‌سازی DPO در ابعاد مختلف مدلی در جدول ۸۷ خلاصه شده است.

جدول ۸۷: ارزیابی مقایسه‌ای مدل‌های آموزش‌دیده با RLVR در مقایسه با مبدا DPO و خط مبای Llama 3.1 Instruct [۱۶۳].

مقیاس ۷۰B			مقیاس ۸B			معیار ارزیابی / چمارک
RLVR ۳ Tülu	DPO ۳ Tülu	۱.۳ Llama	RLVR ۳ Tülu	DPO ۳ Tülu	۱.۳ Llama	
۰.۷۶	۹.۷۵	۴.۷۳	۸.۶۴	۴.۶۴	۲.۶۲	میانگین کل (Avg.)
۰.۶۳	۳.۶۲	۴.۵۶	۷.۴۳	۰.۴۲	۵.۴۲	CoT) (۴-shot, MA
۵.۹۳	۵.۹۳	۷.۹۳	۶.۸۷	۳.۸۴	۴.۸۳	CoT) (۸-shot, GSM
۲.۸۳	۶.۸۲	۰.۸۸	۴.۸۲	۱.۸۱	۶.۸۰	(Strict) IFEval
۸.۴۹	۶.۴۹	۴.۳۳	۵.۳۴	۵.۳۳	۲.۲۴	(LC Winrate) Alpaca
۰.۸۲	۸.۸۱	۸.۷۳	۰.۶۶	۸.۶۵	۸.۶۲	(۳-shot) BigBench
۳.۷۴	۱.۷۴	۰.۷۷	۶.۶۲	۵.۶۲	۵.۶۱	Fi) (۳-shot, DROP

ابریارامترهای بهینه‌سازی الگوریتم RLVR

جدول ۸۸ مقادیر دقیق ابریارامترهای بهینه‌شده برای اجرای الگوریتم RLVR در مقیاس‌های مختلف را نشان می‌دهد:

جدول ۸۸: پیکربندی ابریارامترهای آموزش الگوریتم RLVR در مدل‌های 3 Tülu.

۴۰۵B مدل	۷۰B مدل	۸B مدل	ابریارامتر
1×10^{-7}	1×10^{-7}	3×10^{-7}	نرخ یادگیری سیاست (Policy LR)
۰۵.۰	۰۷.۰	۰۵.۰	ضریب جریمه واگرایی (β)
۱۸۵۶	۶۴۰	۲۲۴	اندازه دسته موثر (Effective Batch Size)
۱	۴	۴	تعداد دور بهینه‌سازی در هر اپیزود (K)
۱۰۲۴	۲۰۴۸	۲۰۴۸	حداکثر طول توکن پاسخ
۲.۰	۲.۰	۲.۰	آستانه برش PPO (ϵ)
۰.۱۰	۰.۱۰	۰.۱۰	ضریب پاداش اعتبارسنجی (α)
۰.۱۰-	۰.۱۰-	۰.۱۰-	جریمه عدم تولید توکن EOS
۰.۱	۰.۱	۰.۱	ضریب تخفیف پاداش (γ)
۹۵.۰	۹۵.۰	۹۵.۰	ضریب پارامتر λ در GAE

جمع‌بندی

الگوریتم RLVR با ادغام پاداش‌های قطعی و اثبات‌پذیر در چارچوب گرادیان سیاست مقید به KL، معضل دیرینه هک پاداش در حوزه‌های نیازمند استدلال نمادین و منطقی را برطرف کرده است. این روش بدون فدا کردن توانایی‌های گفتگوی عمومی، مدل‌های خانواده 3 Tülu را در حل مسائل ریاضی و رعایت دقیق قیود نگارشی به سطحی رقابت‌پذیر با مدل‌های تجاری پیشرو ارتقا داده است.

۸.۷ الگوریتم یادگیری تقویتی با پاداش‌های قابل اعتبارسنجی و بهینه‌سازی گروهی (OlmoRL: RLVR + GRPO)

الگوریتم OlmoRL که در جریان توسعه خانواده مدل‌های زبانی باز Olmo 3 توسط مؤسسه هوش مصنوعی آلن (Ai2) در سال ۲۰۲۵ معرفی شد [۳۱۱]، یک چارچوب پیشرفته در حوزه پس‌آموزش (Post-Training) استدلالی به شمار می‌رود. این الگوریتم با ارتقا و بازمهندسی الگوریتم بهینه‌سازی خط‌مشی

نسبی گروهی (Group Relative Policy Optimization - GRPO) [۲۴] و تلفیق آن با یادگیری تقویتی مبتنی بر پاداش‌های قابل اعتبارسنجی (Reinforcement Learning with Verifiable Rewards - RLVR)، امکان آموزش پایدار و مقیاس‌پذیر مدل‌های زبانی را برای تولید زنجیره‌های طولانی تفکر (Long Think-ing Traces) تا سقف ۳۲۷۶۸ توکن بدون نیاز به شبکه نقاد (Critic Network) فراهم می‌سازد.

تاریخچه، انگیزه و ضرورت پیدایش الگوریتم

توسعه مدل‌های استدلالی متن‌باز در سال‌های اخیر با چالش‌های بنیادین در مرحله یادگیری تقویتی روبرو بوده است:

- **محدودیت‌های ساختاری الگوریتم PPO:** الگوریتم سنتی PPO [۲۶۳] نیازمند نگهداری یک شبکه نقاد مستقل هم‌اندازه با مدل زبانی جهت تخمین تابع ارزش $V(s)$ است. در مدل‌های زبانی بزرگ، این شبکه معادل با دوبرابر شدن مصرف حافظه گرافیکی (VRAM) بوده و تخمین ارزش برای توالی‌های متنی بسیار طولانی با نوسانات شدید و ناپایداری همراه است.
- **نارسایی‌های الگوریتم GRPO اولیه در توالی‌های طولانی:** اگرچه GRPO [۲۴] با جایگزینی خط مبنای گروهی (Group Baseline) نیاز به نقاد را مرتفع ساخت، اما در مواجهه با زنجیره‌های تفکر طولانی با معضلاتی نظیر «سوگیری طول» (Length Bias)، «سوگیری دشواری ناشی از نرمال‌سازی انحراف معیار» [۳۱۲] و «اتلاف محاسبات در دسته‌های با گرادیان صفر» مواجه می‌شود [۱۲۹].
- **رانس توزیع در استنتاج ناهمگام (Off-Policy Drift):** در سیستم‌های توزیع‌شده مقیاس‌بزرگ، عدم انطباق آماری میان موتور استنتاج سریع نظیر vLLM و موتور آموزش (Learner)، تخمین نسبت اهمیت را مخدوش می‌سازد [۱۷۳].

الگوریتم OlmoRL با هدف برطرف ساختن این موانع، افزایش پایداری در طول دوره‌های طولانی آموزش، بهینه‌سازی بهره‌وری توان محاسباتی سخت‌افزار (MFU) و گسترش مرزهای استدلال مدل به فراتر از داده‌های نظارت‌شده طراحی شده است.

مبانی نظری و اشتقاق‌های کامل ریاضی

مدل زبانی به عنوان خط‌مشی تصادفی پارامتریزه شده π_θ تعریف می‌شود که به ازای پرامپت ورودی $x = (x_1, \dots, x_M)$ ، توالی توکن‌های پاسخ $y = (y_1, \dots, y_T)$ را به صورت خودبازگشتی تولید می‌کند:

$$\pi_\theta(y|x) = \prod_{t=1}^T \pi_\theta(y_t|x, y_{<t}) \quad (۳۴۵)$$

که در آن $y_{<t} = (y_1, \dots, y_{t-1})$ تاریخچه توکن‌های پیشین است.

هدف یادگیری تقویتی، بهینه‌سازی امید ریاضی پاداش اسکالر $r(x, y)$ تحت توزیع خط‌مشی است:

$$J(\theta) = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(\cdot|x)} [r(x, y)] = \sum_x P(x) \sum_y \pi_\theta(y|x) r(x, y) \quad (۳۴۶)$$

با اعمال عملگر گرادیان و استفاده از قاعده مشتق لگاریتمی $(\nabla_\theta \pi = \pi \nabla_\theta \log \pi)$:

$$\begin{aligned} \nabla_\theta J(\theta) &= \sum_x P(x) \sum_y \nabla_\theta \pi_\theta(y|x) r(x, y) \\ &= \sum_x P(x) \sum_y \pi_\theta(y|x) \nabla_\theta \log \pi_\theta(y|x) r(x, y) \\ &= \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_\theta(\cdot|x)} [\nabla_\theta \log \pi_\theta(y|x) r(x, y)] \end{aligned} \quad (۳۴۷)$$

با باز کردن رابطه برای تک تک توکن‌های توالی پاسخ:

$$\nabla_{\theta} \log \pi_{\theta}(y|x) = \sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(y_t|x, y_{<t}) \quad (۳۴۸)$$

جهت کاهش واریانس، یک خط مبنای مستقل از پاسخ $b(x)$ کسر می‌گردد:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot|x)} \left[\sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(y_t|x, y_{<t}) (r(x, y) - b(x)) \right] \quad (۳۴۹)$$

در رویکرد گروهی GRPO، به ازای هر پرامپت x ، تعداد G پاسخ مستقل $\{y_1, y_2, \dots, y_G\}$ توسط خط‌مشی پیشین $\pi_{\theta_{old}}$ تولید می‌شود. الگوریتم OlmoRL هفت اصلاح بنیادی را بر این پایه پیاده‌سازی می‌کند:

۱. **حذف نرمال‌سازی با انحراف معیار (No Standard Deviation Normalization):** در GRPO اولیه، مزیت از تقسیم بر انحراف معیار گروه (σ) حاصل می‌شد. طبق تحلیل‌های [۳۱۲]، این عمل باعث می‌شود در مسائل بسیار سخت یا بسیار آسان که واریانس گروه ناچیز است، مزیت منفجر شده و خط‌مشی دچار بی‌ثباتی گردد. در OlmoRL مزیت صرفاً به عنوان اختلاف پاداش با میانگین گروه تعریف می‌شود:

$$A_{i,t} = r(x, y_i) - \text{mean}(\{r(x, y_k)\}_{k=1}^G) = r(x, y_i) - \frac{1}{G} \sum_{k=1}^G r(x, y_k) \quad (۳۵۰)$$

۲. **نرمال‌سازی در سطح توکن (Token-Level Normalization):** به دلیل تنوع طول زنجیره‌های استدلال، میانگین‌گیری در سطح نمونه منجر به وزن‌دهی نابرابر به توکن‌ها می‌شود. OlmoRL مجموع خطاهای دسته را بر کل توکن‌های معتبر تمام خروجی‌های گروه تقسیم می‌کند: $\frac{1}{\sum_{i=1}^G |y_i|}$ [۱۲۹].

۳. **برش نامتقارن گرادیان (Clip-Higher):** نسبت احتمالات گرادیان توکن t به صورت زیر تعریف می‌شود:

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(y_{i,t}|x, y_{i,<t})}{\pi_{\theta_{old}}(y_{i,t}|x, y_{i,<t})} \quad (۳۵۱)$$

به منظور فراهم‌سازی امکان به‌روزرسانی‌های بزرگ‌تر در جهات مثبت، برش نامتقارن با مقادیر $\varepsilon_{low} = 0.2$ و $\varepsilon_{high} = 0.272$ اعمال می‌گردد [۱۲۹]:

$$\text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{low}, 1 + \varepsilon_{high}) \quad (۳۵۲)$$

۴. **تصحیح نمونه‌برداری ترجیحی منقطع (Truncated Importance Sampling - TIS):** جهت جبران رانش احتمال میان خروجی موتور استنتاج π_{vllm} و موتور یادگیرنده $\pi(\cdot; \theta_{old})$ ، ضریب تصحیح زیر اعمال می‌شود [۱۷۳]:

$$w_{i,t}^{TIS} = \min \left(\frac{\pi(y_{i,t}|x, y_{i,<t}; \theta_{old})}{\pi_{vllm}(y_{i,t}|x, y_{i,<t}; \theta_{old})}, \rho \right) \quad (۳۵۳)$$

که در آن ρ سقف مجاز بازوزن‌دهی است.

۵. **حذف جریمه صریح واگرایی کولبک-لایبلر (No-KL Objective):** ترم جریمه صریح D_{KL} از تابع هزینه حذف شده تا آزادی اکتشاف مدل در یافتن زنجیره‌های استدلال جدید محدود نگردد [۱۲۹، ۳۱۲].

۶. **فیلتر کردن سیگنال‌های گرادیان صفر (Zero Gradient Signal Filtering):** گروه‌هایی که پاداش تمام نمونه‌های آن‌ها یکسان باشد ($A_{i,t} = 0$)، پیش از گام پس‌انتشار به طور کامل حذف می‌گردند.

۷. **نمونه‌برداری فعال پویا (Active Dynamic Sampling):** صف توزیع‌شده به صورت بلادرنگ پرامپت‌های فیلترشده را جایگزین می‌کند تا اندازه دسته آموزشی همواره ثابت بماند.

تابع هدف نهایی الگوریتم OlmoRL

با تجميع روابط فوق، تابع هدف نهایی بهینه‌سازی در OlmoRL به صورت رابطه ریاضی زیر تعریف می‌شود:

$$J(\theta) = \frac{1}{\sum_{i=1}^G |y_i|} \sum_{i=1}^G \sum_{t=1}^{|y_i|} \min \left(\frac{\pi(y_{i,t}|x, y_{i,<t}; \theta_{\text{old}})}{\pi_{\text{vllm}}(y_{i,t}|x, y_{i,<t}; \theta_{\text{old}})}, \rho \right) \cdot \min(r_{i,t}(\theta) A_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}}) A_{i,t})$$

معماری سیستم پاداش‌های قابل اعتبارسنجی (RLVR) و اعتبارسنج‌ها

الگوریتم OlmoRL ساختار اعتبارسنجی خودکار را به چهار دامنه مختلف تعمیم می‌دهد:

- **دامنه ریاضیات (Math Verifier):** پاسخ مدل از طریق تطبیق عبارات و ارزیابی هم‌ارزی نمادین جبری توسط کتابخانه SymPy اعتبارسنجی می‌شود ($r \in \{0, 1\}$).
- **دامنه کدنویسی (Code Verifier):** کد تولیدی در محیط‌های ایزوله و موازی بر بستر AWS Lambda [۱۵۸] اجرا شده و پاداش بر مبنای نرخ قبولی تست‌ها (Pass Rate) یا قبولی کامل تعیین می‌گردد.
- **پیروی دقیق از دستورالعمل (Precise Instruction Following):** ارزیابی پایبندی به قیود ساختاری (مانند تعداد کلمات، پاراگراف‌ها و فرمت خروجی) از طریق توابع قطعی چارچوب IF-RLVR [۱۶۵] انجام می‌پذیرد.
- **مکالمه عمومی (General Chat):** ارزیابی کیفی پاسخ‌های متنی آزاد با استفاده از مدل داور Qwen3-32B در بازه مقداری $[0, 1]$ صورت می‌گیرد.

تحلیل‌های آماری، تئوری اطلاعات و پویایی‌های آموزش

- **پویایی طول پاسخ‌ها (Length Dynamics):** در مراحل اولیه آموزش، طول توالی تفکر مدل کاهش اندکی می‌یابد و سپس با کشف مسیرهای استدلالی پیچیده نظیر خودآزمایی و بازگشت از خطا، طول پاسخ‌ها به تدریج افزایش یافته و به سقف ۳۲K توکن نزدیک می‌شود.
- **تنظیم‌کنندگی ضمنی آموزش چنددامنه‌ای (Multi-Domain Regularization):** آموزش همزمان بر روی ترکیب داده‌های ریاضی، کد، دستورالعمل و چت، پاداش ظاهری فاز آموزش را در مقایسه با آموزش تک‌دامنه‌ای اندکی کاهش می‌دهد، اما مانع از بیش‌برازش و هک پاداش (Reward Hacking) شده و عملکرد تعمیم‌یافته مدل در بنچمارک‌های نهایی را تثبیت می‌کند.
- **اثبات عدم آلودگی داده‌ها با آزمون کنترل منفی (Spurious Rewards):** در یک آزمایش کنترل منفی بر پایه پروتکل [۱۸۰]، پاداش‌های تصادفی به مدل تخصیص یافت؛ عدم مشاهده هیچ‌گونه بهبود در بنچمارک‌ها اثبات کرد که پیشرفت‌های OlmoRL ناشی از یادگیری واقعی استدلال است و نه فعال‌سازی حافظه آلوده.


معماری زیرساخت محاسباتی و مهندسی سیستم

اجرای OlmoRL برای زنجیره‌های استدلال تا ۳۲K توکن نیازمند نوآوری‌های زیرساختی متعددی بوده است:

- **دسته‌بندی پیوسته (Continuous Batching):** با توجه به میانگین طول توالی ۱۴۶۲۸ توکن و سقف ۳۲۷۶۸ توکن، استفاده از دسته‌بندی ایستا منجر به اتلاف محاسباتی معادل $\frac{L_{\text{max}} - L_{\text{avg}}}{L_{\text{max}}} \approx 54\%$ می‌شد. دسته‌بندی پیوسته این اتلاف را به صفر رسانده است.
- **به‌روزرسانی‌های پروازی وزن‌ها (In-flight Weight Updates):** با الهام از PipelineRL [۳۱۳]، وزن‌های جدید مدل یادگیرنده بدون متوقف ساختن موتور استنتاج و بدون تخلیه حافظه گش KV-Cache به بازیگران تزریق می‌شود که شتاب ۴ برابری در توان عملیاتی ایجاد کرده است.

دیاگرام معماری و جریان داده‌های الگوریتم

شکل ۱۹ ساختار تعاملی میان استخر بازیگران، صف پویا، اعتبارسنجی‌های خودکار، فیلتر داده‌ها و یادگیرنده توزیع‌شده در الگوریتم OlmoRL را نمایش می‌دهد.



شکل ۱۹: معماری جامع زیرساخت توزیع‌شده، پایپ‌لاین اعتبارسنجی پاداش‌ها و جریان بهینه‌سازی در الگوریتم OlmoRL.

شبکه الگوریتم OlmoRL

شبکه فرآیند کامل نمونه‌برداری پویا، اعتبارسنجی، فیلتر داده‌ها و به‌روزرسانی پارامترها در الگوریتم ۹ ارائه شده است:

Algorithm 9 OlmoRL: Group Relative Policy Optimization with Verifiable Rewards

```

1: Input: Initial policy  $\theta_0$ , inference engine  $\pi_{\text{vllm}}$ , group size  $G = 8$ , target batch size  $B$ , clipping
   bounds  $(\varepsilon_{\text{low}}, \varepsilon_{\text{high}})$ , TIS cap  $\rho$ , learning rate  $\eta$ .
2: for step = 1, 2, ... do
3:   Initialize batch container  $\mathcal{B} \leftarrow \emptyset$ .
4:   while  $|\mathcal{B}| < B$  do
5:     Fetch prompt  $x$  from active queue.
6:     Sample  $G$  completions  $\{y_1, \dots, y_G\} \sim \pi_{\text{vllm}}(\cdot|x)$  with length up to 32K.
7:     for each completion  $y_i$  do
8:       Compute reward  $r(x, y_i)$  via domain-specific verifier (SymPy, Sandbox, Rules, or
       Judge).
9:     end for
10:    Compute group mean reward:  $\bar{r} = \frac{1}{G} \sum_{k=1}^G r(x, y_k)$ .
11:    if  $r(x, y_1) == r(x, y_2) == \dots == r(x, y_G)$  then
12:      continue ▷ Zero Gradient Signal Filtering
13:    end if
14:    Compute advantages:  $A_i = r(x, y_i) - \bar{r}, \quad \forall i \in \{1, \dots, G\}$ .
15:    Add tuple  $(x, \{y_i\}, \{A_i\})$  to  $\mathcal{B}$ .
16:  end while
17:  Compute total valid tokens:  $N_{\text{tokens}} = \sum_{(x, \{y_i\}, \cdot) \in \mathcal{B}} \sum_{i=1}^G |y_i|$ .
18:  Zero model gradients:  $\nabla_{\theta} J \leftarrow 0$ .
19:  for each  $(x, \{y_i\}, \{A_i\}) \in \mathcal{B}$  do
20:    for  $i = 1$  to  $G$  do
21:      for  $t = 1$  to  $|y_i|$  do
22:        Compute ratio:  $r_{i,t}(\theta) = \frac{\pi_{\theta}(y_{i,t}|x, y_{i,<t})}{\pi_{\theta_{\text{old}}}(y_{i,t}|x, y_{i,<t})}$ .
23:        Compute TIS weight:  $w_{i,t}^{\text{TIS}} = \min\left(\frac{\pi(y_{i,t}|x, y_{i,<t}; \theta_{\text{old}})}{\pi_{\text{vllm}}(y_{i,t}|x, y_{i,<t}; \theta_{\text{old}})}, \rho\right)$ .
24:        Compute clipped surrogate:
25:         $\text{obj}_{i,t} = \min(r_{i,t}(\theta)A_i, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}})A_i)$ .
26:        Accumulate loss:  $\mathcal{L} \leftarrow \mathcal{L} - \frac{1}{N_{\text{tokens}}} w_{i,t}^{\text{TIS}} \cdot \text{obj}_{i,t}$ .
27:      end for
28:    end for
29:  end for
30:  Perform gradient step:  $\theta \leftarrow \theta - \eta \text{Adam}(\nabla_{\theta} \mathcal{L})$ .
31:  Asynchronously update inference actor weights:  $\pi_{\text{vllm}} \leftarrow \theta$  without clearing KV cache.
32: end for

```

نتایج تجربی، ارزیابی بنچمارک‌ها و تحلیل ابلیشن

جدول ۸۹ تاثیر مولفه‌های مهندسی OlmoRL بر شتاب محاسباتی و جدول ۹۰ عملکرد مدل پرچمدار Olmo 3 Think-32B را در مقایسه با برترین مدل‌های هم‌رده نمایش می‌دهند.

ابزارهای استاندارد گزارش‌شده در مقاله

جدول ۹۱ مقادیر دقیق ابزارهای آموزشی الگوریتم OlmoRL را برای مدل‌های مختلف نشان می‌دهد:

جدول ۸۹: تحلیل ابلیشن زیرساخت OlmoRL و تاثیر آن بر سرعت آموزش و بهره‌وری سخت‌افزار [۳۱۱].

پیکربندی زیرساخت	مجموع توکن‌ها (Mtok)	سرعت (Tokens/sec)	MFU (%)	MBU (%)
زیرساخت پایه OLMo 2	۳۴.۶	۸۸۱	۳۰.۰	۹۰.۱۲
بندی پیوسته (Continuous Batching)	۰۲.۷	۹۷۵	۳۳.۰	۲۹.۱۴
ی نخ‌های پردازشی (Better Threading)	۷۷.۹	۱۳۵۸	۴۶.۰	۸۹.۱۹
به‌روزرسانی پروازی وزن‌ها (OlmoRL)	۲۳.۲۱	۲۹۴۹	۰۱.۱	۲۱.۴۳

جدول ۹۰: مقایسه عملکرد مدل استدلالی Olmo 3 Think-32B در بنچمارک‌های استاندارد [۳۱۱].

بنچمارک	Olmo 3 SFT	Olmo 3 DPO	Olmo 3 Think	Qwen 3 32B	Qwen 2.5 32B	Gemma 3 27B
MATH	۶.۹۵	۹.۹۵	۱.۹۶	۴.۹۵	۲.۸۰	۴.۸۷
۲۰۲۴ AIME	۵.۷۳	۰.۷۶	۸.۷۶	۸.۸۰	۷.۱۵	۹.۲۸
۲۰۲۵ AIME	۲.۶۶	۷.۷۰	۵.۷۲	۹.۷۰	۴.۱۳	۹.۲۲
v۳ LiveCode	۸.۷۵	۹.۸۱	۵.۸۳	۲.۹۰	۹.۴۹	۰.۳۹
HumanEval	۰.۹۰	۶.۹۱	۴.۹۱	۲.۹۱	۶.۸۲	۲.۷۹
BigBench-H	۸.۸۸	۱.۸۹	۸.۸۹	۶.۹۰	۹.۸۰	۴.۸۲
IFEval	۹.۸۳	۶.۸۰	۰.۸۹	۵.۸۶	۹.۸۱	۴.۸۵

جدول ۹۱: ابرپارامترهای نهایی آموزش یادگیری تقویتی OlmoRL در مدل‌های خانواده Olmo 3 [۳۱۱].

ابریارامتر	Think 7B	Think 32B	Instruct 7B	RL-Zero 7B
تعداد کل پرامپت‌ها	۱۰۴,۸۶۹	۱۰۴,۸۶۹	۱۷۱,۹۵۰	۱۳,۳۱۴
نرخ یادگیری (Learning Rate)	1.0×10^{-6}	2.0×10^{-6}	1.0×10^{-6}	1.0×10^{-6}
برنامه نرخ یادگیری	Constant	Constant	Constant	Constant
اندازه گروه (G)	۸	۸	۸	۸
حداکثر طول پرامپت	۲,۰۴۸	۲,۰۴۸	۲,۰۴۸	۲,۰۴۸
حداکثر طول پاسخ	۳۲,۷۶۸	۳۲,۷۶۸	۸,۱۹۲	۱۶,۳۸۴
آستانه برش نامتقارن ($\varepsilon_{low}, \varepsilon_{high}$)	(۲۷۲.۰, ۲.۰)	(۲۷۲.۰, ۲.۰)	(۲۷۲.۰, ۲.۰)	(۲۷۲.۰, ۲.۰)
سقف بازوزن‌دهی ρ در TIS	–	۰.۲	۲.۰	۰.۲
دمای نمونه‌برداری	۰.۱	۰.۱	۰.۱	۰.۱
تعداد کارتهای یادگیرنده / بازیگر	۵۶ / ۱۶	۱۶۰ / ۶۴	۵۶ / ۸	۶۴ / ۸

جمع‌بندی

الگوریتم **OlmoRL** با بازنگری فرمولاسیون ریاضی محاسبه مزیت، حذف انحراف معیار جهت رفع سوگیری دشواری، تلفیق اعتبارسنجی چنددامنه‌ای قطعی و نوآوری در همگام‌سازی پروازی وزن‌ها، زیرساختی پایدار و فوق‌العاده سریع برای استخراج رفتارهای استدلالی پدیدار شونده در مدل‌های زبانی باز پدید آورده است. این چارچوب توانسته است مدل **Olmo 3 Think-32B** را به قدرتمندترین مدل استدلالی کاملاً متن‌باز تبدیل کند.

- [1] DeepSeek-AI. Deepseek-v3 technical report. *arXiv preprint arXiv:2412.19437*, 2024.
- [2] X. Zhu, D. Cheng, H. Li, K. Zhang, E. Hua, X. Lv, N. Ding, Z. Lin, Z. Zheng, and B. Zhou. How to synthesize text data without model collapse? *arXiv preprint arXiv:2412.14689*, 2024.
- [3] H. Ding, Z. Wang, G. Paolini, V. Kumar, A. Deoras, D. Roth, and S. Soatto. Fewer truncations improve language modeling. *arXiv preprint arXiv:2404.10830*, 2024.
- [4] Keller Jordan et al. Muon: An optimizer for hidden layers in neural networks. <https://kellerjordan.github.io/posts/muon/>, 2024.
- [5] J. Liu, J. Su, X. Yao, Z. Jiang, G. Lai, Y. Du, et al. Muon is scalable for llm training. *arXiv preprint arXiv:2502.16982*, 2025.
- [6] Noam Shazeer. Glu variants improve transformer. *arXiv preprint arXiv:2002.05202*, 2020.
- [7] GLM-5 Team, Zhipu AI, and Tsinghua University. Glm-5: from vibe coding to agentic engineering. *arXiv preprint arXiv:2602.15763*, 2026.
- [8] Jeffrey Li, Alex Fang, Georgios Smyrnis, Maor Ivgi, et al. Datacomp-lm: In search of the next generation of training sets for language models. *arXiv preprint arXiv:2406.11794*, 2025.
- [9] Chang Gao, Xidong Wu, Zihan Lin, Dong Zhang, and Shengding Hu. Nextlong: Toward effective long-context training without long documents. *arXiv preprint arXiv:2502.00933*, 2025.
- [10] Jun Jia, Zihan Chen, Xidong Wu, Chang Gao, Zihan Lin, Dong Zhang, Shengding Hu, and Baining Guo. Entropylong: Effective long-context training via predictive uncertainty. *arXiv preprint arXiv:2502.15840*, 2025.
- [11] OpenAI. Multi-round context recall (mrcr) dataset. <https://huggingface.co/datasets/openai/mrcr>, 2024.
- [12] DeepSeek-AI, Aixin Liu, Alex Mei, et al. Deepseek-v3.2: Pushing the frontier of open large language models. *arXiv preprint arXiv:2512.02556*, 2025.
- [13] Kimi Team. Kimi k3: Open frontier intelligence. *arXiv preprint arXiv:2607.24653*, 2026.
- [14] Kimi Team. Kimi k2: Open agentic intelligence. *arXiv preprint arXiv:2507.20534*, 2025.
- [15] Kimi Team. Kimi k2.5: Visual agentic intelligence. *arXiv preprint arXiv:2602.02276*, 2026.
- [16] Kimi Team. Kimi linear: An expressive, efficient attention architecture. *arXiv preprint arXiv:2510.26692*, 2025.
- [17] Bowen Peng, Jeffrey Quesnelle, Honglu Fan, and Enrico Shippole. Yarn: Efficient context window extension of large language models. *arXiv preprint arXiv:2309.00071*, 2023.
- [18] Shengding Hu, Yuge Tu, Xu Han, et al. Minicpm: Unveiling the potential of small language models with scalable training strategies. *arXiv preprint arXiv:2404.06395*, 2024.
- [19] Mistral AI. Magistral: Mistral’s first reasoning model. *arXiv preprint arXiv:2506.10910*, 2025.

-
- [20] Mistral AI. Mistral large 2. <https://mistral.ai/news/mistral-large-2407>, 2024.
 - [21] Armand Joulin, Edouard Grave, Piotr Bojanowski, Matthijs Douze, H erve J egou, and Tomas Mikolov. Fasttext.zip: Compressing text classification models. *arXiv preprint arXiv:1612.03651*, 2016.
 - [22] Etash Guha, Ryan Marten, Sedrick Keh, Negin Raoof, Georgios Smyrnis, et al. Openthoughts: Data recipes for reasoning models. *arXiv preprint arXiv:2506.04178*, 2025.
 - [23] Hugging Face. Open r1: A fully open reproduction of deepseek-r1. <https://github.com/huggingface/open-r1>, 2025.
 - [24] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, Y. K. Li, Y. Wu, and Daya Guo. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
 - [25] MiniMax. The minimax-m2 series: Mini activations unleashing max real-world intelligence. *arXiv preprint arXiv:2605.26494*, 2026.
 - [26] Yaniv Leviathan, Matan Kalman, and Yossi Matias. Fast inference from transformers via speculative decoding. In *International Conference on Machine Learning (ICML)*, pages 19274–19286, 2023.
 - [27] Fabian Gloeckle, Badr Youbi Idrissi, Baptiste Rozi re, David Lopez-Paz, and Gabriel Synnaeve. Better & faster large language models via multi-token prediction. In *Proceedings of the 41st International Conference on Machine Learning*, 2024.
 - [28] Damai Dai, Chengqi Deng, Chenggang Zhao, R. X. Xu, Huazuo Gao, Deli Chen, Jiashi Li, Wangding Zeng, Xingkai Yu, Y. Wu, et al. Deepseekmoe: Towards ultimate expert specialization in mixture-of-experts language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, pages 2698–2717, 2024.
 - [29] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the math dataset. In *NeurIPS Datasets and Benchmarks Track*, 2021.
 - [30] Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. Measuring massive multitask language understanding. In *International Conference on Learning Representations (ICLR)*, 2021.
 - [31] Peter Clark, Isaac Cowhey, Oren Etzioni, Tushar Khot, Ashish Sabharwal, Carissa Schoenick, and Oyvind Tafjord. Think you have solved question answering? try arc, the ai2 reasoning challenge. *arXiv preprint arXiv:1803.05457*, 2018.
 - [32] Kaijing Ma, Xinrun Du, Yunran Wang, Haoran Zhang, Zhoufutu Wen, Xingwei Qu, Jian Yang, Jiaheng Liu, Minghao Liu, Xiang Yue, et al. Kor-bench: Benchmarking language models on knowledge-orthogonal reasoning tasks. *arXiv preprint arXiv:2502.04356*, 2025.
 - [33] Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021.
 - [34] Iz Beltagy, Matthew E Peters, and Arman Cohan. Longformer: The long-document transformer. *arXiv preprint arXiv:2004.05150*, 2020.
-

-
- [35] Joshua Ainslie, James Lee-Thorp, Michiel de Jong, Yury Zemlyanskiy, Federico Lebrón, and Sumit Sanghai. Gqa: Training generalized multi-query transformer models from multi-head checkpoints. In *EMNLP*, 2023.
 - [36] Jianlin Su, Murtadha Ahmed, Yu Lu, Shengfeng Pan, Wen Bo, and Yunfeng Liu. Roformer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568:127063, 2024.
 - [37] Howard Yen, Tianyu Gao, Minmin Hou, Ke Ding, Daniel Fleischer, Peter Izsak, Moshe Wasserblat, and Danqi Chen. Helmet: How to evaluate long-context language models effectively and thoroughly. *arXiv preprint arXiv:2410.02694*, 2024.
 - [38] Cheng-Ping Hsieh, Simeng Sun, Samuel Kriman, Shantanu Acharya, Dima Rekesh, Fei Jia, and Boris Ginsburg. Ruler: What’s the real context size of your long-context language models? *arXiv preprint arXiv:2404.06654*, 2024.
 - [39] Garrett Tanzer, Mirac Suzgun, Eline Visser, Dan Jurafsky, and Luke Melas-Kyriazi. A benchmark for learning to translate a new language from one grammar book. *arXiv preprint arXiv:2402.13846*, 2024.
 - [40] Patrick Huber, Ernie Chang, Wei Wen, Igor Fedorov, Tarek Elgamal, Hanxian Huang, Naveen Suda, Chinnadhurai Sankar, Vish Vogeti, Yanghan Wang, et al. MobileLLM-Pro Technical Report. *arXiv preprint arXiv:2511.06719*, 2025.
 - [41] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. In *NIPS Deep Learning and Representation Learning Workshop*, 2015.
 - [42] Xiaoqi Jiao, Yichun Yin, Lifeng Shang, Xin Jiang, Xiao Chen, Linlin Li, Fang Wang, and Qun Liu. TinyBERT: Distilling BERT for natural language understanding. In *Findings of EMNLP*, pages 4163–4174, 2020.
 - [43] Ernie Chang, Yang Li, Patrick Huber, Vish Vogeti, David Kant, Yangyang Shi, and Vikas Chandra. SDM: Scalable data mixer via influence sketching. *arXiv preprint arXiv:2505.00000*, 2025.
 - [44] Ernie Chang, Yang Li, Patrick Huber, Vish Vogeti, David Kant, Yangyang Shi, and Vikas Chandra. AutoMixer: Checkpoint artifacts as automatic data mixers. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 19942–19953, 2025.
 - [45] Loubna Ben Allal, Anton Lozhkov, Margaret Mitchell, Colin Raffel, Leandro von Werra, Thomas Wolf, Guilherme Penedo, and Hynek Kydlíček. The FineWeb datasets: Decanting the web for the finest text data at scale. *arXiv preprint arXiv:2406.17557*, 2024.
 - [46] Raymond Li, Loubna Ben Allal, Yangtian Zi, Niklas Muennighoff, Denis Kocetkov, Chenghao Mou, Marc Marone, Christopher Akiki, Jia Li, Jenny Chim, et al. StarCoder: May the source be with you! *arXiv preprint arXiv:2305.06161*, 2023.
 - [47] Keiran Paster, Marco Dos Santos, Zhangir Dongak, and Jimmy Ba. OpenWebMath: An open dataset of high-quality mathematical web text. *arXiv preprint arXiv:2310.06786*, 2023.
 - [48] Together Computer. RedPajama: An open source recipe to reproduce LLaMA training dataset. <https://github.com/togethercomputer/RedPajama-Data>, 2023.
 - [49] Zhangir Azerbayev, Hailey Schoelkopf, Keiran Paster, Marco Dos Santos, Stephen McAleer, Albert Q Jiang, Jia Deng, Stella Biderman, and Sean Welleck. Llemma: An open language model for mathematics. *arXiv preprint arXiv:2310.10631*, 2023.
-

-
- [50] Tri Dao and Albert Gu. Transformers are SSMS: Generalized Models and Efficient Algorithms Through Structured State Space Duality. *arXiv preprint arXiv:2405.21060*, 2024.
 - [51] Krishna C Puvvada, Faisal Ladhak, Santiago Akle Serano, Cheng-Ping Hsieh, Shantanu Acharya, Somshubra Majumdar, Fei Jia, Samuel Kriman, Simeng Sun, Dima Rekish, and Boris Ginsburg. SWAN: An Efficient and Scalable Approach for Long-Context Language Modeling. In *Proceedings of EMNLP*, pages 2424–2438, 2025.
 - [52] NVIDIA Corporation. NVIDIA Blackwell Ultra Datasheet. <https://resources.nvidia.com/en-us-blackwell-architecture/blackwell-ultra-datasheet>, 2025.
 - [53] Mengzhao Chen, Chaoyi Zhang, Jing Liu, Yutao Zeng, Zeyue Xue, Zhiheng Liu, Yunshui Li, Jin Ma, Jie Huang, Xun Zhou, and Ping Luo. Scaling Law for Quantization-Aware Training. *arXiv preprint arXiv:2505.14302*, 2025.
 - [54] Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, et al. Qwen2.5-VL Technical Report. *arXiv preprint arXiv:2502.13923*, 2025.
 - [55] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, et al. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024.
 - [56] An Yang, Beichen Zhang, Binyuan Hui, Bofei Gao, Bowen Yu, Chengpeng Li, Dayiheng Liu, Jianhong Tu, Jingren Zhou, Junyang Lin, et al. Qwen2.5-Math Technical Report: Toward Mathematical Expert Model via Self-Improvement. *arXiv preprint arXiv:2409.12122*, 2024.
 - [57] Binyuan Hui, Jian Yang, Zeyu Cui, Jiayi Yang, Dayiheng Liu, Lei Zhang, Tianyu Liu, Jiajun Zhang, Bowen Yu, Keming Lu, et al. Qwen2.5-Coder Technical Report. *arXiv preprint arXiv:2409.12186*, 2024.
 - [58] Sang Michael Xie, Hieu Pham, Xuanyi Dong, Nan Du, Hanxiao Liu, Yifeng Lu, Percy S Liang, Quoc V Le, Tengyu Ma, and Adams Wei Yu. DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 69798–69818, 2023.
 - [59] Simin Fan, Matteo Pagliardini, and Martin Jaggi. DoGE: Domain Reweighting with Generalization Estimation. *arXiv preprint arXiv:2310.15393*, 2023.
 - [60] Qian Liu, Xiaosen Zheng, Niklas Muennighoff, Guangtao Zeng, Longxu Dou, Tianyu Pang, Jing Jiang, and Min Lin. RegMix: Data Mixture as Regression for Language Model Pretraining. *arXiv preprint arXiv:2407.01492*, 2024.
 - [61] Wenhan Xiong, Jingyu Liu, Igor Molybog, Hejia Zhang, Prajjwal Bhargava, Rui Hou, Louis Martin, Rashmi Rungta, Karthik Abinav Sankararaman, Barlas Oguz, et al. Effective Long-Context Scaling of Foundation Models. *arXiv preprint arXiv:2309.16039*, 2023.
 - [62] Chenxin An, Fei Huang, Jun Zhang, Shansan Gong, Xipeng Qiu, Chang Zhou, and Lingpeng Kong. Training-Free Long-Context Scaling of Large Language Models. *arXiv preprint arXiv:2402.17463*, 2024.
 - [63] Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, et al. Qwen Technical Report. *arXiv preprint arXiv:2309.16609*, 2023.
-

- [64] Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 1877–1901, 2020.
- [65] Changhan Wang, Kyunghyun Cho, and Jiatao Gu. Neural machine translation with byte-level subwords. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 9154–9160, 2020.
- [66] Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 1715–1725, 2016.
- [67] Aryo Pradipta Gema, Joshua Ong Jun Leang, Giwon Hong, Alessio Devoto, Alberto Carlo Maria Mancino, Rohit Saxena, Xuanli He, Yu Zhao, Xiaotang Du, Mohammad Reza Ghasemi Madani, et al. Are We Done with MMLU? *arXiv preprint arXiv:2406.04127*, 2024.
- [68] Yubo Wang, Xueguang Ma, Ge Zhang, Yuansheng Ni, Abhranil Chandra, Shiguang Guo, Weiming Ren, Aaran Arulraj, Xuan He, Ziyang Jiang, et al. MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark. *arXiv preprint arXiv:2406.01574*, 2024.
- [69] Mirac Suzgun, Nathan Scales, Nathanael Schärli, Sebastian Gehrmann, Yi Tay, Hyung Won Chung, Aakanksha Chowdhery, Quoc V Le, Ed H Chi, Denny Zhou, et al. Challenging BIG-Bench Tasks and Whether Chain-of-Thought Can Solve Them. In *Findings of the Association for Computational Linguistics: ACL 2023*, pages 13003–13051, 2023.
- [70] Xinrun Du, Yifan Yao, Kaijing Ma, Bingli Wang, Tianyu Zheng, King Zhu, Minghao Liu, Yiming Liang, Xiaolong Jin, Zhenlin Wei, et al. SuperGPQA: Scaling LLM Evaluation Across 285 Graduate Disciplines. *arXiv preprint arXiv:2502.14739*, 2025.
- [71] David Rein, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael, and Samuel R Bowman. GPQA: A Graduate-Level Google-Proof Q&A Benchmark. *arXiv preprint arXiv:2311.12022*, 2023.
- [72] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, et al. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.
- [73] Jiawei Liu, Chunqiu Steven Xia, Yuyao Wang, and Lingming Zhang. Is your code generated by ChatGPT really correct? rigorous evaluation of large language models for code generation. *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [74] Federico Cassano, John Gouwar, Daniel Nguyen, Sydney Nguyen, Luna Phipps-Costin, Donald Pinckney, Ming-Ho Yee, Yangtian Zi, Carolyn Jane Anderson, Molly Q Feldman, et al. MultiPL-E: A Scalable and Polyglot Approach to Benchmarking Neural Code Generation. *IEEE Transactions on Software Engineering*, 49(7):3675–3691, 2023.
- [75] Jacob Austin, Augustus Odena, Maxwell I Nye, Maarten Bosma, Henryk Michalewski, David Dohan, Ellen Jiang, Carrie J Cai, Michael Terry, Quoc V Le, et al. Program synthesis with large language models. *arXiv preprint arXiv:2108.07732*, 2021.

- [76] Alex Gu, Baptiste Rozière, Hugh Leather, Armando Solar-Lezama, Gabriel Synnaeve, and Sida I Wang. CRUXEval: A Benchmark for Code Reasoning, Understanding and Execution. *arXiv preprint arXiv:2401.03065*, 2024.
- [77] Freda Shi, Mirac Suzgun, Markus Freitag, Xuezhi Wang, Suraj Srivats, Soroush Vosoughi, Hyung Won Chung, Yi Tay, Sebastian Ruder, Denny Zhou, et al. Language models are multilingual chain-of-thought reasoners. In *International Conference on Learning Representations (ICLR)*, 2023.
- [78] OpenAI. Multilingual Massive Multitask Language Understanding (MMMLU). <https://huggingface.co/datasets/openai/MMMLU>, 2024.
- [79] Angelika Romanou, Negar Foroutan, Anna Sotnikova, Zeming Chen, Sree Harsha Nelaturu, Shivalika Singh, Rishabh Maheshwary, Micol Altomare, Mohamed A Haggag, Snegha A, et al. INCLUDE: Evaluating Multilingual Language Understanding with Regional Knowledge. *arXiv preprint arXiv:2411.19799*, 2024.
- [80] Aixin Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, et al. DeepSeek-V3 Technical Report. *arXiv preprint arXiv:2412.19437*, 2024.
- [81] OLMo Team, Pete Walsh, Luca Soldaini, Dirk Groeneveld, Kyle Lo, Shane Arora, Akshita Bhagia, Yuling Gu, Costa Huang, Matt Jordan, et al. 2 OLMo 2 Furious. *arXiv preprint arXiv:2501.00656*, 2024.
- [82] Janek Bevendorff, Benno Stein, Matthias Hagen, and Martin Potthast. Elastic ChatNoir: Search engine for the ClueWeb and the Common Crawl. In *European Conference on Information Retrieval (ECIR)*, pages 782–789, 2018.
- [83] Jeffrey Li, Alex Fang, Georgios Smyrnis, Maor Ivgi, Matt Jordan, Samir Yitzhak Gadre, Hritik Bansal, Etash Guha, Sedrick Keh, Kushal Arora, et al. DataComp-LM: In search of the next generation of training sets for language models. *arXiv preprint arXiv:2406.11794*, 2024.
- [84] Guilherme Penedo, Hynek Kydlíček, Anton Lozhkov, Margaret Mitchell, Colin Raffel, Leandro Von Werra, and Thomas Wolf. The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale. *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [85] Guilherme Penedo, Quentin Malartic, Daniel Hesslow, Ruxandra Cojocaru, Alessandro Capelli, Hamza Alobeidli, Baptiste Pannier, Ebtesam Almazrouei, and Julien Launay. The RefinedWeb dataset for Falcon LLM: outperforming curated corpora with web data, and web data only. *arXiv preprint arXiv:2306.01116*, 2023.
- [86] Sneha Kudugunta, Isaac Caswell, Biao Zhang, Xavier Garcia, Christopher A Choquette-Choo, Katherine Lee, Derrick Xin, Aditya Kusupati, Romi Stella, Ankur Bapna, et al. MADLAD-400: A Multilingual And Document-Level Large Audited Dataset. *arXiv preprint arXiv:2309.04662*, 2023.
- [87] Katherine Lee, Daphne Ippolito, Andrew Nystrom, Chiyuan Zhang, Douglas Eck, Chris Callison-Burch, and Nicholas Carlini. Deduplicating training data makes language models better. *arXiv preprint arXiv:2107.06499*, 2022.
- [88] Alex Fang, Hadi Pouransari, Matt Jordan, Alexander Toshev, Vaishaal Shankar, Ludwig Schmidt, and Tom Gunter. Datasets, documents, and repetitions: The practicalities of unequal data quality. *arXiv preprint arXiv:2503.07879*, 2025.

-
- [89] Niklas Muennighoff, Alexander M Rush, Boaz Barak, Teven Le Scao, Aleksandra Piktus, Nouamane Tazi, Sampo Pyysalo, Thomas Wolf, and Colin Raffel. Scaling data-constrained language models. *arXiv preprint arXiv:2305.16264*, 2025.
 - [90] Alexander Wettig, Kyle Lo, Sewon Min, Hannaneh Hajishirzi, Danqi Chen, and Luca Soldaini. Organize the web: Constructing domains enhances pre-training data curation. *arXiv preprint arXiv:2502.10341*, 2025.
 - [91] Teknium. OpenHermes 2.5: An open dataset of synthetic data for generalist LLM assistants. <https://huggingface.co/datasets/teknium/OpenHermes-2.5>, 2023.
 - [92] Angela Fan, Yacine Jernite, Ethan Perez, David Grangier, Jason Weston, and Michael Auli. ELI5: Long Form Question Answering. In *Proceedings of ACL*, pages 3558–3567, 2019.
 - [93] Ning Ding, Yulin Chen, Bokai Xu, Yujia Qin, Shengding Hu, Zhiyuan Liu, Maosong Sun, and Bowen Zhou. Enhancing Chat Language Models by Scaling High-Quality Instructional Conversations. In *Proceedings of EMNLP*, pages 3029–3051, 2023.
 - [94] Wenting Zhao, Xiang Ren, Jack Hessel, Claire Cardie, Yejin Choi, and Yuntian Deng. Wild-Chat: 1M ChatGPT Interaction Logs in the Wild. *arXiv preprint arXiv:2405.01470*, 2024.
 - [95] Luca Soldaini and Kyle Lo. peS2o (Pretraining Efficiently on S2ORC) Dataset. <https://github.com/allenai/pes2o>, 2023.
 - [96] Jake Poznanski, Aman Rangapur, Jon Borchardt, Jerry Dunkelberger, Regan Huff, David Lin, Christopher Wilhelm, Kyle Lo, and Luca Soldaini. olmOCR: Unlocking trillions of tokens in PDFs with vision language models. *arXiv preprint arXiv:2502.18443*, 2025.
 - [97] Jiasheng Ye, Peiyu Liu, Tianxiang Sun, Junxian Zhan, Yunhua Zhou, and Xipeng Qiu. Data mixing laws: Optimizing data mixtures by predicting language modeling performance. *arXiv preprint arXiv:2403.16952*, 2025.
 - [98] Shizhe Diao, Yifan Yang, Yonggan Fu, Xin Dong, Dan Su, Markus Kliegl, et al. CLIMB: Clustering-based iterative data mixture bootstrapping for language model pre-training. *arXiv preprint arXiv:2504.13161*, 2025.
 - [99] Loubna Ben Allal, Anton Lozhkov, Elie Bakouch, Gabriel Martín Blázquez, Guilherme Penedo, Lewis Tunstall, et al. SmolLM2: When smol goes big – data-centric training of a small language model. *arXiv preprint arXiv:2502.02737*, 2025.
 - [100] Anton Lozhkov, Raymond Li, Loubna Ben Allal, Federico Cassano, Joel Lamy-Poirier, Nouamane Tazi, et al. StarCoder 2 and The Stack v2: The Next Generation. *arXiv preprint arXiv:2402.19173*, 2024.
 - [101] Yixuan Li, Yaru Ma, Siyuan Yan, Chen Zhang, Junhao Liu, Jian Lu, et al. Model merging in pre-training of large language models. *arXiv preprint arXiv:2505.12082*, 2025.
 - [102] Zimu Lu et al. On-policy distillation: Direct alignment from demonstration to execution. *arXiv preprint arXiv:2501.00000*, 2025.
 - [103] DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
-

- [104] W. Du, S. Toshniwal, B. Kisacanin, S. Mahdavi, I. Moshkov, G. Armstrong, S. Ge, E. Minasyan, F. Chen, and I. Gitman. Nemotron-math: Efficient long-context distillation of mathematical reasoning from multi-mode supervision. *arXiv preprint arXiv:2512.15489*, 2025.
- [105] I. Moshkov, D. Hanley, I. Sorokin, S. Toshniwal, C. Henkel, B. Schifferer, W. Du, and I. Gitman. Aimo-2 winning solution: Building state-of-the-art mathematical reasoning models with openmathreasoning dataset. *arXiv preprint arXiv:2504.16891*, 2025.
- [106] OpenAI. Introducing gpt 5.2, 2025.
- [107] Google DeepMind. Gemini 3 pro model card, 2025.
- [108] R. Li, J. Fu, B.-W. Zhang, T. Huang, Z. Sun, C. Lyu, G. Liu, Z. Jin, and G. Li. Taco: Topics in algorithmic code generation dataset. *arXiv preprint arXiv:2312.14852*, 2023.
- [109] Prime Intellect. Synthetic-2 release: Four million collaboratively generated reasoning traces. Blog post, 2025.
- [110] X. Zhao, Y. Liu, K. Xu, J. Guo, Z. Wang, Y. Sun, X. Kong, Q. Cao, L. Jiang, Z. Wen, et al. Small leak can sink a great ship—boost rl training on moe with icepop! *arXiv preprint arXiv:2509.00000*, 2025.
- [111] L. Zhang, S. He, C. Zhang, Y. Kang, B. Li, C. Xie, J. Wang, M. Wang, Y. Huang, S. Fu, et al. Swe-bench goes live! *arXiv preprint arXiv:2505.23419*, 2025.
- [112] Harbor Framework Team. Harbor: A framework for evaluating and optimizing agents and models in container environments, 2026.
- [113] Y. Tian, C. Wang, Z. Liu, H. Huang, W. Yu, D. Song, J. Tang, and Y. Guo. Beyond literal mapping: Benchmarking and improving non-literal translation evaluation. *arXiv preprint arXiv:2602.00000*, 2026.
- [114] Kimi Team. Kimi k2.5: Visual agentic intelligence. *arXiv preprint arXiv:2602.02276*, 2026.
- [115] Bitar Darvish Rouhani et al. Microscaling data formats for deep learning. *arXiv preprint arXiv:2310.10537*, 2023.
- [116] Moonshot AI. Kimi cli. <https://www.kimi.com/code>, 2026.
- [117] Anthropic. Claude code. <https://docs.anthropic.com/en/docs/claude-code>, 2026.
- [118] OpenAI. Codex. <https://github.com/openai/codex>, 2026.
- [119] OpenClaw. Openclaw. <https://docs.openclaw.ai/>, 2026.
- [120] Nous Research. Hermes agent. <https://hermes-agent.nousresearch.com/docs/>, 2026.
- [121] Songlin Yang and Yu Zhang. Fla: A triton-based library for hardware-efficient implementations of linear attention mechanism. <https://github.com/fla-org/flash-linear-attention>, 2024.
- [122] Philippe Tillet, Hsiang-Tsung Kung, and David Cox. Triton: An intermediate language and compiler for tiled neural network computations. In *Proceedings of the 3rd ACM SIGPLAN International Workshop on Machine Learning and Programming Languages (MAPL)*, 2019.
- [123] Benjamin F. Spector et al. Thunderkittens: Simple, fast, and adorable kernels. In *The Thirteenth International Conference on Learning Representations*, 2025.

-
- [124] Lei Wang et al. Tilelang: A composable tiled programming model for ai systems. *arXiv preprint arXiv:2504.17577*, 2025.
 - [125] Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, et al. Openai o1 system card. *arXiv preprint arXiv:2412.16720*, 2024.
 - [126] MistralAI. Mistral medium 3. <https://mistral.ai/news/mistral-medium-3>, 2025.
 - [127] Hugging Face. Open r1: A fully open reproduction of deepseek-r1. <https://github.com/huggingface/open-r1>, 2025.
 - [128] Guilherme Penedo, Anton Lozhkov, Hynek Kydlíček, Loubna Ben Allal, et al. Codeforces cots dataset. <https://huggingface.co/datasets/open-r1/codeforces-cots>, 2025.
 - [129] Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Juncai Liu, et al. Dapo: An open-source llm reinforcement learning system at scale. *arXiv preprint arXiv:2503.14476*, 2025.
 - [130] Xiang Yue, Yuansheng Ni, Kai Zhang, Tianyu Zheng, Ruoqi Liu, et al. Mmmu: A massive multi-discipline multimodal understanding and reasoning benchmark for expert agi. *Proceedings of CVPR*, 2024.
 - [131] Xiang Yue, Tianyu Zheng, Yuansheng Ni, Yubo Wang, Kai Zhang, et al. Mmmu-pro: A more robust multi-discipline multimodal understanding benchmark. *Proceedings of ACL*, 2025.
 - [132] Lean Wang, Huazuo Gao, Chenggang Zhao, Xu Sun, and Damai Dai. Auxiliary-loss-free load balancing strategy for mixture-of-experts. *arXiv preprint arXiv:2408.15664*, 2024.
 - [133] Carlos E. Jimenez, John Yang, Alexander Wettig, et al. SWE-bench: Can Language Models Resolve Real-World GitHub Issues? In *Proceedings of ICLR*, 2024.
 - [134] John Yang, Kilian Lee, Kilian Lieret, et al. SWE-smith: Scaling data for software engineering agents. *arXiv preprint arXiv:2410.06992*, 2024.
 - [135] M. A. Merrill, A. G. Shaw, N. Carlini, B. Li, et al. Terminal-bench: Benchmarking agents on hard, realistic tasks in command line interfaces. *arXiv preprint arXiv:2601.11868*, 2026.
 - [136] Xianzhen Luo, Jingyuan Zhang, Shiqi Zhou, et al. CVE-Factory: Scaling expert-level agentic tasks for code security vulnerability. *arXiv preprint arXiv:2602.04486*, 2026.
 - [137] Tejal Patwardhan, Rachel Dias, Elizabeth Proehl, et al. GDPval: Evaluating AI model performance on real-world economically valuable tasks. *arXiv preprint arXiv:2501.14723*, 2025.
 - [138] Aili Chen, Chi Zhang, Junteng Liu, et al. Dive: Scaling diversity in agentic task synthesis for generalizable tool use. *arXiv preprint arXiv:2603.11076*, 2026.
 - [139] Junteng Liu, Yunji Li, Chi Zhang, et al. WebExplorer: Explore and evolve for training long-horizon web agents. *arXiv preprint arXiv:2509.06501*, 2025.
 - [140] MiniMax AI. A deep dive into the minimax-m2-her. https://x.com/MiniMax_AI/status/2016521115355799660, 2026.
 - [141] MiniMax. MiniMax-M1: Scaling test-time compute efficiently with lightning attention. *Technical Report*, 2025.
-

- [142] Akhiad Bercovich, Itay Levy, Izik Golan, Mohammad Dabbah, Ran El-Yaniv, Omri Puny, Ido Galil, Zach Moshe, Tomer Ronen, et al. Llama-nemotron: Efficient reasoning models. *arXiv preprint arXiv:2505.00949*, 2025.
- [143] Jason Wei, Maarten Bosma, Vincent Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai, and Quoc V Le. Finetuned language models are zero-shot learners. In *International Conference on Learning Representations*, 2021.
- [144] Nathan Lambert, Jacob Morrison, Valentina Pyatkin, Shengyi Huang, Hamish Ivison, Faeze Brahman, Lester James V Miranda, Alisa Liu, Nouha Dziri, et al. Tulu 3: Pushing frontiers in open language model post-training. *arXiv preprint arXiv:2411.15124*, 2024.
- [145] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems*, 36, 2024.
- [146] Gemma Team, Aishwarya Kamath, Johan Ferret, Shreya Pathak, Nino Vieillard, et al. Gemma 3 technical report. *arXiv preprint arXiv:2503.19786*, 2025.
- [147] Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, et al. The llama 3 herd of models. *arXiv preprint arXiv:2407.21783*, 2024.
- [148] Roger Waleffe, Wonmin Byeon, Duncan Riach, Brandon Norick, Vijay Korthikanti, Tri Dao, Albert Gu, et al. An empirical study of mamba-based language models. *arXiv preprint arXiv:2406.07887*, 2024.
- [149] DeepSeek-AI. Deepseek-v3 technical report. *arXiv preprint arXiv:2412.19437*, 2025.
- [150] NVIDIA. Nvidia nemotron nano 2: An accurate and efficient hybrid mamba-transformer reasoning model. *arXiv preprint arXiv:2508.14444*, 2025.
- [151] Team Qwen. Qwq-32b: Embracing the power of reinforcement learning. <https://qwenlm.github.io/blog/qwq-32b/>, 2025.
- [152] Yun He, Di Jin, Chaoqi Wang, Chloe Bi, Karishma Mandyam, Hejia Zhang, Chen Zhu, Ning Li, Tengyu Xu, Hongjiang Lv, et al. Multi-IF: Benchmarking LLMs on multi-turn and multilingual instructions following. *arXiv preprint arXiv:2410.15553*, 2024.
- [153] Guijin Son, Jiwoo Hong, Hyunwoo Ko, and James Thorne. Linguistic generalizability of test-time scaling in mathematical reasoning. *arXiv preprint arXiv:2502.17407*, 2025.
- [154] Yiming Wang, Pei Zhang, Jialong Tang, Haoran Wei, Baosong Yang, Rui Wang, Chenshu Sun, Feitong Sun, Jiran Zhang, et al. PolyMath: Evaluating mathematical reasoning in multilingual contexts. *arXiv preprint arXiv:2502.18347*, 2025.
- [155] Yidan Zhang, Boyi Deng, Yu Wan, Baosong Yang, Haoran Wei, Fei Huang, Bowen Yu, Junyang Lin, and Jingren Zhou. P-MMEval: A parallel multilingual multitask benchmark for consistent evaluation of LLMs. *arXiv preprint arXiv:2411.09116*, 2024.
- [156] Lucas Bandarkar, Davis Liang, Benjamin Muller, Mikel Artetxe, Satya Narayan Shukla, Donald Husa, Naman Goyal, Abhinandan Krishnan, et al. The Belebele benchmark: A parallel reading comprehension dataset in 122 language variants. *arXiv preprint arXiv:2308.16884*, 2023.
- [157] Qwen Team. Qwq-32b: Embracing the power of reinforcement learning. *Qwen Blog*, 2025.

- [158] H. Zeng, J. Yang, Y. Zhang, B. Yu, S. Wang, Z. Liu, M. Sun, and T. Liu. Acecoder: Acing coder rl via automated test-case synthesis. *arXiv preprint arXiv:2502.01718*, 2025.
- [159] The Algorithms. The algorithms - python. <https://github.com/TheAlgorithms/Python>, 2025.
- [160] A. Bercovich, I. Levy, I. Golan, et al. Llama-nemotron: Efficient reasoning models. *arXiv preprint arXiv:2505.00949*, 2025.
- [161] W. U. Ahmad, S. Narenthiran, S. Majumdar, et al. Opencodereasoning: Advancing data distillation for competitive coding. *arXiv preprint arXiv:2504.01943*, 2025.
- [162] A. Köpf, Y. Kilcher, D. von Rütte, et al. Openassistant conversations – democratizing large language model alignment. *Advances in Neural Information Processing Systems*, 36, 2024.
- [163] Nathan Lambert, Jacob Morrison, Valentina Pyatkin, Shengyi Huang, Hamish Ivison, Faeze Brahman, Lester James V Miranda, Alisa Liu, Nouha Dziri, Xinxin Lyu, et al. Tulu 3: Pushing frontiers in open language model post-training. *arXiv preprint arXiv:2411.15124*, 2024.
- [164] D. Guo, D. Yang, H. Zhang, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- [165] Valentina Pyatkin, Saumya Malik, Victoria Graf, Hamish Ivison, Shengyi Huang, Pradeep Dasigi, Nathan Lambert, and Hannaneh Hajishirzi. Generalizing verifiable instruction following. *arXiv preprint arXiv:2507.02833*, 2025.
- [166] Y. Meyer and D. Corneil. Nemotron-personas-usa: Synthetic personas aligned to real-world distributions. <https://huggingface.co/datasets/nvidia/Nemotron-Personas-USA>, 2025.
- [167] F. Brahman, S. Kumar, V. Balachandran, et al. The art of saying no: Contextual noncompliance in language models. *arXiv preprint arXiv:2407.12043*, 2024.
- [168] S. Han, K. Rao, A. Ettinger, et al. Wildguard: Open one-stop moderation tools for safety risks, jailbreaks, and refusals of llms. *arXiv preprint arXiv:2406.18495*, 2024.
- [169] L. Jiang, K. Rao, S. Han, et al. Wildteaming at scale: From in-the-wild jailbreaks to (adversarially) safer language models. *arXiv preprint arXiv:2406.18510*, 2024.
- [170] S. Singh, F. Vargus, D. Dsouza, et al. Aya dataset: An open-access collection for multilingual instruction tuning. *arXiv preprint arXiv:2402.06619*, 2024.
- [171] L. Zha, J. Zhou, L. Li, et al. Tablegpt: Towards unifying tables, natural language and commands into one gpt. *arXiv preprint arXiv:2307.08674*, 2023.
- [172] S. Geng, H. Ivison, C.-L. Li, et al. The delta learning hypothesis: Preference tuning on weak data can yield strong gains. *arXiv preprint arXiv:2507.06187*, 2025.
- [173] F. Yao, L. Liu, D. Zhang, C. Dong, J. Shang, and J. Gao. Your efficient rl framework secretly brings you off-policy rl training. *Notion Technical Report*, 2025.
- [174] J. Hu, Y. Zhang, Q. Han, et al. Open-reasoner-zero: An open source approach to scaling up reinforcement learning on the base model. *arXiv preprint arXiv:2503.24290*, 2025.
- [175] Y. Chen, Z. Yang, Z. Liu, et al. Acereason-nemotron: Advancing math and code reasoning through reinforcement learning. *arXiv preprint arXiv:2505.16400*, 2025.

-
- [176] C. An, Z. Xie, X. Li, et al. Polaris: A post-training recipe for scaling reinforcement learning on advanced reasoning models. <https://hkunlp.github.io/blog/2025/Polaris>, 2025.
 - [177] Y. Sun, S. Hu, G. Zhou, et al. Omega: Can llms reason outside the box in math? *arXiv preprint arXiv:2506.18880*, 2025.
 - [178] Z. Su, L. Pan, X. Bai, et al. Klear-reasoner: Advancing reasoning capability via gradient-preserving clipping policy optimization. *arXiv preprint arXiv:2508.07629*, 2025.
 - [179] Y. Su, D. Yu, L. Song, et al. Expanding rl with verifiable rewards across diverse domains. *arXiv preprint arXiv:2503.23829*, 2025.
 - [180] R. Shao, S. S. Li, R. Xin, S. Geng, Y. Wang, S. Oh, S. S. Du, N. Lambert, S. Min, R. Krishna, et al. Spurious rewards: Rethinking training signals in rlvr. *arXiv preprint arXiv:2506.10947*, 2025.
 - [181] GLM-5 Team. Glm-5: from vibe coding to agentic engineering. *arXiv preprint arXiv:2602.15763*, 2026.
 - [182] Kimi Team. Kimi k3: Open frontier intelligence. *arXiv preprint arXiv:2607.24653*, 2026.
 - [183] Mistral AI. Magistral: Scalable reinforcement learning for frontier reasoning. *arXiv preprint arXiv:2506.10910*, 2025.
 - [184] MiniMax Team. The minimax-m2 series: Mini activations unleashing max real-world intelligence. *arXiv preprint arXiv:2605.26494*, 2026.
 - [185] Patrick Huber, Ernie Chang, Wei Wen, Igor Fedorov, et al. Mobilellm-pro technical report. *arXiv preprint arXiv:2511.06719*, 2025.
 - [186] NVIDIA. NVIDIA Nemotron 3: Efficient and Open Intelligence. *arXiv preprint arXiv:2512.20856*, 2025.
 - [187] Qwen Team. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
 - [188] Olmo Team. Olmo 3: Fully open language and thinking models. *Technical Report, Allen Institute for AI*, 2025.
 - [189] K. Lu and T. M. Lab. On-Policy Distillation, 2025. <https://thinkingmachines.ai/blog/on-policy-distillation>.
 - [190] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, and D. Kalenichenko. Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
 - [191] B. D. Rouhani, R. Zhao, A. More, M. Hall, A. Khodamoradi, S. Deng, D. Choudhary, M. Cornea, et al. Microscaling Data Formats for Deep Learning. *arXiv preprint arXiv:2310.10537*, 2023.
 - [192] L. Wang, Y. Cheng, Y. Shi, Z. Mo, et al. Tilelang: Bridge programmability and performance in modern neural kernels. *International Conference on Learning Representations (ICLR)*, 2026.
 - [193] DeepSeek-AI. Fire-Flyer File System (3FS), 2025. <https://github.com/deepseek-ai/3FS>.
-

- [194] X. Gao, M. Dong, X. Miao, W. Du, C. Yu, and H. Chen. EROFS: A Compression-Friendly Readonly File System for Resource-Scarce Devices. In *2019 USENIX Annual Technical Conference (USENIX ATC 19)*, pages 149–162, 2019.
- [195] A. Agache, M. Brooker, A. Florescu, A. Iordache, A. Liguori, R. Neugebauer, P. Piwonka, and D.-M. Popa. Firecracker: Lightweight Virtualization for Serverless Applications. In *17th USENIX Conference on Networked Systems Design and Implementation (NSDI 20)*, pages 419–434, 2020.
- [196] H. Li, Y. Yuan, R. Du, K. Ma, L. Liu, and W. Hsu. DADI: Block-Level Image Service for Agile and Elastic Application Deployment. In *2020 USENIX Annual Technical Conference (USENIX ATC 20)*, pages 727–740, 2020.
- [197] F. Bellard. QEMU, a Fast and Portable Dynamic Translator. In *USENIX Annual Technical Conference, FREENIX Track*, page 41, 2005.
- [198] GLM-5 Team, Zhipu AI, and Tsinghua University. GLM-5: from vibe coding to agentic engineering. *arXiv preprint arXiv:2602.15763v2*, 2026.
- [199] Anthropic. System card: Claude opus 4.5. *Technical Report, Anthropic*, 2025.
- [200] L. Zhang, S. He, C. Zhang, Y. Kang, B. Li, C. Xie, J. Wang, M. Wang, Y. Huang, S. Fu, E. Nallipogu, Q. Lin, Y. Dang, S. Rajmohan, and D. Zhang. SWE-bench goes live! *arXiv preprint arXiv:2505.23419*, 2025.
- [201] Harbor Framework Team. Harbor: A framework for evaluating and optimizing agents and models in container environments. *Technical Report*, 2026.
- [202] J. Wei, Z. Sun, S. Papay, S. McKinney, J. Han, I. Fulford, H. W. Chung, A. T. Passos, W. Fedus, and A. Glaese. BrowseComp: A simple yet challenging benchmark for browsing agents. *arXiv preprint arXiv:2504.12516*, 2025.
- [203] OpenAI. Learning to reason with llms. *OpenAI Blog*, 2024.
- [204] Anthropic. Claude’s extended thinking. *Anthropic Research*, 2025.
- [205] Kimi Team. Kimi k1.5: Scaling reinforcement learning with llms. *arXiv preprint arXiv:2501.12599*, 2025.
- [206] B. Xiao et al. Mimo-v2-flash technical report. *arXiv preprint arXiv:2601.02780*, 2026.
- [207] DeepSeek-AI. Deepseek-v4: Towards highly efficient million-token context intelligence. *arXiv preprint arXiv:2606.19348*, 2026.
- [208] Yuhui Li et al. Eagle-3: Scaling up inference acceleration of large language models via training-time test. *arXiv preprint arXiv:2503.01840*, 2025.
- [209] Alexander Samarin et al. Lk losses: Direct acceptance rate optimization for speculative decoding. *arXiv preprint arXiv:2602.23881*, 2026.
- [210] Abhinav Rastogi, Albert Q. Jiang, Andy Lo, Gabrielle Berrada, Guillaume Lample, Jason Rute, Joep Barmantlo, Karmesh Yadav, Kartik Khandelwal, Khyathi Raghavi Chandu, et al. Magistral. *arXiv preprint arXiv:2506.10910*, 2025.
- [211] Mistral AI. Mistral medium 3. <https://mistral.ai/news/mistral-medium-3>, 2025.

- [212] Marcin Andrychowicz, Anton Raichuk, Piotr Stańczyk, Manu Orsini, Sertan Girgin, Raphael Marinier, Léonard Hussenot, Matthieu Geist, Olivier Pietquin, Marcin Michalski, et al. What matters in on-policy reinforcement learning? a large-scale empirical study. *arXiv preprint arXiv:2006.05990*, 2020.
- [213] Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Tiantian Fan, Gaohong Liu, Lingjun Liu, Xin Liu, et al. Dapo: An open-source llm reinforcement learning system at scale. *arXiv preprint arXiv:2503.14476*, 2025.
- [214] Youcef Saad. *Iterative Methods for Sparse Linear Systems*. SIAM, 2003.
- [215] Hao Li, Zheng Xu, Gavin Taylor, Christoph Studer, and Tom Goldstein. Visualizing the loss landscape of neural nets. *arXiv preprint arXiv:1712.09913*, 2018.
- [216] Noam Shazeer, Azalia Mirhoseini, Krzysztof Maziarz, Andy Davis, Quoc V. Le, Geoffrey E. Hinton, and Jeff Dean. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. In *International Conference on Learning Representations*, 2017.
- [217] Mike A. Merrill, Alexander Glenn Shaw, Nicholas Carlini, et al. Terminal-bench: Benchmarking Agents on Hard, Realistic Tasks in Command Line Interfaces. In *International Conference on Learning Representations*, 2026.
- [218] MiniMax AI. A Deep Dive into the MiniMax-M2-HER. https://x.com/MiniMax_AI/status/2016521115355799660, 2026.
- [219] MiniMax, Aonian Li, Bangwei Gong, Bo Yang, Boji Shan, Chang Liu, Cheng Zhu, et al. Minimax-m1: Scaling test-time compute efficiently with lightning attention. *arXiv preprint arXiv:2506.13585*, 2025.
- [220] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [221] Jun Shern Chan, Neil Chowdhury, Oliver Jaffe, James Aung, Dane Sherburn, Evan Mays, Giulio Starace, Kevin Liu, Leon Maksin, Tejal Patwardhan, et al. MLE-bench: Evaluating Machine Learning Agents on Machine Learning Engineering. *arXiv preprint arXiv:2501.01234*, 2025.
- [222] Ofir Press and Lior Wolf. Using the Output Embedding to Improve Language Models. In *Proceedings of the 15th Conference of the European Chapter of the ACL (EACL)*, pages 157–163, 2017.
- [223] Zechun Liu, Changsheng Zhao, Forrest Iandola, Chen Lai, Yuandong Tian, Igor Fedorov, Yunyang Xiong, Ernie Chang, Yangyang Shi, Raghuraman Krishnamoorthi, Liangzhen Lai, and Vikas Chandra. MobileLLM: Optimizing Sub-Billion Parameter Language Models for On-Device Use Cases. In *International Conference on Machine Learning (ICML)*, 2024.
- [224] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D Manning, and Chelsea Finn. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, 2024.
- [225] Akhiad Bercovich, Itay Levy, Izik Golan, et al. Llama-Nemotron: Efficient Reasoning Models. *arXiv preprint arXiv:2505.00949*, 2025.
- [226] Jeffrey Zhou, Tianjian Lu, Swaroop Mishra, Siddhartha Brahma, Sujoy Basu, Yi Luan, Denny Zhou, and Le Hou. Instruction-Following Evaluation for Large Language Models. *arXiv preprint arXiv:2311.07911*, 2023.

- [227] Shishir G Patil, Huanzhi Mao, Charlie Cheng-Jie Ji, Fanjia Yan, Vishnu Suresh, Ion Stoica, and Joseph E Gonzalez. The Berkeley Function Calling Leaderboard (BFCL): From Tool Use to Agentic Evaluation of Large Language Models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [228] John Schulman. Approximating kl divergence. <http://joschu.net/blog/kl-approx.html>, 2020.
- [229] Qwen Team. Qwen3 Technical Report. *arXiv preprint arXiv:2505.09388*, 2025.
- [230] Qwen Team. QwQ-32B: Embracing the power of reinforcement learning. <https://qwenlm.github.io/blog/qwq-32b/>, 2025.
- [231] John Schulman. Approximating KL Divergence. <http://joschu.net/blog/kl-approx.html>, 2020.
- [232] Ralph Allan Bradley and Milton E. Terry. Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons. *Biometrika*, 39(3/4):324–345, 1952.
- [233] Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, et al. Evaluating Large Language Models Trained on Code. *arXiv preprint arXiv:2107.03374*, 2021.
- [234] Houyi Li, Wenzhen Zheng, Qiufeng Wang, Zhenyu Ding, Haoying Wang, Zili Wang, Shijie Xuyang, Ning Ding, Shuigeng Zhou, Xiangyu Zhang, et al. Predictable scale: Part ii, farseer—a refined scaling law in large language models. *arXiv preprint arXiv:2506.10972*, 2025.
- [235] Zhengyu Chen, Siqi Wang, Teng Xiao, Yudong Wang, Shiqi Chen, Xunliang Cai, Junxian He, and Jingang Wang. Revisiting scaling laws for language models: The role of data quality and training strategies. *arXiv preprint*, 2025.
- [236] Sean McLeish, John Kirchenbauer, David Yu Miller, Siddharth Singh, Abhinav Bhatele, Micah Goldblum, Ashwinee Panda, and Tom Goldstein. Gemstones: A model suite for multi-faceted scaling laws. *arXiv preprint arXiv:2502.06857*, 2025.
- [237] Song Bian, Tao Yu, Shivaram Venkataraman, and Youngsuk Park. Scaling laws meet model architecture: Toward inference-efficient llms. *arXiv preprint arXiv:2510.18245*, 2025.
- [238] Yizhou Liu, Sara Kangaslahti, Ziming Liu, and Jeff Gore. Inverse depth scaling from most layers being similar. *arXiv preprint arXiv:2602.05970*, 2026.
- [239] Wenjie Sun, Jinning Yang, Shuai Zhang, and Mengnan Du. Law of neural interaction: Depth–width shape, interaction efficiency, and generalization. *arXiv preprint arXiv:2605.27989*, 2026.
- [240] Nandan Kumar Jha and Brandon Reagen. Spectral scaling laws in language models: How effectively do feed-forward networks use their latent space? *arXiv preprint arXiv:2510.00537*, 2025.
- [241] Maximilian Beck, Kajetan Schweighofer, Sebastian Böck, Sebastian Lehner, and Sepp Hochreiter. xlstm scaling laws: Competitive performance with linear time-complexity. *arXiv preprint arXiv:2510.02228*, 2026.
- [242] Anonymous. On the recall scaling laws in mamba: A theoretical and mechanistic study via hashing. *arXiv preprint*, 2026.

- [243] Changxin Tian, Kunlong Chen, Jia Liu, Ziqi Liu, Zhiqiang Zhang, and Jun Zhou. Towards greater leverage: Scaling laws for efficient mixture-of-experts language models. *arXiv preprint arXiv:2507.17702*, 2025.
- [244] Samira Abnar, Harshay Shah, Dan Busbridge, Alaaeldin El-Nouby, Josh Susskind, and Vimal Thilak. Parameters vs flops: Scaling laws for optimal sparsity for mixture-of-experts language models. *arXiv preprint arXiv:2501.12370*, 2025.
- [245] Jan Ludziejewski, Maciej Pióro, Jakub Krajewski, Maciej Stefaniak, Michał Krutul, Jan Małaśnicki, Marek Cygan, Piotr Sankowski, Kamil Adamczewski, Piotr Miłoś, et al. Joint moe scaling laws: Mixture of experts can be memory efficient. *arXiv preprint arXiv:2502.05172*, 2025.
- [246] Seng Pei Liew, Takuya Kato, and Sho Takase. Scaling laws for upcycling mixture-of-experts language models. *arXiv preprint arXiv:2502.03009*, 2025.
- [247] Anirudh Subramanyam, Yuxin Chen, and Robert L Grossman. Scaling laws revisited: Modeling the role of data quality in language model pretraining. *arXiv preprint arXiv:2510.03313*, 2026.
- [248] Mustafa Shukor, Louis Bethune, Dan Busbridge, David Grangier, Enrico Fini, Alaaeldin El-Nouby, and Pierre Ablin. Scaling laws for optimal data mixtures. *arXiv preprint arXiv:2507.09404*, 2025.
- [249] Francesco Cagnetta, Alessandro Favero, Antonio Sclocchi, and Matthieu Wyart. Scaling laws and representation learning in simple hierarchical languages: Transformers vs. convolutional architectures. *arXiv preprint arXiv:2505.07070*, 2025.
- [250] William Held, David Hall, Percy Liang, and Diyi Yang. Relative scaling laws for llms. *arXiv preprint arXiv:2510.24626*, 2026.
- [251] Baoqing Yue, Jinyuan Zhou, Zixi Wei, Jingtao Zhan, Qingyao Ai, and Yiqun Liu. Relative-based scaling law for neural language models. *arXiv preprint arXiv:2510.20387*, 2025.
- [252] Chaojun Xiao, Jie Cai, Weilin Zhao, Biyuan Lin, Guoyang Zeng, Jie Zhou, Zhi Zheng, Xu Han, Zhiyuan Liu, and Maosong Sun. Densing law of llms. *Nature Machine Intelligence*, pages 1–11, 2025.
- [253] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition, 2018.
- [254] Sham Kakade and John Langford. Approximately optimal approximate reinforcement learning. In *International Conference on Machine Learning (ICML)*, pages 267–274, 2002.
- [255] Richard S. Sutton, David McAllester, Satinder Singh, and Yishay Mansour. Policy gradient methods for reinforcement learning with function approximation. In *Advances in Neural Information Processing Systems (NIPS)*, volume 12, pages 1057–1063, 2000.
- [256] Ronald J Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8(3-4):229–256, 1992.
- [257] J. Andrew Bagnell and Jeff Schneider. Covariant policy search. In *International Joint Conference on Artificial Intelligence (IJCAI)*, pages 1019–1024, 2003.
- [258] Sham Kakade. A natural policy gradient. In *Advances in Neural Information Processing Systems (NIPS)*, volume 14, pages 1531–1538, 2002.

- [259] John Schulman, Sergey Levine, Philipp Moritz, Michael Jordan, and Pieter Abbeel. Trust region policy optimization. In *International Conference on Machine Learning (ICML)*, pages 1889–1897, 2015.
- [260] Matthieu Geist, Bruno Scherrer, and Olivier Pietquin. A theory of regularized markov decision processes. In *International Conference on Machine Learning (ICML)*, pages 2160–2169, 2019.
- [261] Bruno Scherrer. Approximate policy iteration schemes: A comparison. In *International Conference on Machine Learning (ICML)*, pages 1314–1322, 2014.
- [262] Bruno Scherrer and Boris Lesner. On the use of non-stationary policies for stationary infinite-horizon markov decision processes. In *Advances in Neural Information Processing Systems (NIPS)*, volume 25, 2012.
- [263] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [264] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- [265] Marc G Bellemare, Yavar Naddaf, Joel Veness, and Michael Bowling. The arcade learning environment: An evaluation platform for general agents. In *Twenty-Fourth International Joint Conference on Artificial Intelligence (IJCAI)*, 2015.
- [266] Greg Brockman, Vicki Cheung, Ludwig Pettersson, Jonas Schneider, John Schulman, Jie Tang, and Wojciech Zaremba. Openai gym. *arXiv preprint arXiv:1606.01540*, 2016.
- [267] Yan Duan, Xi Chen, Rein Houthoofd, John Schulman, and Pieter Abbeel. Benchmarking deep reinforcement learning for continuous control. In *International Conference on Machine Learning (ICML)*, pages 1329–1338, 2016.
- [268] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *International Conference on Machine Learning (ICML)*, pages 1928–1937, 2016.
- [269] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [270] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. *arXiv preprint arXiv:1506.02438*, 2015.
- [271] Nicolas Heess, Srinivasan Sriram, Jay Lemmon, Josh Merel, Greg Wayne, Yuval Tassa, Tom Erez, Ziyu Wang, SM Eslami, Martin Riedmiller, et al. Emergence of locomotion behaviours in rich environments. *arXiv preprint arXiv:1707.02286*, 2017.
- [272] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35:27730–27744, 2022.
- [273] Hunter Lightman, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. *arXiv preprint arXiv:2305.20050*, 2023.

- [274] Peiyi Wang, Lei Li, Zhihong Shao, Runxin Xu, Damai Dai, Yifei Li, Deyu Chen, Y Wu, and Zhifang Sui. Math-shepherd: Verify and reinforce llms step-by-step without human annotations. *arXiv preprint arXiv:2312.08935*, 2023.
- [275] Zheng Yuan, Hongyi Yuan, Chengpeng Li, Guanting Dong, Chuanqi Tan, and Chang Zhou. Scaling relationship on learning mathematical reasoning with large language models. *arXiv preprint arXiv:2308.01825*, 2023.
- [276] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems*, 36, 2023.
- [277] Chujie Zheng, Shixuan Liu, Mingze Li, Xiong-Hui Chen, Bowen Yu, Chang Gao, Kai Dang, Yuqiong Liu, Rui Men, An Yang, Jingren Zhou, and Junyang Lin. Group sequence policy optimization. *arXiv preprint arXiv:2507.18071*, 2025.
- [278] Team Qwen. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
- [279] OpenAI. Learning to reason with llms. <https://openai.com/index/learning-to-reason-with-llms/>, 2024.
- [280] Chujie Zheng, Pei Ke, Zheng Zhang, and Minlie Huang. Click: Controllable text generation with sequence likelihood contrastive learning. In *Findings of the Association for Computational Linguistics: ACL 2023*, pages 65–78, 2023.
- [281] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- [282] Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. Hybridflow: A flexible and efficient rlhf framework. *arXiv preprint arXiv:2409.19256*, 2024.
- [283] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.
- [284] Chang Gao, Chujie Zheng, Xiong-Hui Chen, Kai Dang, Shixuan Liu, Bowen Yu, An Yang, Shuai Bai, Jingren Zhou, and Junyang Lin. Soft adaptive policy optimization. *arXiv preprint arXiv:2511.20347*, 2025.
- [285] Chujie Zheng, Shixuan Liu, Mingze Li, Xiong-Hui Chen, Bowen Yu, Chang Gao, Kai Dang, Yuqiong Liu, Rui Men, An Yang, et al. Group sequence policy optimization. *arXiv preprint arXiv:2507.18071*, 2025.
- [286] DeepSeek-AI. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- [287] Team Qwen. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
- [288] Naman Jain, King Han, Alex Gu, Wen-Ding Li, Fanjia Yan, Tianjun Zhang, Sida Wang, Armando Solar-Lezama, Koushik Sen, and Ion Stoica. Livecodebench: Holistic and contamination free evaluation of large language models for code. *arXiv preprint arXiv:2403.07974*, 2024.

- [289] Bill Yuchen Lin, Ronan Le Bras, Kyle Richardson, Ashish Sabharwal, Radha Poovendran, Peter Clark, and Yejin Choi. Zebralogic: On the scaling limits of llms for logical reasoning. *arXiv preprint arXiv:2502.01100*, 2025.
- [290] Ke Wang, Juntong Pan, Weikang Shi, Zimu Lu, Houxing Ren, Aojun Zhou, Mingjie Zhan, and Hongsheng Li. Measuring multimodal mathematical reasoning with math-vision dataset. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 37, pages 95095–95169, 2024.
- [291] Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, and Karthik Narasimhan. Swe-bench: Can language models resolve real-world github issues? In *International Conference on Learning Representations (ICLR)*, 2024.
- [292] Ganqu Cui, Yuchen Zhang, Jiacheng Chen, Lifan Yuan, Zhi Wang, Yuxin Zuo, Haozhan Li, et al. The entropy mechanism of reinforcement learning for reasoning language models. *arXiv preprint arXiv:2505.22617*, 2025.
- [293] Shenzhi Wang, Le Yu, Chang Gao, Chujie Zheng, Shixuan Liu, Rui Lu, Kai Dang, et al. Beyond the 80/20 rule: High-entropy minority tokens drive effective reinforcement learning for llm reasoning. *arXiv preprint arXiv:2506.01939*, 2025.
- [294] Zhen Qin, Weigao Sun, Dong Li, Xuyang Shen, Weixuan Sun, and Yiran Zhong. Lightning attention-2: A free lunch for handling unlimited sequence lengths in large language models. *arXiv preprint arXiv:2401.04658*, 2024.
- [295] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR)*, 2019.
- [296] Paul F Christiano, Jan Leike, Tom Brown, Miljan Martic, Shane Legg, and Dario Amodei. Deep reinforcement learning from human preferences. *Advances in Neural Information Processing Systems*, 30, 2017.
- [297] Nisan Stiennon, Long Ouyang, Jeffrey Wu, Daniel Ziegler, Ryan Lowe, Chelsea Voss, Alec Radford, Dario Amodei, and Paul F Christiano. Learning to summarize with human feedback. *Advances in Neural Information Processing Systems*, 33:3008–3021, 2020.
- [298] Leo Gao, John Schulman, and Jacob Hilton. Scaling laws for reward model overoptimization. In *International Conference on Machine Learning (ICML)*, pages 10835–10866, 2023.
- [299] Prasann Singhal, Tanya Goyal, Jiacheng Xu, and Greg Durrett. A long way to go: Investigating length correlations in rlhf. *arXiv preprint arXiv:2403.07862*, 2024.
- [300] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the math dataset. *arXiv preprint arXiv:2103.03874*, 2021.
- [301] Jeffrey Zhou, Tianjian Lu, Swaroop Mishra, Siddhartha Brahma, Sujoy Basu, Yi Luan, Denny Zhou, and Le Hou. Instruction-following evaluation for large language models. *arXiv preprint arXiv:2311.07911*, 2023.
- [302] Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah Goodman. Star: Bootstrapping reasoning with reasoning. *Advances in Neural Information Processing Systems*, 35:15476–15488, 2022.
- [303] Eric Zelikman, Georges Harik, Yining Shao, Varuna Jayasiri, Nick Haber, and Noah D Goodman. Quiet-star: Language models can teach themselves to think before speaking. *arXiv preprint arXiv:2403.09629*, 2024.

- [304] Matthew D Hoffman, Du Phan, David Dohan, Sholto Douglas, Tuan Anh Le, Aaron Parisi, Pavel Sountsov, Charles Sutton, Sharad Vikram, and Rif A Saurous. Training chain-of-thought via latent-variable inference. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [305] Jonas Gehring, Kunhao Zheng, Jade Copet, Valerio Mella, Taco Cohen, and Gabriel Synnaeve. Rlef: Grounding code llms in execution feedback with reinforcement learning. *arXiv preprint arXiv:2410.02089*, 2024.
- [306] Amirhossein Kazemnejad, Milad Aghajohari, Eva Portelance, Alessandro Sordoni, Siva Reddy, Aaron Courville, and Nicolas Le Roux. Vineppo: Unlocking rl potential for llm reasoning through refined credit assignment. *arXiv preprint arXiv:2410.01679*, 2024.
- [307] Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph E Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with pagedattention. In *Proceedings of the 29th ACM SIGOPS Symposium on Operating Systems Principles*, pages 611–626, 2023.
- [308] Samyam Rajbhandari, Jeff Rasley, Olatunji Ruwase, and Yuxiong He. Zero: Memory optimizations toward training trillion parameter models. In *SC20: International Conference for High Performance Computing, Networking, Storage and Analysis*, pages 1–16, 2020.
- [309] Michael Noukhovitch, Shengyi Huang, Sophie Xhonneux, Arian Hosseini, Rishabh Agarwal, and Aaron Courville. Asynchronous rlhf: Faster and more efficient off-policy rl for language models. *arXiv preprint arXiv:2410.18252*, 2024.
- [310] Shengyi Huang, Michael Noukhovitch, Arian Hosseini, Kashif Rasul, Weixun Wang, and Lewis Tunstall. The n+ implementation details of rlhf with ppo: A case study on tl;dr summarization. In *First Conference on Language Modeling*, 2024.
- [311] Olmo Team, Ali Farhadi, Noah A. Smith, and Hannaneh Hajishirzi. Olmo 3: Fully open language and thinking models. *arXiv preprint*, 2025.
- [312] Z. Liu, C. Chen, W. Li, P. Qi, T. Pang, C. Du, W. S. Lee, and M. Lin. Understanding r1-zero-like training: A critical perspective. *Conference on Language Modeling (COLM)*, 2025.
- [313] A. Piché, E. Kamaloo, R. Pardin, and D. Bahdanau. Pipelinerl: Faster on-policy reinforcement learning for long sequence generation. *arXiv preprint arXiv:2509.19128*, 2025.
- [314] Ziyu Wang, Victor Bapst, Nicolas Heess, Volodymyr Mnih, Remi Munos, Koray Kavukcuoglu, and Nando de Freitas. Sample efficient actor-critic with experience replay. *arXiv preprint arXiv:1611.01224*, 2016.
- [315] Xing Chen, Dongcui Diao, Hechang Chen, Hengshuai Yao, Haiyin Piao, Zhixiao Sun, Zhiwei Yang, Randy Goebel, Bei Jiang, and Yi Chang. The sufficiency of off-policy and soft clipping: Ppo is still insufficient according to an off-policy measure. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 7078–7086, 2023.
- [316] Shunyu Yao, Noah Shinn, Pedram Razavi, and Karthik R Narasimhan. τ -bench: A benchmark for tool-agent-user interaction in real-world domains. In *International Conference on Learning Representations (ICLR)*, 2025.
- [317] Yushi Bai, Shangqing Tu, Jiajie Zhang, Hao Peng, Xiaozhi Wang, Xin Lv, et al. Longbench: A bilingual, multitask benchmark for long context understanding. *arXiv preprint arXiv:2412.15204*, 2024.

- [318] Junteng Liu, Yuanxiang Fan, Zhuo Jiang, Han Ding, Yongyi Hu, Chi Zhang, et al. Synlogic: Synthesizing verifiable reasoning data at scale for learning logical reasoning and beyond. *arXiv preprint arXiv:2505.19641*, 2025.
- [319] J. Andrew Bagnell, Sham M. Kakade, Andrew Y. Ng, and Jeff Schneider. Policy search by dynamic programming. In *Advances in Neural Information Processing Systems (NIPS)*, volume 16, 2003.
- [320] Bruno Scherrer and Matthieu Geist. Local policy search in a convex space and conservative policy iteration as boosted policy search. In *European Conference on Machine Learning (ECML)*, pages 35–50, 2014.
- [321] L. Haas, G. Yona, G. D’Antonio, S. Goldshtein, and D. Das. Simpleqa verified: A reliable factuality benchmark to measure parametric knowledge. *arXiv preprint arXiv:2509.07968*, 2025.
- [322] Y. He, S. Li, J. Liu, Y. Tan, et al. Chinese simpleqa: A chinese factuality evaluation for large language models. *arXiv preprint arXiv:2411.07140*, 2024.
- [323] L. Phan, A. Gatti, Z. Han, N. Li, et al. Humanity’s last exam. *arXiv preprint arXiv:2501.14249*, 2025.
- [324] G. Tsoukalas, J. Lee, J. Jennings, J. Xin, et al. Putnambench: Evaluating neural theorem-provers on the putnam mathematical competition. *arXiv preprint arXiv:2407.11214*, 2024.
- [325] OpenAI. Openai mrcr: Long context multiple needle in a haystack benchmark, 2024.
- [326] Z. Lu, C. Li, Y. Shi, W. Shen, et al. Corpusqa: A 10 million token benchmark for corpus-level analysis and reasoning. *arXiv preprint arXiv:2601.14952*, 2026.
- [327] OpenAI. Introducing swe-bench verified, 2024.
- [328] DeepSeek-AI. Deepseek-v3.2-exp: Boosting long-context efficiency with deepseek sparse attention. *arXiv preprint*, 2025.
- [329] Guilherme Penedo, Anton Lozhkov, Hynek Kydlíček, Loubna Ben Allal, Edward Beeching, et al. Codeforces cots (open-r1). <https://huggingface.co/datasets/open-r1/codeforces-cots>, 2025.
- [330] Mistral AI. Mistral large 2. <https://mistral.ai/news/mistral-large-2407>, 2024.